

1장. 의사결정 과학과 AI 기반 인과 데이터 사이언스

이 장 한 줄 요약

데이터로 답할 수 있는 질문은 "무슨 일이 일어날까"와 "무엇을 해야 할까" 두 가지이며, 앞의 질문은 예측이 답하고 뒤의 질문은 인과추론이 답한다. 이 교재는 뒤의 질문을 다룬다.

학습 목표

- 예측이 답하는 질문과 인과가 답하는 질문을 같은 데이터에서 나온 두 숫자로 구분한다.
- 참값을 알고 있는 데이터로 방법을 검증하는 실습 구조를 이해하고, 실습 환경을 스스로 점검한다.
- 처치 집단과 통제 집단의 평균을 그냥 빼서 얻은 첫 추정치를 계산하고, 그 값이 무엇을 포함하고 있는지 분해한다.
- 예측 성능 지표와 변수 중요도가 인과효과의 근거가 되지 못하는 이유를 설명한다.
- 두 집단이 처치 말고 다른 점이 있는지 균형 진단으로 판정하고, 판정 결과에 따라 추정치를 보고할지 결정한다.
- 무작위 배정이 무엇을 해결하는지 말하고, 무작위 배정을 쓸 수 없는 상황을 네 가지 든다.
- 추정치를 비용과 함께 순이익 부호까지 계산해 실제 결정으로 옮긴다.
- 문제 상황을 보고 2장부터 12장까지의 방법 중 어느 갈래로 갈지 판단한다.

이 장을 읽는 방법

이 장은 65분짜리 두 차시로 구성된다. 각 차시는 그 자체로 완결되며, 끝날 때마다 손에 남는 결과물이 있다.

- **1부:** 예측과 인과라는 두 질문을 가르고, 쿠폰 효과의 첫 추정치를 직접 계산한다. 그 값이 참값과 얼마나 어긋나는지까지 확인한다.
- **2부:** 그 추정치가 왜 어긋났는지 진단하고, 무작위 배정으로 바로잡은 다음, 그 숫자를 발행 여부라는 결정으로 옮긴다.

실습 코드는 모두 `practice/chapter01/code/`에 있으며, 본문에는 핵심 부분만 옮긴다. 세 스크립트가 데이터를 직접 만드는데, 참값을 알고 있어야 추정이 맞았는지 확인할 수 있기 때문이다.

```
practice/chapter01/
├─ code/
│   ├── 1-1-environment-check.py      ← 환경 점검 (1.1.2절)
│   ├── 1-2-prediction-vs-causation.py ← 예측과 인과 (1.1.3~1.1.5, 1.2.3절)
│   └── 1-3-randomization.py          ← 무작위 배정 (1.2.4~1.2.6절)
└─ data/
    ├── 1-2-coupon-observational.csv   (스크립트가 생성)
    ├── 1-3-observational.csv          (스크립트가 생성)
    └── 1-3-experimental.csv           (스크립트가 생성)
```

2장부터는 방법 하나에 한 장씩 배정되며, 1장은 전체 지도를 그리는 장이다.

1부 (65분). 두 질문을 가르고 첫 추정치를 얻는다

이 파트가 끝나면: 쿠폰 효과의 첫 추정치 12,710원을 직접 산출하고, 그 값이 참값 3,000원의 4.2배라는 사실과 그렇게 된 경로를 설명할 수 있다. **다루는 절:** 1.1.1 ~ 1.1.6

1.1 AI 시대의 인과적 데이터 사이언스

1.1.1 두 개의 질문 — 예측과 인과

왜 필요한가

온라인 쇼핑몰의 고객 데이터를 앞에 두고 두 가지 질문을 던질 수 있다.

- **질문 A:** 이 고객이 다음 달에 얼마를 살 것인가
- **질문 B:** 이 고객에게 쿠폰을 보내면 구매액이 얼마나 늘어나는가

두 질문은 겉으로 비슷해 보이지만 답하는 방식이 전혀 다르다. A는 지금 있는 데이터를 그대로 두고 답하는 반면, B는 **값을 바꿔 넣었을 때** 무슨 일이 생기는지 묻는다. 쿠폰을 받지 않은 고객이 만약 쿠폰을 받았다면 얼마를 샀을지는 데이터 어디에도 적혀 있지 않으므로, B에 답하려면 데이터에 없는 상태를 추정해야 한다.

A에 답하는 것이 **예측**(prediction)이고, B에 답하는 것이 **인과추론**(causal inference)이다. 이 구분을 흐린 채 분석을 시작하면 잘 맞는 모형을 만들어 놓고 엉뚱한 결론을 내리게 되는데, 1.1.3절부터 그 과정을 숫자로 따라간다.

그림 1-1. 예측과 인과는 다른 질문에 답한다

예측	인과
이 고객이 얼마를 살 것인가	쿠폰을 보내면 얼마가 늘어나는가
데이터를 있는 그대로 본다	값을 바꿔 넣었을 때를 계산한다
맞히는 정확도로 평가한다	참 효과와의 차이로 평가한다
실습 1-2: R^2 0.552	실습 1-3: 실험값 2,978원

실습 1-2에서 쿠폰 효과를 단순 비교하면 12,710원, 참값은 3,000원이다

비유: 체온계와 해열제

체온계와 해열제	예측과 인과
체온계로 38.5도를 잰다	예측 모형으로 구매액을 맞힌다
체온계는 열이 몇 도인지 알려준다	예측 모형은 얼마를 살지 알려준다
해열제를 먹으면 몇 도 내려가는가	쿠폰을 보내면 얼마가 늘어나는가
체온계로는 이 질문에 답할 수 없다	예측 모형으로는 이 질문에 답할 수 없다
약을 먹은 사람이 원래 더 아팠다	쿠폰 받은 고객이 원래 더 많이 샀다

속성 대응은 마지막 줄이 핵심이다. 아픈 사람이 약을 먹으므로 약을 먹은 집단의 체온이 더 높게 나오며, 이 숫자를 그대로 "약이 열을 올린다"고 읽으면 안 된다. 이 비유는 **측정과 개입이 다른 일이라는 구조**를 옮기는 데까지만 맞고, 체온이라는 단일 지표와 달리 구매액에는 수십 개의 요인이 동시에 얹힌다는 점에서 깨진다.

무엇을 계산하는가

이 장의 실습은 참 효과를 미리 정해 놓고 데이터를 만든 다음, 여러 계산 방법이 그 값을 되찾는지 확인하는 구조를 쓴다. 입력은 고객 특성이고, 출력은 구매액이며, 그 사이에 쿠폰의 효과를 3,000원으로 못 박아 넣는다.

코드로 해 보기

```
# 구매액: 쿠폰의 참 효과는 3,000원이다
TRUE_EFFECT = 3000
purchase = (40000
            + TRUE_EFFECT * coupon      # 쿠폰이 만드는 몫
            + 12000 * loyalty          # 충성도가 만드는 몫 (관측 불가)
            + 200 * months
            + 150 * (age - 38)
            + np.random.normal(0, 8000, n))
```

전체 코드는 *practice/chapter01/code/1-2-prediction-vs-causation.py* 참고

결과를 읽는 법

이 식에서 `TRUE_EFFECT * coupon` 항은 쿠폰이 만드는 몫이고, `12000 * loyalty` 항은 충성도가 만드는 몫이다. 두 항은 서로 다른 원인이지만 최종 구매액에서는 하나의 숫자로 합쳐져 나오므로, 관측된 구매액만 보고 두 몫을 갈라내는 것이 이 장의 과제가 된다.

- **판정 기준:** 어떤 계산이 3,000원 근처를 되찾으면 그 계산은 쓸 수 있고, 크게 벗어나면 계산이 아니라 데이터를 모은 방식을 먼저 의심한다.

실제 연구에서는 참값을 모르므로 이런 확인이 불가능하지만, 배우는 단계에서는 참값을 알고 시작해야 어느 방법이 왜 실패하는지 볼 수 있다.

1.1.2 실습 환경 점검 — 참값을 되찾는지 확인한다

왜 필요한가

실습 도중 패키지가 없거나 한글 폰트가 잡히지 않으면 분석이 아니라 설치 문제로 시간을 다 쓰게 된다. 본격적인 계산에 들어가기 전에 네 항목을 확인해 두면 이후 장에서 같은 문제로 막히지 않는다.

먼저 설치가 필요하다. VS Code는 공식 사이트(<https://code.visualstudio.com/>)에서, Python 3.10 이상은 <https://www.python.org/> 에서, Git은 <https://git-scm.com/> 에서 내려받는다. 윈도우에서 파이썬을 설치할 때는 설치 화면의 "Add Python to PATH"를 반드시 체크해야 하며, macOS는 `brew install python` 과 `xcode-select --install` 로 대신할 수 있다. 패키지는 다음 한 줄로 설치한다.

```
pip install numpy pandas scipy matplotlib scikit-learn statsmodels linearmodels
```

패키지	쓰임	처음 쓰는 장
numpy, pandas	데이터 처리	1장
scipy	통계 함수	1장
matplotlib	그래프	1장
scikit-learn	머신러닝	1장
statsmodels	회귀분석	1장
linearmodels	도구변수 추정	6장

econml과 torch처럼 특정 장에서만 쓰는 패키지는 해당 장에서 따로 안내한다.

무엇을 계산하는가

점검 스크립트는 파이썬 버전, 패키지 설치 여부, 한글 폰트, 회귀 실행 네 가지를 차례로 확인한다. 네 번째 항목이 중요한데, 참 기울기를 2.0으로 정해 데이터를 만든 뒤 그 데이터로 다시 기울기를 추정해 참값을 되찾는지 본다.

코드로 해 보기

```
np.random.seed(0)
x = np.random.normal(10, 2, 300)
y = 5 + 2.0 * x + np.random.normal(0, 1, 300)  # 참 기울기 2.0

fit = smf.ols('y ~ x', data=pd.DataFrame({'x': x, 'y': y})).fit()
lo, hi = fit.conf_int().loc['x']
print(f"추정 기울기: {fit.params['x']:.3f} (표준오차 {fit.bse['x']:.3f})")
print(f"신뢰구간이 참값을 포함하는가: {'예' if lo <= 2.0 <= hi else '아니오'}")
```

전체 코드는 [practice/chapter01/code/1-1-environment-check.py](#) 참고

실행은 다음과 같이 한다.

```
cd practice/chapter01/code
python 1-1-environment-check.py
```

결과를 읽는 법

[1단계] 파이썬 버전

설치된 버전: 3.12.7

판정: 통과 (3.10 이상 필요)

[2단계] 패키지 확인

numpy	1.26.4	수치 계산
pandas	2.3.3	표 형태 데이터 처리
scipy	1.16.2	통계 함수
matplotlib	3.10.6	그래프
sklearn	1.6.1	머신러닝
statsmodels	0.14.5	회귀분석
linearmodels	7.0	도구변수 추정 (6장)

판정: 통과 (필요한 패키지가 모두 있다)

[3단계] 한글 그래프 확인

사용할 한글 폰트: Malgun Gothic

[4단계] 회귀 한 번 돌려 보기

참 기울기: 2.000

추정 기울기: 2.015 (표준오차 0.029)

95% 신뢰구간: [1.958, 2.072]

신뢰구간이 참값을 포함하는가: 예


네 줄을 순서대로 판정한다.

- **설치된 버전: 3.12.7** — 3.10 이상이면 통과하고, 그 아래면 파이썬을 다시 설치한다.
- **패키지 목록에 없음 이 뜨는 경우** — 스크립트가 `pip install` 명령을 만들어 출력하므로 그대로 복사해 실행한 뒤 다시 돌린다.
- **사용할 한글 폰트: Malgun Gothic** — 이 줄이 나오지 않으면 그래프의 한글이 네모로 표시되므로, 모든 실습 스크립트 맨 위에 아래 두 줄을 넣는다. 두 번째 줄을 빠뜨리면 `-1.5` 가 `1.5` 로 나온다.

```
plt.rcParams['font.family'] = 'Malgun Gothic' # macOS는 'AppleGothic'
plt.rcParams['axes.unicode_minus'] = False
```

- **95% 신뢰구간: [1.958, 2.072]** — 참값 2.000이 이 구간 안에 있으므로 통과다. 추정치 2.015가 참값과 정확히 같지 않아도 문제가 아니며, **구간이 참값을 포함하면 정상**이다. 구간이 참값을 벗어나면 난수 설정이나 코드 수정 이력을 먼저 확인한다.

환경 점검용 회귀



그래프에서는 점들이 오른쪽 위로 올라가고 빨간 직선이 그 가운데를 지나야 하며, 축 이름의 한글이 네모로 보이면 3단계 폰트 설정이 적용되지 않은 것이다.

1.1.3 첫 추정 — 처치 집단과 통제 집단의 평균을 뺀다

왜 필요한가

실무에서 "쿠폰이 효과가 있었는가"를 물으면 가장 먼저 나오는 계산이 쿠폰 받은 고객의 평균과 안 받은 고객의 평균을 빼는 것이다. 이 계산은 누구나 할 수 있고 보고서에도 자주 실리지만, 조건이 갖춰지지 않으면 참값에서 크게 벗어난다. 어긋나는 폭을 미리 알아 두지 않으면 그 숫자를 그대로 결정에 쓰게 된다.

무엇을 계산하는가

분석에 쓰는 변수는 네 종류로 나뉜다.

역할	변수	설명
결과 Y	구매액	월 구매 금액(원)
처치 D	쿠폰 수령 여부	0 또는 1
관측 변수 X	나이, 가입기간, 월 앱 접속 횟수	분석에 쓸 수 있다
숨은 원인 U	충성도	쿠폰 수령과 구매액 양쪽에 영향을 주지만 관측되지 않는다

입력은 5,000명의 고객 표이고, 출력은 두 집단의 평균 구매액과 그 차이 한 개다. 계산 자체에는 가정이 하나 들어가는데, 두 집단이 쿠폰 말고 다른 점이 없어야 그 차이를 쿠폰 효과로 읽을 수 있다.

코드로 해 보기

```
mean_yes = df.loc[df.coupon == 1, 'purchase'].mean()
mean_no  = df.loc[df.coupon == 0, 'purchase'].mean()
naive_gap = mean_yes - mean_no
print(f"차이: {naive_gap:>10,.0f}원")
print(f"참 효과 {TRUE_EFFECT:,}원의 {naive_gap/TRUE_EFFECT:.1f}배로 부풀려졌다.")
```

전체 코드는 [practice/chapter01/code/1-2-prediction-vs-causation.py](#) 참고

결과를 읽는 법

[1단계] 데이터 만들기

고객 수: 5,000명

쿠폰 수령률: 39.4%

쿠폰의 참 효과: 3,000원 (데이터를 만들 때 넣은 값)

[2단계] 쿠폰 받은 고객과 안 받은 고객을 그냥 비교하면

쿠폰 받은 고객 평균 구매액: 53,717원 (n=1,971)

쿠폰 안 받은 고객 평균 구매액: 41,007원 (n=3,029)

차이: 12,710원

참 효과 3,000원의 4.2배로 부풀려졌다.

차이: 12,710원 이 이 장의 첫 추정치다. 참값 3,000원의 4.2배이며, 부풀려진 9,710원은 쿠폰이 아니라 다른 데서 왔다. 구조를 분해하면 이렇다.

쿠폰 받은 고객의 구매액이 높은 이유

= 쿠폰 효과 (3,000원)

+ 원래 많이 사던 사람이라서 (9,710원)

쿠폰이 무작위로 뿌려지지 않았기 때문에 두 몫이 섞였다. 앱을 자주 여는 고객이 쿠폰을 더 많이 받아 갖는데, 그 고객들은 쿠폰이 없어도 원래 많이 사던 사람들이다.

- **판정 기준:** 단순 평균 차이는 두 집단이 처치 말고 같다는 것이 확인되기 전까지 효과로 보고하지 않는다. 확인 절차는 1.2.3절의 균형 진단이며, 이 실습에서는 진단을 건너뛴 결과로 4.2배 오차가 났다.

1.1.4 예측 성능은 인과 추정을 보증하지 않는다

왜 필요한가

"모형 성능이 좋으니 결론도 믿을 만하다"는 말이 회의에서 자주 나온다. 성능 지표가 높으면 분석 전체가 검증된 것처럼 보이지만, 예측 성능과 인과 추정의 정확도는 서로 다른 것을 재는 지표이므로 한쪽이 좋다고 다른 쪽이 보증되지 않는다.

무엇을 계산하는가

같은 데이터로 랜덤 포레스트를 학습시켜 구매액을 예측하고, 학습에 쓰지 않은 테스트셋에서 **결정계수**(R^2 , coefficient of determination)를 계산한다. 결정계수는 결과변수의 변동 중 모형이 설명한 비율이며, 1에 가까울수록 예측이 실제값에 가깝다.

코드로 해 보기

```
X = df[['coupon', 'age', 'months', 'app_open']]
y = df['purchase']
X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.3, random_state=42)

rf = RandomForestRegressor(n_estimators=200, random_state=42, n_jobs=-1)
rf.fit(X_tr, y_tr)
r2 = r2_score(y_te, rf.predict(X_te))
print(f"테스트셋 결정계수( $R^2$ ): {r2:.3f}")
```

전체 코드는 [practice/chapter01/code/1-2-prediction-vs-causation.py](#) 참고

결과를 읽는 법

[3단계] 예측 모형을 학습시키면
테스트셋 결정계수(R^2): 0.552
구매액을 상당히 잘 맞힌다.

0.552 는 구매액 변동의 55.2%를 모형이 설명했다는 뜻이며, 예측 모형으로는 쓸 만한 수준이다. 그런데 같은 데이터에서 나온 쿠폰 효과 추정치는 참값의 4.2배였으므로, 두 지표가 같은 방향을 가리키지 않는다는 것이 여기서 드러난다.

지표	재는 것	답하는 질문
결정계수 0.552	예측이 실제와 얼마나 가까운가	이 고객이 얼마를 살 것인가
참값과의 차이	추정 효과가 참 효과와 얼마나 가까운가	쿠폰을 보내면 얼마가 늘어나는가

- **판정 기준:** 결정계수가 0.9로 올라가도 쿠폰 효과 추정은 나아지지 않는다. 인과 추정의 정확도는 참값 대비 오차와 신뢰구간으로 판단하며, 예측 성능 지표를 근거로 인과 결론을 보고하지 않는다.

1.1.5 변수 중요도는 인과효과가 아니다

왜 필요한가

머신러닝 모형은 어느 변수가 예측에 많이 기여했는지를 **변수 중요도**(feature importance)로 알려 준다. 이 값이 클수록 그 변수가 결과를 좌우한다고 읽는 습관이 널리 퍼져 있는데, 중요도가 재는 것은 예측 기여도이지 개입 효과가 아니다.

무엇을 계산하는가

랜덤 포레스트가 각 변수를 분할 기준으로 썼을 때 예측 오차가 얼마나 줄었는지를 합산해 변수별로 정규화한 값을 뽑는다. 입력은 학습된 모형이고, 출력은 변수마다 하나씩 붙는 0과 1 사이의 값이다.

코드로 해 보기

```
imp = pd.Series(rf.feature_importances_, index=X.columns).sort_values(ascending=False)
names = {'coupon': '쿠폰 수령', 'age': '나이', 'months': '가입기간', 'app_open': '앱 접속'}
for k, v in imp.items():
    print(f" {names[k]:<8} {v:.3f}")
```

전체 코드는 [practice/chapter01/code/1-2-prediction-vs-causation.py](#) 참고

결과를 읽는 법

변수 중요도:	
앱 접속	0.642
나이	0.220
가입기간	0.113
쿠폰 수령	0.025

쿠폰 수령 0.025 로 쿠폰이 네 변수 중 가장 낮다. 1.1.3절의 단순 비교는 12,710원이라는 큰 값을 냈는데, 같은 데이터에서 중요도는 쿠폰이 거의 쓸모없다고 판정했으므로 두 숫자가 서로 반대 방향으로 틀린 셈이다.

원인은 앱 접속 횟수에 있다. 앱 접속 횟수가 충성도 정보를 이미 담고 있어서 쿠폰 여부를 추가로 알려 줘도 예측이 별로 나아지지 않으며, 그래서 모형은 쿠폰에 낮은 중요도를 준다.

방법	나온 값	방향
단순 비교	12,710원	참값의 4.2배로 과대
변수 중요도	0.025 (최하위)	효과가 거의 없다고 과소
참값	3,000원	

- **판정 기준:** 변수 중요도 순위는 "무엇을 바꾸면 결과가 달라지는가"의 근거로 쓰지 않는다. 개입 대상을 고를 때는 2장 이후의 인과 추정 방법으로 효과 크기를 따로 추정한다.

1.1.6 인과 데이터 사이언스가 서 있는 세 기반

왜 필요한가

지금까지 나온 두 개의 틀린 답은 방법을 몰라서 생긴 것이 아니라, 어떤 데이터를 어떻게 모았고 무엇을 관측하지 못했는지에서 생겼다. 인과 데이터 사이언스(Causal Data Science)는 "무엇을 해야 원하는 결과를 얻는가"에 답하는 분야인데(Hernán & Robins, 2020), 현장에서 작동하려면 세 가지 기반이 함께 갖춰져야 한다.

세 기반과 실습에서의 대응

- **데이터** — 행정 기록, 거래 기록, 센서, 텍스트를 모아 쓴다. 실습에서 충성도를 관측하지 못해 12,710원이 나왔듯이, 어떤 변수를 확보했는지가 추정 결과를 직접 좌우한다. 표본 수백 개로는 집단별로 효과가 어떻게 다른지도 볼 수 없다.
- **모형** — 머신러닝으로 복잡한 관계를 학습하고 개입 결과를 사전에 계산한다. 다만 1.1.4절에서 확인했듯이 모형 성능만으로는 인과 결론이 서지 않으므로, 모형은 설계와 함께 쓰여야 한다.
- **평가** — 효과를 실행과 동시에 측정하고 그 결과를 다음 결정에 반영한다. 실습 3에서 계산할 순이익 부호가 이 단계의 산출물이다.

세 가지 중 하나만 빠져도 작동하지 않는다. 데이터가 많아도 인과 설계가 없으면 12,710원 같은 값이 나오고, 설계가 좋아도 데이터가 부족하면 추정이 크게 흔들린다.

데이터 기반이 갖춰진 경우: 에스토니아

에스토니아는 인구 130만의 작은 나라인데 정부 서비스의 99%를 온라인으로 제공한다(e-Estonia, 2024a). 기관 간 데이터 교환 플랫폼인 **X-Road**로 연간 22억 건 이상이 오가며 약 1,345년 분의 근무 시간을 절감하고(e-Estonia, 2024b), 시민 문의를 자동 처리하는 **Bürokratt**가 운영되며, 디지털 ID 보급률은 99%에 이른다.

여기서 볼 점은 기술 자체가 아니라 **데이터가 한곳에 모여 있다는 사실**이다. 부처마다 자료가 흩어져 있으면 "이 정책을 받은 사람이 그 뒤에 어떻게 됐는가"를 추적할 수 없고, 추적이 안 되면 인과추론의 출발점인 결과변수 자체를 구성할 수 없다.

한국의 현황

한국은 2024년 UN 전자정부 평가에서 193개국 중 4위이며, 온라인 서비스와 통신 인프라가 세계 최고 수준이다(United Nations, 2024). 중앙부처와 지자체 서비스를 통합한 **정부24**가 운영되고, 공공데이터포털이 10만 개 이상의 데이터를 개방했으며(행정안전부, 2024), 코로나19 대응에서 마스크 재고 실시간 공개가 국제적 모범 사례로 인정받았다.

기말 프로젝트에서 실제 데이터를 쓰려면 공공데이터포털(data.go.kr)과 KOSIS 국가통계포털(kosis.kr)에서 시작하면 된다.

1부 정리

1부에서 손에 남은 것은 다음 세 가지다.

- **첫 추정치 12,710원** — 처치 집단과 통제 집단의 평균을 뺀 값이며, 참값 3,000원의 4.2배다.
- **두 개의 반대 방향 오차** — 단순 비교는 과대 추정했고 변수 중요도는 과소 판정했으므로, 어느 쪽도 개입 효과의 근거가 되지 못한다.
- **다음에 할 일의 목록** — 추정치가 왜 틀렸는지 판정하는 진단, 배정 구조를 바로잡는 보정, 그 숫자를 발행 여부로 옮기는 결정 세 가지가 남았다.

2부에서 답할 질문은 하나다. **12,710원이 왜 틀렸는지 어떻게 판정하고, 무엇으로 바로잡는가.**

2부 (65분). 추정치를 진단하고 결정으로 옮긴다

이 파트가 끝나면: 균형 진단으로 12,710원을 보고 불가로 판정하고, 무작위 배정으로 얻은 2,978원을 비용과 함께 계산해 쿠폰 발행 여부를 결정할 수 있다. **다루는 절:** 1.2.1 ~ 1.3.3

1.2 인과적 데이터 사이언스 프레임워크

1.2.1 전통적 분석·평가 모델의 세 한계

전통적 방식은 "문제 정의 → 대안 설계 → 의사결정 → 실행 → 평가"를 순서대로 한 번 지나간다. 반세기 넘게 쓰인 틀이지만 환경이 빠르게 바뀌면서 세 곳에서 막힌다.


한계	무엇이 문제인가	구체적으로
시간 지연	평가가 실행 한참 뒤에 나온다	3년 사업의 평가가 4년째에 나오면 고칠 기회가 없다
정보 비대칭	현장 상황이 위로 올라가지 않는다	담당 공무원은 아는 문제를 결정권자는 모른다
단절적 피드백	피드백이 평가 단계에서만 생긴다	실행 중 발견한 문제를 그 자리에서 못 고친다

세 한계는 서로 맞물린다. 평가가 늦게 나오므로 현장 정보가 반영될 통로가 좁아지고, 통로가 좁으므로 문제를 발견해도 다음 사업을 기다려야 한다.

1.2.2 5단계 순환 구조 — 지금 우리가 선 자리

앞의 한계를 넘기 위해 각 단계를 순환으로 잇고, 단계마다 인과추론과 AI 기술을 붙인다.

그림 1-2. 인과적 데이터 사이언스의 5단계 순환



전통적 모델은 1에서 5까지 한 번 지나가고 끝난다.
여기서는 5의 결과가 1로 돌아가 다시 돈다.

- **1단계 문제 정의** — 정기 보고서를 기다리지 않고 고객센터 문의, 앱 삭제율, 반품률 같은 신호를 실시간으로 본다. 텍스트 마이닝과 토픽 모델링으로 비정형 자료에서 이슈를 뽑아내며, 10장에서 다룬다.
- **2단계 대안 설계** — 과거 유사 사례의 성과 데이터를 학습해 후보를 만들고, 시뮬레이션으로 부작용을 미리 본다. 행위자 기반 모델링은 11장에서 다룬다.
- **3단계 의사결정** — 여러 기준으로 대안을 평가한다. 이해관계자마다 중요하게 보는 것이 다르므로 가중치를 나눠 반영하고, 설명가능 AI로 선택 근거를 남긴다.
- **4단계 적응형 실행** — 반응을 보며 배분을 조정한다. A/B 테스트처럼 끝날 때까지 기다리는 대신 성과가 좋은 쪽에 노출을 늘려 가며, 8장에서 다룬다.

- **5단계 평가와 학습** — 효과를 측정하고 그 결과를 다음 순환의 문제 정의로 되돌린다. 이 교재의 2장부터 7장까지가 전부 이 단계의 방법이다.

5단계가 전통적 평가와 다른 점은 세 가지다. 실행이 끝난 뒤가 아니라 진행 중에 측정한다는 점(실시간 평가), 다른 요인의 몫을 걷어내고 개입 자체의 효과만 재려 한다는 점(인과적 평가), 평가 결과가 다음 순환의 문제 정의로 돌아간다는 점(적응적 학습)이다. 가운데 항목이 1.1.3절에서 얻은 12,710원과 참값 3,000원의 거리를 좁히는 일이며, 1.2.3절부터 그 작업에 들어간다.

1.2.3 진단 — 두 집단이 처치 말고 무엇이 다른가

왜 필요한가

1.1.3절의 단순 비교는 "두 집단이 쿠폰 말고 같다"는 가정 위에 서 있었지만, 그 가정을 확인하지 않고 계산부터 했다. 가정이 깨져 있는지는 데이터로 확인할 수 있으며, 이 확인을 **균형 진단**(balance check)이라 한다. 진단을 건너뛰고 평균 차이부터 보고하는 것이 실무에서 가장 자주 나는 사고다.

무엇을 계산하는가

처치 집단과 통제 집단에서 처치 이외의 변수들의 평균을 각각 구해 비교한다. 입력은 고객 표이고, 출력은 변수별로 두 집단의 평균 한 쌍이다. 두 평균이 크게 다르면 그 변수가 결과에도 영향을 주는 한 평균 차이에 그 몫이 섞여 있다고 본다.

코드로 해 보기

```
loy_yes = df.loc[df.coupon == 1, 'loyalty'].mean()
loy_no  = df.loc[df.coupon == 0, 'loyalty'].mean()
app_yes = df.loc[df.coupon == 1, 'app_open'].mean()
app_no  = df.loc[df.coupon == 0, 'app_open'].mean()

print(f" 충성도 평균      쿠폰 받음 {loy_yes:>6.2f} vs 안 받음 {loy_no:>6.2f}")
print(f" 월 앱 접속 횟수  쿠폰 받음 {app_yes:>6.1f} vs 안 받음 {app_no:>6.1f}")
```

전체 코드는 [practice/chapter01/code/1-2-prediction-vs-causation.py](#) 참고

결과를 읽는 법

[4단계] 왜 어긋났는가


두 집단은 쿠폰 말고도 다른 점이 있다.

충성도 평균 쿠폰 받음 0.46 vs 안 받음 -0.29

월 앱 접속 횟수 쿠폰 받음 10.8 vs 안 받음 6.7

충성도 평균 0.46 vs -0.29 가 12,710원의 정체를 설명한다. 충성도는 평균 0, 표준편차 1로 만들어진 변수이므로 0.75라는 격차는 표준편차의 4분의 3에 해당하며, 두 집단이 애초에 다른 사람들로 채워졌다는 뜻이다. 앱 접속 횟수도 10.8회와 6.7회로 갈리므로 같은 결론이 나온다.

- **판정 기준:** 처치 이외의 변수에서 두 집단의 평균이 눈에 띄게 벌어지면 단순 평균 차이를 효과로 보고하지 않고, 진단 결과를 함께 적어 보류한다. 여기서는 충성도 격차 0.75가 확인되었으므로 12,710원은 **보고 불가**로 판정한다.



- (a) 두 막대 높이 차이가 12,710원이며, 이 그림만 보면 쿠폰 효과가 커 보인다.
- (b) 충성도 분포 두 개가 겹치기는 하지만 중심이 어긋나 있고 쿠폰 받은 쪽이 오른쪽에 있는데, 이것이 두 집단이 비교 가능하지 않다는 증거다.
- (c) 단순 비교 12,710원과 참값 3,000원을 나란히 놓았으며, 막대 높이 차이가 오차의 크기다.

읽는 순서를 (b)부터로 바꿔야 한다. 두 집단이 비교 가능한지 확인한 뒤에 평균 차이를 계산하는 것이 옳은 순서이며, 순서를 뒤집었기 때문에 잘못된 숫자가 먼저 나왔다.

1.2.4 보정의 기준점 — 무작위 배정

왜 필요한가

진단으로 문제를 확인했다면 다음은 바로잡는 일이다. 가장 확실한 방법은 두 집단이 처음부터 같아지게 만드는 것이며, 그 방법이 **무작위 배정**(randomization)이다. 무작위 배정으로 얻은 값은 이후 모든 방법의 기준점이 되므로, 관찰 데이터로 무엇을 재현하려는지 알려면 이 값을 먼저 봐야 한다.

무엇을 계산하는가

같은 모집단에서 뽑은 고객에게 두 가지 방식으로 쿠폰을 배정한다. 관찰 데이터에서는 고객이 스스로 받아 가게 두고, 실험 데이터에서는 동전을 던져 배정한다. 두 데이터에 **똑같은 계산**을 적용해 처치 집단 평균에서 통제 집단 평균을 빼며, 계산이 아니라 배정 방식만 다르게 둔 것이 핵심이다.

비유: 제비뽑기로 조 나누기

조 나누기	처치 배정
하고 싶은 사람이 손 들어 A조에 간다	고객이 스스로 쿠폰을 받아 간다
A조에 의욕적인 학생이 몰린다	쿠폰 집단에 충성도 높은 고객이 몰린다
A조 성적이 좋아도 조 편성 덕인지 알 수 없다	구매액이 높아도 쿠폰 덕인지 알 수 없다
제비뽑기로 나눈다	무작위로 배정한다
두 조의 평균 실력이 같아진다	두 집단의 충성도 평균이 같아진다
그다음 성적 차이는 조 편성 효과다	그다음 구매액 차이는 쿠폰 효과다

속성 대응은 "자원 선택이 집단을 기울인다 → 무작위 추첨이 그 기울기를 없앤다 → 남은 차이를 처치 효과로 읽는다"는 순서에 있다. 이 비유는 **배정 규칙이 비교 가능성을 만든다는 구조**까지만 맞고, 조 나누기는 몇십 명이면 되지만 무작위 배정의 균형은 표본이 클수록 정확해진다는 점에서 깨진다.

코드로 해 보기

```
# 관찰: 고객이 스스로 선택 - 충성도가 높을수록 쿠폰을 받는다
p = expit(-0.5 + 0.9 * log_o + 0.01 * (age_o - 38))
coupon_o = rng_o.binomial(1, p)

# 실험: 동전 던지기 - 충성도와 무관하게 배정한다
coupon_e = rng_e.binomial(1, 0.5, n)
```

전체 코드는 [practice/chapter01/code/1-3-randomization.py](#) 참고

실행은 다음과 같이 한다.

```
python 1-3-randomization.py
```

결과를 읽는 법

[1단계] 관찰 데이터: 고객이 스스로 쿠폰을 받아 갔다

쿠폰 수령률: 39.5%

두 집단 충성도 차이: +0.76 (0에서 멀수록 집단이 다르다)

평균 구매액 차이: 12,373원

[2단계] 실험 데이터: 동전을 던져 무작위로 배정했다

쿠폰 수령률: 50.0%

두 집단 충성도 차이: -0.00 (무작위 배정이라 0에 가깝다)

평균 구매액 차이: 2,978원

[3단계] 같은 계산, 다른 답

데이터	쿠폰배정	충성도차이	추정효과	참값대비
관찰 고객이 선택	0.76	12373	4.1배	
실험 동전 던지기	-0.00	2978	1.0배	

두 집단 충성도 차이: +0.76 대 -0.00 이 두 줄이 전부를 설명한다. 관찰 데이터에서는 쿠폰 집단의 충성도가 0.76 높은 반면, 실험 데이터에서는 차이가 사실상 0인데 동전을 던져 배정했으므로 충성도가 높은 고객과 낮은 고객이 양쪽에 골고루 들어갔기 때문이다. 무작위 배정이 하는 일이 정확히 이것이며, 관측하지 못하는 변수까지 두 집단에서 평균적으로 같아진다는 점이 결정적이다.

12,373원 대 2,978원 은 똑같은 뺄셈에서 나온 값인데도 4.1배 차이가 난다. 차이를 만든 것은 분석 방법이 아니라 데이터를 모은 방식이며, 이 문장이 이 과목 전체의 출발점이다. 아무리 정교한 모형을 써도 처치가 어떻게 배정됐는지를 다루지 않으면 답이 어긋난다.

- **판정 기준:** 균형 진단에서 처치 이외 변수의 차이가 0 근처면 평균 차이를 효과로 읽는다. 0에서 멀면 그 추정치는 쓰지 않고, 2장부터 7장까지의 방법 중 하나로 배정 구조를 다루어 다시 추정한다.

1.2.5 추정치의 폭 — 신뢰구간 읽기

왜 필요한가

실험 데이터에서 나온 2,978원은 참값 3,000원과 22원 다르다. 이 차이를 편향으로 볼지 우연으로 볼지 판단하지 못하면 추정치를 어디까지 믿을지 정할 수 없으며, 판단 근거를 주는 것이 **신뢰구간**(confidence interval)이다.

무엇을 계산하는가

두 집단 평균의 차이에 표준오차를 붙여 구간을 만든다. 입력은 두 집단의 관측값이고, 출력은 하한과 상한 두 숫자다. 표본이 작거나 결과변수의 변동이 크면 구간이 넓어지므로, 구간의 폭 자체가 자료의 정보량을 알려 준다.

코드로 해 보기

```
se = np.sqrt(y_e[coupon_e == 1].var(ddof=1) / (coupon_e == 1).sum()
            + y_e[coupon_e == 0].var(ddof=1) / (coupon_e == 0).sum())
lo, hi = exp_gap - 1.96 * se, exp_gap + 1.96 * se

print(f"95% 신뢰구간: [{lo:,.0f}원, {hi:,.0f}원]")
print(f"신뢰구간이 참값 {TRUE_EFFECT:,}원을 포함하는가: "
      f"'예' if lo <= TRUE_EFFECT <= hi else '아니오'")
```

전체 코드는 *practice/chapter01/code/1-3-randomization.py* 참고

결과를 읽는 법

```
95% 신뢰구간: [2,177원, 3,779원]
신뢰구간이 참값 3,000원을 포함하는가: 예
```

구간의 폭이 1,602원으로 상당히 넓은데, 표본이 5,000명이고 구매액의 변동이 크기 때문이다. 참값 3,000원이 이 구간 안에 들어 있으므로 추정치 2,978원과 참값의 22원 차이는 편향이 아니라 표본 추출에서 생긴 우연으로 읽는다.

- **판정 기준:** 점추정치만 보고 결론을 내리지 않고 구간을 함께 본다. 구간이 0을 포함하면 효과가 있다고 단정하지 않으며, 구간의 폭이 의사결정 기준선을 걸치면 표본을 늘리거나 결정을 보류한다. 여기서는 구간 하한 2,177원도 상한 3,779원도 뒤에 나올 비용 5,000원보다 작으므로, 구간 전체가 같은 결정을 가리킨다.

1.2.6 결정으로 옮기기 — 순이익 부호까지 계산한다

왜 필요한가

추정치를 보고서에 적는 것으로 분석이 끝나지 않는다. 결정권자가 알아야 하는 것은 효과가 몇 원인지가 아니라 쿠폰을 발행할지 말지이며, 그 판단은 효과에서 비용을 뺀 순이익의 **부호**로 갈린다. 추정치가 부풀려지면 크기만 틀리는 것이 아니라 결정 자체가 반대로 간다.

무엇을 계산하는가

쿠폰 1장당 순이익을 효과에서 비용을 빼서 구하고, 전체 고객 수를 곱해 총액을 계산한다. 입력은 추정 효과, 쿠폰 1장 비용 5,000원, 전체 고객 100만 명이고, 출력은 순이익 총액 하나다.

코드로 해 보기

```

COUPON_COST = 5000
N_CUSTOMERS = 1_000_000

for label, est in [('관찰 데이터를 믿으면', obs_gap), ('실제로는', TRUE_EFFECT)]:
    margin = est - COUPON_COST
    total = margin * N_CUSTOMERS
    verdict = '발행한다' if margin > 0 else '발행하지 않는다'
    print(f"{label}")
    print(f"  쿠폰 1장당 순이익: {est:,.0f} - {COUPON_COST:,.0f} = {margin:,.0f}원 → {verdict}")
    print(f"  전 고객 발행 시:   {total/1e8:,.1f}억원")

```

전체 코드는 [practice/chapter01/code/1-3-randomization.py](#) 참고

결과를 읽는 법

[4단계] 이 차이는 얼마짜리인가

쿠폰 1장 비용: 5,000원

전체 고객: 1,000,000명

관찰 데이터를 믿으면

쿠폰 1장당 순이익: 12,373 - 5,000 = 7,373원 → 발행한다

전 고객 발행 시: 73.7억원

실제로는


쿠폰 1장당 순이익: 3,000 - 5,000 = -2,000원 → 발행하지 않는다

전 고객 발행 시: -20.0억원

관찰 데이터를 믿고 100만 장을 발행하면 실제로는 20.0억원 손실이다.

순이익 부호가 +7,373원 에서 -2,000원 으로 뒤집힌다. 관찰 데이터를 믿으면 발행하라는 결론이 나오고 실제로는 발행하지 말라는 결론이 나오므로, 크기가 틀린 정도가 아니라 결정이 반대가 된다. 100만 명에게 발행하면 73.7억원을 기대하고 시작해 20.0억원을 잃는다.

- **판정 기준:** 추정치를 결정에 쓸 때는 비용을 넣어 부호까지 계산하고, 신뢰구간의 양 끝을 각각 넣어 부호가 바뀌는지 확인한다. 구간의 어느 한쪽에서 부호가 뒤집히면 그 추정치로는 결정을 내리지 않고 표본을 늘리거나 설계를 다시 짠다.



- (a) 두 집단의 총성도 차이이며, 관찰 데이터는 0.76으로 높이 솟아 있고 실험 데이터는 0에 붙어 있다. 막대가 낮을수록 비교 가능한 두 집단이다.
- (b) 관찰·실험·참값을 나란히 놓았으며, 실험 막대와 참값 막대의 높이가 거의 같고 관찰 막대만 4배 높다.
- (c) 100만 장 발행의 손익이며, 왼쪽은 관찰 데이터를 믿었을 때 기대한 73.7억원이고 오른쪽은 실제 결과인 -20.0억원이다. 막대가 0선 위아래로 갈린다.

여기서도 (a)를 먼저 보는 순서가 중요하다. 두 집단이 처치 말고 다른 점이 있는지 확인하지 않고 (b)의 평균 차이부터 계산하면 (c)의 손실이 생긴다.

1.3 전통적 방법론과 Causal ML의 비교

1.3.1 무작위 배정을 못 하는 네 가지 경우

무작위 배정이 답을 바로잡는다는 것을 확인했지만, 현실에서는 자주 쓸 수 없다.

- 윤리 — 어떤 학생에게만 장학금을 주고 나머지를 대조군으로 두는 설계는 승인받기 어렵다.
- 법·제도 — 소득 기준을 충족한 모든 가구에 지급해야 하는 급여를 무작위로 나눠 줄 수 없다.
- 비용·시간 — 도시 절반에 지하철을 놓고 절반에 놓지 않는 실험은 실행 자체가 불가능하다.
- 이미 벌어진 일 — 작년에 시행된 정책의 효과를 지금 와서 실험으로 확인할 수 없다.

네 경우 모두 데이터는 관찰 데이터뿐이므로, 배정 구조를 분석 단계에서 다루어야 한다. 그 방법이 2장부터 7장까지의 내용이며, 각 방법은 배정 구조에 대해 서로 다른 가정을 세운다.

1.3.2 전통적 방법론과 Causal ML 중 무엇을 쓰는가

전통적 방법론은 비용편익분석, 회귀분석, 설문조사, 델파이 기법처럼 20세기 중반 이후 자리 잡은 도구를 말하며, 계수와 유의성을 명확히 보고할 수 있다는 강점이 있다. 반면 선형성과 독립성 같은 강한 가정에 기대므로 현실 데이터가 그 가정을 벗어나면 추정이 왜곡된다. Causal ML은 가정을 완화하고 규모를 감당하는 대신 해석이 어려워진다.

표 1-1 방법론 비교

비교 항목	전통적 방법론	Causal ML 방법론
데이터 처리 규모	수백~수천 개 표본	수백만~수십억 개 데이터 포인트
분석 속도	일~주 단위	실시간~분 단위
비선형성 처리	제한적 (변환 필요)	자동 학습
해석가능성	높음 (명확한 계수)	낮음~중간 (블랙박스)
전문성 요구	통계·경제학 지식	프로그래밍·ML 지식
적응성	정적 모델	동적 학습
편향 위험	분석자 편향	데이터·알고리즘 편향
규제 준수	확립된 기준	발전 중인 기준


무엇을 쓸지는 상황이 정한다.

상황	적합한 쪽	이유
법적·규제 근거를 제시해야 한다	전통적 방법론	계수와 유의성을 명확히 보고할 수 있다
표본이 수백 개 수준이다	전통적 방법론	머신러닝은 학습할 데이터가 부족하다
이해관계자를 설득해야 한다	전통적 방법론	해석이 직관적이다
수백만 건을 처리해야 한다	Causal ML	규모를 감당한다
관계가 곡선이고 상호작용이 많다	Causal ML	항을 사람이 고르지 않아도 된다
실시간 판단이 필요하다	Causal ML	재학습과 갱신이 빠르다
텍스트·이미지가 자료다	Causal ML	비정형 자료를 다룰 수 있다

실무에서는 둘 다 돌려 결론의 방향이 같은지 보는 편이 안전하며, 방향이 갈리면 가정이 어디서 깨졌는지 찾는 단서가 된다. 이 원칙은 6장에서 다시 다룬다.

1.3.3 이 교재의 지도

그림 1-3. 이 교재에서 배울 방법의 지도



첫 갈림길은 **무작위 배정이 가능한가**이며, 불가능할 때 배정 구조를 어떻게 다루느냐에 따라 이후 갈래가 나뉜다.

갈래	아이디어	장
무작위 배정이 가능하다	직접 실험을 설계한다	8장 A/B 테스트와 적응형 설계
비슷한 사람끼리 짝짓는다	관측된 특성이 같은 사람을 비교한다	2장 DML, 3장 성향점수 매칭
시점·경계를 이용한다	정책 전후, 기준선 좌우를 비교한다	4장 이중차분·합성통제, 5장 회귀불연속
외부 충격을 이용한다	본인 의사와 무관한 변동만 골라 쓴다	6장 도구변수, 7장 분위 회귀
자료 종류가 다르다	시계열·텍스트·네트워크·시뮬레이션	9~12장

각 장은 "이런 상황에서 이렇게 한다"를 하나씩 다룬다. 어떤 방법이 다른 방법보다 낫다는 순위는 없으며, 쓸 수 있는 조건이 다를 뿐이다.

결과를 어떻게 읽는가

이 장에서 나온 숫자를 한자리에 놓고 읽는 순서를 정리한다. 순서가 곧 분석 절차이며, 앞 단계를 건너뛰면 뒤 단계의 숫자가 의미를 잃는다.

순서	보는 값	이 장의 실측치	판정
1	환경 점검의 신뢰구간	[1.958, 2.072], 참값 2.000 포함	통과. 실습을 진행한다
2	처치 이외 변수의 집단 간 평균	충성도 0.46 대 -0.29	격차 있음. 단순 비교 보고 불가
3	단순 평균 차이	12,710원 (참값의 4.2배)	진단 실패 상태의 값이므로 쓰지 않는다
4	예측 성능과 변수 중요도	R^2 0.552, 쿠폰 중요도 0.025	인과 결론의 근거로 쓰지 않는다
5	배정을 바로잡은 추정치	2,978원	충성도 차이 -0.00이므로 채택한다
6	신뢰구간	[2,177원, 3,779원]	참값 포함. 구간 폭 1,602원
7	순이익 부호	-2,000원	발행하지 않는다

2번을 보지 않고 3번으로 건너뛴 것이 이 장에서 재현한 사고이며, 7번의 20.0억원 손실이 그 대가다. 자주 나는 오류를 네 가지로 정리하면 다음과 같다.

오류	왜 문제인가	대신 할 것
평균 차이를 효과로 읽는다	집단이 애초에 다르면 차이에 다른 요인이 섞인다	균형 진단을 먼저 하고 그 결과를 함께 보고한다
변수 중요도를 인과효과로 읽는다	중요도는 예측 기여도를 잴다	인과 추정 방법으로 효과 크기를 따로 구한다
예측 성능이 좋으니 결론도 맞다고 본다	두 지표는 다른 것을 잴다	참값 대비 오차와 신뢰구간으로 판단한다
추정치 크기만 보고 결정한다	부호가 뒤집히면 결정이 반대가 된다	비용을 넣어 순이익 부호까지 계산한다

실무 적용 점검표

새로운 과제에 이 장의 절차를 적용할 때 다음 여덟 항목을 확인한다.

- 답하려는 질문이 예측인지 인과인지 한 문장으로 적었는가. "얼마가 될 것인가"면 예측이고 "무엇을 하면 얼마나 달라지는가"면 인과다.
- 결과 Y , 처치 D , 관측 변수 X 를 표로 구분했는가. 각각이 데이터의 어느 열인지 지목할 수 있어야 한다.
- 처치를 누가 어떻게 받았는지 배정 규칙을 서술했는가. 규칙을 모르면 어느 방법을 쓸지 정할 수 없다.

- 관측하지 못하는 원인 중 처치와 결과 양쪽에 영향을 주는 것이 무엇인지 적었는가. 이 장의 충성도에 해당하는 변수다.
- 처치 이외 변수에 대해 두 집단의 평균을 비교했는가. 격차가 있으면 단순 비교 결과를 보고하지 않는다.
- 추정치에 신뢰구간을 붙였는가. 점추정치만 있는 보고서는 결정 근거로 부족하다.
- 비용을 넣어 순이익 부호를 계산했는가. 신뢰구간의 양 끝에서도 부호가 같은지 확인한다.
- 무작위 배정이 가능한지 검토했는가. 불가능하다면 이유를 윤리·법·비용·시점 중 어디에 해당하는지 적고 1.3.3절의 지도에서 갈래를 고른다.

핵심 정리

- 데이터로 답하는 질문은 예측과 인과 두 가지이며, 이 교재는 "무엇을 하면 얼마나 달라지는가"에 해당하는 두 번째 질문을 다룬다.
- 예측 성능이 좋아도 인과 추정이 옳다는 근거가 되지 않는다. 결정계수 0.552인 모형과 참값의 4.2배인 추정치가 같은 데이터에서 나왔다.
- 변수 중요도는 예측 기여도를 재는 값이므로 개입 효과로 읽지 않는다. 쿠폰 중요도 0.025와 단순 비교 12,710원이 서로 반대 방향으로 틀렸다.
- 추정이 어긋나는 원인은 두 집단이 처치 말고도 다르다는 데 있으며, 충성도 평균 0.46과 -0.29의 격차가 그 증거다.
- 무작위 배정은 처치 말고 다른 모든 것을 두 집단에서 평균적으로 같게 만들고, 관측하지 못하는 변수까지 포함한다. 충성도 차이가 관찰 0.76에서 실험 -0.00으로 바뀌었다.
- 같은 계산에 다른 답이 나온 이유는 분석 방법이 아니라 데이터를 모은 방식이다. 관찰 12,373원, 실험 2,978원, 참값 3,000원이 이를 보여 준다.
- 틀린 추정치에는 값이 붙는다. 순이익 부호가 +7,373원에서 -2,000원으로 뒤집히며, 100만 장 발행 시 73.7억원을 기대하고 20.0억원을 잃는다.
- 무작위 배정은 윤리·법·비용·시점 때문에 자주 불가능하며, 그때 관찰 데이터로 인과효과를 찾는 방법이 2장부터 7장까지다.
- 방법에 우열은 없고 쓸 수 있는 조건이 다를 뿐이므로, 문제 상황을 보고 갈래를 고르는 판단이 방법을 아는 것보다 앞선다.

연습 문제

1. 어느 지자체가 청년 창업 지원금을 신청자에게 지급한 뒤, 지원받은 창업자의 3년 생존율이 미지원 창업자보다 18%포인트 높다고 발표했다. 이 숫자를 지원금 효과로 읽으면 안 되는 이유를 이 장의 균형 진단 개념으로 설명하고, 발표 전에 확인했어야 할 항목을 두 가지 적어라.

- 어느 분석팀이 이탈 예측 모델을 만들어 결정계수 0.87을 얻은 뒤, 변수 중요도 1위인 "고객센터 문의 횟수"를 줄이면 이탈이 줄 것이라고 제안했다. 이 제안의 어느 지점이 잘못되었는지 지적하고, 제안을 검증하려면 무엇을 해야 하는지 서술하라.
- 1.2.5절의 신뢰구간 [2,177원, 3,779원]에서 쿠폰 비용이 5,000원이 아니라 2,000원이었다고 하자. 구간의 하한과 상한을 각각 순이익 계산에 넣었을 때 결정이 갈리는지 판정하고, 갈리지 않는다면 그 사실이 의사결정에 어떤 의미인지 적어라.
- 어느 온라인 서비스가 신규 추천 알고리즘의 효과를 재려 한다. 전체 사용자에게 한꺼번에 적용한 뒤 적용 전후 한 달을 비교하는 안과, 사용자 절반에게만 무작위로 적용하는 안이 있다. 두 안의 차이를 이 장의 개념으로 설명하고, 앞의 안을 택할 수밖에 없는 상황을 하나 들어라.
- 이 장의 절차 일곱 단계 중 2번(균형 진단)을 실무에서 건너뛰게 되는 이유를 세 가지 추측해 적고, 각각을 막을 수 있는 조직 차원의 장치를 하나씩 제안하라.

더 공부할 자료

무료 교재 (영문, 온라인 전문 공개)

- Causal Inference: The Mixtape — 1장과 2장이 이 장의 내용과 겹친다. <https://mixtape.scunning.com/>
- The Effect: An Introduction to Research Design and Causality — 1~4장. <https://theeffectbook.net/>

영상 강의

- Marginal Revolution University, Mastering Econometrics. <https://mru.org/courses/mastering-econometrics>

실습 데이터를 구할 곳

- 공공데이터포털 — 정부·지자체 개방 데이터. <https://www.data.go.kr>
- KOSIS 국가통계포털 — 통계청 자료. <https://kosis.kr>

패키지 문서

- statsmodels — 회귀분석과 진단. <https://www.statsmodels.org/stable/index.html>
- scikit-learn — 머신러닝. <https://scikit-learn.org/stable/>

위 URL은 2026년 8월 17일 기준 접속을 확인했다.

참고문헌

과학기술정보통신부. (2024). 국가인공지능 전략 정책방향. 정책보고서.

행정안전부. (2024). 정부24 및 공공데이터 개방 현황. <https://www.gov.kr>; <https://www.data.go.kr>

Athey, S., & Imbens, G. W. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685-725.

e-Estonia. (2024a). Facts and Figures. <https://e-estonia.com/facts-and-figures/>

e-Estonia. (2024b). X-Road: Interoperability Services. <https://e-estonia.com/solutions/interoperability-services/x-road/>

Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Boca Raton: Chapman & Hall/CRC.

Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.

Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495.

Pearl, J., & Mackenzie, D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books.

United Nations. (2024). *UN E-Government Survey 2024*. United Nations DESA.