

5장. 회귀불연속설계(RDD)와 기계학습

□ 이 장의 질문

- 성적 우수 장학금을 받은 학생들의 다음 학기 평점이 못 받은 학생들보다 높게 나왔다. 그러면 "장학금의 효과"라고 보고해도 될까?
- 이 장의 답은 "그대로는 안 되지만, 커트라인을 이용하면 된다"이다. 자격을 가르는 커트라인 바로 아래 학생과 바로 위 학생은 사실상 같은 사람들이므로, 그 경계에서 결과가 수직으로 얼마나 튀는지를 재면 효과를 읽을 수 있다. 이 방법이 언제 성립하고, 무엇을 검사해야 하며, 그 숫자를 어디까지 해석해도 되는지를 차례로 배운다

□ 이 장을 읽는 방법

- 이 장은 두 파트로 나뉜다
 - 1부(5.1~5.3): 커트라인이 왜 자연실험이 되는지 이해하고, 국소선형회귀로 첫 추정치를 얻은 뒤, 대역폭 계산과 네 가지 타당성 검정으로 그 숫자를 믿어도 되는지 판정한다
 - 2부(5.4~5.8): 기준을 넘어도 처치를 받지 않는 경우(퍼지), 공변량이 많은 경우(이중 기계학습), 효과가 사람마다 다른 경우(CATE), 기준선이 지도 위의 선인 경우(지리적 RDD)로 설계를 넓히고, 결론을 적는 범위를 정한다
- 수식은 쓰지 않는다. 모든 계산은 구체적인 숫자 예시로만 따라간다
- 실습 데이터는 정답을 알고 만든 연습용 데이터다. 예를 들어 5.1의 데이터에는 참 효과 3.8을 심어 두었으므로, 계산한 값이 얼마나 빗나갔는지 채점할 수 있다. 현실 데이터에서는 이 채점이 불가능하므로, 채점 없이 판정하는 검정들을 함께 배운다
- 실습 코드는 `practice/chapter05/code/` 에 있다. 스크립트를 실행하면 콘솔 출력 전체가 `practice/chapter05/results/<스크립트명>.log` 로 저장되고, 그림도 `results` 폴더에 저장된다. 본문의 실행 결과 발췌는 모두 이 코드가 실제로 계산한 값이다
- 용어 미리보기 — 본문에서 처음 나올 때마다 다시 풀어 설명하므로, 여기서는 눈에 익히기만 하면 된다

용어	쉬운 뜻
배정변수	처치 여부를 가르는 연속적인 점수 (예: 학점, 나이, 소득)
기준점(컷오프)	처치가 갈리는 경계값 (예: 학점 3.5, 만 65세)
처치 지시자	기준점을 넘었으면 1, 아니면 0으로 적은 표시
대역폭	기준점 좌우 몇 점까지를 분석에 넣을지 정한 폭
국소선형회귀	기준점 좌우 각각에 직선을 그어, 두 직선이 기준점에서 갖는 값의 차이를 재는 방법
신뢰구간	참값이 들어 있을 법하다고 계산한 범위
밀도 검정	기준점 근처에 사람 수가 부자연스럽게 몰렸는지(조작 여부) 세어 보는 검사
플라시보 검정	가짜 기준점에서도 점프가 나오는지 확인하는 검사
도넛홀 검정	기준점 바로 옆 관측치를 빼고 다시 재어 결과가 흔들리는지 보는 검사
퍼지 RDD	기준을 넘어도 일부만 처치를 받을 때, 결과의 점프를 처치 확률의 점프로 나눠 보정하는 설계
1단계 F통계량	기준점이 처치 확률을 실제로 얼마나 강하게 바꾸는지 잴 값. 10이 판정선이다
LATE	기준을 넘었기 때문에 처치를 받은 사람들(순응자)에 대한 효과

1부. 커트라인에서 첫 추정치를 얻고 검증한다

□ 1부 개요

- 이 파트가 끝나면: 국소선형회귀로 처치효과 3.51과 95% 신뢰구간 [1.94, 5.08]을 얻고, 대역폭을 자료에서 계산하고, 네 가지 타당성 검정을 통과시켜 이 숫자를 보고해도 되는지 판정할 수 있다
- 다루는 절: 5.1 ~ 5.3

□ 5.1.1 왜 그냥 비교하면 안 되는가

- 장학금을 받은 학생과 못 받은 학생의 평점 차이에는 장학금의 효과와 원래 실력 차이가 섞여 있다
 - 장학금은 원래 성적이 좋은 학생에게 갔으므로, 두 집단은 처치 이전부터 다른 사람들이다. 3장에서 본 선택편향과 같은 문제이며, 두 집단을 통째로 비교하는 한 이 섞임은 갈라지지 않는다
- 그런데 지금 기준이 "학점 3.5 이상"처럼 숫자 하나로 정해져 있다면 상황이 달라진다
 - 예를 들어 학점 3.49인 학생과 3.51인 학생만 떼어 놓고 보면, 두 사람의 실력 차이는 사실상 없고 다른 점은 장학금 수혜 여부 하나뿐이다

- 3.49와 3.51을 가른 것은 실력이 아니라 채점의 미세한 흔들림이므로, 기준점을 아주 좁게 둘러싼 구간 안에서는 처치가 거의 제비뽑기처럼 나뉜다
- 이 착상이 **회귀불연속설계**(Regression Discontinuity Design, RDD)다. Thistlethwaite와 Campbell(1960)이 장학금 자료로 처음 제안했다
 - 구조는 무작위 실험의 동전 던지기와 같다. 동전의 앞뒷면이 기준점 통과 여부에, 동전이 사람의 특성과 무관하다는 성질이 "3.49와 3.51은 실력 차이가 아니다"에, 두 집단 결과의 차이를 효과로 읽는 절차가 기준점 좌우 평균의 차이를 효과로 읽는 절차에 대응한다
 - 단, 동전은 표본 전체에 적용되지만 커트라인은 기준점 근처에서만 제비뽑기다. 학점 2.0과 4.0인 학생은 제비뽑기로 갈린 사이가 아니므로, 이 설계의 결론은 기준점 근처 사람들에 대한 효과로 제한된다(5.8에서 다시 다룬다)
- 이 구조는 제도 곳곳에 있다. 기초연금의 만 65세, 청년 지원 사업의 만 34세, 신용 점수 컷오프, 무료 배송의 주문 금액 3만 원처럼 기준선이 숫자 하나로 박힌 제도는 모두 후보다

한 줄 정리: 집단 전체는 비교할 수 없지만, 커트라인 바로 양옆 사람들은 비교할 수 있다.

□ 5.1.2 용어 네 개와 성립 조건

- 계산에 들어가기 전에, 자료의 어느 열이 무엇을 말는지 네 가지 이름부터 정한다 (표 5-1)

<표 5-1: 회귀불연속설계의 기본 용어>

용어	뜻	장학금 예시	코드에서
배정변수	처치를 가르는 연속 점수	직전 학기 학점	score
기준점	처치가 갈리는 경계값	3.5	cutoff
처치 지시자	기준점 이상이면 1, 아니면 0	장학금 수혜 여부	treat
대역폭	기준점 좌우 몇 점까지 넣을지 정한 폭	3.5 ± 0.5	h


- 재려는 값은 기준점에서 결과가 수직으로 튀어 오른 크기다
 - 예를 들어 기준점 바로 위 학생들의 다음 학기 평점 평균이 3.71이고 바로 아래 학생들의 평균이 3.55라면, 점프는 $3.71 - 3.55 = 0.16$ 이다
 - 이 0.16은 "장학금을 받으면 평점이 0.16 오른다"가 아니라 "학점 3.5 언저리 학생이 장학금을 받으면 평점이 0.16 오른다"로 읽는다
- 이 점프가 인과효과가 되려면 조건이 두 개 필요하다
 - 첫째, 처치가 없었다면 결과가 기준점에서 매끄럽게 이어졌어야 한다(**연속성**). 학점 3.5가 장학금 기준이면서 교환학생 자격 기준이기도 하다면, 점프에 두 제도의 효과가 겹쳐 장학금 몫만 떼어 낼 수 없다

- 둘째, 사람들이 배정변수를 조작해 기준점을 넘을 수 있으면 안 된다. 자영업자가 소득을 낮춰 신고하거나 커트라인 바로 아래 학생만 재시험을 보는 경우가 여기에 해당하며, 조작이 있으면 기준점 바로 위 사람들은 "운 좋게 넘은 사람"이 아니라 "넘으려고 애쓴 사람"이라 비교가 무너진다. 조작을 검사하는 절차는 5.3에서 배운다

○ 마지막으로 자기 자료가 두 갈래 중 어느 쪽인지 가른다

- 기준을 넘은 사람이 전부 처치를 받고 못 넘은 사람은 아무도 안 받으면 **명확(Sharp) RDD**다. 만 65세가 되면 신청 없이 급여가 나가는 제도가 여기에 해당한다
- 기준을 넘어도 신청하지 않는 사람이 있고 미달이어도 예외로 받는 사람이 있으면 **퍼지(Fuzzy) RDD**다(5.4에서 다룬다)
- 판별 방법: 기준점 좌우에서 실제 처치 수혜율을 각각 계산한다. 좌측이 0에 가깝고 우측이 1에 가까우면 명확 RDD로 진행한다

그림 5-1. Sharp RDD의 구조



○ 그림 5-1 읽는 법

- 파란 점(대조군)과 빨간 점(처치군)이 기준점 $c = 50$ 의 세로 점선에서 갈리고, 노란 화살표의 길이가 우리가 재는 수직 점프 τ 다
- 초록 음영이 대역폭 안이다. 추정에는 이 구간의 자료만 쓰며, 음영 밖의 점들은 계산에 들어가지 않는다
- 좌우 직선의 기울기가 서로 달라도 문제가 아니다. 읽는 값은 기울기가 아니라 기준점에서의 세로 간격이다

한 줄 정리: 배정변수·기준점·처치 지시자·대역폭을 지목하고, 명확인지 퍼지인지부터 가른다.

□ 5.1.3 국소선형회귀 — 첫 추정치를 얻는다

- 기준점 "바로 옆" 평균을 그대로 구할 수는 없으므로(정확히 3.5인 사람은 거의 없다), 기준점 좌우 각각에 직선을 긋고 두 직선이 기준점에서 갖는 값의 차이를 점프로 쓴다. 이 방법이 국소선형회귀다
- 절차는 네 단계다
 - ① 대역폭 h 를 정해 기준점에서 h 이내인 관측치만 남긴다 ② 배정변수에서 기준점을 빼서 기준점이 0이 되게 만든다 ③ 좌우의 기울기가 다를 수 있도록 처치×점수 항을 추가한다 ④ 회귀를 적합해 `treat` 계수를 읽는다. 이 계수가 점프다
- 실습 코드(핵심 부분, 전체는 `5-1-sharp-rdd.py`)

```
bandwidth = 0.5 * df['score'].std() # 대역폭: 표준편차의 절반
near_cutoff = df[np.abs(df['score'] - cutoff) <= bandwidth].copy()

near_cutoff['score_centered'] = near_cutoff['score'] - cutoff # 기준점을 0으로
near_cutoff['treat_score'] = near_cutoff['treat'] * near_cutoff['score_centered']

model = smf.ols('outcome ~ treat + score_centered + treat_score',
                data=near_cutoff).fit() # treat 계수 = 점프
```

- 실행 결과(`results/5-1-sharp-rdd.log` 발췌)

```
선택된 대역폭: 4.90
유효 표본 크기: 375

처치효과 추정 (t): 3.51
표준오차: 0.80
p-value: 0.0000
95% 신뢰구간: [1.94, 5.08]
R²: 0.383
좌측 기울기: 0.705
우측 기울기: 0.353
```

- 해석: 기준점에서 결과가 3.51만큼 튀었고, 신뢰구간 [1.94, 5.08]이 0을 벗어나므로 "점프가 없다"고 보기 어렵다. 이 데이터에 심어 둔 참 효과는 3.8이므로, 추정치 3.51은 참값을 신뢰구간 안에 담았다
- 유효 표본 375는 전체 1,000명이 아니라 대역폭 안에 들어온 사람 수다. 자료가 아무리 많아도 실제 추정에는 기준점 근처 일부만 쓰므로, RDD의 표준오차는 다른 방법보다 큰 편이다

- R^2 0.383이 낮다는 이유로 모형을 바꾸지 않는다. 목적은 결과를 잘 예측하는 것이 아니라 기준점의 점프를 재는 것이므로, 판단 근거는 R^2 가 아니라 t 의 신뢰구간과 5.3의 진단 검정이다
- 좌우 기울기 0.705와 0.353이 다른 것도 문제가 아니다. 처치×점수 항을 넣은 이유가 이 차이를 허용하기 위해서다

한 줄 정리: 좌우에 직선을 긋고 기준점에서의 세로 간격을 읽는다. 여기서는 3.51이다.

□ 5.1.4 추정치를 흔들어 본다 — 대역폭 민감도와 공변량 균형

- 3.51은 대역폭을 표준편차의 0.5배로 정하고 얻은 값이므로, 그 선택 하나에 결과가 얼마나 매달려 있는지 확인해야 한다. 확인 방법은 대역폭을 바꿔 가며 같은 회귀를 반복하는 것이다
- 실행 결과(같은 로그의 "대역폭 민감도 분석" 발췌, 표기 정리)

배수	대역폭	추정값	SE	유효표본
0.5	4.90	3.510	0.797	375
1.0	9.79	3.524	0.589	691
1.5	14.69	3.856	0.501	861
2.0	19.58	3.536	0.455	956

- 해석: 세로로 SE 열을 따라가면 대역폭이 넓어질수록 0.797에서 0.455로 준다. 표본이 375명에서 956명으로 늘었기 때문이다. 가로로 추정값을 보면 3.51~3.86에 머물러, 부호가 바뀌거나 크기가 몇 배로 뛰는 일이 없다
- 판정 눈금
 - 대역폭을 바꿔도 부호가 유지되고 신뢰구간들이 서로 겹치면, 대역폭 선택이 결론을 좌우하지 않는다고 보고 진행한다
 - 대역폭을 절반으로 줄였을 때 부호가 뒤집히거나 유의성이 사라지면, 보고하지 않고 자료와 설계를 다시 본다
 - 넓은 대역폭에서만 유의하면 기준점에서 먼 관측치가 결과를 끌고 있다는 신호이므로, 좁은 쪽을 기준으로 결론을 적는다
 - SE가 작다는 이유만으로 가장 넓은 대역폭을 고르지 않는다. 넓힐수록 편향이 커진다(5.2에서 다룬다)
- 판정 연습(가상의 수치다): 어느 분석에서 대역폭 3종의 추정값이 +2.1, +2.3, -0.4로 나왔다면?
 - 좁은 대역폭에서 부호가 뒤집혔으므로 보고하지 않는다. 대역폭 선택이 결론 자체를 바꾸는 자료다
- 두 번째 확인: 기준점 근처 두 집단이 실제로 비슷한가. 처치가 영향을 줄 수 없는 사전 변수(연령·성별·교육연수)를 결과 자리에 넣고 같은 회귀를 돌린다. 이 변수들은 기준점에서 점프하면 안 된다
- 실행 결과(같은 로그의 "공변량 균형 검정" 발췌, 표기 정리)

공변량	기준점 불연속	p-value
연령	0.582	0.618
성별	0.094	0.201
교육연수	0.200	0.582


- 해석: 세 변수 모두 p값이 0.2를 넘어 유의한 점프가 없다. 관측한 특성이 균형이면 관측 못 한 특성도 균형일 가능성이 높다는 정황 증거이며, 증명은 아니다
- 처치 이후에 측정된 변수는 이 검정에 넣지 않는다. 처치의 영향을 받은 변수가 점프하는 것은 위반이 아니라 효과의 일부다

한 줄 정리: 대역폭을 흔들어도 3.51~3.86이면 안정, 사전 변수가 점프하지 않으면 비교 가능성이 뒷받침된다.

□ 5.2 대역폭을 감으로 정하지 않고 계산한다 — IK 대역폭

- 5.1에서는 대역폭을 표준편차의 절반으로 "그냥" 정했다. 심사자가 가장 먼저 묻는 것이 "왜 하필 그 폭인가"이며, 근거 없이 답하면 결과 전체가 임의의 선택으로 읽힌다
- 대역폭을 정하는 일은 두 가지 손실을 맞바꾸는 작업이어서, 어느 한쪽만 공짜로 줄일 수는 없다
 - 폭을 좁히면 기준점에 가까운 사람만 남아 직선이 실제 관계를 잘 따라가므로, 추정값이 한쪽으로 치우치는 정도가 줄어든다. 이 치우침을 **빗나감**(편향, bias)이라 부른다. 대신 쓰는 사람 수가 적어져, 표본을 다시 뽑을 때마다 값이 달라지는 폭이 커진다. 이 흔들림을 **분산**(variance)이라 부른다
 - 폭을 넓히면 쓰는 사람 수가 늘어 흔들림은 줄지만, 기준점에서 먼 곡선 구간까지 직선 하나로 이어 붙이게 되어 빗나감이 커진다

그림 5-3. 대역폭은 자료 양과 직선 근사 정확도를 맞바꾼다



- 그림 5-3 읽는 법

- 왼쪽(좁은 대역폭): 색칠된 점이 적다. 계산에 쓰는 사람이 적어 신뢰구간이 넓다
- 오른쪽(넓은 대역폭): 회색 점선으로 그린 실제 관계는 곡선인데 파란.빨간 직선이 그 곡선을 따라가지 못한다. 직선과 곡선이 벌어진 만큼이 빗나감이 되어 점프 추정값에 섞인다
- Imbens와 Kalyanaraman(2012)이 제안한 방법(줄여서 **IK 대역폭**)은 두 손실을 하나의 점수로 합친 다음, 그 점수가 가장 작아지는 폭을 자료에서 직접 찾는다
 - 합치는 방법은 빗나감을 제공한 값에 흔들림을 더하는 것이다. 이 합을 **평균제곱오차(MSE)**라 부르며, 추정값이 참값에서 평균적으로 얼마나 멀어지는지를 숫자 하나로 나타낸다
 - 빗나감만 보고 폭을 정하지 않는 이유는, 치우침이 거의 없어도 흔들림이 크면 실제로 손에 쥔 표본 하나에서 얻은 값이 참값과 멀어지기 때문이다
- 계산에 넣는 재료는 세 가지다
 - 잡음: 자료가 직선 주위로 얼마나 흩어져 있는지를 재는 값이다. 흩어짐이 클수록 값 하나하나를 믿기 어려워 사람을 더 모아야 하므로 대역폭이 넓어진다
 - 휘어짐: 기준점 근처에서 실제 관계가 직선에서 얼마나 벗어나 휘는지를 재는 값이다. 많이 휘수록 직선으로 이어 붙일 수 있는 구간이 짧아 대역폭이 좁아진다
 - 표본 크기: 전체 관측치가 몇 개인지다. 많을수록 좁게 잘라도 쓸 사람이 남으므로 대역폭이 좁아진다
- 실습 코드(핵심 부분, 전체는 `5-2-bandwidth-selection.py`)

```
# 1단계: 전체 자료에 3차 곡선을 맞춰, 자료가 선 주위로 흩어진 정도(잡음) 측정
model_global = sm.OLS(y, sm.add_constant(x_poly3)).fit()
sigma_sq = np.var(model_global.resid)

# 2단계: 기준점 좌우에 2차 곡선을 맞춰, 휘어진 정도 측정
m2_left = 2 * model_left.params[2]
m2 = (abs(m2_left) + abs(m2_right)) / 2

# 3단계: 세 재료를 공식에 넣어 MSE가 가장 작아지는 폭 계산
# (C_K = 3.4375는 삼각 커널을 쓸 때 정해져 있는 상수)
h_opt = C_K * ((sigma_sq / (N * m2**2)) ** 0.2)
```

- 실행 결과(`results/5-2-bandwidth-selection.log` 발췌, 표기 정리)

IK 대역폭: 6.17 (잡음 17.67, 좌측 휘어짐 -0.0499, 우측 휘어짐 -0.0116)

폭을 정한 방법	폭	추정값	SE	95% 신뢰구간	MSE
IK 공식 (2012)	6.17	2.762	0.667	[1.45, 4.07]	1.44
눈대중: 표준편차 1배	8.37	2.738	0.583	[1.59, 3.88]	1.38
눈대중의 절반	4.18	2.579	0.787	[1.03, 4.13]	2.01
눈대중의 두 배	16.73	2.657	0.462	[1.75, 3.56]	1.43

가중치 규칙(커널)	추정값	SE
삼각 (멀수록 직선으로 줄임)	2.430	0.574
에파네치니코프 (곡선으로 줄임)	2.533	0.611
균등 (대역폭 안을 똑같이 쏘)	2.762	0.667

- 해석: IK 공식으로 계산한 6.17은 표준편차를 그대로 쓰는 눈대중 값 8.37보다 좁은데, 좌우 휘어짐 정보가 들어가면서 폭이 줄었다. 이 데이터에 심어 둔 참 효과는 3.76이며, 네 가지 폭에서 나온 추정값이 2.58~2.76에 모여 있어 폭 선택 때문에 결론이 뒤집히지는 않는다
- 좌우 휘어짐이 -0.0499와 -0.0116으로 4배 넘게 벌어진 점은 그냥 넘기지 않는다. 이 표본 규모에서는 휘어짐이 안정적으로 측정되지 않으므로, IK 대역폭 6.17도 소수점까지 믿을 값이 아니라 출발점으로 쓰는 값이다
- MSE 열을 참값 3.76 기준으로 읽으면 눈대중의 1.38이 IK의 1.44보다 오히려 낮다. 이론상 가장 좋은 폭을 겨냥한 공식이 표본 하나에서 눈대중에 밀리는 일은 드물지 않으므로, IK 값을 유일한 정답으로 보고하지 않고 여러 폭의 결과를 함께 신는다
- 커널은 기준점에 가까운 관측치에 더 큰 가중치를 주는 규칙이다. 삼각 커널은 기준점에서 멀어질수록 가중치를 직선으로 줄이고, 균등 커널은 대역폭 안의 모든 관측치를 똑같이 쓴다. 삼각 커널에서 2.43으로 가장 작은 값이 나온 이유는 기준점에 가장 가까운 자료 쪽으로 가장 많이 치우친 계산이기 때문이다

○ 판정 눈금

- 주 결과는 IK 대역폭으로 보고하고, 그 절반과 두 배로 다시 계산한 결과를 함께 실어 안정성을 보인다. 세 값의 부호가 같고 신뢰구간이 겹치면 그대로 보고한다 — 여기서는 겹치므로 보고한다
- IK 대역폭에서만 유의하고 절반에서 사라지면 잠정 결과로만 쓴다
- 커널을 바꿨을 때 추정값이 두 배 이상 달라지면, 좌우에 직선을 긋는 방식 자체부터 다시 점검한다. 여기서는 2.43~2.76 안에서 움직이므로 커널 세 종을 부록에 실는 선에서 마친다
- 실무 분석에서는 rdrobust 패키지를 쓴다. 폭을 자동으로 계산해 주고, 남은 빗나감을 보정한 신뢰구간까지 함께 내놓는다(Calónico et al., 2014)

한 줄 정리: 대역폭은 감이 아니라 잡음·휘어짐·표본 크기로 계산하고, 절반과 두 배에서도 결론이 버티는지 확인한다.

□ 5.3 타당성 검정 네 가지


- 기준점에서 점프를 보았다는 사실만으로는 효과를 말할 수 없다. 처치 말고도 점프를 만들 수 있는 원인이 세 가지 더 있기 때문이다
 - 사람들이 점수를 조정해 기준을 넘었다면, 기준점 위아래는 "운이 갈린 비슷한 사람"이 아니라 "넘으려 애쓴 사람과 그러지 못한 사람"이다
 - 기준점 위아래가 애초에 다른 사람들이었다면, 점프는 제도가 아니라 두 집단의 차이를 보여 준다
 - 실제 관계가 휘어 있는데 좌우에 직선을 그어 끊으면, 제도가 없어도 이음매에서 점프처럼 보이는 간격이 생긴다
- 네 검정의 원리는 하나로 같다. **효과가 진짜라면 일어나지 않아야 할 일**을 미리 정해 놓고, 그 일이 자료에 있는지 확인한다. 검정마다 겨누는 원인이 다르므로 하나로 다른 하나를 대신할 수 없다 (표 5-2)

<표 5-2: 네 검정이 각각 무엇을 겨누는가>

검정	무엇을 보는가	진짜라면	잡아내는 거짓 점프
밀도(McCrary)	기준점 좌우의 사람 수	사람 수가 이어진다	점수를 조정해 기준을 넘은 경우
공변량 균형	처치 전에 이미 정해진 변수	그 변수는 튀지 않는다	양쪽이 애초에 다른 사람들인 경우
가짜 기준점	기준점이 아닌 지점의 점프	거기서는 점프가 없다	곡선을 직선으로 끊어 생긴 점프
도넛홀	경계 바로 옆을 뺀 추정값	값이 그대로 버틴다	경계에 몰린 소수가 만든 점프

- 검정 1 — **McCrary 밀도 검정**: 점수를 조정해 기준을 넘은 사람이 있는지 본다(McCrary, 2008)
 - 원리: 아무도 점수를 조정하지 않았다면, 기준점 바로 아래에 있을 사람과 바로 위에 있을 사람의 수는 비슷하다. 반대로 넘으려는 움직임이 있었다면 아래쪽 사람이 위쪽으로 옮겨 가므로, 바로 아래는 비고 바로 위는 몰린다
 - 그래서 결과값이 아니라 **사람 수**를 센다. 기준점을 사이에 두고 사람 수가 끊기지 않고 이어지는지만 본다
 - 이 검정은 "사람 수가 이어진다"를 깨지 못해야 통과다. p값이 크게 나오는 쪽이 통과이고, 작게 나오면 그 자료로는 진행하지 않는다

그림 5-4. 결과가 아니라 사람 수를 세어 조작을 찾는다




○ 그림 5-4 읽는 법

- 왼쪽(조작 없음): 막대 높이(사람 수)가 기준점 50을 지나며 매끄럽게 이어진다
- 오른쪽(조작 있음): 기준점 바로 아래 막대가 꺼지고 바로 위 막대가 솟는다. 커트라인을 넘으려고 점수를 조정해 사람들이 만든 모양이며, 이런 자료로는 RDD를 진행하지 않는다

○ 검정 2 — 공변량 균형 검정: 기준점 위아래가 애초에 같은 사람들이었는지 본다

- 원리: 처치는 처치를 받은 다음에만 영향을 줄 수 있다. 나이·성별·교육연수처럼 처치 전에 이미 정해진 값은 제도가 바꿀 수 없으므로, 기준점에서 뿔 이유가 없다
- 그래서 결과 변수 자리에 이 사전 변수를 하나씩 넣고 5.1.3과 똑같은 회귀를 돌린다. 점프가 0 근처면 양쪽이 비슷한 사람들이라는 뜻이고, 점프가 나오면 두 집단이 처치 전부터 달랐다는 뜻이다
- 변수를 하나씩 보는 검정에 더해, 여러 변수를 한꺼번에 보는 결합 검정을 함께 돌린다. 변수 스무 개를 따로 검사하면 모두 멀쩡해도 우연히 한 개쯤 유의해지므로, 한 번에 보는 검정으로 받쳐 준다

그림 5-5. 처치가 바꿀 수 없는 변수는 기준점에서 이어져야 한다




○ 그림 5-5 읽는 법

- 세로축이 결과가 아니라 **처치 전에 측정한 나이**라는 점이 핵심이다. 결과 변수를 잠시 치워 두고 그 자리에 사전 변수를 넣은 그림이다
- 왼쪽(통과): 기준점에서 좌우 직선이 같은 높이로 만난다. 두 집단의 나이가 처치 전부터 같았다
- 오른쪽(불통과): 나이가 기준점에서 뒀다. 제도가 나이를 바꿀 수는 없으므로, 이 점프는 기준점 위아래가 다른 사람들이라는 증거이며 결과의 점프도 믿을 수 없다

○ 검정 3 — **플라시보 기준점 검정**: 제도가 바뀌지 않는 지점에서도 점프가 나오는지 본다

- 원리: 제도는 진짜 기준점에서만 바뀐다. 아무 일도 일어나지 않는 지점에서 같은 계산을 돌리면 점프가 0이어야 정상이다
- 그래서 진짜 기준점을 잠시 잊고, 40·45·55·60처럼 아무 일도 없는 지점을 가짜 기준점으로 삼아 같은 회귀를 돌린다
- 가짜에서도 점프가 나온다면, 그 점프를 만든 것은 제도가 아니라 좌우에 직선을 그어 끊은 방식이다. 진짜 기준점의 점프 역시 같은 이유로 생겼을 수 있으므로 효과로 보고하지 않는다

그림 5-6. 가짜 기준점에서도 점프가 나오면 처치효과가 아니다




○ 그림 5-6 읽는 법

- 점 하나가 그 지점에서 댄 점프이고, 세로 막대가 95% 신뢰구간이다. 가로선 0은 "점프가 없다"에 해당한다
- 왼쪽(통과): 노란 음영의 진짜 기준점에서만 구간이 0을 벗어나고, 가짜 네 곳은 구간이 0을 지난다
- 오른쪽(불통과): 가짜 45와 55에서도 구간이 0을 벗어났다. 이 자료에서는 점프가 제도와 무관하게 여기저기서 나오므로, 진짜 기준점의 값도 효과로 읽지 않는다

○ 검정 4 — **도넛홀 검정**: 경계에 바짝 붙은 소수가 결과를 만든 것은 아닌지 본다

- 원리: 점수를 조정해 기준을 넘었다면 그 사람들은 기준점 바로 옆에 몰려 있다. 그 구간을 통째로 빼고 다시 계산했을 때도 같은 값이 나오면, 결과가 경계의 소수에 매달려 있지 않다는 뜻이다
- 기준점 양옆을 ± 0.5 , ± 1.0 , ± 1.5 로 넓혀 가며 빼고, 그때마다 추정값이 어떻게 움직이는지 본다. 도넛의 가운데 구멍처럼 경계를 비운다고 해서 붙은 이름이다
- 쓰는 사람이 줄어드니 신뢰구간이 넓어지는 것은 정상이다. 보는 것은 구간의 폭이 아니라 추정값이 한 방향으로 계속 밀려가는지 여부다

그림 5-7. 기준점 바로 옆을 빼고도 값이 버티는지 본다



○ 그림 5-7 읽는 법

- 왼쪽: 회색으로 비운 구간이 계산에서 빠지는 사람들이다. 속이 빈 동그라미가 빠진 사람이고, 색이 찬 점만 다시 계산에 들어간다
- 오른쪽: 맨 왼쪽이 아무도 빠지 않은 원래 추정값이고, 오른쪽으로 갈수록 더 넓게 비운 결과다. 노란 띠는 원래 추정값의 신뢰구간이며, 나머지 세 구간이 이 띠와 겹치면 통과다
- 폭을 넓힐수록 값이 계속 내려가기만 한다면 경계 근처 관측치에 문제가 있다는 신호다

- 실습 코드(핵심 부분, 전체는 5-3-validity-tests.py)

McCrary: 기준점 좌우에서 사람이 몰린 정도를 각각 재어 차이를 검정한다

```
kde_left = gaussian_kde(left_data, bw_method=bandwidth/np.std(left_data))
kde_right = gaussian_kde(right_data, bw_method=bandwidth/np.std(right_data))
log_diff = np.log(density_right) - np.log(density_left)
se = np.sqrt(1/len(left_data) + 1/len(right_data))
t_stat = log_diff / se
```

○ 실행 결과(results/5-3-validity-tests.log 발췌, 표기 정리)

[McCrary] 좌측 밀도 0.0347 / 우측 밀도 0.0343 / $t = -0.156$ / $p = 0.876$

[공변량 균형] 연령 $p=0.918$, 성별 $p=0.659$, 교육연수 $p=0.966$, 소득 $p=0.983$

[결합 검정] $F = 0.640, p = 0.590$

[플라시보] 기준점 40: -0.30 (p=0.694) 45: -0.84 (p=0.188)

50(진짜): 2.94 ($p<0.001$) 55: -0.57 ($p=0.393$) 60: -1.41 ($p=0.062$)

[도넛홀] 제외 없음 2.94 / $\pm 0.5 \rightarrow 2.49$ (-15.5%) / $\pm 1.0 \rightarrow 2.40$ (-18.3%) / $\pm 1.5 \rightarrow 2.81$ (-4.4%)

- 해석: McCrary의 $p = 0.876$ 은 사람 수가 끊겼다는 증거가 없다는 뜻이다. 조작이 없음을 증명한 것이 아니라, 조작이 있었다면 걸렸을 장치에 걸리지 않았다는 정도로 읽는다
- 공변량은 변수별로도 한꺼번에 보아도 통과다. 플라시보는 진짜 기준점(2.94, $p < 0.001$)에서만 유의하고 가짜 네 곳은 모두 비유의하다
- 도넛홀에서는 추정값이 2.94에서 2.40까지 최대 18.3% 내려간다. 다만 변화가 한 방향으로 계속 가지 않고(-15.5 → -18.3 → -4.4) 표준오차가 0.60에서 0.87로 커진 것을 감안하면 신뢰구간들이 서로 겹친다. 기준점 옆 소수 관측치가 결과를 통째로 만든 것은 아니라고 보되, 변화 폭이 작지 않으므로 도넛홀 결과를 부록에 함께 싣는다

○ 판정 눈금

- McCrary가 기각되면($p < 0.05$) 그 자료로는 RDD를 진행하지 않는다. 조작이 불가능한 다른 기준점이나 다른 설계를 찾는다
- 공변량 결합 검정이 기각되면 그 변수를 통제한 결과와 안 한 결과를 나란히 보고하고, 둘이 크게 다르면 인과 해석을 유보한다
- 가짜 기준점에서 진짜와 같은 부호·비슷한 크기의 점프가 나오면 처치효과로 보고하지 않는다
- 도넛홀을 넓힐수록 추정값이 한 방향으로 계속 움직이면 기준점 근처 관측치에 문제가 있다는 신호이므로, 도넛홀 적용 값을 주 결과로 삼는다
- 네 검정 중 하나라도 불통과인 채로 효과를 단정해 적지 않는다

○ 판정 연습(가상의 수치다): 어느 소득 기준 급여 자료에서 McCrary $p = 0.003$ 이 나오고, 신청자 수가 기준점 바로 아래에서 급증했다면?

- 진행하지 않는다. 소득을 낮춰 신고한 움직임이 의심되는 자료이므로, 조작이 어려운 다른 기준(예: 연령 기준)이나 다른 설계로 바꾼다

한 줄 정리: 네 검정은 "효과가 진짜라면 없어야 할 일"을 각각 다른 각도에서 확인한다. 네 개 모두 통과해야 보고한다.

□ 1부 정리

- 지금까지 만든 것 네 가지: 용어 네 개를 자료 옆에 대응시킨 설계표, 국소선형회귀 추정치 3.51과 신뢰구간 [1.94, 5.08], 자료에서 계산한 대역폭 6.17, 타당성 검정 4종의 판정표
- 확인한 판정 기준
 - 대역폭을 절반·두 배로 바꿔도 부호가 유지되고 신뢰구간이 겹쳐야 한다
 - McCrary·공변량·플라시보·도넛홀 네 검정을 모두 통과해야 하며, McCrary 기각이면 그 자료는 버린다
 - R^2 가 낮다는 이유로 모형을 바꾸지 않고, SE가 작다는 이유로 넓은 대역폭을 고르지 않는다
- 2부로 넘길 질문: 기준을 넘어도 처치를 안 받는 사람이 섞이면 어떻게 보정하나(5.4), 공변량이 수십 개면 어떻게 걸어 내나(5.5), 효과가 사람마다 다르면 누구에게 주나(5.6), 기준선이 지도 위의 선이면 어떻게 하나(5.7)

2부. 설계를 확장하고 결론의 범위를 정한다


□ 2부 개요

- 이 파트가 끝나면: 불완전 순응(퍼지 RDD), 고차원 공변량(이중 기계학습), 하위 집단별 이질성(CATE), 지리적 경계까지 다룬 확장 추정치를 얻고, 각 숫자를 어느 범위까지 결론 문장에 옮겨도 되는지 판정할 수 있다
- 다루는 절: 5.4 ~ 5.8

□ 5.4 퍼지 RDD — 점프를 점프로 나눈다

- 청년 지원 사업이 만 34세를 기준으로 두어도, 이하인데 몰라서 신청 안 하는 사람과 초과인데 예외로 참여하는 사람이 있다. 기준점 통과가 처치를 결정하지 않고 처치 **확률**만 올리는 상황이며, 이것이 **퍼지 RDD**다(Hahn et al., 2001)
 - 이때 1부의 방법을 그대로 쓰면 효과가 축소된다. 기준점 위 집단의 절반만 참여했는데 전원이 참여한 것처럼 계산하기 때문이다

그림 5-2. Sharp와 Fuzzy의 차이는 세로 점프 폭 하나다



○ 그림 5-2 읽는 법

- 세로축이 결과가 아니라 **처치받을 확률**이다. 왼쪽(Sharp)은 기준점에서 확률이 0에서 1로 완전히 된다(점프 폭 = 1)
- 오른쪽(Fuzzy)은 확률이 0.14 근처에서 0.62 근처로만 된다(점프 폭 < 1). 기준 미달인데 받는 사람(파란 선이 0보다 위)과 기준을 넘겼는데 안 받는 사람(빨간 선이 1보다 아래)이 있기 때문이며, 이 점프 폭이 아래에서 말하는 1단계 계수다

○ 보정은 나눗셈 하나다: 결과의 점프 ÷ 처치 확률의 점프

- 예를 들어 결과가 1.0 튀었고 처치 확률이 0.5 튀었다면, 실제로 처치를 받은 사람 기준의 효과는 $1.0 \div 0.5 = 2.0$ 이다
- 분자(결과의 점프)는 기준점을 넘었다는 사실 자체의 효과이며 **ITT**(의도된 처치효과)라 부른다.
나눈 값은 기준을 넘었기 때문에 참여한 사람들, 곧 **순응자**에 대한 효과이며 **LATE**라 부른다
- 이 계산이 성립하려면 세 가지가 필요하다: 기준점에서 처치 확률이 실제로 될 것(관련성), 기준점 통과가 오직 처치를 통해서만 결과에 영향을 줄 것(배제제약), 기준을 넘어서 오히려 처치를 안 받게 되는 사람이 없을 것(단조성)
- 실습 코드(핵심 부분, 전체는 5-4-fuzzy-rdd.py)

```
# 1단계: 실제 처치 D를 기준점 통과 여부 Z에 회귀 → 확률의 점프
first_stage = smf.ols('treatment ~ above_cutoff + score_centered + above_score',
                      data=near_cutoff).fit()
f_stat = first_stage.tvalues['above_cutoff'] ** 2 # 1단계 F통계량

# LATE = 결과의 점프(ITT) ÷ 처치 확률의 점프
late = itt_estimate / first_stage.params['above_cutoff']
late_se = itt_se / abs(first_stage.params['above_cutoff'])
```

- 실행 결과(results/5-4-fuzzy-rdd.log 발췌)

1단계 (First Stage): 배정 지시자 계수 0.485, F-통계량 49.70 → 강한 도구변수
 축약형 (ITT): 1.380 (SE 0.722, p = 0.0566)
 Fuzzy RDD (LATE): 2.847 (SE 1.490, 95% CI [-0.073, 5.768])

순응 패턴: 순응자 48.5% / Always-taker 13.2% / Never-taker 38.3%

- 해석: 1단계 계수 0.485는 기준점을 넘으면 처치 확률이 48.5%포인트 오른다는 뜻이고, $F = 49.70$ 은 이 관계가 충분히 강하다는 신호다. LATE 2.847이 ITT 1.380의 약 두 배인 것은 나눗셈에서 그대로 따라 나온다($1.380 \div 0.485 = 2.847$)
- 표준오차가 0.722에서 1.490으로 커진 점도 함께 읽는다. 분모에 추정값이 들어가 불확실성이 하나 더 쌓였기 때문이며, 여기서는 LATE의 신뢰구간이 0을 포함해 효과를 단정하지 못한다
- 판정 눈금
 - **1단계 F통계량이 10 미만이면 2단계(LATE)를 보고하지 않는다.** 도구가 약하면 LATE의 분산이 폭발하고 편향도 심해지므로, ITT만 보고하거나 설계를 다시 짤다. 여기서는 49.70이므로 진행한다
 - LATE를 보고할 때는 반드시 대상을 함께 적는다: "기준을 넘었기 때문에 참여한 48.5%에 대한 효과". 전체 대상자의 효과로 옮겨 적으면 과대 보고다
 - 참여를 강제할 수 없는 제도라면 실제로 관측될 값은 ITT 쪽이다. 정책 확대 검토에는 LATE를, 제도의 총량 효과에는 ITT를 쓴다
- 판정 연습(가상의 수치다): 1단계 F가 6.4이고 LATE가 8.2($p = 0.03$)로 나왔다면?

- LATE 8.2는 보고하지 않는다. $F < 10$ 이므로 약한 도구이며, 유의해 보이는 p값 자체를 믿을 수 없다. 보고할 수 있는 값은 ITT뿐이다

한 줄 정리: 결과의 점프를 확률의 점프로 나눈다. 단, $F < 10$ 이면 나눈 값을 버리고, 나눈 값은 순응자의 효과로만 적는다.

□ 5.5 이중 기계학습(DML)을 결합한 RDD

- 대역폭 안에 수백 명이 들어오면 그 안에서도 특성 분포가 어긋날 수 있다. 공변량이 수십 개이고 결과와의 관계가 곡선이면, 회귀식에 변수를 그냥 추가하는 방식으로는 이 어긋남을 다 견어 내지 못한다
- **이중 기계학습**(Double Machine Learning, DML)은 결과와 처치를 각각 공변량으로 예측한 뒤, 예측에서 벗어난 부분(잔차)끼리만 비교한다(Chernozhukov et al., 2018)
 - 공변량으로 설명되는 부분을 양쪽에서 미리 덜어 내므로, 남은 부분에는 공변량의 영향이 거의 남지 않는다
 - 자료를 5조각으로 나눠 4조각으로 모형을 학습하고 남긴 1조각에서만 잔차를 계산하는 **교차 적합**을 쓴다. 기계학습 모형이 학습 자료를 외워 버려 생기는 편향을 막는 장치다
- 실습 코드(핵심 부분, 전체는 5-5-dml-rdd.py)

```
for train_idx, test_idx in kf.split(near_cutoff):          # 5-fold 교차 적합
    rf_outcome = RandomForestRegressor(n_estimators=200, max_depth=15,
                                       min_samples_leaf=5, random_state=42, n_jobs=-1)
    rf_outcome.fit(train_data[covariates_cols], train_data['outcome'])
    rf_treat = RandomForestRegressor(n_estimators=200, max_depth=10,
                                    min_samples_leaf=5, random_state=42, n_jobs=-1)
    rf_treat.fit(train_data[covariates_cols], train_data['treat'])

    # 학습에 쓰지 않은 조각에서 잔차를 계산해 잔차 대 잔차로 효과 추정
    y_res = test_data['outcome'].values - rf_outcome.predict(test_data[covariates_cols])
    d_res = test_data['treat'].values - rf_treat.predict(test_data[covariates_cols])
    theta = np.sum(y_res * d_res) / np.sum(d_res ** 2)
```

- 실행 결과(results/5-5-dml-rdd.log 발췌 — 참 효과 3.5, 공변량 25개, 유효 표본 1,826)

방법	추정값	SE	편향	MSE	참값 포함
전통 RDD (공변량 없음)	5.562	0.621	2.062	4.637	아니오
선형 공변량 조정 (5개)	3.681	0.233	0.181	0.087	예
DML-RDD (Random Forest)	3.757	0.116	0.257	0.079	아니오
DML-RDD (Gradient Boosting)	3.602	0.113	0.102	0.023	예

변수 중요도 1위: pre_outcome 0.870 / 결과 모형 R^2 0.949 / 처치 모형 R^2 0.615

- 해석: 이 데이터에는 기준점 근처 공변량 불균형을 일부러 심어 두었다. 전통 RDD는 그 불균형을 견여 내지 못해 5.562를 내놓아 2.062만큼 위로 빗나갔고, 신뢰구간도 참값 3.5를 놓쳤다
- 그라디언트 부스팅 DML은 편향 0.102, MSE 0.023으로 가장 정확했고, SE도 0.621에서 0.113으로 줄었다. 랜덤 포레스트 쪽은 편향 0.257이 남아 좁아진 신뢰구간 [3.530, 3.984]가 참값을 아슬아슬하게 놓쳤다 — 구간이 좁아질수록 남은 편향이 포함 여부를 가르기 쉬워진다
- 변수 중요도 0.870을 차지한 사전 결과 변수가 불균형의 주된 통로다. 처치 이전에 켜 같은 변수가 이후 결과를 가장 잘 예측하기 때문이다

○ 판정 눈금

- 공변량 균형 검정을 먼저 돌린다. 균형이면 DML을 쓸 이유가 약하므로 전통 추정과 선형 조정으로 충분하다
- 전통 추정·선형 조정·DML 세 값을 나란히 놓는다. 비슷하면 어느 것을 주 결과로 삼아도 되고, 크게 다르면(여기서는 5.56 대 3.6대) 그 차이의 원인을 찾기 전에 결론을 적지 않는다
- SE가 줄었다는 이유만으로 DML을 고르지 않는다. 좁은 구간은 편향이 남아 있을 때 오히려 잘못된 결론을 굳힌다
- 실무에서는 DoubleML 패키지나 RDFlex 구현체(Noack et al., 2024)를 쓰고, 사용한 모형과 폴드 수를 보고서에 적는다

한 줄 정리: 공변량이 많고 균형이 깨졌으면 잔차 대 잔차로 켜. 단, 세 방법의 값이 왜 다른지 설명하지 못하면 보고하지 않는다.

□ 5.6 이질적 처치효과 — 평균 하나로 배분을 정하지 못한다

- 지금까지 얻은 값은 기준점 근처 사람들의 평균이다. 예산이 한정되어 전원을 지원할 수 없다면, 평균이 아니라 **누구에게 효과가 큰지**를 알아야 배분을 정할 수 있다
 - 특성이 같은 사람들로 좁혀서 켜 효과를 **조건부 평균처치효과(CATE)**라 부른다. RDD에서는 이미 기준점 근처로 표본을 좁혀 놓았는데 하위 집단으로 또 나누면 조각마다 표본이 적어지므로, 추정이 쉽지 않다
- 이 실습이 쓰는 **T-학습기**는 구조가 단순하다: 처치군과 대조군에 각각 예측 모형을 학습시키고, 같은 사람에 대한 두 예측값의 차이를 그 사람의 효과로 삼는다. 비교 대상으로 상호작용 선형 회귀와 인과 포레스트 근사(랜덤 포레스트)도 함께 돌린다

○ 실습 코드(핵심 부분, 전체는 5-6-cate-rdd.py)

```
model_1 = GradientBoostingRegressor(n_estimators=200, max_depth=3,
                                    learning_rate=0.1, random_state=42)
model_1.fit(treated[covariates], treated['outcome'])    # 처치군 모형
model_0 = GradientBoostingRegressor(n_estimators=200, max_depth=3,
                                    learning_rate=0.1, random_state=42)
model_0.fit(control[covariates], control['outcome'])    # 대조군 모형

# 같은 사람에 대한 두 예측값의 차이 = 그 사람의 CATE
near_cutoff['cate_tlearner'] = (model_1.predict(near_cutoff[covariates]) -
                               model_0.predict(near_cutoff[covariates]))
```

○ 실행 결과(results/5-6-cate-rdd.log 발췌 — 참 CATE 평균 6.37, 유효 표본 1,110)

[하위 집단별 CATE (T-학습기)]	평균	참값	N
사건 성과 하위 33%	5.04	5.18	370
사건 성과 중위 34%	6.07	6.22	370
사건 성과 상위 33%	7.28	7.63	370

[대상 선정 시뮬레이션]	대상 비율	평균 효과	총 효과	효율성
전원 지원	100%	6.13	6,804	1.00
CATE 상위 50%	50%	7.89	4,381	1.29
CATE 상위 25%	25%	9.31	2,578	1.52

[방법 비교] 인과 포레스트 RMSE 1.04 / 선형 상호작용 1.16 / T-학습기 1.47

- 해석: 상위 집단의 효과(7.28)가 하위 집단(5.04)보다 약 44% 크다. 평균 6.13 하나만 보고하면 이 차이가 통째로 가려진다. 세 집단의 추정값이 참값(5.18 / 6.22 / 7.63)과 같은 순서로 늘어선 점이 이질성 추정의 신뢰를 뒷받침한다
- 효율성 1.52는 상위 25%에게만 지원하면 대상자 1인당 평균 효과가 전체 평균의 1.52배라는 뜻이다. 다만 총 효과는 6,804에서 2,578로 준다 — 대상 인원 자체가 4분의 1이기 때문이며, 이 표는 예산이 고정된 배분 판단에 쓰는 것이지 총량을 늘리는 방법이 아니다
- 방법 비교에서는 인과 포레스트의 RMSE(개인별 참 효과와의 평균 오차)가 1.04로 가장 작고 T-학습기가 1.47로 가장 크다. T-학습기는 두 모형을 따로 학습해 잡음이 겹쳐 쌓이기 때문이다

○ 판정 눈금

- 하위 집단 CATE의 범위가 평균값에 견줄 만큼 넓으면 평균만 보고하지 않고 하위 집단 표를 함께 신는다
- 하위 집단 표본이 수십 개 수준이면 그 값은 참고용으로만 쓰고 배분 근거로 삼지 않는다

- 방법 두세 가지의 CATE 순위가 서로 크게 다르면 이질성 추정 자체를 믿지 않는다. 순위가 대체로 일치할 때만 대상 선정에 쓴다
- 효과가 큰 집단에 집중하는 결정은 형평성 판단과 함께 적는다. 사전 성과가 높은 쪽에 효과가 물린 자료에서 상위 집단만 지원하면 격차가 벌어지므로, 효율성 수치 하나로 배분을 확정하지 않는다

한 줄 정리: 평균 6.13 뒤에 5.04와 7.28이 숨어 있다. 배분을 정하려면 하위 집단 표까지 보되, 형평성 단서를 함께 적는다.

□ 5.7 지리적 RDD — 기준선이 숫자가 아니라 선일 때

- 투기과열지구 지정, 특정 시·군에만 시행되는 사업, 학군 경계처럼 지도 위의 선을 사이에 두고 제도가 달라지는 경우가 많다
 - 경계선까지의 거리를 배정변수로 쓰면 RDD를 그대로 적용할 수 있다. 이것이 **지리적 RDD**다(Keele & Titiunik, 2015). 경계선 바로 양쪽 동네는 붙어 있어 주민 구성이 비슷하지만 적용되는 제도만 다르다
- 한 가지가 더 붙는다: 경계선을 **따라가는** 방향의 추세를 통제해야 한다
 - 이 실습 자료는 남북 경계선(위도 5.0)으로 처치가 갈리는데, 결과가 동서 방향(경도)으로도 체계적으로 변하게 만들어져 있다. 경도를 통제하지 않으면 그 추세가 경계선의 점프에 섞여 든다
- 실습 코드(핵심 부분, 전체는 5-7-geographic-rdd.py)

```
cutoff = 5.0

data['dist_lat'] = data['latitude'] - cutoff      # 배정변수: 경계선까지의 거리
data['treat'] = (data['dist_lat'] >= 0).astype(int)

bandwidth = 2.0                                # 경계선 ±2.0만 남긴다
df_near = data[abs(data['dist_lat']) <= bandwidth].copy()

# 경계선을 따라 이동할 때의 변동(경도)을 함께 통제한다
model_grdd = smf.ols('outcome ~ treat + dist_lat + treat:dist_lat + longitude',
                     data=df_near).fit()
```

- 실행 결과(results/5-7-geographic-rdd.log 발췌 — 참 효과 5.0, 유효 표본 397)

treat	4.6066	(SE 0.396, t = 11.63)	95% CI [3.828, 5.385]
dist_lat	2.4549	(SE 0.241)	
longitude	1.5079	(SE 0.034, t = 44.74)	

- 해석: 추정 효과 4.61은 참값 5.0을 신뢰구간 안에 담았다. 경도 계수 1.51이 $t = 44.74$ 로 매우 강하게 유의한데, 이 자료에 동서 방향 추세가 실제로 들어 있고 그 추세를 통제했기 때문에 경계선의 점프를 제대로 짚 수 있었다는 뜻이다. 경도 항을 빼면 이 추세가 처치효과 쪽으로 흘러든다

○ 판정 눈금

- 경계선을 따라가는 방향의 공변량·결과 추세가 있는지 먼저 확인하고, 있으면 경도(또는 경계 구간 고정효과)를 반드시 넣는다
- 경계선 근처 인구 밀도의 불연속을 McCrary 검정으로 확인한다. 혜택을 찾아 경계 안쪽으로 이주하는 움직임이 있으면 전제가 깨진다
- 경계선이 강·산맥을 따라 그어졌으면 이 설계를 쓰지 않는다. 지형이 결과에 직접 영향을 줘 연속성이 성립하지 않는다
- 가까운 지역끼리 결과가 닮는 공간 자기상관 탓에 통상 표준오차는 실제보다 작게 나온다. 표준오차를 공간 구조를 반영해 다시 계산한다

한 줄 정리: 경계선까지의 거리로 재되, 경계선을 따라가는 추세와 이주 가능성부터 확인한다.

□ 5.8 한국 제도 적용과 보고 문장의 범위

○ 한국 제도는 자격을 숫자 하나로 끊는 방식이 많아 RDD의 재료가 풍부하다

- 기초연금의 만 65세, 청년 지원의 만 34세, 소득 분위 기준 장학금·복지 급여, 점수 기준 전형이 후보다. 기업 자료에서도 신용 점수 컷오프, 무료 배송 기준 금액, 회원 등급 기준선이 같은 구조다

○ 자주 걸리는 세 가지 문제

- 기준점이 흐릿하다: 예외 조항이 여러 겹이거나 실무 재량이 개입하면 자료상 기준점과 실제 배정이 어긋나 배정변수를 특정할 수 없다
- 조작 가능성이 남아 있다: 소득 기준 급여에서 자영업자의 신고 소득이 대표적이며, 이런 자료에서는 McCrary 검정이 기각되기 쉽다. 기각되면 그 기준점으로는 분석하지 않는다
- 기준점 근처 표본이 부족하다: 기초자치단체 사업은 대역폭 안에 수십 명만 들어오는 일이 흔하고, 신뢰구간이 넓어져 효과 유무를 가리지 못한다. 여러 해·여러 지역을 합치거나 다른 설계를 쓴다


○ 숫자를 보고서 문장으로 옮길 때 지킬 범위

- 추정 효과는 기준점 근처 사람들의 값이다. "대상자 전체의 결과를 3.51 올린다"가 아니라 "기준점 언저리 대상자의 결과를 3.51 올린다"로 적는다
- 퍼지 설계의 값은 순응자의 값이다. 대상을 밝히지 않은 채 LATE를 전체 효과처럼 적지 않는다
- 진단 검정은 통과 여부만 적지 않고 통계량과 p값을 함께 싣는다. 통과했다는 서술만으로는 독자가 다시 판정할 수 없다
- 대역폭·커널을 무엇으로 정했는지, 바꿨을 때 결과가 어떻게 움직였는지 부록에 남긴다
- 참고로 미국 What Works Clearinghouse(2022)는 잘 설계된 RDD를 준실험 증거의 상위 등급으로 인정하고, 영국 재무부 Magenta Book(2020)은 적용 조건과 보고 항목을 지침으로 둔다. 두 문서 모두 추정치보다 대역폭·진단·보고 범위를 기준으로 삼는다

한 줄 정리: 효과의 숫자보다 "누구에 대한 효과인가"를 먼저 적는다.

□ 결과를 읽는 순서

그림 5-8. RDD 분석 순서



- 그림 5-8 읽는 법: 위에서 아래로 관문을 통과하는 순서이며, ②(공변량)와 ⑤(플라시보·도넛홀)를 건너뛴 추정값은 보고서에 실지 않는다
- RDD 분석의 산출물은 다음 순서로 읽는다
 - 1순위 **밀도(McCrory)**: 기준점 근처에 사람이 몰렸으면 뒤의 숫자는 읽지 않고 멈춘다
 - 2순위 **공변량 균형**: 사전 변수가 기준점에서 점프하는지 변수별·결합으로 확인한다
 - 3순위 **대역폭**: 자료에서 계산한 값과 그 절반·두 배에서 추정값이 버티는지 본다
 - 4순위 **설계 갈래**: 기준점에서 처치가 전원 바뀌면 Sharp, 일부만 바뀌면 Fuzzy로 가고 1단계 F부터 확인한다
 - 5순위 **효과와 신뢰구간**: 앞의 관문을 통과한 뒤에야 효과 크기를 읽고, 플라시보·도넛홀로 되짚는다

□ 실무 적용 점검표

- 자격을 가르는 숫자 기준이 문서로 확정되어 있는가? 실무 재량이 개입하면 기준점을 특정할 수 없다
- 배정변수가 연속적으로 측정되어 있는가? 등급처럼 몇 개 값만 갖는 변수로는 기준점 근처를 좁힐 수 없다

- 기준점 좌우의 실제 처치 수혜율을 계산해 Sharp와 Fuzzy를 갈랐는가?
- 대역폭을 자료에서 계산하고, 절반·두 배에서도 추정했는가?
- McCrary·공변량 균형·플라시보·도넛홀 네 검정을 모두 돌리고 결과를 표로 남겼는가?
- 퍼지 설계라면 1단계 F통계량이 10을 넘는가? 넘지 않으면 LATE를 보고하지 않는다
- 기준점 근처 공변량 불균형이 있으면 이중 기계학습을 병행하고 세 방법의 값을 비교했는가?
- 하위 집단별 효과가 크게 갈리면 평균과 함께 하위 집단 표(표본 크기 포함)를 실었는가?
- 결론 문장에 효과의 대상 집단(기준점 근처, 순응자)과 적용 범위를 명시했는가?

□ 핵심 정리

방법	핵심 계산	쓰는 상황	판정 기준
Sharp RDD	기준점에서의 수직 점프	기준을 넘으면 전원이 처치받을 때	신뢰구간이 0을 포함하지 않는가
IK 대역폭	편향 ² +분산 최소화 폭	대역폭의 근거가 필요할 때	절반·두 배에서도 부호가 유지되는가
타당성 검정 4종	밀도·균형·플라시보· 도넛홀	항상	네 검정이 모두 통과했는가
Fuzzy RDD	결과 점프 ÷ 처치 확률 점프	자격이 있어도 참여하지 않을 때	1단계 F가 10을 넘는가
DML-RDD	잔차 대 잔차 + 교차 적합	공변량이 많고 불균형이 있을 때	세 방법의 추정값이 수렴하는가
CATE	특성별 효과의 차이	예산 제약 아래 배분을 정할 때	방법 간 순위가 일치하는가
지리적 RDD	경계선까지의 거리로 추정	제도가 구역 단위로 갈릴 때	공간 추세를 통제했는가

- 이 장의 판정 규칙 세 가지
 - **McCrary** 기각이면 그 자료를 버린다. 조작된 커트라인 위의 점프는 효과가 아니다
 - **F 10 미만이면 LATE를 버리고 ITT만 보고한다.** 약한 도구로 나눈 값은 유의해 보여도 믿을 수 없다
 - **효과에는 항상 대상을 붙인다.** 기준점 근처 사람들, 순응자 48.5% — 대상 없는 효과 숫자는 과대 보고의 시작이다