6장. 내생성과 도구변수 — 2SLS에서 DeepIV까지

□ 이 장의 질문

○ 예를 들어 헬스장 회원권을 끊은 사람들이 1년 뒤 평균 4kg 더 빠졌다고 하자(가상의 수치다). "회원권의 효과는 4kg"이라고 보고해도 될까

○ 이 장의 답도 "안 된다"이다. 회원권을 끊는 사람은 원래 건강에 관심이 많고, 그 관심은 식단과 수면에도 영향을 주므로, 4kg 안에는 회원권의 효과와 원래 성향의 효과가 섞여 있다

○ 3장의 매칭은 나이·소득처럼 **데이터에 있는** 특성을 맞춰 이 문제를 풀었다. 그런데 "건강 관심도"는 데이터에 아예 없다. 관측되지 않는 원인이 섞였을 때 효과를 재는 도구가 이 장의 주제, **도구변수**다

□ 이 장을 읽는 방법

○ 이 장은 두 파트로 나뉜다

– 1부(6.1~6.3): 숨은 원인이 회귀 계수를 얼마나 비트는지 숫자로 확인하고, 도구변수의 세 조건을 점검한 뒤, 2단계 최소제곱(2SLS)으로 첫 추정치와 제출용 결과표를 만든다

– 2부(6.4~6.9): 그 추정치를 믿어도 되는지 진단하고(F통계량), 그 숫자가 누구의 효과인지 해석하며(LATE), 관계가 곡선일 때의 확장(다항항·DeepIV 계열)과 집단별 효과·정책 연결까지 다룬다

○ 용어 미리보기 — 본문에서 처음 나올 때마다 다시 풀어 설명하므로, 여기서는 눈에 익히기만 하면 된다

용어	쉬운 뜻
OLS(보통 회귀)	변수 사이 관계를 직선 하나로 요약해 “하나 늘면 얼마 변하나”를 구하는 기본 계산법
내생성	처치를 정한 숨은 이유가 결과에도 영향을 줘서, 회귀 계수에 그 이유의 몫이 섞이는 상태
도구변수(Z)	처치는 움직이지만, 결과에는 처치를 거쳐서만 닿는 제3의 변수
2단계 최소제곱(2SLS)	도구변수로 처치의 “깨끗한 부분”을 골라내고(1단계), 그 부분만으로 효과를 재는(2단계) 방법
관련성	도구변수가 처치를 실제로 움직인다는 조건. 셋 중 유일하게 데이터로 검증된다
배제제약	도구변수가 처치를 거치지 않고는 결과에 닿지 않는다는 조건
F통계량	도구변수가 처치를 얼마나 확실히 움직이는지 잰 숫자. 실무 기준선은 10
약한 도구변수	F가 10 미만인 상태. 이때의 추정치는 OLS보다 나쁠 수 있다
강건 표준오차	오차의 흩어짐이 고르지 않아도 버티도록 계산한 표준오차
LATE·순응자	도구변수 때문에 행동이 바뀐 사람(순응자)들의 평균 효과. 2SLS가 실제로 재는 값
RESET 검정	”직선 가정이 맞는가”를 데이터로 검사하는 절차
CATE	집단(또는 사람)마다 따로 잰 평균 처치효과

1부. 내생성을 확인하고 2SLS로 첫 추정치를 만든다

□ 6.1 내생성 — 회귀 계수가 어긋나는 조건

○ 같은 구조의 문제가 정책과 비즈니스 곳곳에 있다

– 학원 수강 → 성적(숨은 원인: 학습 동기), 직업훈련 → 취업률(구직 의지), 대학 졸업 → 임금(능력·가정 배경). 셋 다 처치(D)를 고른 이유가 결과(Y)에도 따로 영향을 준다

○ **내생성**(endogeneity)의 정의는 한 줄이다 — 회귀식에 넣은 처치 D가 **그 식의 오차와 상관된 상태**다. “숨은 원인이 있다”는 설명은 정의가 아니라 그 상태를 만드는 경로 하나를 말한 것이다

– 회귀식을 `Y = β × D + 오차`로 쓸 때, 오차에는 Y를 움직이는 나머지 전부가 들어간다. 키·날씨·의지처럼 식에 적지 않은 것이 모두 여기에 들어간다

– D와 오차가 서로 무관하면 D를 1 늘렸을 때 오차는 평균적으로 그대로 있고, 그래서 Y가 변한 몫이 곧 β다

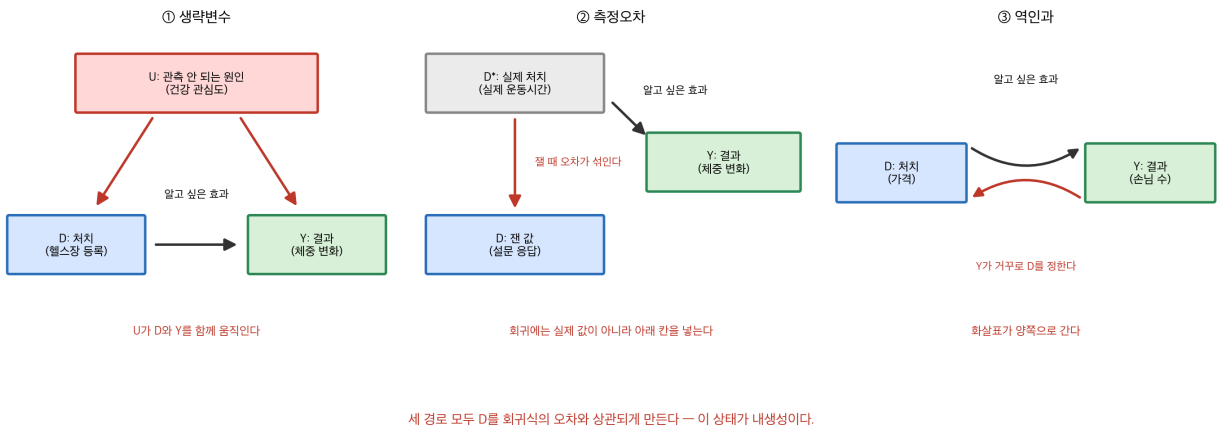
– D와 오차가 상관되면 D를 1 늘릴 때 오차도 같이 움직이므로, 회귀는 오차가 움직인 몫까지 β에 더해 보고한다. 추정값은 “D의 효과 + 오차가 같이 움직인 몫”이 되고, **표본을 늘려도 이 몫은 줄지 않는다**

○ 이 상관이 생기는 경로가 세 가지다 (표 6-1). 셋은 겉모습이 다르지만 D와 오차를 붙여 놓는다는 결과는 같다

<표 6-1: 내생성이 생기는 세 경로>

경로	무엇이 문제인가	왜 D가 오차와 상관되는가	일상 예
생략변수	관측 못 한 원인 U가 D와 Y를 둘 다 움직임	U를 식에 못 넣어 오차 안에 들어가는데, 그 U가 D도 움직인다	건강 관심도가 헬스장 등록과 체중을 동시에 좌우
측정오차	실제 처치가 아니라 잘못 잰 값을 씀	잰 값 = 실제 값 + 오차이므로, 잴 때 생긴 오차가 회귀 오차로 넘어가 잰 값과 붙는다	설문에서 “주당 운동시간”을 부풀려 답함
역인과	Y가 거꾸로 D를 정함	Y를 흔든 오차가 Y를 거쳐 D까지 전달된다	손님이 몰리는 식당이 가격을 올림

그림 6-1. 내생성이 생기는 세 경로



○ 그림 6-1 읽는 법: 세 칸이 표 6-1의 세 줄과 같은 순서다. 왼쪽 칸은 빨간 U에서 화살표가 두 개 나가고, 가운데 칸은 실제 값이 아니라 잰 값이 회귀에 들어가며, 오른쪽 칸은 D와 Y 사이에 화살표가 양쪽으로 간다

– 세 칸의 모양은 다르지만 아래 한 줄은 같다. 어느 경로든 D가 오차와 상관되고, 그 순간 회귀 계수는 효과가 아닌 값을 보고한다

○ 이 장이 다루는 것은 셋 중 **생략변수** 경로다. 뒤의 실습과 그림은 모두 이 경로를 가정하고 만들었으며, 측정오차와 역인과도 같은 도구변수로 다루지만 필요한 가정이 조금씩 다르다

○ 편향의 크기는 곱셈 하나로 나온다: **(U가 Y를 바꾸는 크기) × (D가 U와 붙어 있는 정도)**

– 이 장의 실습 데이터(1,000명)는 참 효과를 3.42로 심어 두었고, 현실에서는 볼 수 없는 U도 채점용으로 들어 있다. 그래서 이 곱셈을 직접 확인할 수 있다

- U를 넣고 돌린 회귀에서 U의 계수는 -1.946, U를 D에 회귀한 계수는 0.625다. 곱하면 -1.946 × 0.625 = -1.216 — 편향이 이만큼 생길 것이라는 예측이다
- 어긋나는 방향도 부호의 곱으로 정해진다. 이 데이터에서 D와 U의 상관은 +0.527로 양수인데 U가 Y를 낮추는 쪽(-1.946)이라 곱이 음수이고, 추정값은 참값 아래로 내려간다. 부호가 같으면 위로, 다르면 아래로 어긋나므로, 내생성을 확인한 것만으로는 추정값이 참값보다 큰지 작은지 말할 수 없다

○ 실습 — U 없이 그냥 돌린 OLS가 얼마나 어긋나는지 확인한다 (전체 코드 `6-1-traditional-2sls.py`, 로그 `results/6-1-traditional-2sls.log`)

```
df = pd.read_csv('../data/6-1-iv-data.csv')             # 참값 3.42를 심은 데이터
ols_model = smf.ols('Y ~ D + X1 + X2', data=df).fit()  # U 없이 그냥 회귀 (편향)
```

```
샘플 크기: 1000
참값 인과효과: 3.42
내생성 상관: Corr(D, U) = 0.527

[2단계] OLS 추정 (편향된 결과)
OLS 추정값: 2.171 (SE: 0.065)
참값과의 차이: -1.249 (-36.5%)
95% CI: [2.043, 2.298]
```

- 판정: 실측 편향 -1.249가 곱셈 예측 -1.216과 거의 일치한다. 편향은 우연이 아니라 계산되는 값이다

○ 더 위험한 사실: OLS는 오류 신호를 내지 않는다. 표준오차 0.065, p값 0.000까지 전부 정상으로 나오는데 값만 36.5% 어긋나 있다

- 구조는 눈금이 어긋난 체중계와 같다. 또렷한 눈금이 작은 표준오차에, 열 번 재도 같은 값이 좁은 신뢰구간에, 고장 표시등 없음이 경고 없음에, 분동을 올려야 오차가 드러나는 것이 도구변수에 대응한다. 다만 실제 연구에서는 참값(분동)을 모르므로 편향을 직접 재서 고칠 수 없고, 애초에 편향이 섞이지 않은 변동만 골라 쓴다

한 줄 정리: 내생성은 D가 회귀식의 오차와 상관된 상태이며, 이때 회귀는 "효과 + 섞인 몫"을 효과라고 보고하고 경고는 내지 않는다.

□ 6.2 도구변수 — 처치의 깨끗한 부분만 골라 쓴다

○ D 전체는 믿을 수 없지만 통째로 버릴 필요는 없다. **D 안에서 U와 무관하게 움직인 부분만** 골라내면 되고, 그 부분을 골라내는 장치가 **도구변수(Z)** 다

– 헬스장 예에서, 집에서 헬스장까지의 거리는 등록 여부를 움직이지만 그 사람의 건강 관심도와는 무관하게 정해진 조건이다. “가까워서 등록한” 만큼의 변동은 U가 섞이지 않은 깨끗한 변동이다

○ 도구변수로 효과를 재는 계산은 나눗셈 하나다. 20명이면 손으로 끝까지 셀 수 있으므로, 조건을 따지기 전에 숫자부터 확인한다

– 앱 설정: 이 앱은 **무료로도 쓸 수 있고**, 돈을 내고 유료로 바꾸면 기능이 늘어난다. 그래서 유료로 바꾸지 않은 사람에게도 이용시간이 기록된다

– 분석 설정: 유료 전환 할인 쿠폰(Z)을 한 동네에만 뿌리고 옆 동네에는 뿌리지 않았다. 두 동네에 열 명씩 살고, 처치 D는 **유료 이용 여부**, 결과 Y는 **월 이용시간**이다. 사람은 쿠폰에 어떻게 반응하는지에 따라 세 부류로 갈린다(가상의 수치다)

<표 6-2: 쿠폰을 뿌린 동네와 뿌리지 않은 동네, 각 10명>

어떤 사람인가	동네마다 몇 명	쿠폰 뿌린 동네	쿠폰 안 뿌린 동네
쿠폰과 상관없이 원래 유료로 쓴다	2명	유료 · 90분	유료 · 90분
쿠폰을 받으면 유료로 바꾸고, 없으면 무료로 쓴다	4명	유료 · 80분	무료 · 50분
쿠폰을 줘도 무료로만 쓴다	4명	무료 · 50분	무료 · 50분

– 표 6-2를 세로로 읽으면 세 숫자의 뜻이 갈린다. 90분은 원래부터 유료로 쓰던 사람, 80분은 쿠폰 때문에 유료로 바꾼 사람, 50분은 무료로만 쓴 사람의 이용시간이다

○ 표 6-2에서 동네마다 두 가지를 센다. 유료로 쓰는 사람의 비율과 이용시간 평균이다

– 둘 다 **동네 사람 열 명 전부**를 기준으로 낸다. 아래에서 나누는 10은 동네 인원이고, 6명·2명은 그중 유료로 쓴 사람 수다

```
쿠폰 뿌린 동네 (10명)
  유료 이용자     2 + 4 = 6명          → 유료 이용자 비율 6 ÷ 10 = 60%
  이용시간 평균   (90×2 + 80×4 + 50×4) ÷ 10명 = 70분

쿠폰 안 뿌린 동네 (10명)
  유료 이용자     2명                  → 유료 이용자 비율 2 ÷ 10 = 20%
  이용시간 평균   (90×2 + 50×4 + 50×4) ÷ 10명 = 58분

두 동네 차이     유료 이용자 비율 60% − 20% = 40%p    ← 쿠폰이 전환시킨 비율
                 이용시간         70분 − 58분 = 12분

쿠폰이 전환시킨 1명당 효과 = 12분 ÷ 0.4 = 30분
```

○ 두 비율을 섞어 부르지 않는다. **각 동네에서 센 60%·20%는 "유료로 쓰는 사람의 비율"이고, 두 동네의 차이 40%p가 "쿠폰이 전환시킨 사람의 비율"이다**

– 안 뿌린 동네의 2명은 쿠폰이 없어도 유료였으므로 전환한 사람이 아니다. 그런데도 분자·분모를 셀 때 빼지 않고 그대로 둔다

– 빼지 않아도 되는 이유는 이 2명이 양쪽 동네에 똑같이 들어가 **차이에서 저절로 사라지기** 때문이다. 60% – 20%에서도, 70분 – 58분에서도 이들의 몫은 상쇄된다

– 거꾸로 이들을 미리 골라내려면 누가 그 2명인지 알아야 하는데, 현실에서는 알 수 없다. 두 동네를 통째로 빼는 계산이 그 구분 없이도 답을 내주는 것이 도구변수의 이점이다

○ **왜 나누는가.** 쿠폰이 열 명 중 네 명만 움직였기 때문이다

– 이용시간 차이 12분은 행동이 바뀐 네 명이 만든 값인데, 동네 평균을 내는 과정에서 열 명에게 나뉘어 작아졌다. 실제로 움직인 비율 0.4로 되돌려 나눠야 1인당 효과가 나온다

– 사람 수로 세도 답은 같다. 네 명이 30분씩 늘어 120분이고, 120 ÷ 4 = 30분이다

– 같은 나눗셈을 5장에서 이미 한 번 했다. 퍼지 RDD의 LATE는 결과의 점프를 처치 확률의 점프로 나눈 값이었고(5.4), 분자와 분모를 만드는 장치가 기준점에서 도구변수로 바뀌었을 뿐이다

○ 이 장의 나머지는 모두 이 나눗셈의 분자와 분모를 손보는 일이다

– Z가 연속형이거나 통제변수가 붙으면 손으로 못 나눈다 → 6.3의 2SLS

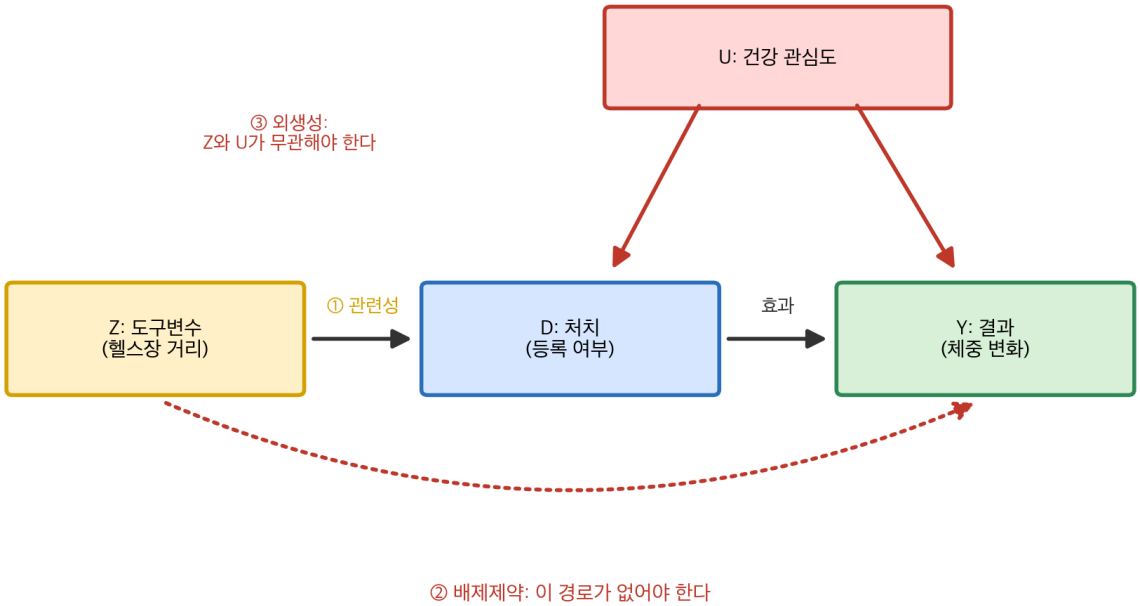
– 분모가 작으면 같은 잡음에도 답이 크게 달라진다 → 6.4의 F통계량

– 답은 분모에 들어간 사람의 효과다 → 6.5의 LATE

– 분자와 분모의 관계가 직선이 아니면 → 6.6·6.7의 확장

그림 6-2. 유효한 도구변수의 3조건

세 조건 중 데이터로 확인되는 것은 ①뿐이다



○ 그림 6-2 읽는 법: Z에서 D로 가는 실선 화살표(관련성)는 **있어야** 하고, Z에서 Y로 직접 가는 점선(배제제약 위반)과 Z와 U를 잇는 점선(외생성 위반)은 **없어야** 한다. 없어야 할 화살표가 없음을 보이는 일이 IV 분석의 가장 어려운 부분이다

○ 유효한 도구변수의 3조건 (표 6-3)

<표 6-3: 유효한 도구변수의 3조건>

조건	뜻	데이터로 확인	헬스장 예
관련성	Z가 D를 실제로 움직인다	**가능** (1단계 회귀·F통계량)	거리가 가까우면 등록률이 높다
배제제약	Z는 D를 거쳐서만 Y에 닿는다	**불가능** (논리로 설득)	거리 자체가 체중을 바꾸지는 않는다
외생성	Z가 U와 무관하다	부분적	거리가 건강 관심도와 무관해야 한다

○ 각 조건이 깨지는 상황을 알아 둔다

– 관련성이 깨지면: 골라낼 변동 자체가 없어서 추정치가 크게 흔들린다. 판정 기준(F통계량)은 6.4에서 다룬다

- 배제제약이 깨지면: 헬스장이 가까운 동네는 공원·산책로도 잘 갖춰져 있어, 거리가 등록을 거치지 않고도 체중에 영향을 줄 수 있다
- 외생성이 깨지면: 건강에 관심 많은 사람이 애초에 헬스장 근처로 이사했다면, 거리는 U의 대리변수가 되어 버린다

○ 배제제약은 증명할 수 없으므로, 논문에서는 Z가 Y로 직접 갈 경로를 숨기지 않고 나열하고 → 그 경로가 작동하면 데이터에 남을 흔적을 적고 → 그 흔적이 안 보인다는 약한 증거를 제시하는 순서로 설득한다

- 보조 점검 세 가지: ① 영향받을 이유가 없는 결과변수에도 효과가 나오면 위험 신호 ② 정책 시행 이전 기간에 효과가 보여도 위험 신호 ③ 직접 경로가 의심되는 집단을 빼도 결론이 유지되는지 확인

○ 실습 — 셋 중 데이터로 확인되는 관련성을 점검한다 (전체 코드 `6-1-traditional-2sls.py`, 로그 `results/6-1-traditional-2sls.log`)

```
first_stage = smf.ols('D ~ Z + X1 + X2', data=df).fit()   # 1단계: Z가 D를 움직이는가
```

```
--- 1단계 (First Stage) ---
π₁ (Z → D): 0.610 (SE: 0.023, t: 26.31)
F-통계량: 295.05
```

- 판정: Z가 1 늘 때 D가 0.610 늘고 t값 26.31은 우연이 아니라는 뜻이다. 계수가 0 근처이거나 t가 2 미만이면 그 Z로 2SLS를 돌리지 않고 다른 도구변수를 찾는다

한 줄 정리: 세 조건 중 데이터로 검증되는 것은 관련성 하나뿐이고, 나머지 둘은 제도와 논리로 설득한다.

□ 6.3 2SLS — 두 번 회귀하는 이유

○ 6.2의 나눗셈은 손으로 할 수 있는 조건이 좁다. 조건이 깨지는 경우가 셋이다

- **Z가 연속된 값일 때**: 거리나 정원 증가율처럼 값이 이어져 있으면, 평균을 낼 "쿠폰 뿌린 동네"와 "안 뿌린 동네"로 묶을 수가 없다
- **통제변수를 넣어야 할 때**: 두 동네의 나이·소득이 다르면 그것까지 맞춰야 하는데, 평균 두 개로는 조정할 방법이 없다
- **도구변수가 여러 개일 때**: 분모 후보가 여럿이라 어느 것으로 나눌지 정해지지 않는다

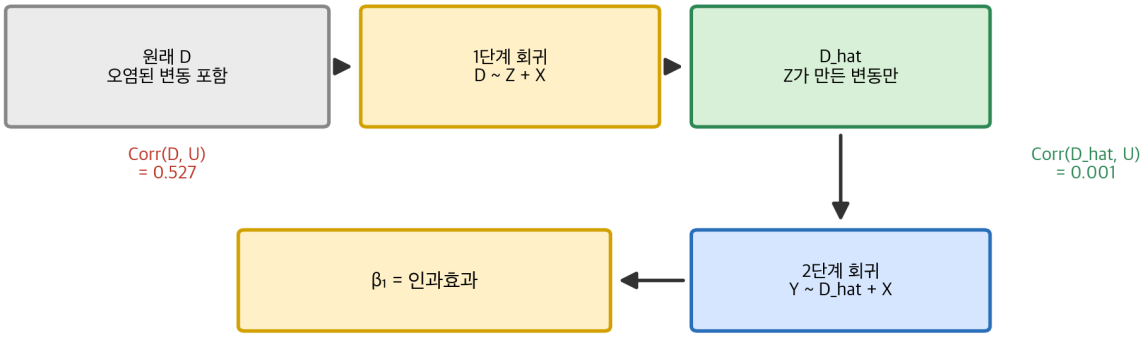
○ **2단계 최소제곱**(2SLS)은 세 경우 모두에서 같은 답을 내주는 절차이며, 회귀를 두 번 돌린다

– 1단계 `D ~ Z + X`: D 안에서 Z가 만든 부분만 남긴 예측값 **D_hat**을 얻는다

– 2단계 `Y ~ D_hat + X`: D 자리에 D_hat을 넣고 돌린다. 이때의 계수가 인과효과 추정치다

– Z를 그대로 Y에 회귀하면 "Z의 효과"가 나올 뿐이라 한 번으로는 끝나지 않는다

그림 6-3. 2SLS의 두 단계



1단계를 거치면 숨은 원인과의 연결이 끊어진다 (실습 6-1 실측값)

○ 그림 6-3 읽는 법: 왼쪽 회색 상자의 원래 D에는 U와 얽힌 변동이 섞여 있고(Corr(D, U) = 0.527), 1단계를 거친 D_hat에는 Z가 만든 변동만 남는다(Corr(D_hat, U) = 0.001). 아래 파란 상자가 2단계이고, 그 계수 β_1이 추정치다

– 상관이 0.527에서 0.001로 떨어진 것이 1단계가 한 일이다. 실제 연구에서는 U를 관측할 수 없어 이 확인이 불가능하므로, 여기서 원리만 눈으로 익히고 실전에서는 제도적 근거로 대신한다

○ 실습 — 두 단계를 손으로 이어 붙여 돌린다 (전체 코드 `6-1-traditional-2sls.py`, 로그 `results/6-1-traditional-2sls.log`)

```
first_stage = smf.ols('D ~ Z + X1 + X2', data=df).fit()        # 1단계
df['D_hat'] = first_stage.fittedvalues                          # 걸러 낸 깨끗한 부분
second_stage = smf.ols('Y ~ D_hat + X1 + X2', data=df).fit()   # 2단계: D 대신
D_hat
```

```
1단계 R²: 0.471
✓ 강한 도구변수 (F > 10)

--- 2단계 (Second Stage) ---
β₁ (D → Y): 3.353 (SE: 0.103)
95% CI: [3.151, 3.555]
참값과의 차이: -0.067 (2.0%)
```

  - 판정: 2SLS 추정값 3.353은 참값 3.42와 2.0% 차이이고 신뢰구간 [3.151, 3.555]가 참값을 담는다. OLS(2.171, 구간 [2.043, 2.298])는 참값 근처에도 못 갔다

○ **축약형**(reduced form) **— Z가 Y를 움직인 크기를 한 번에 재는 회귀**

  - 식은 `Y ~ Z + X` 하나다. 1단계가 왼쪽에 D를 두었다면 축약형은 왼쪽에 Y를 두며, D는 아예 식에 들어가지 않는다. 이 자료에서 Z 계수는 2.0438이고 아래 코드로 확인한다

  - 이 계수가 답하는 질문은 "Z가 1 늘면 Y가 얼마나 변하는가"다. Z가 D를 움직여 Y를 바꾼 몫까지 전부 합친 값이므로, D를 따로 떼지 않고 **Z를 움직이는 쪽을 결정할 때 보는 숫자**다

  - Z가 뿌렸다·안 뿌렸다 두 값뿐이면 이 계수에 따로 붙는 이름이 있다. 5.4 퍼지 RDD에서 축약형 1.380을 **ITT**(의도된 처치효과)라 부르고 1단계 0.485로 나눠 LATE 2.847을 얻은 것이 같은 계산이다. 이 절의 Z는 값이 이어진 연속형이라 묶을 두 집단이 없으므로, 2.0438은 "Z 1단위의 효과"로 읽는다

  - **축약형 하나로는 D의 효과를 말할 수 없다.** Z가 D를 얼마나 움직였는지 모르면 1인당 효과로 되돌릴 수 없고, 그 크기는 1단계 회귀에만 있다

  - 판정 기준: 축약형 계수가 0과 구분되지 않으면 D의 효과를 주장하지 않는다. 분자가 0 근처인데 분모까지 작아 나눗셈 결과만 커 보이는 것이 약한 도구변수의 전형적 증상이며, 분모 쪽 판정은 6.4에서 다룬다

○ 같은 자료로 돌린 세 회귀가 각각 다른 질문에 답한다

  - 1단계 `D ~ Z + X`의 0.6096: Z가 1 늘 때 D가 얼마나 늘었는가. 6.2에서 관련성을 점검하며 이미 돌린 회귀다

  - 축약형 `Y ~ Z + X`의 2.0438: Z가 1 늘 때 Y가 얼마나 변했는가

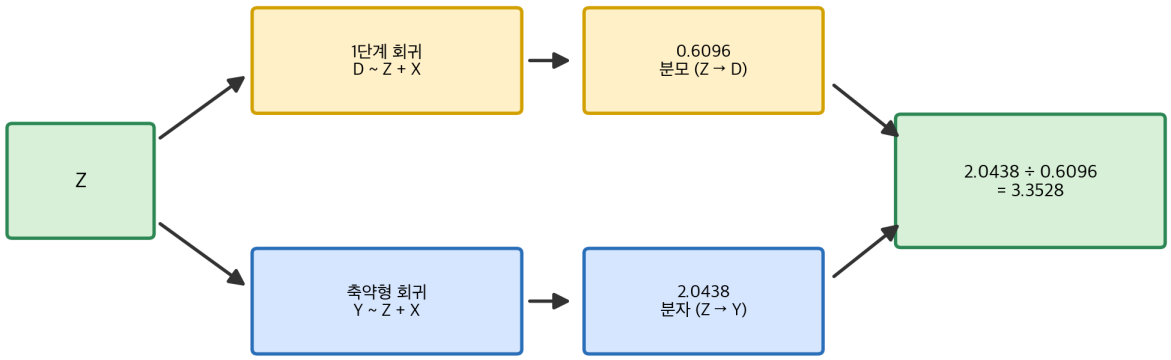
  - 2SLS의 3.353: D가 1 늘 때 Y가 얼마나 변했는가. 셋 중 D의 효과를 재는 것은 이것 하나다

– 6.2의 20명으로 돌려 보면 짝이 맞는다. 축약형에 해당하는 값이 이용시간 차이 12분이고, 1단계에 해당하는 값이 유료 이용자 비율 차이 0.4이며, 2SLS에 해당하는 값이 1인당 30분이다

○ 축약형을 1단계로 나누면 2SLS와 같은 값이 나온다. **6.2에서 손으로 한 나눗셈과 같은 계산**이다

– 분모는 방금 돌린 1단계 회귀의 Z 계수를 그대로 쓰므로 새로 돌릴 것이 없고, 분자로 쓸 축약형 회귀 하나만 더 돌린다

그림 6-4. 축약형 ÷ 1단계 — 2SLS와 같은 답



2SLS가 내놓은 3.353과 같은 값이다 — 같은 추정량을 다른 순서로 계산했다

○ 그림 6-4 읽는 법: 왼쪽 Z에서 두 회귀가 갈라진다. 위 길(1단계)이 분모 0.6096을, 아래 길(축약형)이 분자 2.0438을 만들고, 오른쪽에서 나눠 3.3528을 얻는다. 그림 6-3의 2SLS와 같은 값이며, D_hat을 만드는 중간 단계 없이 계수 두 개로 바로 간다

```
fs = smf.ols('D ~ Z + X1 + X2', data=df).fit()   # 1단계 — 분모
rf = smf.ols('Y ~ Z + X1 + X2', data=df).fit()   # 축약형 — 분자
print(rf.params['Z'] / fs.params['Z'])
```

```
분모 (Z → D)  0.6096      ← 1단계 회귀의 Z 계수
분자 (Z → Y)  2.0438      ← 축약형 회귀의 Z 계수

나눗셈  2.0438 ÷ 0.6096 = 3.3528
```

위 세 줄은 `data/6-1-iv-data.csv` 로 직접 계산한 값이다

– 2SLS가 내놓은 3.353과 소수 셋째 자리까지 같다. 20명을 손으로 센 계산과 1,000명을 2SLS로 돌린 계산은 **같은 나눗셈**이며, 달라진 것은 Z가 연속형이고 통제변수 X1·X2가 붙었다는 점뿐이다

- 방법이 둘인 것이 아니다. 도구변수가 하나일 때 나눗셈과 2SLS는 **같은 추정량**이고 계산 순서만 다르다. 도구변수가 여럿이면 나눌 후보가 여럿 생겨 답이 하나로 정해지지 않으므로, 그때 남는 것은 2SLS뿐이다(이 절 앞머리의 세 번째 경우)

- 세 회귀를 갈라 보는 것이 뒤에 쓸 데가 있다. 분모가 작으면 답이 흔들린다는 6.4의 진단이 1단계 회귀를 보는 일이고, 분자가 누구 때문에 생겼는지 따지는 6.5의 해석이 축약형을 보는 일이다

- 다만 보고서에 싣는 숫자는 2SLS 출력에서 받는다. 추정값은 어느 길로 가도 같지만 표준오차가 다르며, 그 이유는 이 절 끝에서 다룬다

○ 정밀도를 내주고 얻은 결과다

- 1단계 R^2 0.471은 D 변동의 47.1%만 남기고 52.9%를 버렸다는 뜻이다. 버린 만큼 2단계에 쓸 정보가 줄어 2SLS의 표준오차(0.103)가 OLS(0.065)보다 커졌다

- **편향을 줄이는 대가로 정밀도를 내주는 교환**이며, 다음 표가 그 교환을 한눈에 보여준다

<표 6-4: OLS와 2SLS 비교 (참값 3.42)>

방법	추정값	표준오차	참값 대비	신뢰구간이 참값을 포함하는가
OLS	2.171	0.065	-36.5%	아니오
2SLS	3.353	0.103	-2.0%	예

- 표에서 내릴 결론은 하나다. **좁은 신뢰구간과 작은 p값은 정확성의 증거가 아니다.** 설계가 틀리면 정밀하게 틀린 답이 나온다

○ 보고서에 실을 때는 앞에서처럼 두 회귀를 손으로 이어 붙이지 않고 전용 패키지를 쓴다. 손으로 이으면 "D_hat 자체가 추정값"이라는 불확실성이 2단계 표준오차에 반영되지 않아, 표준오차를 실제보다 작게 보고하게 된다

○ 실습 — 제출용 결과표를 전용 패키지로 만든다 (전체 코드 `6-8-iv2sls-report.py`, 로그 `results/6-8-iv2sls-report.log`)

```
res = IV2SLS.from_formula('Y ~ 1 + X1 + X2 + [D ~ Z]',
                          data=df).fit(cov_type='robust')   # 대괄호 안: 내생변수 ~ 도구변수
fs = res.first_stage                                        # 1단계 진단 자동 출력
```

- 물결표 왼쪽이 결과변수, X1·X2가 통제변수, 대괄호 안이 "내생변수 ~ 도구변수"다. cov_type='robust'는 **강건 표준오차** — 오차의 흩어짐이 고르지 않아도 버티는 계산 방식 — 를 뜻한다

```
[3단계] 추정값은 같고 표준오차는 다르다
추정값 차이: 0.000000  (사실상 0)
표준오차: 손으로 0.1029 vs 패키지 0.1224
손으로 계산한 표준오차가 15.9% 작다

[5단계] 제출용 결과표
  방법   추정값  표준오차  CI하한  CI상한  참값과의차이 CI가참값포함
 OLS 2.171 0.065 2.043 2.298  -1.249     아니오
2SLS 3.353 0.122 3.113 3.593  -0.067       예
결과표 저장: 6-8-results-table.csv
```

  - 판정: 추정값은 손 계산과 같은 3.353이지만, 손 계산 표준오차 0.1029는 패키지 0.1224보다 15.9% 작다 — 신뢰구간을 좁게 적으면 실제보다 확신에 찬 보고서가 된다. **보고서에는 패키지 출력을 싣고**, 표 아래에 “1단계 F통계량은 732.40이며, 표준오차는 이분산에 강건한 방식으로 계산했다”를 붙인다

한 줄 정리: 축약형은 Z가 Y를 움직인 크기를, 2SLS는 D의 효과를 잰다. 두 숫자는 1단계 계수로 이어지며, 보고서에 싣는 값은 전용 패키지 출력이다.

□ 1부 정리

○ 지금까지 만든 것 네 가지: 편향의 곱셈 확인(-1.946 × 0.625 = -1.216 ≈ 실제 -1.249), 20명 손계산(12분 ÷ 0.4 = 30분), 관련성 점검(Z 계수 0.610, t 26.31), 제출용 결과표(OLS 2.171 vs 2SLS 3.353)

○ 손으로 한 나눗셈과 2SLS가 같은 계산이라는 것은 축약형 2.0438을 1단계 계수 0.6096으로 나눠 확인했다(= 3.3528). 2부의 F·LATE·곡선 확장은 모두 이 분자와 분모를 손보는 이야기다

○ 확인한 판정 기준

  - 1단계에서 Z의 계수가 0 근처이거나 t가 2 미만이면 그 도구변수를 쓰지 않는다

  - 손으로 이어 붙인 2단계의 표준오차는 보고하지 않는다(이번 실행에서 15.9% 과소)

○ 2부로 넘길 질문: 이 결과표의 숫자를 믿어도 되는가, 그리고 이 숫자는 누구의 효과인가

2부. 진단하고 해석하고, 곡선이면 확장한다

□ 2부 개요

○ 이 파트가 끝나면: F통계량으로 도구변수의 강도를 판정하고, 추정치를 LATE로 해석해 보고서 문장으로 옮기며, 관계가 곡선일 때 다항항 → DeepIV 계열의 순서로 확장하고, 집단별 효과를 정책 숫자로 연결할 수 있다

○ 다루는 절: 6.4 ~ 6.9

□ 6.4 진단 — 이 도구변수를 믿어도 되는가

○ Z가 D를 거의 못 움직여도 2SLS는 오류 없이 숫자를 뱉는다. 이 상태가 **약한 도구변수**이며, 이때의 추정치는 OLS보다 나쁠 수 있다

○ 왜 위험한지는 6.2의 나눗셈에서 바로 보인다. 분모가 작아지면 분자의 작은 오차가 답을 크게 밀어낸다

```
쿠폰이 열 명 중 네 명을 움직인 경우      분모 0.40, 분자 12.0분 →  30.0분
  이용시간을 1분 잘못 쟀다면              분모 0.40, 분자 13.0분 →  32.5분

쿠폰이 백 명 중 네 명을 움직인 경우     분모 0.04, 분자  1.2분 →  30.0분
  이용시간을 1분 잘못 쟀다면              분모 0.04, 분자  2.2분 →  55.0분
```

– 두 경우 모두 참 효과는 30분이고 잘못 잰 크기도 1분으로 같은데, 분모가 10분의 1이 되자 어긋난 폭이 2.5분에서 25분으로 커졌다

– 분자의 오차는 표본 크기와 이용시간이 흩어진 정도로 정해질 뿐 분모와 무관하므로, 분모가 작을수록 같은 잡음이 답을 더 크게 흔든다. 그래서 추정값을 읽기 전에 분모부터 본다

○ 분모를 판정하는 자가 **F통계량**이다 — 1단계에서 “Z가 D를 얼마나 확실히 움직이는가”, 곧 분모가 0과 구별되는지를 하나의 숫자로 요약한 값이며, 실무 기준선은 10이다

<표 6-5: 1단계 F통계량의 판정 눈금>

F통계량	판정	다음 행동
10 미만	약한 도구변수	추정치를 쓰지 않는다. 다른 Z를 찾는다
10~30	보통	추정값을 쓰되, 약한 IV에 강건한 신뢰구간을 함께 싣는다
30 초과	강함	통상적 방식으로 보고한다

○ F가 기준선 아래로 내려가면 세 가지가 동시에 일어난다. 표준오차가 커져 표본을 조금만 바꿔도 값이 크게 달라지고, 표본을 늘려도 편향이 잘 줄지 않으며, **그런데도 p값은 그럴듯하게 나온다**. 세 번째가 문제다 — F를 직접 보지 않으면 알 길이 없다

○ 실습 코드(핵심 부분, 전체는 `6-8-iv2sls-report.py`)

```
first_stage = smf.ols('D ~ Z + X1 + X2', data=df).fit()
print(first_stage.tvalues['Z'] ** 2)   # 도구변수가 하나면 t의 제곱이 F다
```

○ 실행 결과(`results/6-8-iv2sls-report.log` 발췌)

```
[4단계] 1단계 진단 자동 출력
Partial R-squared               0.4100
Partial F-statistic             732.40
P-value (Partial F-stat)        0.0000
```

– 해석: 부분 F 732.40은 기준선 10을 크게 넘고, 부분 R^2 0.410은 통제변수를 뺀 뒤에도 Z가 D 변동의 41%를 추가로 설명한다는 뜻이다. 두 값 모두 통과이므로 1부의 결과표를 그대로 보고할 수 있다. 참고로 6-1 로그의 F 295.05는 1단계 회귀 전체의 F이고, 732.40은 Z만 떼어 본 부분 F라서 값이 다르다

○ 판정 연습(가상의 수치다): 세 분석의 1단계 F가 각각 340, 17, 4라면?

– 340은 통상대로 보고하고, 17은 보고하되 약한 IV에 강건한 신뢰구간을 함께 실으며, 4는 추정값·p값을 읽지 않고 도구변수부터 다시 찾는다

한 줄 정리: F가 10 미만이면 나머지 숫자는 읽지 않는다. p값은 약한 도구를 경고해 주지 않는다.

□ 6.5 LATE — 이 숫자는 누구의 효과인가

○ F를 통과했다고 그 숫자가 전체 인구의 평균 효과인 것은 아니다. 6.2의 20명을 세 부류로 갈랐는데, 여기에 이름을 붙이고 쿠폰 때문에 오히려 안 하는 한 부류를 더하면 넷이 된다

<표 6-6: 도구변수에 대한 반응으로 나눈 네 유형>

유형	쿠폰 없을 때	쿠폰 있을 때	설명
순응자	무료로 씀	유료로 바꿈	쿠폰 때문에 행동이 바뀐 사람
항상수용자	유료로 씀	유료로 씀	쿠폰과 무관하게 원래 유료로 쓸 사람
절대거부자	무료로 씀	무료로 씀	쿠폰을 줘도 안 바꿀 사람
반항자	유료로 씀	무료로 씀	쿠폰 때문에 오히려 안 바꿈(보통 없다고 가정)

  - 6.2의 표 6-2와 짝지으면 이렇다. “쿠폰을 받으면 유료로 바꾸는 4명”이 순응자, “원래 유료로 쓰는 2명”이 항상수용자, “줘도 무료로만 쓰는 4명”이 절대거부자다

- 누가 답을 만들었는지는 20명을 유형별로 나눠 빼 보면 숫자로 갈린다. 동네마다 이용시간을 합한 뒤 두 동네를 뺀 값이다

```
원래 유료로 쓰는 2명     쿠폰 동네 180분 − 안 뿌린 동네 180분 =   0분
쿠폰 때문에 바꾼 4명     쿠폰 동네 320분 − 안 뿌린 동네 200분 = 120분
줘도 무료로만 쓴 4명     쿠폰 동네 200분 − 안 뿌린 동네 200분 =   0분
                                                  합계  120분
```

  - 분자 12분(= 120분 ÷ 10명)을 전부 네 명이 만들었고, 분모 0.4도 같은 네 명의 비율이다. 분자와 분모가 같은 사람에게서 나오므로 나눗셈의 답 30분은 **그 네 명의 1인당 효과**다

  - 나머지 여섯 명은 두 동네에서 똑같이 행동해 차이가 0이고, 그래서 자기 효과를 답에 남기지 못한다. 이들의 효과가 30분과 다르더라도 2SLS는 그 값을 재지 못한다

- 그래서 **2SLS가 재는 것은 순응자들의 평균 효과**이며, 이 값을 **LATE**(국지적 평균 처치효과)라고 부른다. Z가 바뀌어도 행동이 안 바뀌는 사람은 인과 정보를 주지 못한다

- 그래서 **도구변수를 바꾸면 추정값이 바뀌는 것이 정상이다**

  - 같은 교육 수익률을 재도 “대학까지 거리”를 쓴 연구와 “출생 분기”를 쓴 연구의 값이 다른데, 어느 하나가 틀린 것이 아니라 순응자 집단이 다르기 때문이다. 거리를 도구로 쓴 연구의 순응자는 “가까워서 진학했지만 멀었으면 안 갔을” 한계선상의 학생이므로, 그 추정치는 “정원을 늘리면”에는 맞지만 “모든 국민이 대학을 나오면”에는 맞지 않는다

- 판정 규칙은 보고서 문장으로 옮긴다. 추정치 옆에 **”이 추정치는 도구변수에 반응해 처치가 바뀐 집단의 효과다”** 를 넣고, 순응자가 어떤 사람인지 한 문단으로 서술한다

한 줄 정리: 2SLS의 답은 전체 평균이 아니라 순응자의 평균이다. 도구가 다르면 답도 달라진다.

□ 6.6 2SLS가 잘 맞지 않는 세 경우

○ 지금까지는 세 가지를 가정했다: D와 Y의 관계가 직선이고, 통제변수가 적으며, 효과가 모두에게 같다. 하나라도 깨지면 F가 커도 추정치가 어긋난다

– **곡선일 때**: 이 절의 실습 데이터에서는 D를 1 늘렸을 때의 효과가 D 값에 따라 다르다 — D가 0이면 3.0, 평균(0.8)이면 3.8, 2면 5.0이다. 직선 2SLS는 이 차이를 숫자 하나로 뭉갠다

– **통제변수가 많을 때**: 변수 50개면 두 개씩 조합만 해도 50×49÷2 = 1,225개인데 표본이 500이면 추정할 항이 관측치의 두 배가 넘는다

– **효과가 사람마다 다를 때**: 평균 하나로는 “누구에게 먼저 쓸까”를 정할 수 없다. 6.8에서 다룬다

○ 실습 코드(핵심 부분, 전체는 `6-2-iv-limitations.py`) — 곡선 데이터에 D² 항을 추가한 2SLS다

```
first_stage_quad = sm.OLS(D, sm.add_constant(np.column_stack([Z, Z**2]))).fit()
D_hat_quad = first_stage_quad.fittedvalues
second_stage_quad = sm.OLS(Y, sm.add_constant(
    np.column_stack([D_hat_quad, D_hat_quad**2]))).fit()   # 2단계에 D²도 넣는다
```

○ 실행 결과(`results/6-2-iv-limitations.log` 발췌)

```
실제 평균 한계효과: 3.800
2SLS (선형) 추정값: 4.447   → 편향: 0.647 (17.0%)
OLS 추정값: 2.821           → 편향: -0.980 (-25.8%)
[4단계] 비선형 항 추가
D 계수: 3.125 (참값: 3.0) / D² 계수: 0.465 (참값: 0.5)
평균 한계효과: 3.870        → 편향: 0.070 (1.8%)
[5단계] RESET 검정
RESET F-통계량: 791.60, p-value: 0.0000
```

<표 6-7: 곡선 데이터에서의 세 추정값 (참값 3.800)>

방법	추정값	참값 대비
OLS	2.821	-25.8%
선형 2SLS	4.447	+17.0%
2SLS + D² 항	3.870	+1.8%

  - 해석: 선형 2SLS는 내생성은 잡았지만 곡선을 못 잡아 위로 17% 어긋났고, OLS는 내생성 때문에 아래로 26% 어긋났다. 항 하나(D^2)만 추가해도 오차가 1.8%로 줄었다

  - 판정 도구는 **RESET 검정** — "직선 가정이 맞는가"를 묻는 검사다. 참값을 모르는 실제 연구에서도 돌릴 수 있다. **p값이 0.05 미만이면 직선 모형을 그대로 보고하지 않고 다항항을 넣어 다시 추정한다.** 이번 실행은 F 791.60, p 0.0000으로 직선 가정이 기각됐다

- 판정 연습(가상의 수치다): 두 분석의 RESET p값이 각각 0.42와 0.003이라면?

  - 0.42는 직선 모형을 유지해도 되고, 0.003은 다항항을 넣어 다시 추정한 뒤 두 결과를 함께 보고한다

- 여기서 행동 규칙 하나를 정한다. **곡선이 의심되면 먼저 다항항을 넣어 본다.** 딥러닝은 곡선의 모양을 짐작조차 못 할 때 꺼내는 도구다

한 줄 정리: F 통과와 직선 가정은 별개다. RESET이 기각되면 다항항부터 넣는다.

☐ 6.7 DeepIV 계열 — 곡선 모양을 모를 때

- 2차인지 3차인지, 어디서 꺾이는지 모르면 넣을 항을 고를 수 없다. DeepIV는 2SLS의 1단계·2단계 뼈대는 그대로 두고, 직선 공식 대신 신경망(계산 단위를 여러 층 쌓아 복잡한 관계를 배우는 예측 모형)이 곡선을 스스로 찾게 한다

  - 원래 DeepIV의 1단계는 D의 평균이 아니라 **D가 나올 법한 범위 전체**를 배운다. 어떤 지역의 주당 근무시간이 20시간(시간제)과 45시간(전일제)으로 갈라져 있으면 평균 32.5시간은 아무도 해당하지 않는 값이기 때문이다

- 실습 코드(핵심 부분, 전체는 `6-3-deepiv-implementation.py`)

```
stage1_model = MLPRegressor(hidden_layer_sizes=(64, 64), activation='relu',
                            max_iter=200, random_state=42,
                            early_stopping=True, validation_fraction=0.2)
stage1_model.fit(ZX_train, D_train)                  # 1단계: 신경망으로 D를 예측
stage2_model = MLPRegressor(hidden_layer_sizes=(128, 128), activation='relu',
                            max_iter=500, random_state=42, early_stopping=True)
stage2_model.fit(DX_train, Y_train)                  # 2단계: 예측값으로 Y를 설명
```

- 실행 결과(`results/6-3-deepiv-implementation.log` 발췌)

```
샘플 크기: 2000
참값 ATE: 3.383
Stage 1 R²: 0.360
DeepIV 추정값: 3.330   → 오차: 0.053 (1.6%)
2SLS 추정값: 4.180     → 오차: 0.797 (23.6%)
```

  - 해석: 곡선 데이터에서 DeepIV 오차 1.6% 대 선형 2SLS 23.6% — 6.6과 같은 현상이다. Stage 1 R² 0.360은 낮아 보이지만 IV에서는 낮은 것이 정상이며, 100%에 가까우면 D가 사실상 Z의 함수가 되어 2단계가 성립하지 않는다. 주의: 이 코드는 원래 방법의 "범위 학습" 대신 평균 예측만 쓰는 교육용 간소화 버전이다. 정식 구현이 필요하면 EconML의 DeepIV를 쓴다

○ 같은 계열의 방법이 두 가지 더 있다. DeepGMM은 "잔차가 Z와 무관해야 한다"는 조건을 직접 맞추도록 학습하고, DFIV는 1단계에서 특징(요약된 변수)을 배워 2단계에 넘긴다. 네 방법을 같은 데이터(참값 3.383)에 적용한 결과가 아래다

○ 실행 결과(`results/6-6-latest-methods-comparison.log` 발췌)

```
 Method  Estimate     RMSE  Time (sec)      Bias
   2SLS  4.180201 3.407494    0.002511  0.797232
 DeepIV  3.395943 1.848706    0.680399  0.012975
DeepGMM  2.343872 1.359109    0.822161 -1.039096
   DFIV  3.393966 1.882761    1.647380  0.010998
```

  - 해석: DeepIV(3.396)와 DFIV(3.394)는 참값 3.383에 붙었지만, 간소화 DeepGMM(2.344)은 31% 아래로 어긋났다 — 간소화 구현이 원 방법의 성질을 보장하지 않는다는 증거다. 예측 오차(RMSE)는 DeepGMM이 가장 작은데 효과 추정은 가장 나쁘다. **예측을 잘하는 모형과 효과를 잘 재는 모형은 다르다**

  - DeepIV 값이 6-3 실행(3.330)과 6-6 실행(3.396)에서 조금 다른데, 두 스크립트의 학습 설정(검증 데이터 비율)이 달라서다. 같은 이름의 방법도 구현 세부에 따라 값이 출렁이므로, 신경망 결과만 단독으로 제출하지 않고 2SLS를 기준값으로 항상 함께 싣는다

○ 쓰기 전에 확인할 것 세 가지: 표본이 수천 개 이하면 과적합 위험이 커서 D² 항 쪽이 낫고, 1단계가 무너지면 2단계도 무너지므로 1단계 설명력을 먼저 보며, 방향이 크게 다를 때 따져 볼 수 있도록 2SLS 결과를 함께 싣는다

한 줄 정리: 딥러닝 IV는 곡선을 잡지만 구현에 따라 값이 출렁인다. 2SLS 기준값 없이 단독으로 보고하지 않는다.

□ 6.8 집단별 효과 — 교육 수익률 실습으로 전 과정을 돌린다

○ 예산이 한정된 정책에서는 평균보다 "누구에게 먼저 쓸까"가 결정을 좌우한다. 집단(또는 사람)마다 따로 잰 평균 효과가 **CATE**다

– 함정 세 가지: ① 데이터에 없는 구간의 효과를 뽑는 외삽 ② 전체 F는 강해도 집단을 나누면 약해지는 하위집단 약한 도구변수 ③ 신뢰구간 없이 집단 순서를 말하는 오류

○ 실습: 가상의 한국 대졸자 5만 명 데이터로 진단 → 추정 → 집단별 해석 → 정책 연결을 한 번에 돌린다

– 결과 Y는 로그 임금, 처치 D는 대학 졸업, 숨은 원인 U는 능력(관측 불가), 도구변수 Z는 지역별 대학 정원 증가율이다. 정원은 학생 개인의 능력과 무관하게 정부·대학 사정으로 정해지고, 정원이 는 지역에서는 능력이 같아도 진학 확률이 올라간다

○ 실습 코드(핵심 부분, 전체는 `6-7-education-returns.py`)

```
iv_res = IV2SLS.from_formula(
    'log_wage ~ 1 + age + gender + parent_edu + C(region) + [college ~
expansion]',
    data=df).fit(cov_type='robust')
for lv, name in [(1, '중졸 이하'), (2, '고졸'), (3, '대졸 이상')]:
    sub = df[df.parent_edu == lv]
    fs_sub = smf.ols('college ~ expansion + age + gender + C(region)',
data=sub).fit()
    f_sub = fs_sub.tvalues['expansion'] ** 2      # 집단별 1단계 F를 다시 계산
```

○ 실행 결과(`results/6-7-education-returns.log` 발췌)

```
평균 대졸 프리미엄 (참값): 0.130 (임금 13.9% 증가)
OLS 대졸 프리미엄: 0.260 → 참값 0.130 대비: +99.3%
1단계 F통계량: 3266.90
2SLS 대졸 프리미엄: 0.131 (SE: 0.013), 95% 신뢰구간: [0.106, 0.156]

[5단계] 부모 학력 집단별 효과
집단              1단계 F        추정값              95% 신뢰구간        참값
중졸 이하         1429.1     0.070 [  0.033,  0.107]    0.050
고졸              1246.8     0.152 [  0.111,  0.192]    0.150
대졸 이상          591.1     0.222 [  0.163,  0.280]    0.250

[6단계] 정책 시뮬레이션: 정원 증가율을 1%p 올리면
  - 대졸률 변화: +7.0%p (1단계 계수 0.0701 x 1)
  - 평균 임금 변화: +0.92%
```

- 해석 1: OLS 0.260은 참값 0.130의 두 배다. 능력 높은 사람이 대학도 가고 임금도 높으니, 능력의 몫까지 대학 몫으로 계산됐다(6.1의 생략변수 편향). 2SLS 0.131은 참값과 0.5% 차이다

- 해석 2: 집단별 표는 세 가지를 순서대로 본다. 첫째, 집단마다 1단계 F를 다시 계산했고 셋 다 10을 넘는다(가장 낮은 대졸 이상도 591). 둘째, 추정 순서 0.070 < 0.152 < 0.222가 참값 순서와 일치한다. 셋째, 중졸 이하 [0.033, 0.107]과 대졸 이상 [0.163, 0.280]의 구간이 겹치지 않으므로 "부모 학력이 높을수록 프리미엄이 크다"고 말할 수 있다

- 해석 3: 정책 효과 = 늘어난 대졸률 × 프리미엄 = 0.070 × 0.131 = 0.0092, 곧 0.92%다. 프리미엄 14%는 큰 값인데 평균 효과는 1%가 안 된다 — **정책의 총효과는 효과 크기와 실제로 움직이는 사람 수의 곱**이기 때문이다. 앞 숫자는 1단계에서, 뒤 숫자는 2단계에서 나오므로 두 단계를 다 돌려야 이 계산이 가능하다

○ 판정 규칙 두 가지: 어느 집단의 F가 10 아래로 내려가면 그 집단의 추정값은 보고하지 않는다. 그리고 **신뢰구간이 겹치면 추정값 순서가 어떻든 집단 간 차이를 주장하지 않는다** — 집단별 분석에서 가장 자주 어기는 규칙이다

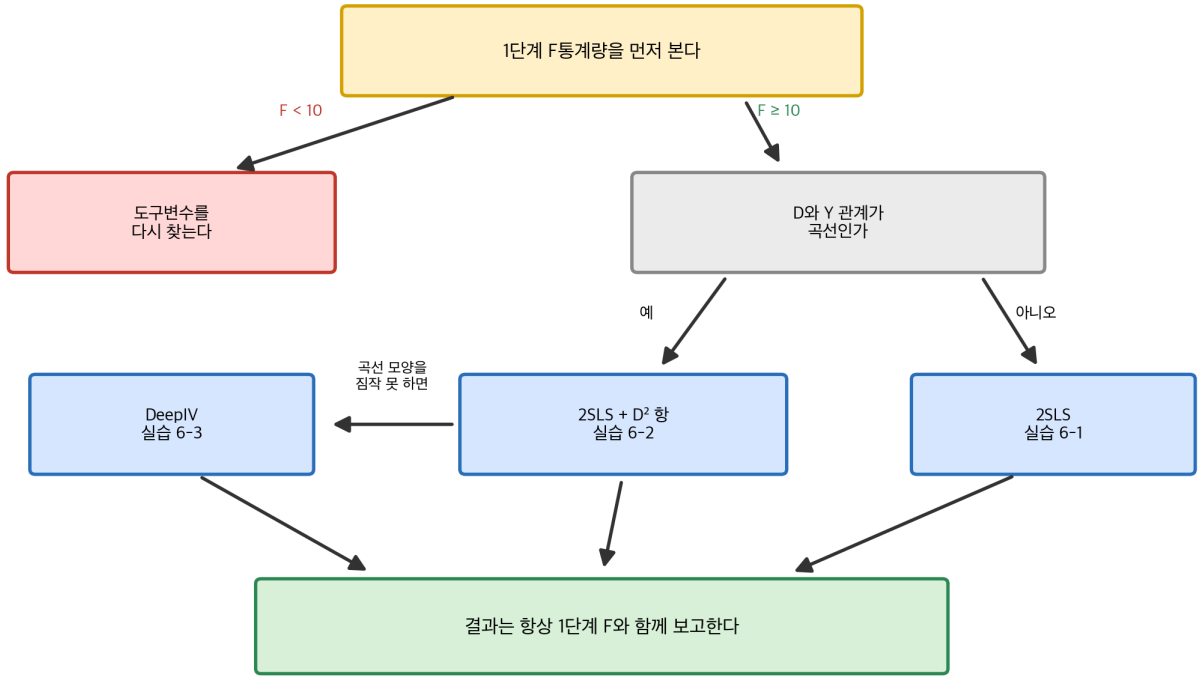
○ 판정 연습(가상의 수치다): 두 집단의 추정값이 0.12(구간 [0.02, 0.22])와 0.18(구간 [0.08, 0.28])이라면?

- 0.18이 더 커 보여도 두 구간이 [0.08, 0.22]에서 겹치므로, "두 집단의 효과가 다르다"고 쓰지 않고 두 값과 구간을 그대로 싣는다

한 줄 정리: 집단별 결론에는 관문이 둘이다 — 집단별 F 10, 그리고 겹치지 않는 신뢰구간.

□ 6.9 방법 선택 — 어떤 순서로 정하는가

그림 6-5. 어떤 방법을 쓸지 정하는 순서



○ 그림 6-5 읽는 법 — 위에서 아래로 관문을 통과하는 순서도다

– 첫 관문은 1단계 F통계량이다. F < 10이면 어떤 방법을 써도 소용없으므로 왼쪽 빨간 상자(도구변수를 다시 찾는다)로 간다

– F ≥ 10이면 “D와 Y 관계가 곡선인가”를 묻는다(판정 도구는 RESET 검정). 아니오면 2SLS(실습 6-1), 예면 2SLS + D² 항(실습 6-2), 다항항으로도 곡선 모양을 짐작 못 하면 그때만 DeepIV(실습 6-3)로 간다

– 세 갈래가 모두 맨 아래 초록 상자로 모인다: **결과는 항상 1단계 F와 함께 보고한다**

– 그림에는 없지만 집단별 결정이 필요하면 관문이 하나 더 붙는다. CATE를 추정하되 집단마다 1단계 F를 다시 계산한다(6.8)

한 줄 정리: 판단 순서는 F → RESET → 다항항 → 딥러닝 → 집단별이다. 앞 관문을 건너뛰고 뒤로 가지 않는다.

□ 결과를 읽는 순서

○ IV 결과표를 받으면 추정값이 아니라 진단부터 읽는다. 순서를 지키지 않으면 약한 도구의 정밀해 보이는 오답을 채택하게 된다

– 1순위 **1단계 F통계량**: 10 미만이면 나머지 숫자를 읽지 않고 보고를 중단한다

– 2순위 **표준오차의 종류**: 손으로 나눈 2단계 값이면 실제보다 작을 수 있다(이번 실행에서 15.9%). 전용 패키지 출력인지, 어떤 강건 방식인지 확인한다

– 3순위 **직선 가정**: RESET 검정 결과를 본다. 기각됐는데 직선 모형만 실려 있으면 다항항 추정을 요구한다

– 4순위 **효과와 신뢰구간**: 구간이 0을 포함하면 “효과가 있다”고 말하지 않는다

– 5순위 **LATE 해석과 총효과**: 순응자가 누구인지 확인하고, 효과 크기에 영향받는 사람 수를 곱한 값으로 정책을 판단한다

□ 실무 적용 점검표

○ Z가 D를 움직이는 제도적 이유를 한 문장으로 쓸 수 있는가

○ Z가 Y로 직접 갈 수 있는 경로를 세 개 이상 나열하고 각각 반박했는가

○ 1단계 F통계량·부분 R^2·Z의 계수와 t값을 표에 넣었는가

○ 관계가 곡선일 가능성을 RESET 검정으로 확인했는가

○ 지역·학교·기업처럼 묶인 단위가 있다면 표준오차 종류(클러스터 강건)를 명시했는가

○ 순응자가 어떤 사람인지 한 문단으로 서술하고, 결론을 순응자 효과로 적었는가

○ 신경망 결과를 실었다면 2SLS 기준값을 나란히 실었는가

○ 하위집단 분석마다 1단계 F를 다시 계산했는가

□ 핵심 정리

방법	원리	유의할 점
OLS	직선 하나로 관계를 요약	내생성이 있으면 경고 없이 어긋남(이번 실행 -36.5%)
2SLS	도구변수로 깨끗한 변동만 골라 계산	재는 것은 LATE, 정밀도는 OLS보다 낮음
2SLS + 다항항	곡선을 항 추가로 근사	RESET 기각 시 첫 번째 선택(17.0% → 1.8%)
DeepIV 계열	신경망이 곡선을 스스로 학습	구현·설정 따라 출렁임. 2SLS 기준값 병행

○ 이 장의 판정 규칙 세 가지

– **F 10 미만이면 추정치를 쓰지 않는다.** 표준오차와 p값은 약한 도구를 경고해 주지 않는다

– **좁은 신뢰구간은 정확성의 증거가 아니다.** OLS는 구간 [2.043, 2.298]로 정밀하게 참값 3.42를 비껴갔다

– **집단 간 차이는 신뢰구간이 겹치지 않을 때만 주장한다.** 그리고 집단마다 1단계 F를 다시 계산한다

□ 부록. 도구변수를 실제로 어디에서 찾는가

○ 이 장의 본문은 가상 데이터로 계산 절차를 익히는 데 썼다. 부록에서는 같은 나눗셈이 현실의 어떤 자료에서 성립하는지를 세 묶음으로 모은다

○ 세 묶음의 성격이 다르므로 쓰는 방법도 다르다

– 부록 A는 원 논문이 있는 **직접 선례**다. 수업에서 설계를 그대로 읽고 세 조건을 점검한다

– 부록 B는 한국 제도에 같은 설계를 옮긴 **설계 아이디어**이며, 선행 연구가 있는지는 각자 확인해야 한다

– 부록 C는 회사에서 매일 돌아가는 자료로, 학생이 졸업 후 가장 먼저 만날 형태다

부록 A. 원 논문이 있는 고전 설계

○ 아래 여섯 설계는 모두 “사람이 스스로 고를 수 없는 조건”을 Z로 썼다

<표 6-8: 도구변수를 쓴 대표 연구 여섯>

설계	처치 D → 결과 Y	도구변수 Z	Z를 사람이 고를 수 없는 이유
징병 추첨	군 복무 → 평생 소득	생일로 뽑은 징집 추첨 번호	생일과 추첨은 본인이 정하지 못한다
통학 거리	대학 진학 → 임금	자란 곳에 4년제 대학이 있었는지	어릴 때 살던 곳은 진학 결정 이전에 정해졌다
의무교육 경계	재학 연수 → 임금	태어난 분기	입학 기준일과 의무교육 연령이 함께 작용해 중퇴 가능 시점이 갈린다
자녀 성비	셋째 출산 → 여성 노동공급	첫 두 자녀의 성별이 같은지	성별은 부모가 정하지 못한다
판사 배정	소년원 수용 → 재범·학업	배정된 판사가 평소 얼마나 엄한지	사건이 판사에게 무작위로 배정된다
강우량	경제 성장 → 내전 발생	전년 강우량	날씨는 어느 나라도 바꾸지 못한다

○ 수업에서는 표를 읽고 끝내지 않고, 설계마다 6.2의 세 조건을 하나씩 묻는다

– 관련성: 분모가 얼마나 되는가. 징병 추첨에서 번호가 낮다고 전원이 복무한 것은 아니므로 분모는 1보다 한참 작다

– 배제제약: Z가 D를 거치지 않고 Y에 닿을 경로가 있는가. 통학 거리라면 “대학이 있는 동네는 일자리도 많다”가 첫 번째 반박 대상이다

– 외생성: Z가 숨은 원인과 얽혀 있는가. 통학 거리라면 “교육에 관심 많은 부모가 대학 근처로 이사했다”가 의심 지점이다

○ 비판이 따라붙은 설계를 함께 읽으면 세 조건을 점검하는 연습이 된다

– 태어난 분기를 Z로 쓴 연구는 표본이 32만 9천 명인데도 분모가 너무 작아 추정치가 흔들린다는 반박을 받았다. 6.4에서 말한 약한 도구변수가 실제 논문에서 문제가 된 사례다

– 강우량을 Z로 쓴 연구에는 설계를 재검토한 논평과 저자들의 재분석이 뒤따랐다. “Z가 D 말고 다른 경로로 Y에 닿는가”를 학생이 직접 따져 보는 재료로 쓴다

○ 서지 사항

– Angrist, J. D. (1990). Lifetime Earnings and the Vietnam Era Draft Lottery. *American Economic Review*, 80(3), 313–336.

– Card, D. (1995). Using Geographic Variation in College Proximity to Estimate the Return to Schooling. In *Aspects of Labour Market Behaviour: Essays in Honour of John Vanderkamp*. (단행본 수록 논문이므로 쪽수는 판본에 따라 다르다)

– Angrist, J. D., & Krueger, A. B. (1991). Does Compulsory School Attendance Affect Schooling and Earnings? *Quarterly Journal of Economics*, 106(4), 979–1014.

– Bound, J., Jaeger, D. A., & Baker, R. M. (1995). Problems with Instrumental Variables Estimation When the Correlation between the Instruments and the Endogenous Explanatory Variables is Weak. *Journal of the American Statistical Association*, 90(430), 443–450.

– Angrist, J. D., & Evans, W. N. (1998). Children and Their Parents' Labor Supply. *American Economic Review*, 88(3), 450–477.

– Aizer, A., & Doyle, J. J. (2015). Juvenile Incarceration, Human Capital, and Future Crime: Evidence from Randomly Assigned Judges. *Quarterly Journal of Economics*, 130(2), 759–803.

– Miguel, E., Satyanath, S., & Sergenti, E. (2004). Economic Shocks and Civil Conflict: An Instrumental Variables Approach. *Journal of Political Economy*, 112(4), 725–753.

– Ciccone, A. (2011). Economic Shocks and Civil Conflict: A Comment. *American Economic Journal: Applied Economics*, 3(4), 215–227.

– Finkelstein, A. et al. (2012). The Oregon Health Insurance Experiment: Evidence from the First Year. *Quarterly Journal of Economics*, 127(3), 1057–1106.

부록 B. 한국 제도에서 찾는 도구변수

○ 아래 네 가지는 **설계 아이디어**다. 같은 설계를 쓴 선행 연구가 있는지, 필요한 자료를 받을 수 있는지는 과제를 시작하기 전에 각자 확인한다

<표 6-9: 한국 제도에 기대어 세울 수 있는 설계 네 가지>

제도	처치 D → 결과 Y	도구변수 Z	분모가 생기는 이유
추첨으로 뽑는 공공사업	지원 수령 → 주거 안정·소득	추첨 당첨 여부	추첨은 신청자의 성향과 무관하게 결정된다
제도 시행 연도 경계	재학 연수 → 임금	태어난 해	무상교육·의무교육 확대 시점이 출생 연도마다 다르다
지역별 시행 차이	영업시간 제한 준수 → 매출	사업장이 속한 지자체	거리두기 단계와 지급 시점이 지자체마다 달랐다
대학 정원 조정	대학 진학 → 임금	지역별 정원 증가율	정원은 정부·대학 사정으로 정해지고 학생 능력과 무관하다

○ 네 설계가 똑같이 튼튼하지는 않다. 배제제약이 깨질 위험은 아래로 갈수록 크다

– 추첨 당첨 여부는 당첨 자체가 결과에 직접 닿을 경로를 떠올리기 어렵다. 네 설계 중 가장 안전하다

– 거리두기 단계를 Z로 쓰면 단계가 영업시간 말고도 소비 심리와 이동량을 함께 바꾸므로, Z가 D를 거치지 않고 매출에 닿는다. 이 설계를 쓰려면 다른 경로를 하나씩 반박해야 하고, 반박하지 못하면 6장이 아니라 다른 설계를 골라야 한다

– 태어난 해를 Z로 쓰면 같은 해에 태어난 사람이 같은 경기 국면과 같은 입시 경쟁을 함께 겪으므로, 연도 효과를 따로 통제했는지 확인한다

○ 네 번째 설계는 이미 6.8 실습에서 돌려 봤다. 실습 데이터는 가상이지만 제도 구조는 실제와 같으므로, 실제 자료로 옮길 때 무엇을 구해야 하는지 바로 적을 수 있다

– 필요한 것은 세 가지다. 지역·연도별 정원 자료, 개인의 진학 여부와 임금, 그리고 둘을 잇는 지역 코드다

○ 추첨으로 뽑는 사업이 수업 재료로 가장 다루기 쉽다

– 추첨이므로 외생성을 제도로 설명할 수 있고, 당첨되고도 신청을 포기한 사람이 있어 순응자 개념이 그대로 맞는다

– 다만 당첨자 명단과 결과 자료를 함께 볼 수 있어야 하므로, 자료 접근 가능성을 먼저 확인한 뒤 주제를 정한다

○ 주의할 점 하나를 미리 적는다. 지역을 Z로 쓰는 설계에서는 같은 지역 사람끼리 오차가 묶이므로, 표준오차를 지역 단위로 묶어 계산했는지 보고서에 밝힌다(실무 점검표의 다섯 번째 항목)

부록 C. 비즈니스 — 권유는 무작위, 사용은 선택

○ 회사의 A/B 테스트에서 **권유만 무작위로 배정하고 실제 사용은 사용자가 고르는** 상황은 전부 이 장의 구조다

<표 6-10: 실무에서 자주 나오는 네 가지>

상황	도구변수 Z	처치 D	결과 Y
푸시 알림 무작위 발송	알림을 받았는지	기능을 켰는지	체류시간
쿠폰 무작위 발송	쿠폰을 받았는지	구독했는지	매출
배송 지연	날씨·물류 사고로 늦어졌는지	늦게 받았는지	재구매 여부
광고 입찰 경쟁	경쟁 강도로 갈린 노출 여부	광고를 봤는지	구매 전환

○ 여기서 학생이 가장 자주 오해하는 것을 바로잡는다. **무작위 배정을 했는데도 도구변수가 필요한 경우가 실무에서는 더 흔하다**

– 알림을 받고도 기능을 안 켠 사람이 있으므로 Z와 D가 다르다. 알림을 받은 집단과 안 받은 집단을 그냥 비교한 값은 “알림의 효과”일 뿐 “기능의 효과”가 아니다

– 둘을 구분해 부르는 이름이 있다. 받은 쪽과 안 받은 쪽의 결과 차이가 **ITT**(의도된 처치효과)로 6.2 나눗셈의 분자이고, 그것을 사용률 차이로 나눈 값이 기능 자체의 효과다

○ 실무 계산 예(가상의 수치다). 알림을 보낸 집단의 기능 사용률이 35%, 안 보낸 집단이 15%이고, 체류시간이 각각 48분과 42분이라면

```
분자 (ITT)   48 − 42 = 6분
분모 (사용률) 0.35 − 0.15 = 0.20

기능을 켠 1명당 효과 = 6 ÷ 0.20 = 30분
```

– 보고할 때 두 숫자를 모두 싣는다. 알림을 전체에 보낼지는 ITT 6분으로 정하고, 기능 자체를 개선할지는 30분으로 정한다. **쓰임이 다르므로 하나만 보고하면 결정을 그르친다**

– 6.8의 정책 계산과 같은 구조다. 총효과 = 움직인 사람 비율 × 1인당 효과이며, 0.20 × 30 = 6분으로 분자가 다시 나온다

○ 사용률 차이가 작으면 이 계산을 하지 않는다. 분모 0.02에서 나온 추정값이 얼마나 흔들리는지는 6.4에서 숫자로 확인했다