7장. 분위 회귀와 분포적 처치효과

□ 이 장의 질문

○ 한 지역의 평균 임금이 정책 시행 뒤 70에서 72로 올랐다. "정책이 성공했다"고 보고해도 될까

○ 이 장의 답은 "그 숫자만으로는 안 된다"이다. 모든 사람이 2씩 오른 경우와, 상위 20%만 10씩 오르고 하위 절반은 전혀 오르지 않은 경우 모두 평균은 똑같이 2가 오른다

○ 이 장은 평균 대신 **분포의 여러 지점**(하위 10%, 중간, 상위 10%)에서 효과를 따로 구하는 방법을 배운다. 방법마다 같은 순서를 따른다: 왜 필요한가 → 원리(손으로 계산하는 작은 예) → 코드 → 결과 읽기

□ 이 장을 읽는 방법

○ 이 장은 두 파트로 나뉜다

– 1부(7.1~7.2): "줄 세워 몇 번째 값"이라는 분위수의 원리를 익히고, 분위 회귀와 RIF 회귀로 분위별 효과 표 두 개를 만든다

– 2부(7.3~7.6): 그 도구를 전후 비교(분포적 DID)와 기계학습(분위 랜덤 포레스트)으로 넓히고, 나온 숫자를 정책 판단으로 옮긴다

○ 수식은 쓰지 않는다. 원리는 5~10명짜리 작은 예를 손으로 계산해 이해한다

○ 실습 코드는 practice/chapter07/code/ 에 있다. 스크립트를 실행하면 콘솔 출력 전체가 practice/chapter07/results/<스크립트명>.log 로 저장되고, 그림도 results 폴더에 저장된다. 본문의 실행 결과 발췌는 이 코드가 실제로 계산한 값이다. 원리를 보이려고 손으로 만든 작은 예는 "가상의 수치"라고 표시한다

○ 용어 미리보기 — 본문에서 처음 나올 때마다 다시 풀어 설명하므로, 여기서는 눈에 익히기만 하면 된다

용어	쉬운 뜻
분위수	전원을 값 순서로 줄 세웠을 때, 앞에서 일정 비율(τ) 지점에 있는 사람의 값
중위수	줄의 정확히 한가운데(τ=0.5) 사람의 값
분위 회귀	평균이 아니라 분위수가 설명변수에 따라 어떻게 움직이는지 구하는 회귀
체크 함수	위로 빗나감과 아래로 빗나감에 벌점을 다르게 매겨, 원하는 분위수를 찾게 하는 채점 규칙
조건부 분위 효과	특성(교육·나이 등)이 같은 사람들 안에서 구한 분위별 효과
무조건부 분위 효과	사회 전체를 한 줄로 세워 놓고 구한 분위별 효과
QTE	처치가 결과 분포의 각 지점을 움직인 크기(분위 처치효과)
QTT	처치받은 집단 안에서만 구한 QTE
RIF 회귀	분위수를 회귀에 넣을 수 있는 변수로 바꿔, 무조건부 효과를 구하는 방법
분포적 DID	처치·대조군의 전후 비교(DID)를 평균 대신 분위수마다 반복하는 방법
CIC	대조군의 "변화량" 대신 "줄에서의 위치"를 옮겨 와 반사실을 만드는 방법
coverage	분위 예측선보다 아래에 실제 값이 들어온 비율. τ와 비슷해야 합격

1부. 평균에서 분위수로 — 분포의 어디가 움직였는지 구한다

□ 1부 개요

○ 이 파트가 끝나면: 분위별 계수 표(표 7-1)와 분위별 처치효과 표(표 7-2)를 직접 만들고, 각 행에 판정 기준을 적용해 보고 문장을 쓸 수 있다

○ 다루는 절: 7.1 ~ 7.2

□ 7.1 분위수와 분위 회귀

7.1.1 왜 평균 하나로는 안 되는가

○ 평균이 같아도 사는 모습은 전혀 다를 수 있다

– 상황 A: 모든 사람의 임금이 고르게 2씩 올랐다. 상황 B: 상위 20%만 10씩 오르고 하위 50%는 전혀 오르지 않았다. 두 상황의 평균 상승분은 같다

– 상황 A는 격차가 그대로인 성장이고, 상황 B는 격차가 커진 성장이다. 평균 하나로는 두 상황을 구분할 수 없다

○ 이 구분이 필요한 상황은 정책과 비즈니스 양쪽에 흔하다

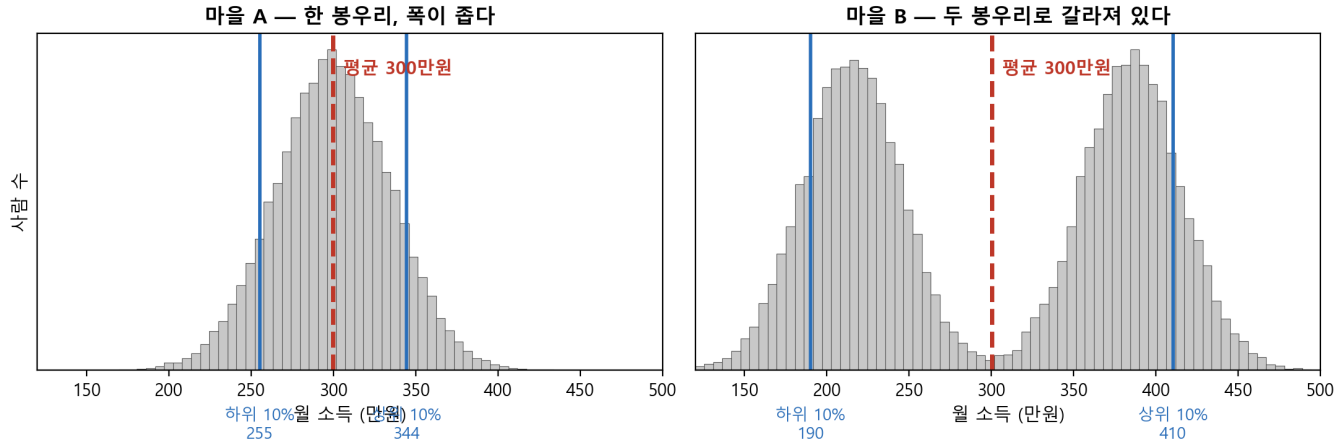
– 최저임금 인상은 임금 분포의 아래쪽을 겨냥한 정책이므로, 상위 구간에 효과가 없어도 실패가 아니다. 평가 기준이 "하위 구간이 올랐는가"다

– 배송 서비스에서 문제가 되는 것은 평균 배송 시간이 아니라 상위 5% 지연 시간이다. 평균 30분이어도 20명 중 1명이 두 시간을 기다리면 품질 문제다

○ 비유: 강을 건널지 판단하는 일. 강의 평균 수심(=결과의 평균)이 1.2m여도 가장 깊은 지점(=상위 분위)이 3m면 건널 수 없다. 판단에 필요한 값은 평균이 아니라 지점별 깊이다

– 이 비유는 여기까지만 맞다. 강의 깊이는 위치를 정해 다시 측정하면 되지만, 소득의 "상위 10%"는 고정된 사람 집단이 아니라 매번 줄을 다시 세워 정해지는 위치다

그림 7-1. 두 마을의 평균 소득은 같다. 사는 모습은 같지 않다.



평균 하나만 보고하면 두 마을이 구별되지 않는다. 하위 10%와 상위 10%를 같이 보면 갈라진다.

○ 그림 7-1 읽는 법

– 두 마을 모두 평균 월 소득이 300만원(빨간 점선)으로 같다. 마을 A는 한 봉우리로 모여 있고(하위 10% 255만원, 상위 10% 344만원), 마을 B는 두 봉우리로 갈라져 있다(하위 10% 190만원, 상위 10% 410만원)

– 평균 하나만 보고하면 두 마을이 구별되지 않는다. 하위 10%와 상위 10% 값을 함께 보면 갈라진다

한 줄 정리: 평균은 분포를 숫자 하나로 눌러 놓은 값이다. 정책 판단에는 눌리기 전의 지점별 값이 필요하다.

7.1.2 분위수 — 줄 세운 뒤 몇 번째 사람의 값

○ **분위수(quantile)** 는 전원을 값 순서로 줄 세운 뒤, 앞에서 일정 비율 지점에 있는 사람의 값이다. 그 비율을 τ(타우)라고 쓴다

– τ=0.10이면 앞에서 10% 지점(하위 10%), τ=0.50이면 한가운데, τ=0.90이면 90% 지점(상위 10% 경계)의 값이다

– τ=0.50의 값은 따로 **중위수(median)** 라고 부른다

○ 손으로 계산해 본다. 9명의 월 소득(만원)이 100, 120, 130, 150, 180, 200, 240, 300, 900이라고 하자 (가상의 수치다)

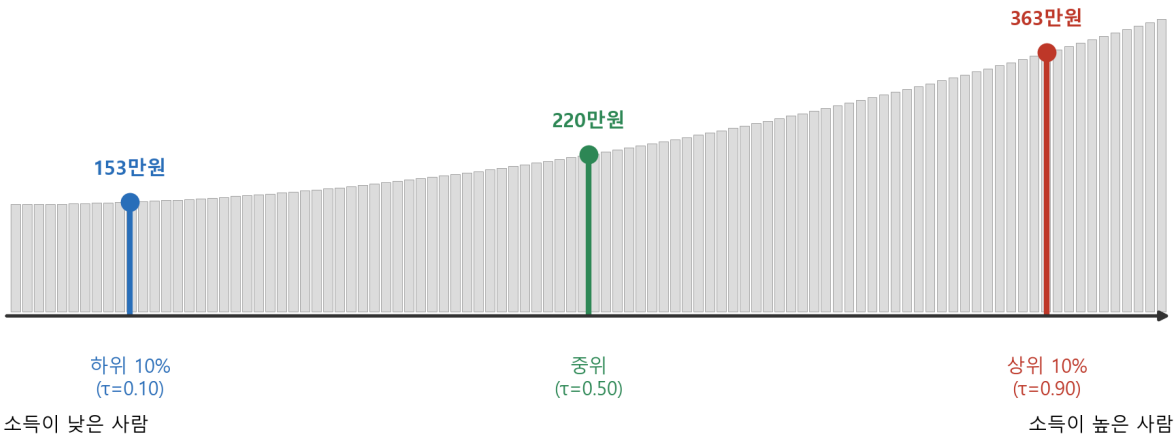
– 중위수는 줄의 5번째 사람의 값인 180이다. 하위 지점을 보려면 앞쪽(100, 120)을, 상위 지점을 보려면 뒤쪽(300, 900)을 읽는다

– 평균은 2,320 ÷ 9 ≈ 258이다. 900을 버는 한 명이 평균을 중위수보다 78만큼 끌어올렸고, 9명 중 7명은 평균보다 적게 번다

– 원리: 평균은 모든 값을 더하므로 극단값 하나에 끌려가고, 분위수는 줄의 순서만 쓰므로 극단값이 얼마나 큰지에 흔들리지 않는다

그림 7-2. 분위수는 줄 세운 뒤 몇 번째 사람인지를 가리킨다

100명을 소득 순으로 줄 세운다. τ분위수는 앞에서 τ×100번째 사람의 소득이다.



○ 그림 7-2 읽는 법

– 100명을 소득 순으로 줄 세운 그림이다. τ분위수는 앞에서 τ×100번째 사람의 소득이다

– 이 그림의 예에서는 하위 10%(τ=0.10) 지점이 153만원, 중위(τ=0.50)가 220만원, 상위 10%(τ=0.90) 지점이 363만원이다

한 줄 정리: 분위수는 "줄 세워 몇 번째 사람의 값"이다.

7.1.3 분위 회귀의 원리 — 벌점을 비대칭으로 매기면 분위수가 나온다

○ **분위 회귀(quantile regression)** 는 분위수가 설명변수에 따라 어떻게 움직이는지 구하는 회귀다 (Koenker & Bassett, 1978)

– 보통의 회귀(OLS)는 "교육이 1년 늘면 소득의 **평균**이 얼마나 오르는가"에 계수 하나로 답한다

– 분위 회귀는 τ를 하나 정하고 "교육이 1년 늘면 그 τ 지점의 소득이 얼마나 오르는가"에 답한다. τ=0.10, 0.50, 0.90마다 **다른 계수**가 나온다

○ 컴퓨터는 어떻게 "τ 지점"을 찾는가. 답은 **체크 함수(check function)** 라는 채점 규칙이다. 예측선을 여러 위치에 놓아 보고, 벌점 합이 가장 작은 위치를 고른다

– OLS는 예측선이 실제 값에서 위로 빗나가든 아래로 빗나가든 같은 방식으로 벌점을 준다(빗나간 거리의 제곱). 그래서 선이 평균에 멈춘다

– 체크 함수는 방향에 따라 단가를 다르게 매긴다. τ=0.9이면, 예측이 실제보다 낮을 때(과소 예측)는 거리 1당 벌점 0.9, 높을 때(과대 예측)는 거리 1당 벌점 0.1이다

○ 손으로 계산한다. 값이 10, 20, 30, 40, 100인 다섯 개 관측치에서, 예측선(=하나의 숫자 c)을 여러 위치에 놓고 벌점 합을 비교한다(가상의 수치다)

– τ=0.5(위아래 단가 모두 0.5): c=30이면 거리가 20, 10, 0, 10, 70으로 합 110이고 벌점은 55다. c=40이면 거리 합 120, 벌점 60이다. 30이 더 작으므로 선은 중위수 30에 멈춘다

– τ=0.9(과소 예측 0.9, 과대 예측 0.1): c=30이면 벌점 75, c=40이면 60, c=100이면 30, c=110이면 35다. 벌점이 가장 작은 c=100이 이 다섯 개 값의 90분위수다

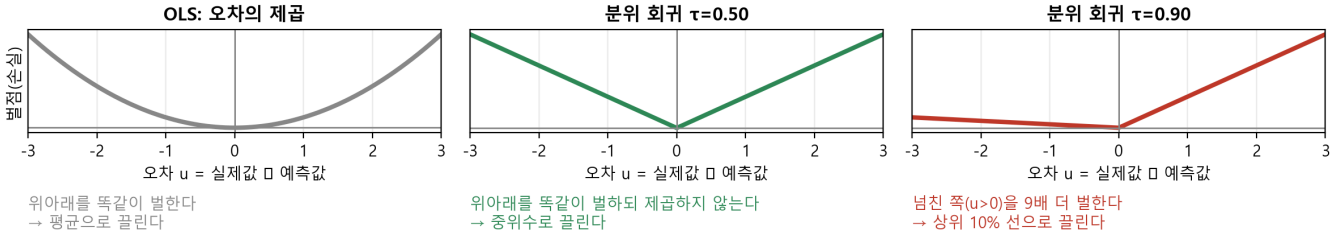
– 평균은 40이므로 OLS는 40을 답으로 낸다. 100이 1,000으로 바뀌어도 중위수는 30 그대로이며, 극단값 하나가 값을 끌고 가지 못하는 이 성질을 "이상치에 강건하다"고 한다

○ 왜 비대칭 단가가 90분위에서 멈추게 하는가

– τ=0.9에서 선을 1만큼 올리면, 선 아래 점들은 벌점이 0.1씩 늘고 선 위 점들은 0.9씩 준다. 아래쪽 점의 비율이 90%가 되기 전까지는 올리는 쪽이 이득이다

– 아래쪽 점이 정확히 90%가 되는 위치에서 늘어난 벌점과 줄어든 벌점이 같아져 선이 멈춘다. 그 위치가 90분위수다. τ=0.5이면 위아래 단가가 같으므로 점 개수가 같아지는 위치, 곧 중위수에서 멈춘다

그림 7-4. 어느 쪽 오차를 더 아프게 벌하느냐로 목표 지점이 정해진다



○ 그림 7-4 읽는 법

– 왼쪽(OLS)은 위아래를 똑같이 거리의 제곱으로 벌한다 → 선이 평균에 멈춘다

– 가운데(τ=0.50)는 위아래를 똑같이 벌하되 제곱하지 않는다 → 선이 중위수에 멈춘다

– 오른쪽(τ=0.90)은 과소 예측 쪽을 9배 더 벌한다 → 선이 상위 10% 경계에 멈춘다

한 줄 정리: 벌점 단가의 비율이 τ를 정한다. 위쪽 빗나감을 9배 벌하면 선은 90분위에서 멈춘다.

7.1.4 실습 7-1 — 분위별 계수 표를 만들고 판정한다

○ 실습 데이터: 5,000명의 임금 자료(income, education, experience). 교육과 경력이 소득 분포의 다섯 지점(τ=0.10, 0.25, 0.50, 0.75, 0.90)에서 각각 얼마나 작용하는지 구한다

○ 실습 코드(핵심 부분, 전체는 `7-1-basic-quantile-regression.py`)

```
for q in quantiles:                          # [0.10, 0.25, 0.50, 0.75, 0.90]
    mod = smf.quantreg('income ~ education + experience', data=df)
    results[q] = mod.fit(q=q)                # q가 곧 τ. 같은 회귀를 τ만 바꿔 반복
ols_res = smf.ols('income ~ education + experience', data=df).fit()  # 비교 기준선
```

○ 실행 결과(`results/7-1-basic-quantile-regression.log` 발췌)

```
Quantile Edu_Coef Edu_SE Exp_Coef Exp_SE
    0.10  2.18*** (0.23)  1.02*** (0.08)
    0.25  2.38*** (0.32)  0.94*** (0.11)
    0.50  3.50*** (0.37)  0.91*** (0.13)
    0.75  4.88*** (0.33)  0.94*** (0.11)
    0.90  5.26*** (0.30)  0.96*** (0.10)
     OLS  3.72*** (0.23)  0.96*** (0.08)

[Wald Test] H₀: 10분위와 90분위 교육 계수 동일
Wald 통계량: 66.96 / p-value: 0.0000 / 계수 차이: 3.08

[Breusch-Pagan Test] LM 통계량: 85.60 / p-value: 0.0000
```

○ 이 출력을 정리한 것이 표 7-1이다

<표 7-1: 분위별 교육·경력 계수와 OLS 비교>

분위수 (τ)	교육 계수	경력 계수	읽는 법
0.10	2.18	1.02	하위 10% 지점에서 교육 1년당 소득 2.18 증가
0.25	2.38	0.94	하위 25% 지점에서 2.38 증가
0.50	3.50	0.91	중위 지점에서 3.50 증가
0.75	4.88	0.94	상위 25% 지점에서 4.88 증가
0.90	5.26	0.96	상위 10% 지점에서 5.26 증가
OLS(평균)	3.72	0.96	평균 효과 3.72

○ 표 읽는 순서와 판정 눈금

– 첫째, 표를 위에서 아래로 내려가며 계수가 어떻게 변하는지 본다. 교육 계수는 2.18에서 5.26으로 2.4배가 된다. 교육 1년의 효과가 소득이 이미 높은 구간에서 더 크므로, 교육 확대만으로는 격차가 좁혀지지 않는다고 읽는다. 경력 계수는 1.02~0.91로 거의 일정하다. **변동폭이 작은 변수는 평균 하나로 보고해도 정보 손실이 적다**

- 둘째, 분위 간 차이가 표본 흔들림이 아닌지 Wald 검정으로 확인한다. **판정 눈금: p < 0.05면 분위별 표를 보고서에 싣고, p ≥ 0.05면 평균 효과 하나만 보고한다.** 여기서는 p < 0.001이므로 분위별 보고가 필요하다
- 셋째, 이분산성(X 값에 따라 오차의 흩어진 정도가 달라지는 성질)을 본다. Breusch-Pagan 검정 p < 0.05면 OLS에는 강건 표준오차를 적용한다. 여기서는 LM 85.60(p < 0.001)이 이에 해당한다. 분위 회귀는 지점별로 따로 추정하므로 이 문제에 자연스럽게 대응한다

○ 판정 연습(가상의 수치다): 두 분석에서 10분위-90분위 계수 차이의 Wald p값이 각각 0.61, 0.002라면

- 0.61은 분위별 표를 만들지 않고 평균 효과만 보고한다. 0.002는 분위별 표를 싣고 어느 구간에서 효과가 큰지 본문에 적는다

한 줄 정리: 분위별 표는 "차이가 유의한가(Wald)"를 통과했을 때만 싣는다. 통과하지 못하면 평균 하나로 충분하다.

□ 7.2 처치효과를 분위별로 — QTE와 RIF 회귀

7.2.1 조건부와 무조건부 — 두 문장은 다른 값을 가리킨다

○ 7.1의 분위 회귀로 정책 보고서를 쓰려면 먼저 이 구분이 필요하다. 아래 두 문장은 뜻이 다르다

- "전체 임금 분포의 하위 25% 지점이 올랐다" — **무조건부(unconditional)** 진술이다. 사회 전체를 한 줄로 세웠을 때의 위치를 말한다
- "나이와 학력이 같은 사람들 안에서 하위 25% 지점이 올랐다" — **조건부(conditional)** 진술이다. 특성을 고정한 하위 집단 안에서의 위치를 말한다

○ 7.1의 분위 회귀는 기본적으로 조건부다. "어떤 특성의 집단에서 효과가 큰가"를 볼 때 맞는 도구다

○ 정책 보고서의 문장 — "정책이 하위 10% 임금을 올렸다" — 은 대개 무조건부다. 이 값을 구하려면 아래 RIF 회귀가 필요하며, 조건부 계수를 그대로 옮겨 쓰면 틀린 해석이 된다. 두 값이 실제로 얼마나 벌어지는지는 7.2.4의 실측(조건부 184 대 무조건부 511)에서 확인한다

한 줄 정리: "같은 특성인 사람들 안에서"와 "사회 전체에서"는 다른 질문이다. 보고서 문장이 어느 쪽인지부터 정한다.

7.2.2 QTE와 QTT — 분포의 지점을 따라가는 효과

○ 정책 평가에서 묻는 것은 대개 처치 여부다: 직업훈련이 하위 10% 소득자의 소득을 얼마나 올렸는가, 상위 10%에는 얼마나 작용했는가

○ 용어 셋을 구분한다

- **QTE(분위 처치효과)**: 처치받았을 때의 결과 분포와 받지 않았을 때의 결과 분포에서, 같은 τ 지점의 값을 뺀 것
- **QTT**: 처치받은 집단 안에서만 같은 계산을 한 것. 7.3의 전후 비교 설계에서 주로 나온다

- **CQTE(조건부 QTE)**: 특성을 고정한 뒤의 QTE. "40대 고졸 남성 안에서의 분위 효과"처럼 집단을 지정해 본다

○ 주의: QTE는 **같은 사람의 변화가 아니라 줄에서 같은 위치의 변화**다

- 처치 전 하위 10%였던 사람이 처치 후에도 하위 10%에 있다는 보장은 없다. "QTE(0.10) = 64만원"은 "하위 10% **지점의 값**이 64만원 높아졌다"이지 "그 사람의 소득이 64만원 올랐다"가 아니다

한 줄 정리: QTE는 분포의 지점을 따라가는 값이지 개인을 따라가는 값이 아니다.

7.2.3 RIF 회귀의 원리 — 분위수를 사람마다 쪼개 회귀에 넣는다

○ 왜 필요한가: 평균은 각 사람의 값을 더해 나눈 것이라 "사람마다의 기여"가 나뉘어 회귀에 바로 들어간다. 분위수는 줄 세우기로 정해지는 값이라 사람마다의 기여가 바로 나뉘지 않는다

○ Firpo, Fortin & Lemieux(2009)의 **RIF 회귀**는 각 사람에게 "이 사람이 분위수를 올리는 쪽인가 내리는 쪽인가"를 숫자 하나(RIF 값)로 매겨 이 문제를 푼다. 그 숫자를 종속변수로 삼아 보통의 OLS를 돌리면, 처치 변수의 계수가 무조건부 QTE가 된다

○ 손으로 계산한다(가상의 수치다). 10명의 중위수가 q=200이고, 중위수 주변의 붐비는 정도(밀도)가 낮아 1/밀도=200이라고 하자

- RIF 값은 "분위수 + (τ − 표시) ÷ 밀도"로 만든다. 여기서 표시는 그 사람이 분위수 이하면 1, 위면 0이다. τ=0.5이므로 중위수 이하인 5명은 200 + (0.5−1)×200 = 100, 위인 5명은 200 + 0.5×200 = 300이다
- 10명의 RIF 평균은 (5×100 + 5×300) ÷ 10 = 200으로, 중위수와 같다. 어느 τ에서나 RIF의 평균은 그 분위수가 되도록 설계되어 있다. 평균이 분위수와 같은 변수이므로, 평균을 다루는 OLS로 분위수를 분석할 수 있다
- 훈련군 10명 중 7명이 q 위에 있다면 훈련군의 RIF 평균은 (7×300 + 3×100) ÷ 10 = 240이다. 대조군은 3명만 위에 있다면 (3×300 + 7×100) ÷ 10 = 160이다. 차이 80이 "훈련이 중위수를 올린 크기"의 추정값이다. 훈련군에서 q 위에 있는 사람의 비율이 클수록 중위수가 많이 오른다는 원리를 그대로 숫자로 옮긴 것이다

○ 밀도가 나눗셈의 분모에 들어간다는 점이 실무에서 중요하다

- 사람이 드문 구간, 곧 분포의 양 끝에서는 밀도가 작아 RIF 값이 크게 요동친다. 그래서 τ=0.01, 0.99 같은 극단 분위의 추정은 불안정하며, 인용할 때 단서를 붙인다

한 줄 정리: RIF는 "이 사람이 분위수를 미는 방향과 힘"을 변수로 만들어, 분위수 문제를 보통의 회귀 문제로 바꾼다.

7.2.4 실습 7-2 — 직업훈련의 분위별 효과 표를 만들고 판정한다

○ 실습 데이터: 3,000명의 직업훈련 자료(income, training, education, age). 훈련 참여율 51.1%. 훈련이 소득 분포의 다섯 지점을 얼마나 밀어 올렸는지 구한다

○ 실습 코드(핵심 부분, 전체는 `7-2-rif-unconditional-qte.py`). 위 손계산의 순서와 같다

```
def compute_rif(y, tau):
    q_tau = np.quantile(y, tau)                          # 표본 τ분위수
    kde = gaussian_kde(y, bw_method='silverman')         # 붐비는 정도(밀도) 추정
    f_q = np.maximum(kde.evaluate(q_tau)[0], 1e-6)
    indicator = (y <= q_tau).astype(float)               # 분위수 이하면 1
    return q_tau + (tau - indicator) / f_q               # 사람마다 RIF 값 하나

df_temp['rif_income'] = compute_rif(df['income'].values, tau)
res = smf.ols('rif_income ~ training + education + age',
              data=df_temp).fit(cov_type='HC3')          # training 계수 = 무조건부 QTE
```

○ 실행 결과(`results/7-2-rif-unconditional-qte.log` 발췌)

```
 Quantile   UQTE SE      CI_95
     0.10  64***  4   [56, 71]
     0.25 143***  5 [134, 152]
     0.50 511***  7 [497, 524]
     0.75 128***  4 [119, 136]
     0.90  62***  4   [55, 69]
ATE (OLS) 185***  2 [181, 189]

[분위 간 효과 차이 검정] H₀: UQTE₀.₁₀ = UQTE₀.₉₀
효과 차이: 2 만원 / Wald 통계량: 0.12 / p-value: 0.732

[조건부 vs 무조건부 QTE 비교 (τ=0.50)]
Conditional QTE (분위 회귀): 184 (SE=3)
Unconditional QTE (RIF 회귀): 511 (SE=7) / 차이: 326
```

○ 이 출력을 정리한 것이 표 7-2다. 표의 값은 훈련 참여 비율이 0에서 1(100%p)로 바뀔 때의 선형 근사다. 같은 로그에 참여율 1%p 상승당 5.11만원(τ=0.50)으로 환산한 줄이 있다

<표 7-2: RIF 회귀로 추정한 무조건부 분위 처치효과 (직업훈련, 만원)>

분위수 (τ)	UQTE	표준오차(HC3)	95% 신뢰구간	읽는 법
0.10	64	4	[56, 71]	하위 10% 지점 64만원 상승
0.25	143	5	[134, 152]	하위 25% 지점 143만원 상승
0.50	511	7	[497, 524]	중위 지점 511만원 상승
0.75	128	4	[119, 136]	상위 25% 지점 128만원 상승
0.90	62	4	[55, 69]	상위 10% 지점 62만원 상승
ATE(OLS)	185	2	[181, 189]	평균 185만원 상승

○ 표 읽는 순서와 판정 눈금

– 첫째, 신뢰구간이 0을 포함하는 분위가 있는지 본다. **판정 눈금: 포함하면 그 지점의 효과는 "확인되지 않았다"로 쓰고 숫자를 단정적으로 인용하지 않는다.** 여기서는 다섯 분위 모두 구간 아래 끝이 0보다 크다

– 둘째, 효과의 모양을 읽는다. 하위 64 → 중위 511 → 상위 62로 가운데가 솟은 역U자다. 훈련이 중간층에 크게, 양 끝에 작게 작용했다는 뜻이다

– 셋째, 정책 목표가 놓인 분위의 값을 읽는다. 목표가 빈곤 완화라면 판단 기준은 하위 분위 값 64만원이지 평균 185만원이 아니다

– 넷째, 양 끝을 비교한다. 하위 10%(64)와 상위 10%(62)의 차이는 2만원, Wald 0.12(p=0.732)다. **판정 눈금: p ≥ 0.05면 "격차를 줄였다"고 쓸 수 없다.** 정확한 서술은 "불평등 완화 효과는 확인되지 않았다"이다

– 다섯째, 조건부와 무조건부의 차이를 본다. 중위 기준 조건부 184만원 대 무조건부 511만원으로 326만원 벌어졌다. 두 값은 묻는 질문이 다르므로 — 특성이 같은 사람 안에서의 효과 대 사회 전체 분포의 반응 — 한 문장에 섞지 않고 보고 목적에 맞는 쪽을 골라 쓴다

○ 자주 하는 실수 세 가지

– 7.1의 분위 회귀 계수(특성의 조건부 효과)를 QTE(처치의 효과)로 착각한다. 계산 대상이 다르다

– "평균 185만원 상승했고 특히 저소득층에 효과적이었다"라고 쓴다. 이 표에서 저소득층 효과(64만원)는 가장 작은 축이므로, 표에서 나올 수 없는 문장이다

– 극단 분위(τ=0.95, 0.99)의 값을 단서 없이 결론에 쓴다. RIF의 분모(밀도)가 작아지는 구간이라 값이 흔들린다

한 줄 정리: 분위별 효과 표는 "목표 분위의 값 + 양 끝 차이의 유의성"으로 읽는다. 평균 문장과 분포 문장은 분리한다.

□ 1부 정리

○ 지금까지 만든 것 두 가지: 특성(교육·경력)의 조건부 분위별 계수 표(표 7-1), 처치(직업훈련)의 무조건부 분위별 효과 표(표 7-2)

○ 확인한 판정 기준
  – 분위 간 계수 차이는 Wald 검정 $p < 0.05$일 때만 분위별로 보고한다
  – 신뢰구간이 0을 포함하는 분위의 효과는 "확인되지 않았다"로 쓴다
  – "격차를 줄였다"는 문장은 양 끝 차이의 검정을 통과해야 쓸 수 있다
○ 두 표 모두 관측 데이터에 회귀를 적용해 얻은 값이므로, 처치 배정이 무작위가 아니라면 인과 해석에 추가 가정이 필요하다. 2부에서는 전후 비교 설계로 그 가정을 명시하고, 기계학습으로 곡선 관계를 다룬다

2부. 전후 비교와 기계학습으로 넓히고, 정책 판단으로 옮긴다

□ 2부 개요

○ 이 파트가 끝나면: 분포적 DID로 분위별 QTT 표를 만들고, 기계학습 분위 예측을 coverage로 판정하고, 종합 사례에서 네 방법의 결과를 나란히 놓고 결론을 쓸 수 있다
○ 다루는 절: 7.3 ~ 7.6

□ 7.3 분포적 DID와 Changes-in-Changes — 시간 축을 더한다

7.3.1 원리 — DID의 뺄셈을 분위마다 반복한다

○ 왜 필요한가: 5장의 DID는 처치군과 대조군의 사전·사후 **평균** 변화를 비교했다. 그런데 최저임금 인상은 임금 분포의 아래쪽을 밀어 올리도록 설계된 정책이라, 평균 DID로는 하위만 크게 오른 경우와 전원이 고르게 오른 경우를 구분하지 못한다
○ **분포적 DID**는 DID의 뺄셈을 평균 대신 분위수마다 반복한다. 각 τ에 대해 네 값을 구해 두 번 뺀다
  – ① 처치군 사후 τ분위수 − ② 처치군 사전 τ분위수 = 처치군의 변화량
  – ③ 대조군 사후 τ분위수 − ④ 대조군 사전 τ분위수 = 대조군의 변화량
  – 처치군 변화량 − 대조군 변화량 = 그 분위의 **QTT**
○ 손으로 계산한다(가상의 수치다). 하위 10% 지점의 시간당 임금(원)이 처치군은 사전 9,000 → 사후 9,300, 대조군은 사전 9,000 → 사후 9,100이라고 하자
  – 처치군 변화량 300, 대조군 변화량 100이므로 하위 10%의 QTT는 300 − 100 = 200원이다. 대조군의 100원은 정책이 없어도 일어났을 변화로 보고 뺀다
○ 이 계산에는 평행추세에 해당하는 가정이 필요하다. 평균 DID가 "정책이 없었다면 두 집단의 평균이 나란히 움직였을 것"을 가정하듯, 분포적 DID는 분포의 모양이 시간이 지나도 안정적이었을 것을 가정한다(Callaway & Li, 2019)

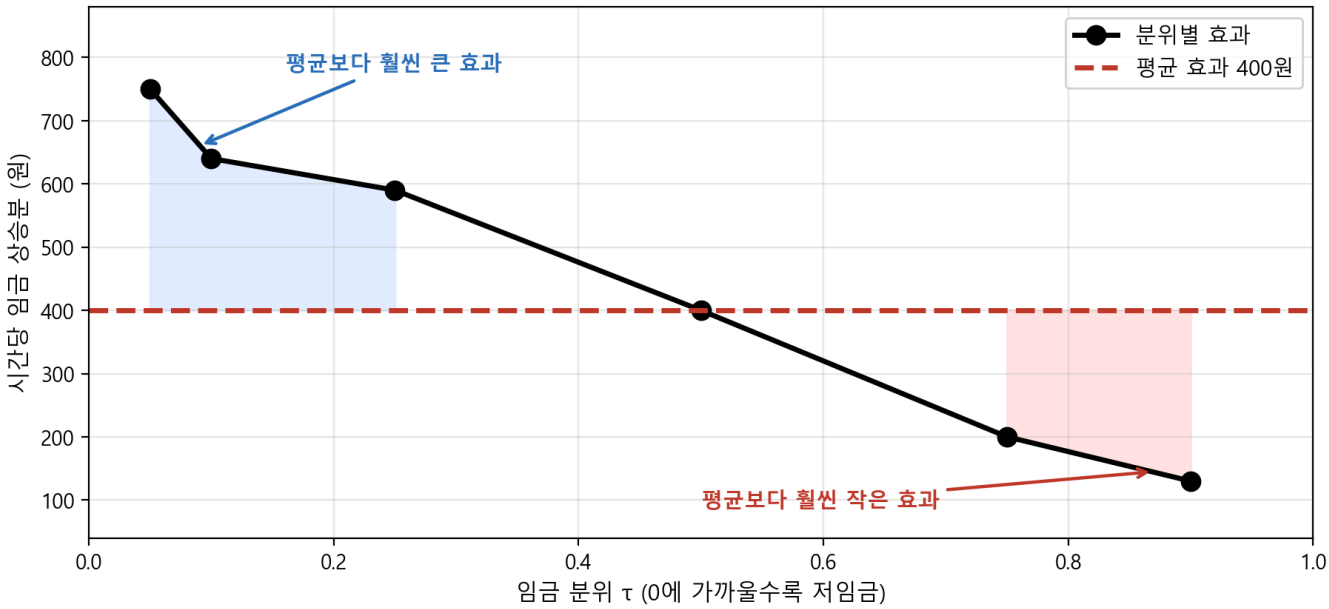
○ **Changes-in-Changes(CIC)** 는 분포가 평행하게 움직이지 않을 때를 대비한 대안이다(Athey & Imbens, 2006)

– 분포적 DID는 대조군의 "변화량"을 옮겨 오고, CIC는 "줄에서의 위치 이동"을 옮겨 온다. 처치군의 사전 값이 대조군 사전 분포에서 몇 번째 위치인지 찾고, 대조군 사후 분포에서 그 위치의 값을 읽어 반사실(정책이 없었을 때의 값)을 만든다

– 예를 들어 처치군 사전 값 9,500이 대조군 사전 분포의 상위 40% 위치이고, 대조군 사후 분포의 같은 위치 값이 9,700이면 반사실은 9,700이다(가상의 수치다)

– 분포가 평행 이동하면 두 방법의 답이 거의 같고, 분포가 늘어나거나 압축되면 갈라진다. 그래서 둘을 나란히 계산해 대조하는 것 자체가 점검 절차가 된다

그림 7-3. 최저임금 인상은 저임금 쪽에서 크게, 고임금 쪽에서 작게 작동한다



평균 400원 하나만 보고하면 750원과 130원이 같은 숫자로 뭉개진다. (모양을 보이려고 그린 예시 값)

○ 그림 7-3 읽는 법 — 분위별 효과의 모양을 보이려고 그린 개념도이며, 그림 속 수치는 예시 값이다

– 가로축은 임금 분위 τ(0에 가까울수록 저임금), 세로축은 시간당 임금 상승분이다. 검은 선(분위별 효과)이 왼쪽에서 높고 오른쪽으로 갈수록 낮아진다

– 빨간 점선이 평균 효과 400원이다. 평균 하나만 보고하면 왼쪽 끝의 750원과 오른쪽 끝의 130원이 같은 숫자로 합쳐진다

7.3.2 실습 7-3 — 분위별 QTT 표를 만들고 판정한다

○ 실습 코드(핵심 부분, 전체는 `7-3-distributional-did.py`). 위 손계산의 네 값을 그대로 구한다

```
for tau in quantiles:              # [0.05, 0.10, 0.25, 0.50, 0.75, 0.90]
    q_treat_post = np.quantile(df_treat_post['outcome'], tau)
    q_treat_pre = np.quantile(df_treat_pre['outcome'], tau)
    q_control_post = np.quantile(df_control_post['outcome'], tau)
    q_control_pre = np.quantile(df_control_pre['outcome'], tau)
    qtt = (q_treat_post - q_treat_pre) - (q_control_post - q_control_pre)
# 표준오차는 개인 단위 부트스트랩(B=500)으로 계산한다
```

○ 실행 결과(`results/7-3-distributional-did.log` 발췌. outcome 단위는 100원/시간이며, 원 단위 열은 100을 곱한 값)

```
Quantile QTT_DID SE_DID    CI95_DID QTT_CIC Won_DID
    0.05    7.4*   1.32 [4.9, 10.1]    8.0*    745원
    0.10    5.9*   1.06  [4.3, 8.4]    6.0*    595원
    0.25    6.0*   0.72  [4.5, 7.4]    5.8*    600원
    0.50    3.9*   0.64  [2.6, 5.0]    4.1*    395원
    0.75    2.0*   0.60  [0.8, 3.1]    2.0*    202원
    0.90     1.0   1.10 [-1.1, 3.4]     2.1    104원

전통적 DID (평균 효과): 3.85 (= 385원/시간, 클러스터 SE=0.41)

[두 방법의 추정값 차이] 분위별 차이의 평균 절댓값: 33원/시간
[불평등 지표] 90-10 비율: 1.31 -> 1.31 / Gini: 0.060 -> 0.057
```

○ 결과를 읽는 판정 눈금 네 가지

– **겨냥 구간 집중**: 하위를 겨냥한 정책은 하위 분위에 효과가 몰려야 한다. 여기서는 효과가 하위 5%의 745원에서 상위 10%의 104원까지 아래쪽에 몰려 있어 설계 의도대로 작동했다. 상위 분위에서 효과가 더 크게 나오면 정책이 의도와 다르게 작동했거나 대조군 선택이 잘못되었을 가능성부터 검토한다

– **0 포함 여부**: 상위 10%의 신뢰구간 [-1.1, 3.4](원 단위 −110~340원)는 0을 포함하므로 상위 구간의 효과는 확인되지 않았다고 쓴다

– **두 방법 대조**: 분포적 DID와 CIC의 분위별 차이는 평균 33원으로, 부트스트랩 표준오차(τ=0.05에서 132원)보다 작다. 차이가 표준오차 안이면 어느 쪽을 써도 결론이 같다. 크게 갈리면 분포가 평행하게 움직이지 않았다는 신호이므로 CIC를 주 결과로 삼는다

– **평균 대 중위**: 전통적 DID 385원과 중위 QTT 395원이 가깝다. 크게 어긋나면 소수의 큰 값이 평균을 끌고 있다는 뜻이므로 중위를 함께 보고한다

○ 분위별 효과와 불평등 지표는 따로 확인한다

– 효과가 하위에 몰렸는데도 90-10 비율(상위 10% 경계값을 하위 10% 경계값으로 나눈 배율)은 1.31에서 1.31로 거의 그대로이고, Gini 계수(0이면 완전 균등, 1이면 한 명이 전부 가진 상태)는 0.060에서 0.057로 0.002 내렸다(로그 기준, 반올림 표기)
– "저임금 근로자에게 더 큰 효과가 갔다"와 "불평등이 완화되었다"는 다른 주장이다. 후자를 쓰려면 지표 변화를 근거로 대야 하며, 이 결과에서는 전자만 성립한다

○ 가정 점검: 정책 이전 기간을 본다
– 정책 시행 이전 여러 시점에서 분위별로 처치군-대조군 격차를 계산해, 격차가 일정하게 유지되었는지 본다. 이미 추세를 그리며 벌어지고 있었다면 추정값에 그 추세가 섞여 있다
– **판정 눈금: 사전 기간의 분위별 격차가 뚜렷한 추세를 보이면 그대로 보고하지 않는다.** 추세를 모형에 넣거나 다른 대조군을 찾는다. 이 점검은 반증 시도이므로, 통과해도 가정이 참으로 증명되는 것은 아니다

한 줄 정리: DID의 뺄셈을 분위마다 반복하면 "정책이 겨냥한 구간에 갔는가"가 보인다. 다만 효과의 집중과 불평등 완화는 별개로 판정한다.

□ 7.4 기계학습 분위 예측 — 한 번 학습해 전 분위를 읽는다

7.4.1 원리 — 평균 대신 값 전체를 저장한다

○ 왜 필요한가: 7.1의 분위 회귀는 관계를 직선으로 놓는다. 변수가 수십 개이거나 관계가 곡선이면 이 가정이 맞지 않는다. 주택 가격이 전형적인 예다 — 면적의 효과는 소형과 대형에서 다르고, 역세권 거리의 효과는 지역에 따라 달라진다

○ **Quantile Regression Forest(QRF)** 는 랜덤 포레스트(3장의 "스무고개 나무" 수백 그루)를 분위 예측으로 넓힌 방법이다(Meinshausen, 2006)
– 보통의 랜덤 포레스트는 나무의 끝 칸마다 도착한 표본들의 **평균**을 저장한다. QRF는 평균 대신 **값 전체**를 저장한다
– 새 관측치가 들어오면 모든 나무에서 그 관측치가 도착한 칸의 값들을 모아 하나의 분포를 만들고, 그 분포를 줄 세워 τ번째 값을 읽는다(7.1.2와 같은 방식이다). 분포를 통째로 갖고 있으므로 **한 번 학습하면 어떤 τ든 다시 학습하지 않고 예측한다**

○ LightGBM 같은 부스팅 계열은 체크 함수(7.1.3)를 학습 목표로 지정하는 방식이라 **분위수마다 모형을 따로 학습**해야 한다

○ 예측이 맞는지는 두 지표로 판정한다
– **pinball loss**: 체크 함수의 벌점을 평가에 그대로 쓴 값이다. 작을수록 그 분위 예측이 정확하다
– **coverage**: 실제 관측치 중 예측선 아래에 놓인 비율이다. τ=0.25 예측이면 25%가 나와야 이상적이다. 예를 들어 테스트 100건 중 실제 값이 25번째 분위 예측선 아래에 25건 있으면 coverage 25%로 정확하다

7.4.2 실습 7-4 — QRF와 LightGBM을 coverage로 판정한다

○ 실습 코드(핵심 부분, 전체는 `7-4-quantile-forest.py`)

```
qrf = RandomForestQuantileRegressor(n_estimators=500, min_samples_split=10,
                                    min_samples_leaf=5, random_state=42, n_jobs=-1)
qrf.fit(X_train, y_train)                    # 학습 한 번

for q in quantiles:                          # [0.05, 0.25, 0.50, 0.75, 0.95]
    lgb_model = lgb.LGBMRegressor(objective='quantile', alpha=q,
                                  n_estimators=500, learning_rate=0.05,
                                  num_leaves=31, random_state=42, verbosity=-1)
    lgb_model.fit(X_train, y_train)          # 분위마다 다시 학습
```

○ 실행 결과(`results/7-4-quantile-forest.log` 발췌. 주택 가격 3,000건, 훈련 2,400 / 테스트 600)

```
Quantile QRF_Pinball LGB_Pinball QRF_Coverage LGB_Coverage Ideal_Coverage
    0.05        3.01        3.77         6.3%        14.3%             5%
    0.25        9.20        9.08        24.0%        29.7%            25%
    0.50       11.22       11.00        48.3%        49.2%            50%
    0.75        8.86        9.04        74.0%        66.2%            75%
    0.95        3.00        3.68        94.0%        84.2%            95%

평균 pinball loss:  QRF 7.06 / LightGBM 7.31
평균 coverage 오차: QRF 1.2%p / LightGBM 6.9%p
훈련 시간: QRF 1.9초(1회) / LightGBM 5.0초(5회)

[90% 예측 구간] 실제 coverage: QRF 87.7% / LightGBM 69.8%
구간 너비: QRF 91만원 / LightGBM 57만원
```

○ 결과를 읽는 순서

– 첫째, coverage로 보정 상태를 판정한다. **판정 눈금: 이상값과의 차이가 ±5%p 이내면 그 분위 예측을 쓰고, 넘으면 의사결정에 직접 쓰지 않는다.** QRF는 다섯 분위 모두 오차 1.7%p 이내로 합격이다. LightGBM은 τ=0.05(+9.3%p)와 τ=0.95(−10.8%p)가 기준을 넘어 극단 분위 예측을 그대로 쓸 수 없다

– 둘째, 90% 예측 구간(τ=0.05~0.95 사이)의 실제 포함률을 본다. QRF 87.7%, LightGBM 69.8%다. LightGBM의 구간은 폭이 57만원으로 좁지만 목표 90%에 20.2%p 모자란다. **좁은 구간이 정확한 구간은 아니다.** 포함률이 모자란 구간을 "90% 구간"이라 표기하면 위험을 낮게 보게 된다

– 셋째, 정확도와 시간을 본다. 평균 pinball loss는 QRF가 3.6% 낮고 훈련도 1회로 끝난다. 이 데이터에서는 정확도·보정·시간 모두 QRF가 앞서지만, 3장에서 확인했듯 **한 데이터의 우열을 다른 데이터로 옮기지 않는다.** 새 데이터마다 coverage를 다시 계산한다

○ 판정 연습(가상의 수치다): 어떤 모형의 τ=0.95 예측 coverage가 84%로 나왔다면

– 이상값 95%와의 차이가 11%p로 기준(±5%p)을 넘는다. 이 예측을 "상위 5% 지연 관리" 같은 의사결정에 쓰지 않고, 모형을 다시 보정하거나 구간을 넓힌 뒤 coverage를 다시 계산한다

한 줄 정리: 기계학습 분위 예측은 정확도보다 coverage부터 본다. ±5%p를 넘는 분위의 값은 결정에 쓰지 않는다.

□ 7.5 종합 사례 — 교육정책 하나를 네 방법으로 비교한다

○ 왜 필요한가: 방법마다 가정이 달라서, 한 방법의 숫자만으로는 결론이 방법 선택의 결과인지 정책의 효과인지 알 수 없다. 같은 데이터에 방법을 여러 개 적용해 숫자가 어떻게 겹치고 갈라지는지 본다

○ 무상 대학교육 정책이 소득 분포에 준 영향을 앞의 방법들로 평가한다: ① RIF 회귀(7.2) ② QRF(7.4) ③ LightGBM 분위 회귀(7.4) ④ 분포적 DID(7.3)

○ 실습 코드(핵심 부분, 전체는 `7-5-education-policy-case.py`). 반사실을 만드는 원리는 "같은 사람을 정책 받음/안 받음 두 가지로 예측해 차이를 낸다"이다

```
qrf = RandomForestQuantileRegressor(n_estimators=300, min_samples_split=10,
                                    min_samples_leaf=5, random_state=42, n_jobs=-1)
qrf.fit(X, y)                                    # X에 policy 변수 포함
df_policy1, df_policy0 = df.copy(), df.copy()    # 반사실 두 벌
df_policy1['policy'], df_policy0['policy'] = 1, 0
# 같은 사람들을 "정책 받음/안 받음"으로 각각 예측해 차이의 평균을 낸다
```

○ 주의: 이 스크립트는 이번 준비 과정의 실행에서 QRF 예측 부분의 코드 오류로 중단되었다 (`results/7-5-education-policy-case.log`가 "Quantile Regression Forest 실행 중..."에서 끝난다). 아래 표 7-6·7-7의 수치는 기존 강의자료가 이전 실행에서 얻어 둔 값이며, 오류를 고친 뒤 직접 실행해 재확인하는 것이 정확하다

<표 7-6: 무상 대학교육 정책의 분위별 처치효과 (연소득, 만원)>

분위수 (τ)	RIF	QRF	LightGBM	분포적 DID
0.05	438	685	529	869
0.25	602	683	621	980
0.50	755	686	646	1,014
0.75	849	688	727	1,073
0.95	796	687	815	1,126

○ 표 읽는 순서 — 방법 간 비교는 세 단계로 한다

– 첫째, **부호가 일치하는가**. 네 방법 모두 전 분위에서 양수다. 부호가 갈리면 보고하지 않고 원인부터 찾는다. 일치하면 "효과가 존재한다"는 결론은 방법 선택에 좌우되지 않는다

– 둘째, **분위별 기울기가 일치하는가**. RIF·LightGBM·분포적 DID는 모두 위쪽 분위에서 값이 크다. QRF만 685 근처에서 평평한데, 단일 모형으로 전 분위를 예측하는 QRF는 분위 간 차이가 줄어드는 경향이 있으므로 분위별 이질성을 볼 때는 다른 방법의 결과를 쓴다

– 셋째, **수준 차이를 설명한다**. 분포적 DID(869~1,126)가 RIF(438~849)보다 일관되게 크다. DID는 수혜자 집단 안의 효과(QTT)를, RIF는 사회 전체 분포에 대한 효과를 추정하므로 서로 다른 것을 추정한 결과다. 어느 쪽이 맞는지 다투지 말고 각각이 답하는 질문을 명시한다

○ 분위별 효과와 불평등 지표를 함께 놓는다 (기존 실행 수치)

<표 7-7: 불평등 지표 변화 (정책 시행 3년 후, 수혜 집단 기준)>

지표	정책 전	정책 후	변화
Gini 계수	0.120	0.106	−0.014 (−11.7%)
90-10 분위수 비율	1.75	1.63	−0.12 (−6.9%)
대학진학률	52.5%	86.8%	+34.3%p
평균 소득	5,214만원	6,246만원	+1,032만원

○ 표 7-6과 표 7-7은 겉보기에 어긋난다 — 분위별 효과는 상위에서 더 큰데 Gini는 11.7% 줄었다. 모순이 아니다

– 표 7-6은 수혜 집단 **안에서의 분위별 효과**를, 표 7-7은 정책 전후 **분포 전체의 형태**를 나타낸다. 하위 분위도 상당한 증가를 얻어 분포 전체가 위로 이동하면, 상대적 격차는 줄어들 수 있다

– **판정 눈금: 분위별 효과 표와 불평등 지표가 다른 방향을 가리키면 둘 다 보고한다.** 정확한 서술은 "정책은 수혜 집단 전체의 소득을 올려 상대적 격차를 줄였으나, 효과의 크기는 소득이 높은 구간에서 더 컸다"이다

○ 시간 축도 확인한다 (기존 실행 수치): 중위 기준 효과는 1년 차 +1,198만원(최종의 37%), 2년 차 +1,568만원(74%), 3년 차 +1,828만원(100%)으로 커지다 안정화된다

– **판정 눈금: 1년 차 효과가 최종값의 절반에 못 미치면 단기 평가로 정책을 판단하지 않는다.** 교육·훈련 정책은 진학과 취업 사이의 시차 때문에 최소 3년을 추적한다

한 줄 정리: 방법 네 개를 나란히 놓고 부호 → 기울기 → 수준 순으로 대조한다. 분위별 효과와 불평등 지표는 반대 방향일 수 있으며, 그때는 둘 다 싣는다.

□ 7.6 연구 동향 — 이 도구들이 넓어지는 방향

○ 이 절은 참고용이며 실습을 동반하지 않는다

– **분포적 합성통제법**: 합성통제(비교 지역을 조합해 가상의 대조군을 만드는 방법)를 평균이 아니라 분포 전체로 넓힌다(Gunsilius, 2023). 처치 단위가 도시 하나뿐인 사례에 쓴다

– **고차원 무조건부 분위 회귀**: 변수가 표본 크기에 가까울 때 RIF 회귀에 변수 선택(Lasso)을 결합한다(Sasaki, Ura & Zhang, 2022). 분위마다 선택되는 변수가 달라진다

– **인과 기계학습과의 결합**: Double Machine Learning·Generalized Random Forest를 분위 처치효과로 넓혀 "누구에게, 분포의 어디에서" 효과가 큰지를 함께 추정한다. EconML, grf 같은 패키지가 이 계열의 도구다

– **평가 기준의 이동**: OECD(2020) 등 국제기구의 정책 평가 지침이 분포적 분석을 표준 항목으로 요구하는 방향으로 바뀌었다. 평균 효과만 실은 평가는 불완전한 것으로 취급된다

□ 결과를 읽는 순서

○ 이 장의 산출물은 다음 순서로 읽는다

– 1순위 **질문의 종류**: 같은 특성인 사람 안에서의 차이인가(분위 회귀), 사회 전체 분포의 반응인가(RIF), 처치군의 시간에 걸친 변화인가(분포적 DID·CIC). 질문이 정해져야 방법과 읽을 표가 정해진다

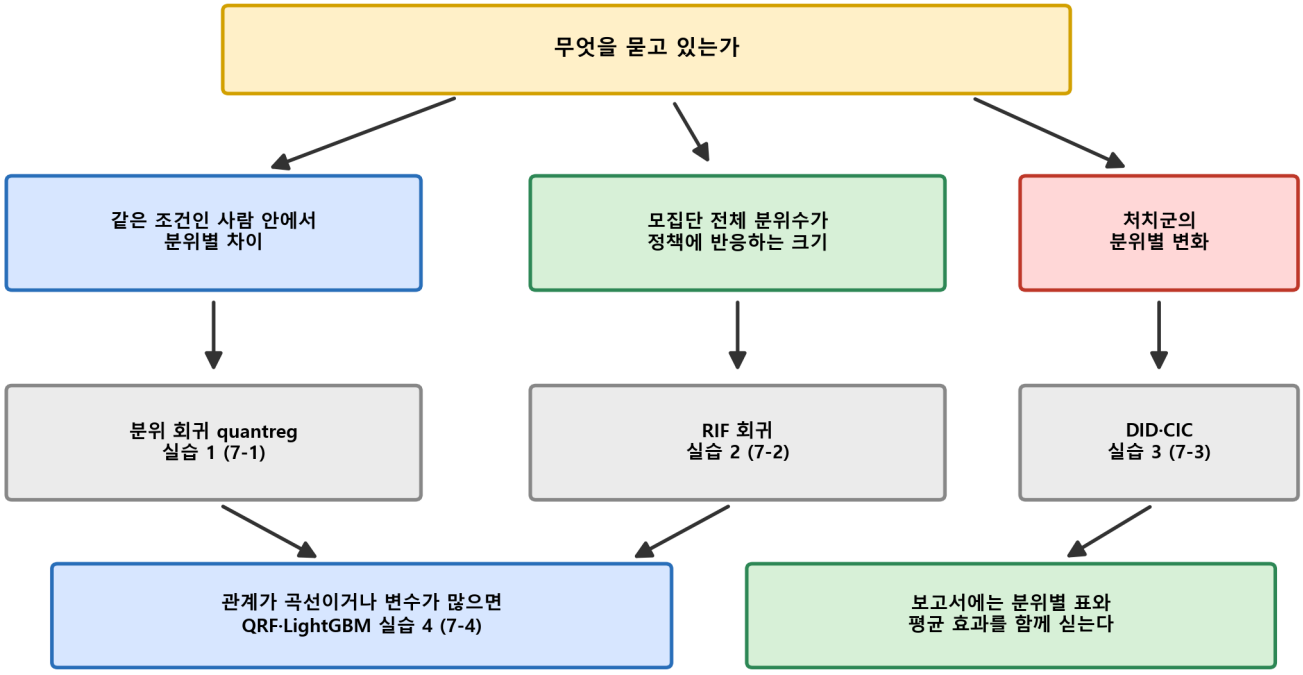
– 2순위 **유의성 관문**: 분위 간 차이의 Wald 검정, 각 분위 신뢰구간의 0 포함 여부. 통과하지 못한 칸의 숫자는 결론에 쓰지 않는다

– 3순위 **방법 간 대조**: 부호 → 분위별 기울기 → 수준 순으로 다른 방법과 비교한다. 기계학습 예측이면 그 전에 coverage(±5%p)부터 본다

– 4순위 **불평등 지표**: 분위별 효과와 별개로 Gini·90-10 비율을 계산한다. 두 결과가 다른 방향이면 둘 다 싣는다

– 5순위 **문장 분리**: "평균 X 상승"과 "하위 10%에서 Y 상승"은 별도 문장으로 두고 접속사로 잇지 않는다

그림 7-5. 질문이 정해지면 방법이 정해진다



평균 하나만 실은 보고서는 이 표의 어느 칸도 답하지 못한다

○ 그림 7-5 읽는 법

– 맨 위의 "무엇을 묻고 있는가"에서 출발해, 질문의 종류에 따라 분위 회귀(실습 7-1), RIF 회귀(실습 7-2), DID·CIC(실습 7-3)로 갈라진다

– 관계가 곡선이거나 변수가 많으면 QRF·LightGBM(실습 7-4)으로 넓히고, 보고서에는 분위별 표와 평균 효과를 함께 싣는다. 평균 하나만 실은 보고서는 이 그림의 어느 질문에도 답하지 못한다

□ 실무 적용 점검표

○ 정책이 겨냥한 대상이 분포의 어느 구간인지 먼저 적었는가? 이 구간이 정해져야 어느 τ를 볼지 정해진다

○ 조건부와 무조건부 중 어느 쪽이 필요한지 정했는가? 보고서 문장이 "사회 전체 분포"를 말한다면 RIF 회귀가 필요하다

○ 분위 간 효과 차이에 Wald 검정을 적용했는가? 눈으로 달라 보인다는 이유로 보고서에 다르다고 쓰지 않는다

○ 극단 분위($\tau \le 0.05$, $\tau \ge 0.95$)의 값을 단서 없이 결론에 인용하지 않았는가?

○ 전후 비교 설계라면 정책 이전 기간의 분위별 격차 추세를 확인했는가?

○ 기계학습 분위 예측이라면 coverage를 계산해 ±5%p 기준으로 판정했는가?

○ 불평등 지표(Gini, 90-10 비율)를 분위별 효과와 별도로 계산했는가?

○ 효과가 시간을 두고 나타나는 정책이라면 추적 기간이 충분한가? 교육·훈련 정책은 최소 3년이다

□ 핵심 정리

도구	무엇에 답하는가	언제 고르는가	확인할 것
OLS	평균 효과	분위 간 변동폭이 작을 때	이분산성, 이상치
분위 회귀	조건부 분위 효과	특성이 같은 집단 내 위치별 효과를 볼 때	분위 간 차이의 Wald 검정
RIF 회귀	무조건부 분위 효과	사회 전체 분포의 변화를 보고할 때	극단 분위의 밀도 불안정
분포적 DID·CIC	시간×분포 효과(QTT)	처치·대조군과 사전·사후가 있을 때	사전 기간의 분위별 격차 추세
QRF·LightGBM	비선형 조건부 분위 예측	변수가 많고 관계가 곡선일 때	coverage(±5%p), 훈련 횟수

○ 이 장의 판정 규칙 세 가지

– **분위별 표는 검정을 통과했을 때만 싣는다.** Wald p ≥ 0.05면 평균 하나로 보고하고, 신뢰구간이 0을 포함한 분위는 "확인되지 않았다"로 쓴다

– **효과의 집중과 불평등 완화는 별개로 판정한다.** 7.3의 최저임금은 하위에 효과가 몰렸지만 90-10 비율은 1.31에서 움직이지 않았다

– **평균 문장과 분포 문장을 섞지 않는다.** 평균은 정책이 얼마나 작동했는지, 분포는 그 작동이 누구에게 갔는지를 알려 주며, 두 정보는 서로를 대체하지 못한다