7장. 분위 회귀와 분포적 처치효과

□ 이 장의 질문

○ 한 지역의 평균 임금이 정책 시행 뒤 70에서 72로 올랐다. "정책이 성공했다"고 보고해도 될까

○ 이 장의 답은 "그 숫자만으로는 안 된다"이다. 모든 사람이 2씩 오른 경우와, 상위 20%만 10씩 오르고 하위 절반은 전혀 오르지 않은 경우 모두 평균은 똑같이 2가 오른다

○ 이 장은 평균 대신 **분포의 여러 지점**(하위 10%, 중간, 상위 10%)에서 효과를 따로 구하는 방법을 배운다. 방법마다 같은 순서를 따른다: 왜 필요한가 → 원리(손으로 계산하는 작은 예) → 코드 → 결과 읽기

□ 이 장을 읽는 방법

○ 이 장은 두 파트로 나뉜다

– 1부(7.1~7.2): "줄 세워 몇 번째 값"이라는 분위수의 원리를 익히고, 분위 회귀로 분위별 계수 표를 만들고 Wald 검정·이분산성 검정으로 판정한다

– 2부(7.3~7.6): 그 도구를 전후 비교(분포적 DID)와 기계학습(분위 랜덤 포레스트)으로 넓히고, 나온 숫자를 정책 판단으로 옮긴다

○ 수식은 쓰지 않는다. 원리는 5~10명짜리 작은 예를 손으로 계산해 이해한다. 실습 번호는 스크립트 파일 이름의 앞부분과 같으며(예: 7-3-distributional-did.py), 이 장에서 쓰는 번호는 7-1, 7-3, 7-4, 7-5다

○ 실습 코드는 practice/chapter07/code/ 에 있다. 스크립트를 실행하면 콘솔 출력 전체가 practice/chapter07/results/<스크립트명>.log 로 저장되고, 그림도 results 폴더에 저장된다. 본문의 실행 결과 발췌는 이 코드가 실제로 계산한 값이다. 원리를 보이려고 손으로 만든 작은 예는 "가상의 수치"라고 표시한다

○ 용어 미리보기 — 본문에서 처음 나올 때마다 다시 풀어 설명하므로, 여기서는 눈에 익히기만 하면 된다

용어	쉬운 뜻
분위수	전원을 값 순서로 줄 세웠을 때, 앞에서 일정 비율(τ) 지점에 있는 사람의 값
중위수	줄의 정확히 한가운데(τ=0.5) 사람의 값
분위 회귀	평균이 아니라 분위수가 설명변수에 따라 어떻게 움직이는지 구하는 회귀
조건부 분위 효과	특성(교육·나이 등)이 같은 사람들 안에서 구한 분위별 효과
QTE	처치가 결과 분포의 각 지점을 움직인 크기(분위 처치효과)
QTT	처치받은 집단 안에서만 구한 QTE
분포적 DID	처치·대조군의 전후 비교(DID)를 평균 대신 분위수마다 반복하는 방법
CIC	대조군의 "변화량" 대신 "줄에서의 위치"를 옮겨 와 반사실을 만드는 방법
coverage	분위 예측선보다 아래에 실제 값이 들어온 비율. τ와 비슷해야 합격

1부. 평균에서 분위수로 — 분포의 어디가 움직였는지 구한다

□ 1부 개요

○ 이 파트가 끝나면: 분위별 계수 표(표 7-1)를 직접 만들고, Wald 검정과 이분산성 검정으로 판정해 보고 문장을 쓸 수 있다

○ 다루는 절: 7.1 ~ 7.2

□ 7.1 분위수와 분위 회귀

7.1.1 왜 평균 하나로는 안 되는가

○ 평균이 같아도 사는 모습은 전혀 다를 수 있다

– 상황 A: 모든 사람의 임금이 고르게 2씩 올랐다. 상황 B: 상위 20%만 10씩 오르고 하위 50%는 전혀 오르지 않았다. 두 상황의 평균 상승분은 같다

– 상황 A는 격차가 그대로인 성장이고, 상황 B는 격차가 커진 성장이다. 평균 하나로는 두 상황을 구분할 수 없다

○ 이 구분이 필요한 상황은 정책과 비즈니스 양쪽에 흔하다

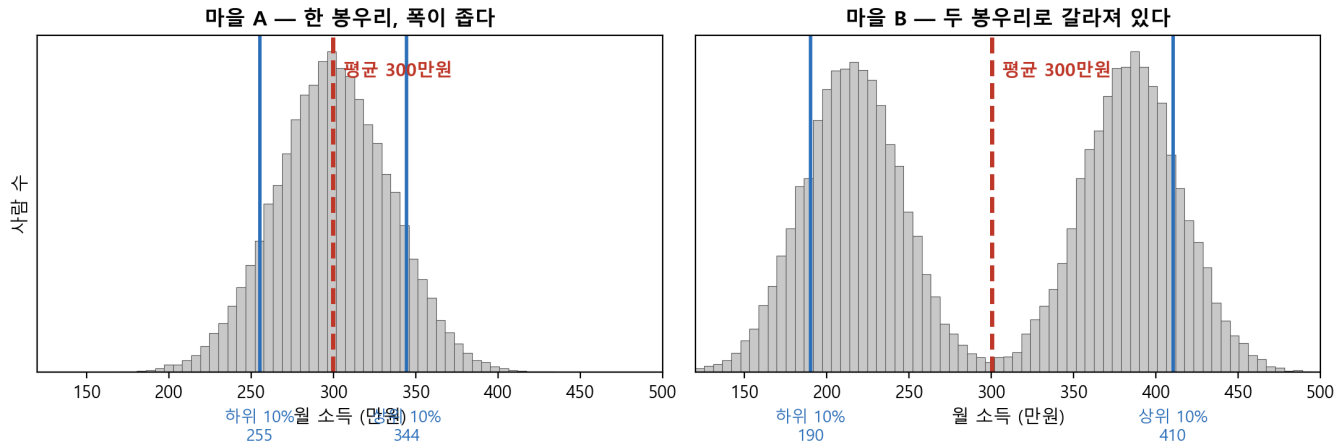
– 최저임금 인상은 임금 분포의 아래쪽을 겨냥한 정책이므로, 상위 구간에 효과가 없어도 실패가 아니다. 평가 기준이 "하위 구간이 올랐는가"다

– 배송 서비스에서 문제가 되는 것은 평균 배송 시간이 아니라 상위 5% 지연 시간이다. 평균 30분이어도 20명 중 1명이 두 시간을 기다리면 품질 문제다

○ 비유: 강을 건널지 판단하는 일. 강의 평균 수심(=결과의 평균)이 1.2m여도 가장 깊은 지점(=상위 분위)이 3m면 건널 수 없다. 판단에 필요한 값은 평균이 아니라 지점별 깊이다

– 이 비유는 여기까지만 맞다. 강의 깊이는 위치를 정해 다시 측정하면 되지만, 소득의 "상위 10%"는 고정된 사람 집단이 아니라 매번 줄을 다시 세워 정해지는 위치다

그림 7-1. 두 마을의 평균 소득은 같다. 사는 모습은 같지 않다.



평균 하나만 보고하면 두 마을이 구별되지 않는다. 하위 10%와 상위 10%를 같이 보면 갈라진다.

○ 그림 7-1 읽는 법

– 두 마을 모두 평균 월 소득이 300만원(빨간 점선)으로 같다. 마을 A는 한 봉우리로 모여 있고(하위 10% 255만원, 상위 10% 344만원), 마을 B는 두 봉우리로 갈라져 있다(하위 10% 190만원, 상위 10% 410만원)

– 평균 하나만 보고하면 두 마을이 구별되지 않는다. 하위 10%와 상위 10% 값을 함께 보면 갈라진다

한 줄 정리: 평균은 분포를 숫자 하나로 눌러 놓은 값이다. 정책 판단에는 눌리기 전의 지점별 값이 필요하다.

7.1.2 분위수 — 줄 세운 뒤 몇 번째 사람의 값

○ **분위수(quantile)** 는 전원을 값 순서로 줄 세운 뒤, 앞에서 일정 비율 지점에 있는 사람의 값이다. 그 비율을 τ(타우)라고 쓴다

– τ=0.10이면 앞에서 10% 지점(하위 10%), τ=0.50이면 한가운데, τ=0.90이면 90% 지점(상위 10% 경계)의 값이다

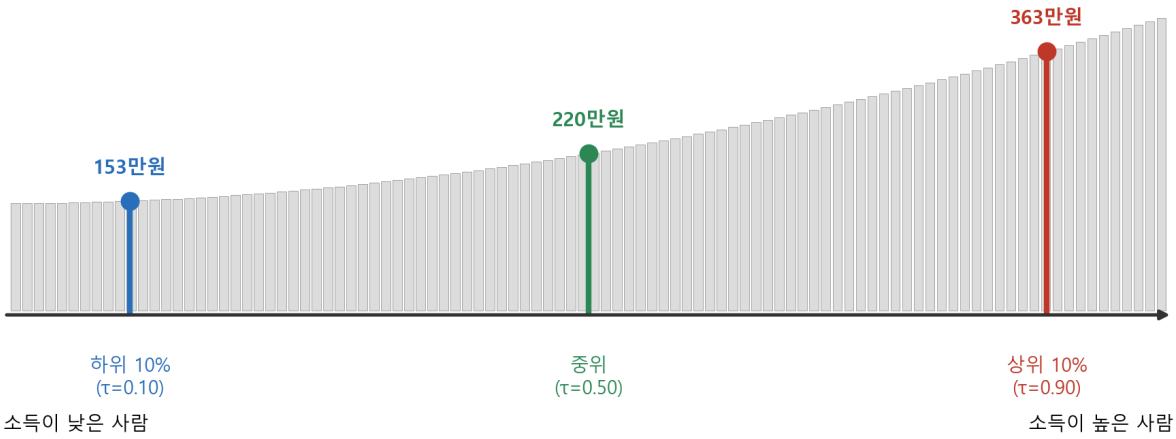
– τ=0.50의 값은 따로 **중위수(median)** 라고 부른다

○ 손으로 계산해 본다. 9명의 월 소득(만원)이 100, 120, 130, 150, 180, 200, 240, 300, 900이라고 하자 (가상의 수치다)

– 중위수는 줄의 5번째 사람의 값인 180이다. 하위 지점을 보려면 앞쪽(100, 120)을, 상위 지점을 보려면 뒤쪽(300, 900)을 읽는다
– 평균은 2,320 ÷ 9 ≈ 258이다. 900을 버는 한 명이 평균을 중위수보다 78만큼 끌어올렸고, 9명 중 7명은 평균보다 적게 번다
– 원리: 평균은 모든 값을 더하므로 극단값 하나에 끌려가고, 분위수는 줄의 순서만 쓰므로 극단값이 얼마나 큰지에 흔들리지 않는다

그림 7-2. 분위수는 줄 세운 뒤 몇 번째 사람인지를 가리킨다

100명을 소득 순으로 줄 세운다. τ분위수는 앞에서 τ×100번째 사람의 소득이다.



○ 그림 7-2 읽는 법
– 100명을 소득 순으로 줄 세운 그림이다. τ분위수는 앞에서 τ×100번째 사람의 소득이다
– 이 그림의 예에서는 하위 10%(τ=0.10) 지점이 153만원, 중위(τ=0.50)가 220만원, 상위 10%(τ=0.90) 지점이 363만원이다

한 줄 정리: 분위수는 "줄 세워 몇 번째 사람의 값"이다.

7.1.3 분위 회귀 — 분위수가 설명변수에 따라 움직이는 크기

○ **분위 회귀(quantile regression)** 는 분위수가 설명변수에 따라 어떻게 움직이는지 구하는 회귀다 (Koenker & Bassett, 1978)
– 보통의 회귀(OLS)는 "교육이 1년 늘면 소득의 **평균**이 얼마나 오르는가"에 계수 하나로 답한다
– 분위 회귀는 τ를 하나 정하고 "교육이 1년 늘면 그 τ 지점의 소득이 얼마나 오르는가"에 답한다. τ=0.10, 0.50, 0.90마다 **다른 계수**가 나온다

7.1.4 실습 7-1 — 분위별 계수 표를 만들고, Wald 검정과 이분산성 검정으로 판정한다

○ 이 실습은 세 단계다: ① 분위별 계수 표 만들기 ② Wald 검정으로 분위 간 차이가 진짜인지 확인 ③ 이분산성 검정으로 OLS를 쓸 수 있는지 확인. ①의 결과가 나온 뒤 ②와 ③으로 그 표를 보고서에 실어도 되는지 판정한다

○ 실습 데이터: 5,000명의 임금 자료(income, education, experience). 교육과 경력이 소득 분포의 다섯 지점(τ=0.10, 0.25, 0.50, 0.75, 0.90)에서 각각 얼마나 작용하는지 구한다

① 분위별 계수 표

○ 실습 코드(핵심 부분, 전체는 `7-1-basic-quantile-regression.py`)

```
for q in quantiles:                          # [0.10, 0.25, 0.50, 0.75, 0.90]
    mod = smf.quantreg('income ~ education + experience', data=df)
    results[q] = mod.fit(q=q)                # q가 곧 τ. 같은 회귀를 τ만 바꿔 반복
ols_res = smf.ols('income ~ education + experience', data=df).fit()  # 비교 기준선
```

○ 실행 결과(`results/7-1-basic-quantile-regression.log` 발췌)

```
Quantile Edu_Coef Edu_SE Exp_Coef Exp_SE
    0.10  2.18*** (0.23)  1.02*** (0.08)
    0.25  2.38*** (0.32)  0.94*** (0.11)
    0.50  3.50*** (0.37)  0.91*** (0.13)
    0.75  4.88*** (0.33)  0.94*** (0.11)
    0.90  5.26*** (0.30)  0.96*** (0.10)
     OLS  3.72*** (0.23)  0.96*** (0.08)
```

○ 이 출력을 정리한 것이 표 7-1이다

<표 7-1: 분위별 교육·경력 계수와 OLS 비교>

분위수 (τ)	교육 계수	경력 계수	읽는 법
0.10	2.18	1.02	하위 10% 지점에서 교육 1년당 소득 2.18 증가
0.25	2.38	0.94	하위 25% 지점에서 2.38 증가
0.50	3.50	0.91	중위 지점에서 3.50 증가
0.75	4.88	0.94	상위 25% 지점에서 4.88 증가
0.90	5.26	0.96	상위 10% 지점에서 5.26 증가
OLS(평균)	3.72	0.96	평균 효과 3.72

○ 표를 위에서 아래로 내려가며 계수가 어떻게 변하는지 본다

– 교육 계수는 2.18에서 5.26으로 2.4배가 된다. 교육 1년의 효과가 소득이 이미 높은 구간에서 더 크므로, 교육 확대만으로는 격차가 좁혀지지 않는다고 읽는다

– 경력 계수는 1.02~0.91로 거의 일정하다. **변동폭이 작은 변수는 평균 하나로 보고해도 정보 손실이 적다**

– 다만 눈으로 본 2.18과 5.26의 차이가 표본이 우연히 만든 흔들림인지는 아직 모른다. 이것을 ②에서 확인한다

② Wald 검정 — 분위 간 계수 차이가 우연이 아닌가

○ 왜 필요한가: 5,000명 표본에서 구한 계수는 다른 5,000명을 뽑으면 조금씩 달라진다. 2.18과 5.26의 차이가 그 정도의 달라짐보다 충분히 큰지 확인해야 분위별 표를 보고서에 싣는 근거가 생긴다

○ 원리: 계수 차이를 그 차이의 오차 범위로 나눈다. 차이가 오차 범위보다 훨씬 크면 우연이 아니라고 본다

– 비유: 두 학급의 평균 점수 차이를 볼 때, 차이가 시험 점수의 들쭉날쭉한 정도보다 훨씬 크면 실력 차이로 보고, 그 정도와 비슷하면 우연으로 본다

– 이 나눗셈의 결과를 제곱한 값이 **Wald 통계량**이다. "두 계수가 사실은 같다"고 가정했을 때 이렇게 큰 값이 나올 확률이 p값이다. 값이 클수록 p값이 작아진다

○ 실습 코드(핵심 부분, 전체는 `7-1-basic-quantile-regression.py` 의 `test_quantile_equality`)

```
diff = coef_high - coef_low                    # 5.26 - 2.18 = 3.08
se_diff = np.sqrt(se_low**2 + se_high**2)      # 차이의 흔들림 크기
wald_stat = (diff / se_diff)**2                # 제곱하면 Wald 통계량
p_value = 1 - chi2.cdf(wald_stat, df=1)        # 우연일 확률
```

○ 실행 결과

```
[Wald Test] H₀: 10분위와 90분위 교육 계수 동일
Wald 통계량: 66.96 / p-value: 0.0000 / 계수 차이: 3.08
```

○ 결과를 읽는 법

– **판정 눈금: p < 0.05면 분위별 표를 보고서에 싣고, p ≥ 0.05면 평균 효과 하나만 보고한다.** 여기서는 p < 0.001이므로 분위별 보고가 필요하다

③ 이분산성 검정 — OLS 표준오차를 그대로 믿어도 되는가

○ 왜 필요한가: OLS는 "오차의 흩어진 정도가 X의 값과 무관하게 일정하다"고 가정하고 표준오차를 계산한다. 흩어진 정도가 X에 따라 달라지면(**이분산성, heteroskedasticity**) 계수의 흔들림이 잘못 계산되어 신뢰구간과 p값을 믿을 수 없다

○ 원리: OLS 잔차(예측과 실제의 차이)의 크기가 X로 설명되는지 본다

– 예를 들어 교육 12년인 사람들의 잔차가 대체로 ±5 안이고, 교육 18년인 사람들은 ±20 안이라고 하자(가상의 수치다). X가 커질수록 흩어짐이 커지므로 이분산성이다

– **Breusch-Pagan 검정**은 잔차의 제곱(흩어짐의 크기)을 X로 다시 회귀해, X가 흩어짐을 설명하는 정도를 통계량(LM)으로 만든다. 설명하는 정도가 클수록 LM이 크고 p값이 작다

○ 실습 코드(핵심 부분, 전체는 `7-1-basic-quantile-regression.py`의 `test_heteroskedasticity`)

```
from statsmodels.stats.diagnostic import het_breuschpagan
bp_test = het_breuschpagan(ols_res.resid, ols_res.model.exog)  # (LM, LM의 p, F, F의 p)
```

○ 실행 결과

```
[Breusch-Pagan Test] LM 통계량: 85.60 / p-value: 0.0000
```

○ 결과를 읽는 법

– **판정 눈금: p < 0.05면 이분산성이 있으므로 OLS 결과를 보고할 때 강건 표준오차(흩어짐이 일정하지 않아도 맞게 계산하는 표준오차)를 쓴다. p ≥ 0.05면 보통의 OLS 표준오차를 쓴다.** 여기서는 LM 85.60(p < 0.001)이므로 OLS에 강건 표준오차를 적용해야 한다. 7-1 스크립트는 이 적용을 하지 않았다는 점에 유의한다(로그가 "강건 조정 필요"라고만 출력한다)

– 이 결과와 표 7-1은 같은 현상의 두 모습이다. 교육 계수가 위쪽 분위로 갈수록 커지면 교육이 높은 사람일수록 소득이 넓게 흩어진다는 뜻이고, 그것이 이분산성이다. 분위 회귀는 지점마다 따로 추정하므로 이 흩어짐을 계수의 차이로 그대로 보여 준다

○ 판정 연습(가상의 수치다): 두 분석에서 10분위-90분위 계수 차이의 Wald p값이 각각 0.61, 0.002이고, Breusch-Pagan p값이 각각 0.40, 0.003이라면

– 첫째 분석: Wald 0.61이므로 분위별 표를 만들지 않고 평균 효과만 보고한다. BP 0.40이므로 보통의 OLS 표준오차를 쓴다

– 둘째 분석: Wald 0.002이므로 분위별 표를 싣고 어느 구간에서 효과가 큰지 본문에 적는다. BP 0.003이므로 함께 싣는 OLS 평균 효과에는 강건 표준오차를 쓴다

한 줄 정리: 분위별 표는 Wald 검정(차이가 우연이 아닌가)을 통과했을 때만 싣고, Breusch-Pagan 검정(흩어짐이 일정한가)으로 OLS 표준오차의 사용 방식을 정한다.

□ 7.2 처치효과를 분위별로 — QTE와 QTT

7.2.1 QTE와 QTT — 분포의 지점을 따라가는 효과

○ 정책 평가에서 묻는 것은 대개 처치 여부다: 직업훈련이 하위 10% 소득자의 소득을 얼마나 올렸는가, 상위 10%에는 얼마나 작용했는가

○ 용어 셋을 구분한다

– **QTE(분위 처치효과)**: 처치받았을 때의 결과 분포와 받지 않았을 때의 결과 분포에서, 같은 τ 지점의 값을 뺀 것

– **QTT**: 처치받은 집단 안에서만 같은 계산을 한 것. 7.3의 전후 비교 설계에서 주로 나온다
– **CQTE(조건부 QTE)**: 특성을 고정한 뒤의 QTE. "40대 고졸 남성 안에서의 분위 효과"처럼 집단을 지정해 본다

○ 주의: QTE는 **같은 사람의 변화가 아니라 줄에서 같은 위치의 변화**다
– 처치 전 하위 10%였던 사람이 처치 후에도 하위 10%에 있다는 보장은 없다. 예를 들어 "QTE(0.10) = 64만원"은 "하위 10% **지점의 값**이 64만원 높아졌다"이지 "그 사람의 소득이 64만원 올랐다"가 아니다(가상의 수치다)

한 줄 정리: QTE는 분포의 지점을 따라가는 값이지 개인을 따라가는 값이 아니다.

□ 1부 정리

○ 지금까지 만든 것: 특성(교육·경력)의 조건부 분위별 계수 표(표 7-1), 그 표를 보고서에 실어도 되는지 판정한 Wald 검정·이분산성 검정, 처치효과를 분위별로 읽는 용어(QTE·QTT·CQTE)

○ 확인한 판정 기준
– 분위 간 계수 차이는 Wald 검정 $p < 0.05$일 때만 분위별로 보고한다
– 이분산성 검정 $p < 0.05$면 OLS에는 강건 표준오차를 쓴다

○ 표 7-1은 관측 데이터에 회귀를 적용해 얻은 값이므로, 처치 배정이 무작위가 아니라면 인과 해석에 추가 가정이 필요하다. 2부에서는 전후 비교 설계로 그 가정을 명시하고, 기계학습으로 곡선 관계를 다룬다

2부. 전후 비교와 기계학습으로 넓히고, 정책 판단으로 옮긴다

□ 2부 개요

○ 이 파트가 끝나면: 분포적 DID로 분위별 QTT 표를 만들고, 기계학습 분위 예측을 coverage로 판정하고, 종합 사례에서 네 방법의 결과를 나란히 놓고 결론을 쓸 수 있다

○ 다루는 절: 7.3 ~ 7.6

□ 7.3 분포적 DID와 Changes-in-Changes — 시간 축을 더한다

7.3.1 원리 — DID의 뺄셈을 분위마다 반복한다

○ 왜 필요한가: 5장의 DID는 처치군과 대조군의 사전·사후 **평균** 변화를 비교했다. 그런데 최저임금 인상은 임금 분포의 아래쪽을 밀어 올리도록 설계된 정책이라, 평균 DID로는 하위만 크게 오른 경우와 전원이 고르게 오른 경우를 구분하지 못한다

○ **분포적 DID**는 DID의 뺄셈을 평균 대신 분위수마다 반복한다. 각 τ에 대해 네 값을 구해 두 번 뺀다

– ① 처치군 사후 τ분위수 − ② 처치군 사전 τ분위수 = 처치군의 변화량

– ③ 대조군 사후 τ분위수 − ④ 대조군 사전 τ분위수 = 대조군의 변화량

– 처치군 변화량 − 대조군 변화량 = 그 분위의 **QTT**

○ 손으로 계산한다(가상의 수치다). 하위 10% 지점의 시간당 임금(원)이 처치군은 사전 9,000 → 사후 9,300, 대조군은 사전 9,000 → 사후 9,100이라고 하자

– 처치군 변화량 300, 대조군 변화량 100이므로 하위 10%의 QTT는 300 − 100 = 200원이다. 대조군의 100원은 정책이 없어도 일어났을 변화로 보고 뺀다

○ 이 계산에는 평행추세에 해당하는 가정이 필요하다. 평균 DID가 "정책이 없었다면 두 집단의 평균이 나란히 움직였을 것"을 가정하듯, 분포적 DID는 분포의 모양이 시간이 지나도 안정적이었을 것을 가정한다(Callaway & Li, 2019)

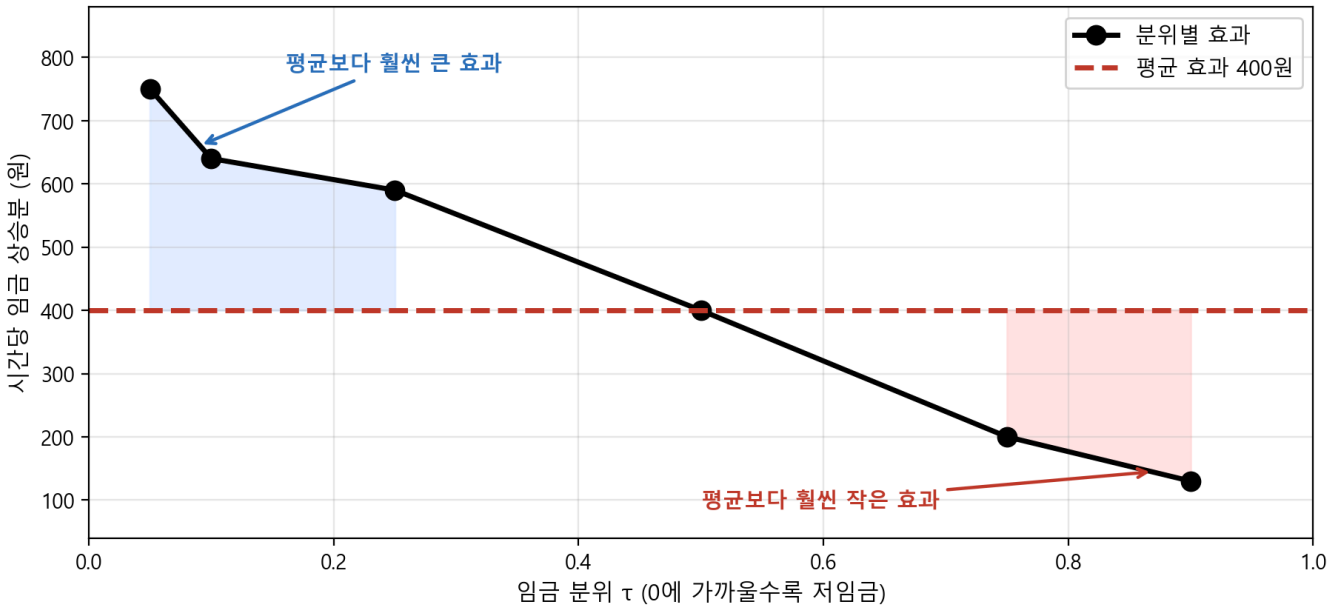
○ **Changes-in-Changes(CIC)** 는 분포가 평행하게 움직이지 않을 때를 대비한 대안이다(Athey & Imbens, 2006)

– 분포적 DID는 대조군의 "변화량"을 옮겨 오고, CIC는 "줄에서의 위치 이동"을 옮겨 온다. 처치군의 사전 값이 대조군 사전 분포에서 몇 번째 위치인지 찾고, 대조군 사후 분포에서 그 위치의 값을 읽어 반사실(정책이 없었을 때의 값)을 만든다

– 예를 들어 처치군 사전 값 9,500이 대조군 사전 분포의 상위 40% 위치이고, 대조군 사후 분포의 같은 위치 값이 9,700이면 반사실은 9,700이다(가상의 수치다)

– 분포가 평행 이동하면 두 방법의 답이 거의 같고, 분포가 늘어나거나 압축되면 갈라진다. 그래서 둘을 나란히 계산해 대조하는 것 자체가 점검 절차가 된다

그림 7-3. 최저임금 인상은 저임금 쪽에서 크게, 고임금 쪽에서 작게 작동한다



평균 400원 하나만 보고하면 750원과 130원이 같은 숫자로 뭉개진다. (모양을 보이려고 그린 예시 값)

○ 그림 7-3 읽는 법 — 분위별 효과의 모양을 보이려고 그린 개념도이며, 그림 속 수치는 예시 값이다

– 가로축은 임금 분위 τ(0에 가까울수록 저임금), 세로축은 시간당 임금 상승분이다. 검은 선(분위별 효과)이 왼쪽에서 높고 오른쪽으로 갈수록 낮아진다

– 빨간 점선이 평균 효과 400원이다. 평균 하나만 보고하면 왼쪽 끝의 750원과 오른쪽 끝의 130원이 같은 숫자로 합쳐진다

7.3.2 실습 7-3 — 분위별 QTT 표를 만들고 판정한다

○ 실습 코드(핵심 부분, 전체는 `7-3-distributional-did.py`). 위 손계산의 네 값을 그대로 구한다

```
for tau in quantiles:                # [0.05, 0.10, 0.25, 0.50, 0.75, 0.90]
    q_treat_post = np.quantile(df_treat_post['outcome'], tau)
    q_treat_pre = np.quantile(df_treat_pre['outcome'], tau)
    q_control_post = np.quantile(df_control_post['outcome'], tau)
    q_control_pre = np.quantile(df_control_pre['outcome'], tau)
    qtt = (q_treat_post - q_treat_pre) - (q_control_post - q_control_pre)
# 표준오차는 개인 단위 부트스트랩(B=500)으로 계산한다
```

○ 실행 결과(`results/7-3-distributional-did.log` 발췌. outcome 단위는 100원/시간이며, 원 단위 열은 100을 곱한 값)

```
Quantile QTT_DID SE_DID    CI95_DID QTT_CIC Won_DID
    0.05    7.4*   1.32 [4.9, 10.1]    8.0*    745원
    0.10    5.9*   1.06  [4.3, 8.4]    6.0*    595원
    0.25    6.0*   0.72  [4.5, 7.4]    5.8*    600원
    0.50    3.9*   0.64  [2.6, 5.0]    4.1*    395원
    0.75    2.0*   0.60  [0.8, 3.1]    2.0*    202원
    0.90     1.0   1.10 [-1.1, 3.4]     2.1    104원

전통적 DID (평균 효과): 3.85 (= 385원/시간, 클러스터 SE=0.41)

[두 방법의 추정값 차이] 분위별 차이의 평균 절댓값: 33원/시간
[불평등 지표] 90-10 비율: 1.31 -> 1.31 / Gini: 0.060 -> 0.057
```

○ 결과를 읽는 판정 눈금 네 가지

– **겨냥 구간 집중**: 하위를 겨냥한 정책은 하위 분위에 효과가 몰려야 한다. 여기서는 효과가 하위 5%의 745원에서 상위 10%의 104원까지 아래쪽에 몰려 있어 설계 의도대로 작동했다. 상위 분위에서 효과가 더 크게 나오면 정책이 의도와 다르게 작동했거나 대조군 선택이 잘못되었을 가능성부터 검토한다

– **0 포함 여부**: 상위 10%의 신뢰구간 [-1.1, 3.4](원 단위 −110~340원)는 0을 포함하므로 상위 구간의 효과는 확인되지 않았다고 쓴다

– **두 방법 대조**: 분포적 DID와 CIC의 분위별 차이는 평균 33원으로, 부트스트랩 표준오차(τ=0.05에서 132원)보다 작다. 차이가 표준오차 안이면 어느 쪽을 써도 결론이 같다. 크게 갈리면 분포가 평행하게 움직이지 않았다는 신호이므로 CIC를 주 결과로 삼는다

– **평균 대 중위**: 전통적 DID 385원과 중위 QTT 395원이 가깝다. 크게 어긋나면 소수의 큰 값이 평균을 끌고 있다는 뜻이므로 중위를 함께 보고한다

○ 분위별 효과와 불평등 지표는 따로 확인한다

– 효과가 하위에 몰렸는데도 90-10 비율(상위 10% 경계값을 하위 10% 경계값으로 나눈 배율)은 1.31에서 1.31로 거의 그대로이고, Gini 계수(0이면 완전 균등, 1이면 한 명이 전부 가진 상태)는 0.060에서 0.057로 0.002 내렸다(로그 기준, 반올림 표기)

– "저임금 근로자에게 더 큰 효과가 갔다"와 "불평등이 완화되었다"는 다른 주장이다. 후자를 쓰려면 지표 변화를 근거로 대야 하며, 이 결과에서는 전자만 성립한다

○ 가정 점검: 정책 이전 기간을 본다

– 정책 시행 이전 여러 시점에서 분위별로 처치군-대조군 격차를 계산해, 격차가 일정하게 유지되었는지 본다. 이미 추세를 그리며 벌어지고 있었다면 추정값에 그 추세가 섞여 있다

– **판정 눈금: 사전 기간의 분위별 격차가 뚜렷한 추세를 보이면 그대로 보고하지 않는다.** 추세를 모형에 넣거나 다른 대조군을 찾는다. 이 점검은 반증 시도이므로, 통과해도 가정이 참으로 증명되는 것은 아니다

한 줄 정리: DID의 뺄셈을 분위마다 반복하면 "정책이 겨냥한 구간에 갔는가"가 보인다. 다만 효과의 집중과 불평등 완화는 별개로 판정한다.

□ 7.4 기계학습 분위 예측 — 한 번 학습해 전 분위를 읽는다

7.4.1 원리 — 평균 대신 값 전체를 저장한다

○ 왜 필요한가: 7.1의 분위 회귀는 관계를 직선으로 놓는다. 변수가 수십 개이거나 관계가 곡선이면 이 가정이 맞지 않는다. 주택 가격이 전형적인 예다 — 면적의 효과는 소형과 대형에서 다르고, 역세권 거리의 효과는 지역에 따라 달라진다

○ **Quantile Regression Forest(QRF)** 는 랜덤 포레스트(3장의 "스무고개 나무" 수백 그루)를 분위 예측으로 넓힌 방법이다(Meinshausen, 2006)

– 보통의 랜덤 포레스트는 나무의 끝 칸마다 도착한 표본들의 **평균**을 저장한다. QRF는 평균 대신 **값 전체**를 저장한다

– 새 관측치가 들어오면 모든 나무에서 그 관측치가 도착한 칸의 값들을 모아 하나의 분포를 만들고, 그 분포를 줄 세워 τ번째 값을 읽는다(7.1.2와 같은 방식이다). 분포를 통째로 갖고 있으므로 **한 번 학습하면 어떤 τ든 다시 학습하지 않고 예측한다**

○ LightGBM 같은 부스팅 계열은 학습 목표를 분위수(`objective='quantile'`)로 지정하는 방식이라 **분위수마다 모형을 따로 학습**해야 한다

○ 예측이 맞는지는 두 지표로 판정한다

– **pinball loss**: 분위 예측이 실제 값에서 빗나간 정도를 벌점으로 계산해 평균한 값이다(τ에 따라 위로 빗나간 경우와 아래로 빗나간 경우의 벌점 비중이 다르다). 작을수록 그 분위 예측이 정확하다

– **coverage**: 실제 관측치 중 예측선 아래에 놓인 비율이다. τ=0.25 예측이면 25%가 나와야 이상적이다. 예를 들어 테스트 100건 중 실제 값이 25번째 분위 예측선 아래에 25건 있으면 coverage 25%로 정확하다

7.4.2 실습 7-4 — QRF와 LightGBM을 coverage로 판정한다

○ 실습 코드(핵심 부분, 전체는 `7-4-quantile-forest.py`)

```
qrf = RandomForestQuantileRegressor(n_estimators=500, min_samples_split=10,
                                    min_samples_leaf=5, random_state=42, n_jobs=-1)
qrf.fit(X_train, y_train)                       # 학습 한 번

for q in quantiles:                             # [0.05, 0.25, 0.50, 0.75, 0.95]
    lgb_model = lgb.LGBMRegressor(objective='quantile', alpha=q,
                                  n_estimators=500, learning_rate=0.05,
                                  num_leaves=31, random_state=42, verbosity=-1)
    lgb_model.fit(X_train, y_train)             # 분위마다 다시 학습
```

○ 실행 결과(`results/7-4-quantile-forest.log` 발췌. 주택 가격 3,000건, 훈련 2,400 / 테스트 600)

```
Quantile QRF_Pinball LGB_Pinball QRF_Coverage LGB_Coverage Ideal_Coverage
    0.05        3.01        3.77         6.3%        14.3%             5%
    0.25        9.20        9.08        24.0%        29.7%            25%
    0.50       11.22       11.00        48.3%        49.2%            50%
    0.75        8.86        9.04        74.0%        66.2%            75%
    0.95        3.00        3.68        94.0%        84.2%            95%

평균 pinball loss:  QRF 7.06 / LightGBM 7.31
평균 coverage 오차: QRF 1.2%p / LightGBM 6.9%p
훈련 시간: QRF 1.9초(1회) / LightGBM 5.0초(5회)

[90% 예측 구간] 실제 coverage: QRF 87.7% / LightGBM 69.8%
구간 너비: QRF 91만원 / LightGBM 57만원
```

○ 결과를 읽는 순서

– 첫째, coverage로 보정 상태를 판정한다. **판정 눈금: 이상값과의 차이가 ±5%p 이내면 그 분위 예측을 쓰고, 넘으면 의사결정에 직접 쓰지 않는다.** QRF는 다섯 분위 모두 오차 1.7%p 이내로 합격이다. LightGBM은 τ=0.05(+9.3%p)와 τ=0.95(−10.8%p)가 기준을 넘어 극단 분위 예측을 그대로 쓸 수 없다

– 둘째, 90% 예측 구간(τ=0.05~0.95 사이)의 실제 포함률을 본다. QRF 87.7%, LightGBM 69.8%다. LightGBM의 구간은 폭이 57만원으로 좁지만 목표 90%에 20.2%p 모자란다. **좁은 구간이 정확한 구간은 아니다.** 포함률이 모자란 구간을 "90% 구간"이라 표기하면 위험을 낮게 보게 된다

– 셋째, 정확도와 시간을 본다. 평균 pinball loss는 QRF가 3.6% 낮고 훈련도 1회로 끝난다. 이 데이터에서는 정확도·보정·시간 모두 QRF가 앞서지만, 3장에서 확인했듯 **한 데이터의 우열을 다른 데이터로 옮기지 않는다.** 새 데이터마다 coverage를 다시 계산한다

○ 판정 연습(가상의 수치다): 어떤 모형의 τ=0.95 예측 coverage가 84%로 나왔다면

– 이상값 95%와의 차이가 11%p로 기준(±5%p)을 넘는다. 이 예측을 "상위 5% 지연 관리" 같은 의사결정에 쓰지 않고, 모형을 다시 보정하거나 구간을 넓힌 뒤 coverage를 다시 계산한다

한 줄 정리: 기계학습 분위 예측은 정확도보다 coverage부터 본다. ±5%p를 넘는 분위의 값은 결정에 쓰지 않는다.

□ 7.5 종합 사례 — 교육정책 하나를 세 방법으로 비교한다

○ 왜 필요한가: 방법마다 가정이 달라서, 한 방법의 숫자만으로는 결론이 방법 선택의 결과인지 정책의 효과인지 알 수 없다. 같은 데이터에 방법을 여러 개 적용해 숫자가 어떻게 겹치고 갈라지는지 본다

○ 무상 대학교육 정책이 소득 분포에 준 영향을 앞의 방법들로 평가한다: ① QRF(7.4) ② LightGBM 분위 회귀(7.4) ③ 분포적 DID(7.3)

○ 실습 코드(핵심 부분, 전체는 `7-5-education-policy-case.py`). 반사실을 만드는 원리는 "같은 사람을 정책 받음/안 받음 두 가지로 예측해 차이를 낸다"이다

```
qrf = RandomForestQuantileRegressor(n_estimators=300, min_samples_split=10,
                                    min_samples_leaf=5, random_state=42, n_jobs=-1)
qrf.fit(X, y)                                    # X에 policy 변수 포함
df_policy1, df_policy0 = df.copy(), df.copy()    # 반사실 두 벌
df_policy1['policy'], df_policy0['policy'] = 1, 0
# 같은 사람들을 "정책 받음/안 받음"으로 각각 예측해 차이의 평균을 낸다
```

○ 주의: 이 스크립트는 이번 준비 과정의 실행에서 QRF 예측 부분의 코드 오류로 중단되었다(`results/7-5-education-policy-case.log`가 "Quantile Regression Forest 실행 중..."에서 끝난다). 아래 표 7-6·7-7의 수치는 기존 강의자료가 이전 실행에서 얻어 둔 값이며, 오류를 고친 뒤 직접 실행해 재확인하는 것이 정확하다

<표 7-6: 무상 대학교육 정책의 분위별 처치효과 (연소득, 만원)>

분위수 (τ)	QRF	LightGBM	분포적 DID
0.05	685	529	869
0.25	683	621	980
0.50	686	646	1,014
0.75	688	727	1,073
0.95	687	815	1,126

○ 표 읽는 순서 — 방법 간 비교는 세 단계로 한다

- 첫째, **부호가 일치하는가**. 세 방법 모두 전 분위에서 양수다. 부호가 갈리면 보고하지 않고 원인부터 찾는다. 일치하면 "효과가 존재한다"는 결론은 방법 선택에 좌우되지 않는다
- 둘째, **분위별 기울기가 일치하는가**. LightGBM·분포적 DID는 위쪽 분위에서 값이 크다. QRF만 685 근처에서 평평한데, 단일 모형으로 전 분위를 예측하는 QRF는 분위 간 차이가 줄어드는 경향이 있으므로 분위별 이질성을 볼 때는 다른 방법의 결과를 쓴다
- 셋째, **수준 차이를 설명한다**. 분포적 DID(869~1,126)가 QRF(683~688)·LightGBM(529~815)보다 일관되게 크다. 비교 대상이 다르기 때문이다. QRF·LightGBM은 같은 사람을 정책 받음/안 받음으로 각각 예측해 조건부 분위 차이를 구한 뒤 전체 표본에서 평균한 값이고(스크립트 상단 설명과 예측 코드 기준), 분포적 DID는 수혜 집단의 QTT다. 어느 쪽이 맞는지 다투지 말고 각각이 답하는 질문을 명시한다

○ 분위별 효과와 불평등 지표를 함께 놓는다 (기존 실행 수치)

<표 7-7: 불평등 지표 변화 (정책 시행 3년 후, 수혜 집단 기준)>

지표	정책 전	정책 후	변화
Gini 계수	0.120	0.106	−0.014 (−11.7%)
90-10 분위수 비율	1.75	1.63	−0.12 (−6.9%)
대학진학률	52.5%	86.8%	+34.3%p
평균 소득	5,214만원	6,246만원	+1,032만원

○ 표 7-6과 표 7-7은 겉보기에 어긋난다 — 분위별 효과는 상위에서 더 큰데 Gini는 11.7% 줄었다. 모순이 아니다

- 표 7-6은 수혜 집단 **안에서의 분위별 효과**를, 표 7-7은 정책 전후 **분포 전체의 형태**를 나타낸다. 하위 분위도 상당한 증가를 얻어 분포 전체가 위로 이동하면, 상대적 격차는 줄어들 수 있다
- **판정 눈금: 분위별 효과 표와 불평등 지표가 다른 방향을 가리키면 둘 다 보고한다.** 정확한 서술은 "정책은 수혜 집단 전체의 소득을 올려 상대적 격차를 줄였으나, 효과의 크기는 소득이 높은 구간에서 더 컸다"이다

○ 시간 축도 확인한다 (기존 실행 수치): 중위 기준 효과는 1년 차 +1,198만원(최종의 37%), 2년 차 +1,568만원(74%), 3년 차 +1,828만원(100%)으로 커지다 안정화된다

- **판정 눈금: 1년 차 효과가 최종값의 절반에 못 미치면 단기 평가로 정책을 판단하지 않는다.** 교육·훈련 정책은 진학과 취업 사이의 시차 때문에 최소 3년을 추적한다

한 줄 정리: 방법 세 개를 나란히 놓고 부호 → 기울기 → 수준 순으로 대조한다. 분위별 효과와 불평등 지표는 반대 방향일 수 있으며, 그때는 둘 다 싣는다.

□ 7.6 연구 동향 — 이 도구들이 넓어지는 방향

○ 이 절은 참고용이며 실습을 동반하지 않는다

– **분포적 합성통제법**: 합성통제(비교 지역을 조합해 가상의 대조군을 만드는 방법)를 평균이 아니라 분포 전체로 넓힌다(Gunsilius, 2023). 처치 단위가 도시 하나뿐인 사례에 쓴다
– **인과 기계학습과의 결합**: Double Machine Learning·Generalized Random Forest를 분위 처치효과로 넓혀 "누구에게, 분포의 어디에서" 효과가 큰지를 함께 추정한다. EconML, grf 같은 패키지가 이 계열의 도구다
– **평가 기준의 이동**: OECD(2020) 등 국제기구의 정책 평가 지침이 분포적 분석을 표준 항목으로 요구하는 방향으로 바뀌었다. 평균 효과만 실은 평가는 불완전한 것으로 취급된다

□ 결과를 읽는 순서

○ 이 장의 산출물은 다음 순서로 읽는다
– 1순위 **질문의 종류**: 같은 특성인 사람 안에서의 차이인가(분위 회귀), 처치군의 시간에 걸친 변화인가(분포적 DID·CIC). 질문이 정해져야 방법과 읽을 표가 정해진다
– 2순위 **유의성 관문**: 분위 간 차이의 Wald 검정, 각 분위 신뢰구간의 0 포함 여부. 통과하지 못한 칸의 숫자는 결론에 쓰지 않는다
– 3순위 **방법 간 대조**: 부호 → 분위별 기울기 → 수준 순으로 다른 방법과 비교한다. 기계학습 예측이면 그 전에 coverage(±5%p)부터 본다
– 4순위 **불평등 지표**: 분위별 효과와 별개로 Gini·90-10 비율을 계산한다. 두 결과가 다른 방향이면 둘 다 싣는다
– 5순위 **문장 분리**: "평균 X 상승"과 "하위 10%에서 Y 상승"은 별도 문장으로 두고 접속사로 잇지 않는다
○ 질문에 따라 방법을 고른다
– 같은 특성인 사람 안에서 분위별 차이를 보려면 분위 회귀(실습 7-1)를 쓴다
– 처치군의 시간에 걸친 분위별 변화를 보려면 DID·CIC(실습 7-3)를 쓴다
– 관계가 곡선이거나 변수가 많으면 QRF·LightGBM(실습 7-4)으로 넓히고, 보고서에는 분위별 표와 평균 효과를 함께 싣는다. 평균 하나만 실은 보고서는 위 질문 어디에도 답하지 못한다

□ 실무 적용 점검표

○ 정책이 겨냥한 대상이 분포의 어느 구간인지 먼저 적었는가? 이 구간이 정해져야 어느 τ를 볼지 정해진다
○ 분위 간 효과 차이에 Wald 검정을 적용했는가? 눈으로 달라 보인다는 이유로 보고서에 다르다고 쓰지 않는다
○ 극단 분위($\tau \le 0.05$, $\tau \ge 0.95$)의 값을 단서 없이 결론에 인용하지 않았는가?
○ 전후 비교 설계라면 정책 이전 기간의 분위별 격차 추세를 확인했는가?
○ 기계학습 분위 예측이라면 coverage를 계산해 ±5%p 기준으로 판정했는가?
○ 불평등 지표(Gini, 90-10 비율)를 분위별 효과와 별도로 계산했는가?

○ 효과가 시간을 두고 나타나는 정책이라면 추적 기간이 충분한가? 교육·훈련 정책은 최소 3년이다

□ 핵심 정리

도구	무엇에 답하는가	언제 고르는가	확인할 것
OLS	평균 효과	분위 간 변동폭이 작을 때	이분산성, 이상치
분위 회귀	조건부 분위 효과	특성이 같은 집단 내 위치별 효과를 볼 때	분위 간 차이의 Wald 검정
분포적 DID·CIC	시간×분포 효과(QTT)	처치·대조군과 사전·사후가 있을 때	사전 기간의 분위별 격차 추세
QRF·LightGBM	비선형 조건부 분위 예측	변수가 많고 관계가 곡선일 때	coverage(±5%p), 훈련 횟수

○ 이 장의 판정 규칙 세 가지

– **분위별 표는 검정을 통과했을 때만 싣는다.** Wald $p \geq 0.05$면 평균 하나로 보고하고, 신뢰구간이 0을 포함한 분위는 "확인되지 않았다"로 쓴다

– **효과의 집중과 불평등 완화는 별개로 판정한다.** 7.3의 최저임금은 하위에 효과가 몰렸지만 90-10 비율은 1.31에서 움직이지 않았다

– **평균 문장과 분포 문장을 섞지 않는다.** 평균은 정책이 얼마나 작동했는지, 분포는 그 작동이 누구에게 갔는지를 알려 주며, 두 정보는 서로를 대체하지 못한다