8장. A/B 테스트와 적응형 실험 설계

□ 이 장의 질문

○ 새 화면(B안)이 기존 화면(A안)보다 나은지 확인하려고 사용자를 반씩 나눠 2주 동안 실험한다. 그동안 절반의 사용자는 두 안 중 나쁜 쪽을 계속 본다. 이 손실을 줄이려고 중간에 결과를 들여다보고 좋아 보이면 멈추거나, 잘되는 안에 사용자를 더 보내도 될까

○ 이 장의 답은 “규칙 없이 하면 안 되고, 규칙을 미리 정하면 된다”이다. 규칙 없이 중간에 멈추면 없는 효과를 있다고 보고할 확률이 커진다. 배분을 바꾸면 손실은 줄지만 나쁜 안의 효과를 정확히 알아내는 일은 포기해야 한다

○ 이 장은 무엇을 얻고 무엇을 내주는지를 숫자로 확인하는 방법을 배운다. 방법마다 같은 순서를 따른다: 왜 필요한가 → 원리(작은 숫자로 손계산) → 코드 → 결과 읽기

□ 이 장을 읽는 방법

○ 이 장은 두 파트로 나뉜다

– 1부(8.1~8.2): 배분을 반반으로 고정한 A/B 테스트를 설계한다. 몇 명이 필요한지 계산하고, 중간에 결과를 들여다봐도 오류가 늘지 않게 하는 규칙을 배운다

– 2부(8.3~8.6): 실험 도중에 배분 비율 자체를 바꾸는 설계(톰슨 샘플링, 베이지안 적응형 설계)를 실행해, 손실이 얼마나 줄고 대신 무엇을 포기하는지 확인한다

○ 수식은 쓰지 않는다. 원리를 보이려고 손으로 만든 예는 “가상의 수치”라고 표시한다

○ 실습 코드는 practice/chapter08/code/ 에 있고, 실행하면 콘솔 출력이 practice/chapter08/results/<스크립트명>.log 로 저장된다. 본문의 실행 결과 발췌는 이 코드가 실제로 계산한 값이다. 실습 데이터는 정답(참 전환율)을 알고 만든 연습용 데이터라서, 계산한 값이 참값에서 얼마나 빗나갔는지 채점할 수 있다

○ 용어 미리보기 — 본문에서 처음 나올 때마다 다시 풀어 설명하므로, 여기서는 눈에 익히기만 하면 된다

용어	쉬운 뜻
무작위 배정	누가 어느 안을 받을지를 동전 던지기처럼 우연으로만 정하는 것
전환율	그 안을 본 사람 100명 중 목표 행동(구매·가입)을 한 사람의 비율
1종 오류	효과가 없는데 “있다”고 잘못 판정하는 실수. 허용 상한(유의수준)은 보통 5%

용어	쉬운 뜻
검정력	효과가 정말 있을 때 실험이 그 효과를 잡아낼 확률. 기준은 0.80
중간 분석	실험이 끝나기 전에 결과를 미리 들여다보고 멈출지 정하는 것
톰슨 샘플링	성과가 좋아 보이는 안에 점점 더 많은 사용자를 보내는 배분 방법
사후확률	지금까지의 데이터를 보고 계산한 “B안이 A안보다 나을 확률”

1부. 반반으로 나눈 실험을 설계하고 끝낼 시점을 정한다

□ 1부 개요

○ 이 파트가 끝나면: 필요 인원과 검정력을 계산해 실험을 시작할지 정하고, 중간에 들여다볼 때 쓸 중단 경계를 고를 수 있다

○ 다루는 절: 8.1 ~ 8.2

□ 8.1 무작위 배정과 A/B 테스트

8.1.1 실험이 기준점인 이유 — 동전이 두 집단을 같게 만든다

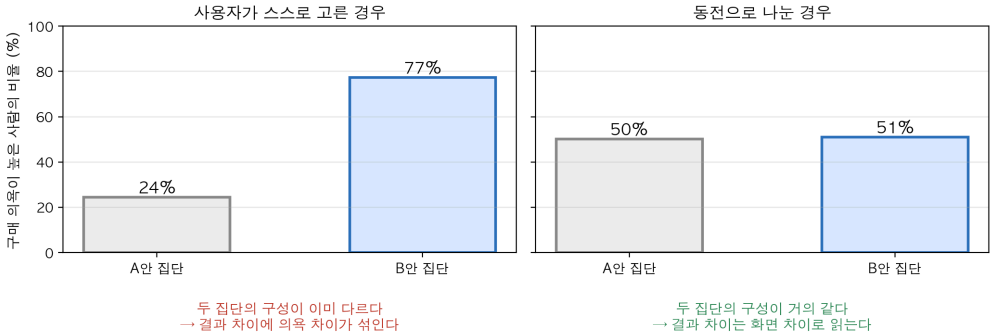
○ 앞 장들의 방법은 관측 데이터에서 효과를 구하려고 가정에 기댔다. 도구변수는 배제제약을, 이중차분은 평행추세를 가정하며, 이 가정들은 데이터로 완전히 확인되지 않는다. 그래서 결과를 읽는 사람은 늘 “그 가정이 맞다면”이라는 단서를 붙여야 한다

○ 실험은 이 단서를 없앤다. 누가 처치를 받을지를 연구자가 동전 던지기로 정하는 것이 **무작위 배정**이다

- 동전은 사람의 나이·소득·의욕을 보지 않는다. 그래서 측정한 특성뿐 아니라 측정하지 못한 특성까지 두 집단에 비슷한 비율로 나뉜다
- 두 집단의 구성이 같으므로, 결과 평균의 차이를 그대로 처치의 효과로 읽는다. 3장에서 매칭으로 애써 만들던 “비슷한 두 집단”이 설계 단계에서 이미 만들어진다

○ 비즈니스에서는 이 절차를 **A/B 테스트**라고 부른다. 사용자를 A안(대조군)과 B안(처치군)에 무작위로 나눠 보여 준 뒤 **전환율**을 비교한다. 전환율은 그 안을 본 100명 중 목표 행동을 한 사람의 비율이다. 의학의 무작위 대조시험(RCT)과 구조가 같다

그림 8-1. 동전으로 나누면 측정하지 못한 특성까지 두 집단에 고르게 퍼진다



○ 그림 8-1 읽는 법 — 2,000명을 만들어 실행한 가상의 예다. 절반이 “구매 의욕이 높은 사람”이며, 이 의욕은 데이터에 기록되지 않는다고 하자

– 왼쪽: 사용자가 화면을 스스로 고르게 하면, 의욕이 높은 사람이 새 화면을 더 많이 고른다. B안 집단의 77%, A안 집단의 24%가 의욕이 높은 사람이다. 이 상태에서 B안의 전환율이 높게 나와도, 화면 덕분인지 원래 의욕이 높은 사람이 모였기 때문인지 구별할 수 없다

– 오른쪽: 동전으로 나누면 두 집단 모두 의욕이 높은 사람이 50%, 51%로 거의 같다. 이 경우 전환율 차이는 화면 차이에서 나온 것으로 읽는다

○ 인원이 적은 실험에서는 **층화 무작위 배정**을 쓴다. 중요한 특성(모바일/데스크톱, 신규/기존)으로 사용자를 먼저 묶고 각 묶음 안에서 반반으로 나누므로, 우연히 한쪽에 모바일 사용자가 몰리는 일을 막는다

한 줄 정리: 동전으로 나누면 측정하지 못한 특성까지 같은 두 집단이 만들어진다. 그래서 결과 차이를 효과로 읽는다.

8.1.2 표본 크기 — 실험 전에 정해야 하는 숫자

○ 왜 필요한가: 실험을 먼저 시작하고 “언제까지 모을지”를 결과를 보며 정하면, 결과가 좋아 보이는 시점에 멈추게 된다. 그러면 결론이 부풀려진다. 그래서 **표본 크기**(실험에 필요한 인원)는 시작 전에 계산해 문서에 적는다

○ 계산에 넣는 값은 세 가지다: A안의 예상 전환율, B안의 예상 전환율, 원하는 검정력(8.1.3). 계산 결과는 “한 안에 몇 명”이다. 이 장에서는 비교하는 안 하나를 **팔(arm)** 이라고 부르므로 “팔당 몇 명”으로 쓴다

○ 원리: 작은 차이를 구별하려면 많이 봐야 한다

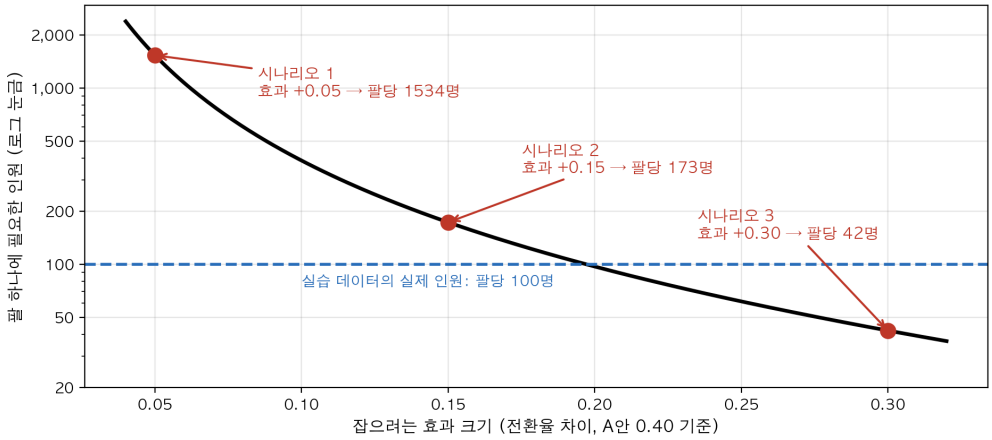
– 동전 두 개 중 하나가 앞면이 조금 더 잘 나오는지 확인한다고 하자. 앞면 확률이 0.4와 0.7이면 몇십 번만 던져도 차이가 보인다. 0.40과 0.45면 수천 번을 던져야 우연과 구별된다

– 필요 인원은 두 전환율 차이의 **제곱**에 반비례한다. 그래서 **잡으려는 효과가 절반이 되면 필요 인원은 약 4배**, 3분의 1이 되면 약 9배가 된다

○ 실습 데이터의 세 실험(A안 전환율은 모두 0.40)에 이 계산을 적용한 결과다(`results/8-1-fixed-rct-simulation.log` 발췌)

시나리오	참 효과	필요 n/팔	필요 총원	실제 n/팔	과부족
시나리오 1 (소효과)	+0.05	1534	3068	100	-1434
시나리오 2 (중효과)	+0.15	173	346	100	-73
시나리오 3 (대효과)	+0.30	42	84	100	+58
시나리오 4 (무효과)	+0.00	무한	무한	100	–

그림 8-2. 잡으려는 효과가 작아질수록 필요한 인원은 빠르게 늘어난다



효과 +0.30 → +0.15로 절반이 되면 42명 → 173명으로 약 4배. 검정력 0.80, 유의수준 0.05 기준.

○ 그림 8-2 읽는 법

– 가로축은 잡으려는 효과(전환율 차이), 세로축은 팔당 필요 인원이다. 세로축은 로그 눈금이라 한 칸 올라갈 때마다 인원이 몇 배씩 늘어난다

– 효과 +0.30 → +0.15로 절반이 되면 42명 → 173명으로 4.1배가 된다. +0.05로 다시 3분의 1이 되면 1,534명으로 다시 8.9배가 된다. 파란 점선(실제 인원 팔당 100명)보다 위에 있는 시나리오 1·2는 인원이 모자란다

○ 결과를 읽는 법

– **판정 눈금: 필요 인원을 확보하지 못하면 실험을 시작하지 않는다.** 시나리오 1은 팔당 1,534명이 필요한데 100명뿐이므로, 효과가 있어도 찾지 못한다

– 시나리오 3은 42명이면 충분한데 100명을 모았다. 팔당 58명이 남았고, 그 인원 중 A안에 배정된 사람은 더 나쁜 화면을 불필요하게 본 셈이다

- 시나리오 4의 “무한”은 계산 실패가 아니다. 참 효과가 0이면 구별할 차이가 없으므로, 아무리 모아도 “차이가 있다”를 확인할 수 없다. 그래서 설계할 때 “이 정도 효과면 의미 있다”는 최소 효과 크기를 먼저 정한다

한 줄 정리: 표본 크기는 실험 전에 정해 문서에 적는다. 잡으려는 효과가 절반이면 인원은 4배다.

8.1.3 검정력 — 지금 인원으로 무엇을 잡을 수 있는가

○ 왜 필요한가: 현실에서는 인원이 먼저 정해져 있는 경우가 많다. 하루 방문자 수가 정해져 있고 실험 기간이 2주로 묶여 있다면, 질문은 “몇 명이 필요한가”가 아니라 “지금 인원으로 어느 크기의 효과까지 잡을 수 있는가”가 된다

○ 그 답이 **검정력(power)** 이다. 검정력 0.80은 “효과가 정말 그 크기라면, 같은 실험을 100번 했을 때 80번은 유의하다는 결론이 나온다”는 뜻이다. 거꾸로 말하면 20번은 효과가 있는데도 놓친다

- 비유: 검정력은 그물의 촘촘함에 대응한다. 큰 물고기(큰 효과)는 성긴 그물(적은 인원)로도 잡히지만, 작은 물고기(작은 효과)는 촘촘한 그물(많은 인원)이 있어야 잡힌다

○ 팔당 100명일 때 네 시나리오의 검정력이다(로그 발췌)

시나리오	참 효과	검정력	판정
시나리오 1 (소효과)	+0.05	0.106	부족 (효과를 놓칠 확률이 큼)
시나리오 2 (중효과)	+0.15	0.566	부족 (효과를 놓칠 확률이 큼)
시나리오 3 (대효과)	+0.30	0.992	충분
시나리오 4 (무효과)	+0.00	0.050	효과 없음 (이 값은 1종 오류율)

○ 결과를 읽는 법

- 팔당 100명으로 +0.05 효과를 잡을 확률은 0.106이다. 열 번 중 아홉 번은 놓친다. 이런 실험에서 “유의하지 않았다”는 결과가 나와도 효과가 없다는 근거가 되지 않는다. 그물이 성겨서 못 잡았을 뿐이다

- 시나리오 4의 0.050은 성격이 다르다. 참 효과가 0인데 “유의하다”고 나올 확률이므로 **1종 오류**의 확률이다. 설계에서 정한 5%와 같으므로 검정이 설계대로 작동한다

- **판정 눈금: 검정력 0.80 미만이면 실험을 그대로 진행하지 않는다.** 인원을 늘리거나, 잡으려는 최소 효과를 키우거나, 흩어짐이 작은 다른 지표로 바꾼 뒤 다시 계산한다. 셋 다 할 수 없으면 실험을 접는다

한 줄 정리: 검정력 0.80이 실험 시작의 관문이다. 관문을 넘지 못한 실험의 “유의하지 않음”은 정보가 아니다.

8.1.4 실습 8-1 — 네 실험을 실제로 돌려 결과를 읽는다

○ 앞의 두 소절은 실험 전의 계산이었다. 이제 실제 데이터(`8-1-fixed-rct.csv`, 시나리오마다 팔당 100명, 모두 800명)로 계산이 예고한 대로 결과가 나오는지 확인한다

○ 실습 코드(`8-1-fixed-rct-simulation.py`)는 시나리오마다 B안 전환율에서 A안 전환율을 빼 관측 효과를 구하고, t검정으로 그 차이가 우연인지 판정한다

○ 실행 결과(로그 발췌)

```
시나리오 1 (소효과)  관측 효과 +0.060  95% CI [-0.076, +0.196]  p=0.3890  유의하지 않음
시나리오 2 (중효과)  관측 효과 +0.100  95% CI [-0.039, +0.239]  p=0.1589  유의하지 않음
시나리오 3 (대효과)  관측 효과 +0.260  95% CI [+0.126, +0.394]  p=0.0002  유의함
시나리오 4 (무효과)  관측 효과 +0.160  95% CI [+0.029, +0.291]  p=0.0176  유의함
```

○ 결과를 읽는 법

– 시나리오 1·2는 참 효과가 있는데도 유의하지 않다. 검정력 0.106과 0.566이 예고한 결과다. 보고서에는 “효과가 없다”가 아니라 “이 인원으로는 판단할 수 없다”고 쓴다

– 시나리오 3은 p=0.0002로 유의하고, 95% 신뢰구간(참값이 들어 있을 법한 범위) [+0.126, +0.394]도 0을 포함하지 않는다

– **시나리오 4가 이 실습의 핵심이다.** 두 안의 참 전환율이 똑같이 0.40인데 p=0.018로 유의하게 나왔다. 관측 효과 +0.160은 순전히 우연이며, 1종 오류다. 유의수준 5%란 이런 실험이 20번에 1번꼴로 나오는 것을 허용한다는 뜻이다

○ **판정 눈금: 유의한 결과를 받으면 세 가지를 순서대로 확인한다.** ① 미리 정한 인원에 도달했는가 ② 중간에 여러 번 들여다보다가 유의할 때 멈춘 것은 아닌가(8.2) ③ 효과 크기가 사업적으로 의미 있는가. 하나라도 걸리면 결론을 미루고 같은 실험을 다시 한다

한 줄 정리: 검정력이 예고한 대로 결과가 나온다. 그리고 효과가 0이어도 20번에 1번은 유의하게 나온다.

8.1.5 실험 점검 — 배정 비율부터 확인한다

○ 분석 방법보다 기본 점검이 실험의 성패를 더 자주 가른다. 가장 자주 생기는 문제가 **표본 비율 불일치 (SRM, Sample Ratio Mismatch)** 다. 50:50으로 배정하도록 설계했는데 실제 기록은 48:52처럼 어긋난 경우다

– 수백만 명 규모에서 이 정도 차이는 우연으로 생기지 않는다. 예를 들어 자동 접속 프로그램(봇)의 기록이 B안에서만 걸러졌다면 두 집단의 구성이 달라지고, 8.1.1에서 동전으로 만든 “같은 두 집단”이 깨진다

  - **판정 눈금: 배정 비율 검정에서 $p < 0.001$이면, 효과 추정치가 아무리 좋아 보여도 결과를 읽지 않는다.** 기록 과정을 고친 뒤 실험을 다시 한다

○ 실험 설계 문서에는 **주 지표 하나**와 **가드레일 지표**(전환율이 올라도 이탈률·오류율이 나빠지면 배포하지 않는다는 조건)를 미리 적는다. 지표를 여러 개 두고 그중 유의한 것만 보고하면, 지표 수만큼 1종 오류의 기회가 늘어난다

○ 반반 고정 실험에는 비용이 세 가지 있다. 실험 내내 절반의 사용자가 나쁜 안을 보고, 효과 크기를 모르니 인원을 넉넉히 잡게 되며(시나리오 3의 남는 58명), 결론이 늦게 나온다. 세 비용 모두 배분 비율과 종료 시점을 미리 고정했기 때문에 생긴다. 8.2는 종료 시점을, 2부는 배분 비율을 실험 도중에 바꾸는 설계를 다룬다

한 줄 정리: 배정 비율이 어긋나면(SRM) 결과를 읽지 않는다. 고정 실험의 비용은 모두 "미리 고정"에서 나온다.

□ 8.2 중간에 들여다보기 — 언제 멈춰도 되는가

8.2.1 왜 문제인가 — 유의할 때까지 보면 우연이 효과가 된다

○ 앞 절에 남은 질문: 효과가 확실해 보이면 그때 멈추면 되지 않는가

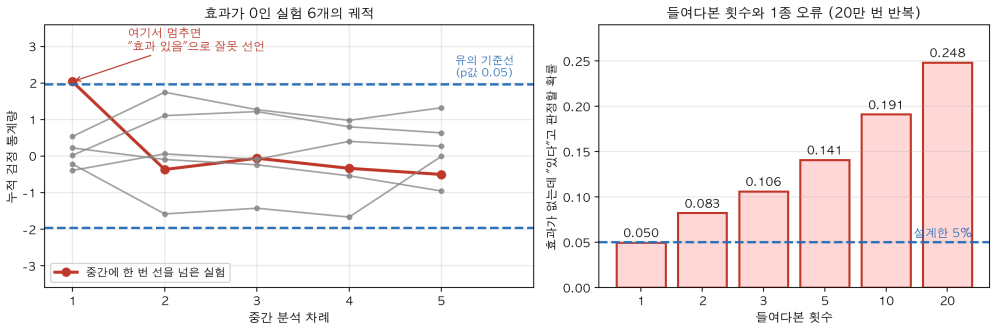
○ 원리: 주사위를 한 번 던져 6이 나올 확률은 1/6이다. 다섯 번 던지면서 "한 번이라도 6이 나오면 이긴다"고 하면, 이길 확률은 크게 오른다

  - 대응 관계: 주사위 한 번 = **중간 분석**(실험이 끝나기 전에 결과를 들여다보는 것) 한 번, 6이 나옴 = $p < 0.05$가 나옴, "6이 나오면 멈추고 이겼다고 선언" = "유의하면 멈추고 효과가 있다고 선언"

  - 효과가 전혀 없는 실험도 결과 수치는 들쭉날쭉하다. 여러 번 들여다보면 그중 한 번쯤은 우연히 기준선을 넘는다

○ 실습 코드(`8-2-group-sequential-design.py`)는 이 상황을 20만 번 반복했다. 두 안의 효과가 정말 같다고 두고, K번 들여다보면서 한 번이라도 $p < 0.05$면 멈추고 "효과 있음"으로 선언한다. 잘못 선언한 비율이 그림 8-3 오른쪽의 막대다(`results/8-2-group-sequential-design.log` 1단계)

그림 8-3. 유의할 때까지 들여다보면 우연이 "효과"로 둔갑한다



○ 그림 8-3 읽는 법

– 왼쪽: 효과가 0인 실험 6개를 다섯 번씩 들여다본 궤적이다(가상의 시뮬레이션). 세로축의 검정 통계량이 파란 점선(±1.96)을 넘으면 $p < 0.05$다. 빨간 실험은 1차에서 선을 넘었다가 다시 내려왔다. 1차에서 멈췄다면 "효과 있음"으로 잘못 선언했을 것이다

– 오른쪽: 한 번만 보면 0.050으로 설계한 5% 그대로다. 다섯 번 보면 0.141로, 효과가 전혀 없는 실험 일곱 개 중 하나에서 "유의하다"는 결론이 나온다. 스무 번이면 네 개 중 하나다

○ 주사위와 다른 점이 하나 있다. 주사위는 매번 독립이지만, 중간 분석은 앞 단계 데이터를 포함한 누적 결과를 쓰므로 단계끼리 닮아 있다. 그래서 다섯 번 봐도 $0.05 \times 5 = 0.25$까지 오르지 않고 0.141에 그친다

○ **판정 눈금: 결과를 확인하는 횟수와 시점은 실험 시작 전에 정해 문서에 적는다.** 정하지 않고 들여다본 뒤 유의해서 멈춘 실험의 p값은 그대로 보고하지 않고, 같은 실험을 다시 해서 확인한다

한 줄 정리: 보정 없이 다섯 번 들여다보면 1종 오류가 5%가 아니라 14%다.

8.2.2 그룹 순차 설계 — 매번의 기준을 엄격하게 바꾼다

○ 왜 필요한가: "중간에 보지 말라"로 끝내면, 나쁜 안이 분명해 보여도 실험을 끝까지 끌고 가야 한다. 필요한 것은 **중간에 보되 전체 1종 오류는 5%로 지키는 규칙**이며, 그 규칙이 **그룹 순차 설계**다

○ 원리: 여러 번 보면 오류가 늘어나므로, 매번 넘어야 하는 기준선(**중단 경계**)을 1.96보다 높게 올린다. 기준선을 얼마나 올릴지는 "전체 오류가 정확히 5%가 되는 높이"를 시뮬레이션으로 찾는다

○ 기준선을 올리는 모양에 따라 두 가지 방식이 있다

– **Pocock 경계**: 모든 차례에 같은 높이의 기준선을 쓴다

– **O'Brien-Fleming 경계(OBF)**: 처음에는 매우 높게, 뒤로 갈수록 낮게 둔다. 데이터가 적은 초기에는 웬만해서는 멈추지 않게 만든 것이다

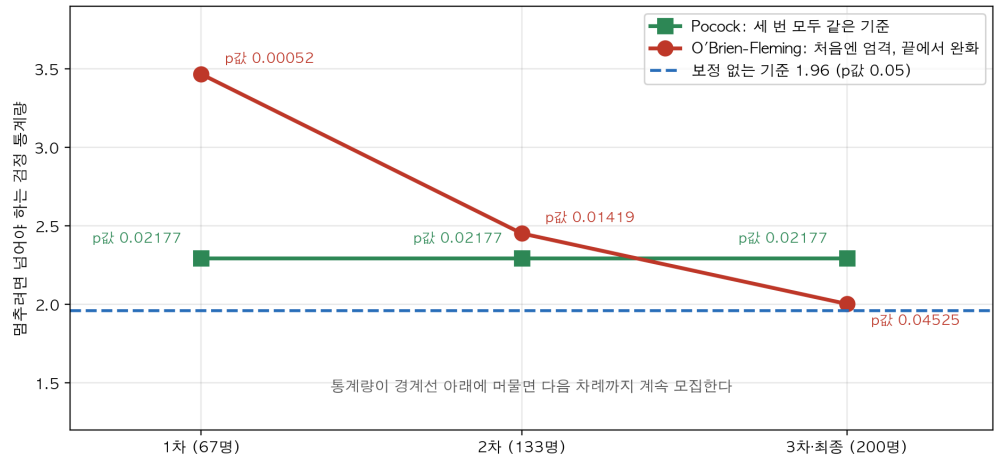
○ 이 실습의 설계: 총 200명을 모으면서 67명·133명·200명 시점에 세 번 판정한다

○ 실행 결과(로그 발췌)

```
  단계      정보 분획      누적 n   Pocock z   Pocock p    OBF z      OBF p
   1        0.33          67       2.294      0.02177     3.468      0.00052
   2        0.67          133      2.294      0.02177     2.452      0.01419
   3        1.00          200      2.294      0.02177     2.002      0.04525

무보정 (매번 1.96)          1종 오류 0.1161   1단계에서 중단 0.0611
Pocock                  1종 오류 0.0510   1단계에서 중단 0.0213
O'Brien-Fleming         1종 오류 0.0520   1단계에서 중단 0.0004
```

그림 8-4. 세 번 들여다보면서 전체 오류를 5%로 지키는 두 가지 방법



○ 그림 8-4 읽는 법

– 가로축은 판정 차례, 세로축은 멈추려면 넘어야 하는 기준선의 높이다. 통계량이 선 아래에 있으면 다음 차례까지 계속 모집한다

– 초록 Pocock 선은 세 차례 모두 2.294(p값 0.02177)로 같다. 빨간 OBF 선은 1차에 3.468(p값 0.00052)로 매우 높고, 3차에는 2.002(p값 0.04525)로 보정하지 않은 기준 1.96(파란 점선) 근처까지 내려온다

○ 결과를 읽는 법 — 아래 세 줄은 두 안의 전환율을 모두 0.40으로 두고 2만 번 실험을 반복한 확인 결과다

– 무보정(매번 1.96)은 1종 오류가 0.1161로 설계의 두 배를 넘는다. 기준선을 올린 두 방식은 0.0510과 0.0520으로 5% 근처로 돌아온다

– 1차에서 멈추는 확률은 Pocock 0.0213, OBF 0.0004다. OBF는 초기에 거의 멈추지 않는다

○ **판정 눈금: 경계를 넘으면 그 차례에서 종료하고, 넘지 못하면 다음 차례까지 계속 모집한다.** “거의 넘을 뻔했다”는 이유로 기준을 낮추지 않는다. 경계값은 실험 시작 전에 계산해 문서에 적는다

한 줄 정리: 매번의 기준을 엄격하게 바꾸면, 세 번 들여다봐도 전체 1종 오류는 5%로 돌아온다.

8.2.3 POCOCK과 O’BRIEN-FLEMING 중 무엇을 고르는가

○ 두 경계는 같은 5%를 차례마다 어떻게 나눠 쓰는지만 다르다

– **OBF를 고르는 경우**: 최종 결론의 정확도가 중요할 때다. 1차 기준이 매우 엄격해 인원이 적은 초기의 우연한 큰 값에 흔들리지 않는다. 규제 기관에 내는 임상시험과 정책 평가의 기본값이다

– **Pocock을 고르는 경우**: 일찍 멈추는 것 자체가 큰 이득일 때다. 나쁜 안을 보여 주는 비용이 크거나 실험 운영비가 높은 상황이다. 대신 마지막 차례에서도 p값 0.02177 미만을 요구하므로, 끝까지 가면 유의한 결과를 얻기가 더 어렵다

○ 판정 연습(가상의 수치다): 위 경계표를 쓰는 실험의 2차(누적 133명)에서 p값 0.018이 나왔다면?

– Pocock이면 0.018 < 0.02177이므로 멈춘다. OBF면 0.018 > 0.01419이므로 3차까지 모집한다. 같은 데이터라도 시작 전에 고른 경계에 따라 행동이 달라진다

한 줄 정리: 끝까지 가서 정확한 결론이 중요하면 OBF, 일찍 멈추는 이득이 크면 Pocock이다.

□ 1부 정리

○ 지금까지 만든 것 두 가지: 네 실험의 요약(참 효과·필요 인원·검정력·관측 효과·p값), 그리고 중간 분석의 중단 경계표

○ 확인한 판정 기준: 검정력 0.80 미만이면 시작하지 않는다. 배정 비율이 어긋나면(SRM) 결과를 읽지 않는다. 중간에 여러 번 판정하려면 경계를 보정하고, 경계와 시점은 실험 전에 문서에 적는다

○ 여기까지는 배분을 반반으로 고정한 채 끝내는 시점만 조정했다. 2부의 질문: 나쁜 안에 절반의 사용자가 계속 배정되는 손실 자체를 줄이려면, 배분 비율을 실험 도중에 바꾸면 되지 않는가

2부. 배분 비율을 바꾸는 설계로 손실을 줄인다

□ 2부 개요

○ 이 파트가 끝나면: 적응형 배분이 줄이는 손실과 그 대가를 숫자로 읽고, 새 과제에 고정 배분과 적응형 배분 중 무엇을 쓸지 정할 수 있다

○ 다루는 절: 8.3 ~ 8.6

□ 8.3 슬롯머신 문제와 톰슨 샘플링

8.3.1 탐험과 활용 — 알아내기와 벌기를 맞바꾼다

○ 실험 도중 관측되는 결과에 따라 배정 확률을 바꾸는 설계를 **반응 적응형 무작위 배정**이라고 부른다. 그룹 순차 설계가 끝내는 시점을 바꿨다면, 이 설계는 배분 비율 자체를 바꾼다

○ 여기서 두 목표가 부딪힌다

– **탐험(exploration)**: 모든 안을 충분히 시도해 어느 것이 좋은지 알아내는 일

– **활용(exploitation)**: 지금까지 좋아 보이는 안을 많이 써서 성과를 올리는 일

– 탐험만 하면 나쁜 안에 계속 사용자를 보낸다. 활용만 하면 초기 몇 번의 운으로 잘못 고른 안에 계속 머문다

○ 이 문제를 **멀티 암드 밴딧(multi-armed bandit)**, 곧 “슬롯머신 여러 대 문제”라고 부른다. 이름이 비유이므로 대응 관계를 표로 정리한다

카지노 상황	실험 상황
슬롯머신 한 대	비교하는 안 하나(팔)
레버를 한 번 당김	사용자 한 명에게 그 안을 보여 줌
기계마다 숨어 있는 당첨 확률	각 안의 참 전환율
최고 기계만 당겼을 때와의 수익 차이	기대 손실

○ 비유가 맞지 않는 지점: 슬롯머신의 당첨 확률은 고정이지만, 서비스의 전환율은 요일·시즌에 따라 움직여 과거 데이터로 정한 배분이 틀릴 수 있다

한 줄 정리: 배분을 바꾸는 설계는 “알아내기”와 “벌기”를 맞바꾸는 문제다.

8.3.2 톰슨 샘플링의 원리 — 분포의 폭이 탐험을 조절한다

○ “다음 한 명을 어느 안에 보낼 것인가”에 답하는 방법은 여러 가지다

방법	다음 사용자를 보내는 기준	약점
Epsilon-Greedy	10%는 아무 안이나, 90%는 지금까지 전환율이 가장 높은 안	10%라는 값을 사람이 정해야 하고, 최적 안을 찾은 뒤에도 10%를 계속 낭비한다

방법	다음 사용자를 보내는 기준	약점
톰슨 샘플링	안마다 “전환율이 얼마쯤일까”의 분포에서 값을 하나씩 뽑아 가장 큰 안	매번 분포를 갱신하는 실시간 계산이 필요하다

○ **톰슨 샘플링(Thompson Sampling)** 의 절차는 네 단계다

– ① 안마다 성공 횟수와 실패 횟수를 센다

– ② 그 두 숫자로 “전환율이 얼마쯤일까”를 나타내는 분포를 만든다. 이 분포를 **Beta 분포**라고 부르며, Beta(1+성공, 1+실패)로 쓴다

– ③ 안마다 그 분포에서 난수를 하나씩 뽑는다

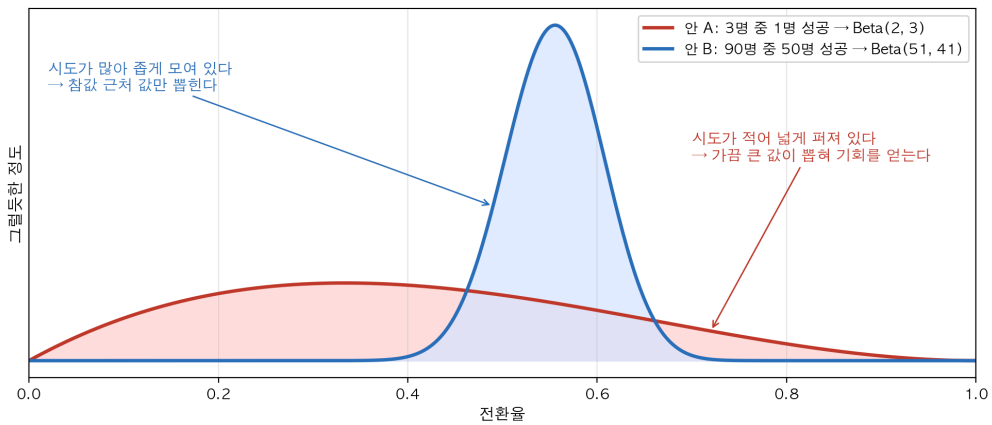
– ④ 가장 큰 난수가 나온 안에 다음 사용자를 보내고, 반응을 기록해 ①로 돌아간다

○ 손으로 따라간다(가상의 수치다). 안 A는 3명 중 1명이 전환했고, 안 B는 90명 중 50명이 전환했다

– 안 A의 분포는 Beta(1+1, 1+2) = Beta(2, 3), 안 B의 분포는 Beta(1+50, 1+40) = Beta(51, 41)이다

– 지금까지의 전환율은 A가 0.33, B가 0.56으로 B가 높다. 그래도 A는 3명밖에 보지 않아서 “사실은 0.7일 수도 있다”는 가능성이 남아 있다

그림 8-5. 톰슨 샘플링은 두 분포에서 하나씩 뽑아 큰 쪽에 다음 사용자를 보낸다



두 분포에서 20만 번 뽑아 보면 안 A가 이기는 비율은 24%다. 안 A는 평균이 낮아도 이만큼 다시 시도된다.

○ 그림 8-5 읽는 법

– 가로축은 전환율, 세로축은 그 값이 얼마나 그럴듯한지다. 봉우리가 높은 곳일수록 그 근처 값이 자주 뽑힌다

  - 파란 안 B는 90명을 봐서 0.55 근처에 좁게 모여 있다. 빨간 안 A는 3명만 봐서 0부터 1까지 넓게 퍼져 있어, 가끔 0.7이나 0.8 같은 큰 값이 뽑힌다

  - 두 분포에서 20만 번 뽑아 보면 A가 이기는 비율이 24%다. 지금 시점에서 다음 사용자가 A에 배정될 확률이 약 24%라는 뜻이다. A는 전환율이 낮아 보여도 다시 기회를 얻는다

- 원리: 시도가 적은 안은 분포가 넓어서 가끔 큰 값이 뽑혀 기회를 얻는다(탐험). 시도가 쌓이면 분포가 좁아져 참값 근처 값만 뽑힌다(활용). 탐험 비율을 사람이 정하지 않아도 분포의 폭이 그 비율을 정한다. Epsilon-Greedy와 갈리는 지점이 여기다

한 줄 정리: 톰슨 샘플링은 "성공·실패를 세고, 분포에서 뽑고, 큰 쪽에 보낸다"의 반복이다.

8.3.3 실습 8-3 — 톰슨 샘플링이 줄인 손실을 계산한다

- 데이터는 `8-3-thompson-sampling.csv`다. 참 전환율이 0.30, 0.55, 0.40인 세 안(안 0, 안 1, 안 2)에 톰슨 샘플링으로 1,000명을 배정한 기록이다. 안 1이 가장 좋다

- 성과는 **기대 손실**로 계산한다. 안마다 "그 안에 보낸 인원 × 최적 안과의 전환율 차이"를 구해 더한다

  - 고정 배분(1:1:1)이면 세 안에 333.3명씩 간다. 안 0의 손실 333.3 × (0.55 − 0.30) = 83.3, 안 2의 손실 333.3 × (0.55 − 0.40) = 50.0이므로 합은 133.33이다

  - 기대 손실 133.33은 "나쁜 안을 본 탓에 놓친 전환이 약 133건"이라는 뜻이다

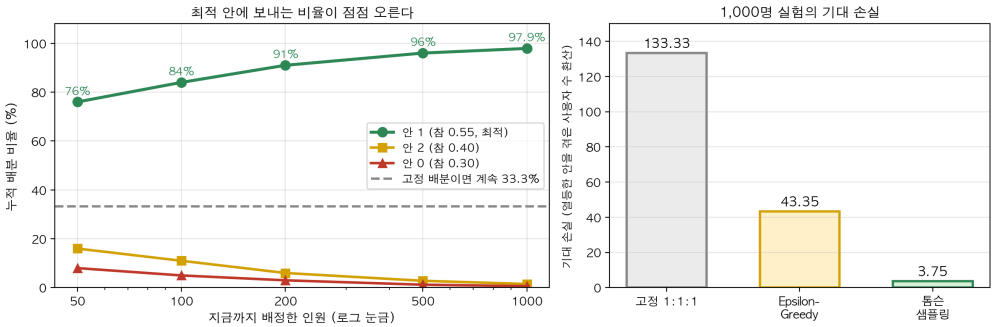
- 실습 코드(`8-3-thompson-sampling.py`)는 안별 배분 인원을 세고 위 계산을 그대로 한다. 실행 결과(`results/8-3-thompson-sampling.log` 발췌)

```
 Arm      참 전환율      배분 인원      배분 비율     성공
   0       0.30          6        0.6%      0
   1       0.55        979       97.9%    569
   2       0.40         15        1.5%      3

                배분 방식 최적팔 배분비율  기대 손실 실현 보상
              고정 1:1:1    33.3% 133.33      -
Epsilon-Greedy (ε=0.1)    73.1%  43.35   524
               톰슨 샘플링    97.9%   3.75   572
```

- 손계산 확인: 톰슨 샘플링의 기대 손실은 6명 × 0.25 + 979명 × 0 + 15명 × 0.15 = 1.5 + 0 + 2.25 = 3.75다

그림 8-6. 톰슨 샘플링은 배분을 최적 안으로 옮겨 손실을 133.33에서 3.75로 줄였다



○ 그림 8-6 읽는 법

– 왼쪽: 가로축은 지금까지 배정한 인원, 세로축은 그때까지 각 안에 보낸 비율이다. 최적인 안 1의 비율이 50명 시점에 이미 76%이고, 200명에 91%, 1,000명에 97.9%까지 오른다. 고정 배분이면 회색 점선처럼 끝까지 33.3%다

– 오른쪽: 1,000명 실험의 기대 손실이다. 고정 배분 133.33, Epsilon-Greedy 43.35, 톰슨 샘플링 3.75 순으로 줄어든다

○ 결과를 읽는 법

– 기대 손실이 133.33에서 3.75로 97.2% 줄었다. 나쁜 안을 겪은 탓에 놓친 전환이 약 130건 줄었다는 뜻이다. 전환 한 건의 가치(예: 평균 구매액)를 곱하면 금액으로 바꿀 수 있다

– **판정 눈금: 도입 여부는 줄어든 손실을 금액으로 바꿔 도입 비용과 비교해 정한다.** 실시간 배분 시스템을 만들고 운영하는 비용이 더 크면 고정 배분을 쓴다. 전체 인원이 수백 명 수준이면 배분이 쏠리기 전에 실험이 끝나 이득이 작다

한 줄 정리: 톰슨 샘플링은 최적 안에 97.9%를 보내 기대 손실을 97.2% 줄였다.

8.3.4 적응형 배분이 포기하는 것

○ 앞 결과만 보면 적응형 배분이 모든 면에서 나아 보인다. 같은 로그의 5단계 출력에 그 대가가 있다

Arm	배분 인원	사후평균	참값	절대오차	95% 신용구간
0	6	0.125	0.30	0.175	[0.004, 0.410]
1	979	0.581	0.55	0.031	[0.550, 0.612]
2	15	0.235	0.40	0.165	[0.073, 0.456]

○ 결과를 읽는 법

- 979명을 받은 안 1은 추정이 정확하다. 추정값 0.581은 참값 0.55와 0.031 차이이고, 구간 폭도 0.062로 좁다
- 6명만 받은 안 0은 추정값 0.125가 참값 0.30에서 0.175나 떨어져 있고, 구간 [0.004, 0.410]은 0.4 넘게 퍼져 있다. “안 0의 전환율은 0.125”라고 보고하면 틀린 숫자를 보고하는 것이다
- 적응형 배분은 **최적 안을 찾고 손실을 줄이는 데는 강하지만, 나쁜 안의 효과를 정확히 알아내는 일은 포기한다.** 나쁜 안에 사람을 보내지 않으니 그 안에 대한 정보도 모이지 않는다

○ **판정 눈금: 배분 인원 30명 미만인 안의 추정치는 보고서에 싣지 않는다.** 과제의 목적이 효과 크기 추정이면 고정 배분을, 실험 기간의 성과 개선이면 적응형 배분을 쓴다. 두 목적을 한 실험으로 동시에 이루려는 설계는 대개 둘 다 놓친다

한 줄 정리: 손실 감소의 대가는 나쁜 안의 추정 포기다. 목적이 추정이면 적응형을 쓰지 않는다.

□ 8.4 베이지안 적응형 설계 — “B안이 나을 확률”로 멈춘다

8.4.1 원리 — 성공·실패를 더해 분포를 갱신한다

○ 왜 필요한가: 그룹 순차 설계는 p값으로 멈출지를 정한다. p값은 “효과가 없다고 가정할 때 이만큼 극단적인 결과가 나올 확률”이라 조건을 붙여 읽어야 한다. 그런데 회의에서는 거의 항상 “B안이 나을 확률 95%”로 잘못 옮겨진다

○ **베이지안 적응형 설계**는 그 잘못된 번역을 정식 계산으로 만든다. **사후확률**은 “지금까지의 데이터를 보고 계산한, B안의 전환율이 A안보다 높을 확률”이며, 조건 없이 문자 그대로 읽는다

○ 계산 절차는 세 단계다

- ① 데이터를 보기 전의 믿음(**사전분포**)을 “0과 1 사이 모든 전환율이 똑같이 그럴듯하다”로 놓는다. Beta(1, 1)이다
- ② 관측이 쌓이면 성공 횟수를 앞 숫자에, 실패 횟수를 뒤 숫자에 더한다. 이렇게 갱신한 분포가 **사후분포**다
- ③ 두 안의 사후분포에서 난수를 많이 뽑아 “B의 값이 A의 값보다 큰 비율”을 세면 그것이 사후확률이다

○ 손으로 따라간다. 실습 데이터의 대효과 실험에서 첫 50명(각 안 25명)의 결과다

- A안: 25명 중 11명 성공, 14명 실패 → Beta(1+11, 1+14) = Beta(12, 15). 분포의 중심(평균)은 12 ÷ 27 = 0.44다

- B안: 25명 중 19명 성공, 6명 실패 → Beta(1+19, 1+6) = Beta(20, 7). 분포의 중심은 20 ÷ 27 = 0.74다
- 두 분포에서 20만 번씩 뽑아 B가 큰 비율을 세면 0.9887이다. "지금까지 데이터로 보면 B안이 나을 확률이 98.87%"로 읽는다

○ 실습 코드(핵심 부분, 전체는 `8-4-bayesian-adaptive.py`)

```
pa = rng_mc.beta(1 + s_c, 1 + n_c - s_c, 200_000)   # A안 사후분포에서 20만 번 뽑기
pb = rng_mc.beta(1 + s_t, 1 + n_t - s_t, 200_000)   # B안 사후분포에서 20만 번 뽑기
pp = float(np.mean(pb > pa))                        # B가 A보다 큰 비율 = 사후확률

# 멈추는 규칙: pp >= 0.99 → B안 채택·중단 / pp <= 0.05 → B안 폐기·중단 / 그 사이 → 계속
```

○ 멈추는 문턱이 위·아래 두 개다

- **위 문턱 0.99**: B안이 나을 확률이 99% 이상이면 더 볼 필요 없이 B안을 채택한다(효능 중단)
- **아래 문턱 0.05**: B안이 나을 확률이 5% 이하이면 더 볼 이유가 없으므로 B안을 접는다(무용성 중단)

한 줄 정리: 사후확률은 "B안이 나을 확률"로 바로 읽는다. 멈추는 문턱은 위·아래 두 개다.

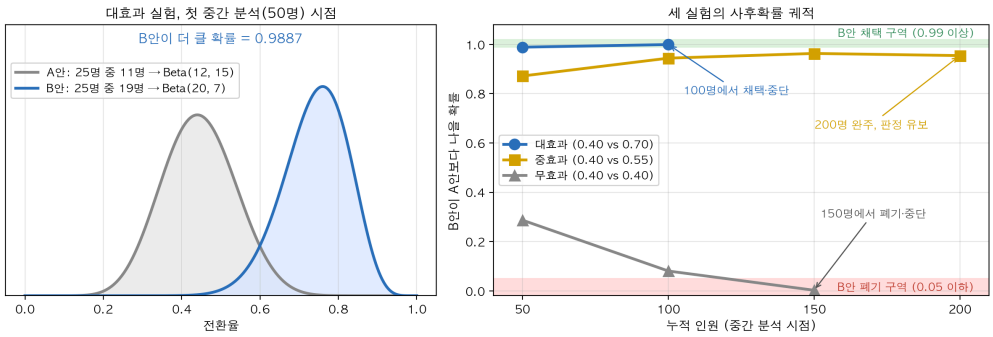
8.4.2 실습 8-4 — 세 실험의 사후확률 궤적을 읽는다

○ 실험마다 최대 200명까지 모집하고, 누적 50·100·150·200명 시점에 중간 분석을 한다. 참 전환율은 대효과 0.40 대 0.70, 중효과 0.40 대 0.55, 무효과 0.40 대 0.40이다

○ 실행 결과(`results/8-4-bayesian-adaptive.log` 발췌)

시나리오	참 A	참 B	최종 n	조기 중단	이유	최종 사후확률	절약한 인원
대효과	0.40	0.70	100	예	efficacy	0.9993	100
중효과	0.40	0.55	200	아니오	-	0.9545	0
무효과	0.40	0.40	150	예	futility	0.0023	50

그림 8-7. 사후확률이 위·아래 문턱 중 하나를 넘으면 멈춘다



○ 그림 8-7 읽는 법

– 왼쪽: 8.4.1에서 손계산한 대효과 실험의 50명 시점이다. 회색 A안 분포(중심 0.44)와 파란 B안 분포(중심 0.74)가 조금 겹친다. 겹친 만큼 “A가 더 클 가능성”이 남아 있어서 사후확률이 1이 아니라 0.9887이다

– 오른쪽: 세 실험의 사후확률이 시점마다 움직인 궤적이다. 위쪽 초록 띠(0.99 이상)에 들어가면 B안 채택, 아래쪽 빨간 띠(0.05 이하)에 들어가면 B안 폐기다

○ 결과를 읽는 법

– 대효과: 50명 시점에 0.9887로 기준 0.99에 0.0013 모자라 계속 모집했다. 100명에서 0.9993으로 넘어 멈췄다. “거의 넘었다”로 멈추지 않는 규칙이 여기서도 적용된다

– 중효과: 0.8718 → 0.9441 → 0.9632 → 0.9545로 움직이며 끝내 0.99에 닿지 못하고 200명을 모두 모았다. 보고서에는 “효과가 없다”가 아니라 “이 인원으로는 0.99 기준을 넘지 못해 판정을 미룬다”고 쓴다

– 무효과: 0.2865 → 0.0803 → 0.0023으로 내려가 150명에서 B안을 접었다

– 세 실험을 고정 설계로 했다면 200명씩 600명이 필요했다. 실제로는 100 + 200 + 150 = 450명을 썼으므로 150명을 아꼈다

한 줄 정리: 효과가 크면 일찍 채택하고, 없으면 일찍 접고, 애매하면 끝까지 모은 뒤 판정을 미룬다.

8.4.3 문턱과 분석 시점은 미리 정한다

○ 0.99라는 문턱은 자연법칙이 아니라 설계자의 선택이다. 문턱을 0.95로 낮추면(로그 4단계) 대효과는 100명 대신 50명에서, 중효과는 200명 대신 150명에서 멈춘다. 실험은 짧아지지만, 효과가 없는 안을 채택할 위험이 함께 커진다

○ 첫 중간 분석 시점도 설계 선택이다. 무효과 실험의 사후확률이 50명 시점 0.2865에서 100명 시점 0.0803으로 크게 움직였다. 인원이 적은 초기에는 값이 크게 흔들리므로, 첫 중간 분석은 각 안에 50명 이상이 모인 뒤에 둔다

○ **판정 눈금: 문턱과 중간 분석 시점은 실험 시작 전에 정하고 실행 중에 바꾸지 않는다.** 규제 기관 제출이나 외부 보고가 걸린 실험이면 0.99, 내부 운영 결정이면 0.95도 쓸 수 있다

○ 판정 연습(가상의 수치다): 문턱이 0.99/0.05인 두 실험의 중간 분석에서 사후확률이 0.97과 0.031이 나왔다면?

– 0.97은 두 문턱 사이이므로 계속 모집하고, 0.031은 0.05 이하이므로 B안을 접는다. 문턱이 0.95였다면 첫 실험은 채택·중단이다

한 줄 정리: 문턱과 분석 시점은 실험 전에 정한 값만 유효하다. 결과를 본 뒤 바꾼 기준은 기준이 아니다.

□ 8.5 종합 사례 — 콘텐츠 5종 중 좋은 것을 찾는 서비스 실험

○ 왜 필요한가: 선택지가 둘일 때와 다섯일 때는 적응형 배분의 움직임이 다르다. 가상의 불면증 관리 앱에서 콘텐츠 5종 중 수면 개선 반응이 좋은 것을 찾는 상황으로 확인한다

– 데이터는 `8-5-korean-dtx.csv`(800명)이며, 참 성공률은 마음챙김 0.52, 수면 개선 0.48, 인지 재구성 0.45, 호흡 훈련 0.38, 운동 독려 0.35로 정해 두었다

– 건강 관리 서비스에서는 효과가 낮은 콘텐츠를 참가자에게 오래 보여 주는 일 자체가 부담이다. 배분을 바꿔 그 노출을 줄이는 설계가 실질적 의미를 갖는다

○ 실습 코드(`8-5-korean-dtx-case.py`)는 8.3.2의 네 단계를 콘텐츠 5개에 그대로 반복한다

○ 실행 결과(`results/8-5-korean-dtx-case.log` 발췌)

```
  콘텐츠              참 성공률      n=200      n=400      n=600      n=800
  마음챙김              0.52      25.5%      20.2%      27.3%      44.2%
  수면 개선             0.48      48.0%      42.2%      34.8%      26.9%

  적응형 배분 기대 성공자 380.2명 / 고정 배분 348.8명 / 전부 최고 콘텐츠 416.0명

  참 성공률 순위 : 마음챙김(0.52) > 수면 개선(0.48) > 인지 재구성(0.45) > 호흡 훈련(0.38) > 운동 독려(0.35)
  배분 인원 순위 : 마음챙김(354명) > 수면 개선(215명) > 인지 재구성(112명) > 운동 독려(89명) > 호흡 훈련(30명)
```

○ 결과를 읽는 법 — 세 가지를 차례로 본다

- **수렴 속도**: 200명 시점에는 2위인 수면 개선이 48.0%로 가장 많이 배정되었고, 1위인 마음챙김은 800명 시점에야 44.2%로 올라섰다. 0.52와 0.48처럼 차이가 작으면 구별하는 데 관측이 많이 필요하다. 8.3의 세 안 실험(50명 시점에 이미 최적 안 76%)보다 훨씬 느리다
- **성과 개선**: 고정 배분이면 다섯 콘텐츠에 160명씩 가므로 기대 성공자는 160 × (0.45 + 0.38 + 0.52 + 0.35 + 0.48) = 348.8명이다. 적응형 배분은 380.2명으로 31.4명(9.0%) 늘었다. 800명 모두 최고 콘텐츠를 받았을 때의 416.0명에는 못 미친다
- **순위**: 1~3위의 배분 순위는 참 순위와 같지만 4위와 5위가 뒤집혔다. 참 성공률 0.38인 호흡 훈련(30명)이 0.35인 운동 독려(89명)보다 적게 배정되었다. 0.03 차이는 800명으로 구별되지 않았고, 두 콘텐츠의 95% 구간 [0.142, 0.446]과 [0.288, 0.486]은 크게 겹친다

○ **판정 눈금: 배분 인원 순위를 효과 순위로 읽지 않는다.** 구간이 겹치는 콘텐츠끼리는 "순위를 가릴 수 없음"으로 적는다. 개선율은 실제 성공자로 계산한 +9.5%가 아니라 기댓값끼리 비교한 +9.0%를 보고한다. 9.5%에는 이번 실행의 운이 섞여 있어 다시 실행하면 같은 값이 나오지 않는다

○ 건강·금융처럼 실패 비용이 큰 영역에서는 증상이 나빠진 참가자 비율에 상한을 두고, 콘텐츠마다 최소 배분 비율(예: 5%)을 두는 안전장치를 설계 문서에 함께 적는다

한 줄 정리: 선택지가 다섯이면 수렴이 느려도 기대 성공자는 9.0% 늘었다. 배분 순위는 효과 순위가 아니다.

□ 8.6 연구 동향 — 이 도구들이 넓어지는 방향

○ 이 절은 참고용이며 실습을 동반하지 않는다

- **문맥적 밴딧**: 사용자가 들어올 때 보이는 정보(기기, 유입 경로, 시간대)를 함께 보고 안을 고른다. 목표가 "전체에서 가장 좋은 안 하나"에서 "이런 사용자에게 가장 좋은 안"으로 바뀐다
- **강화학습**: 지금의 선택이 다음 분기 이탈처럼 미래 성과에 주는 영향까지 계산에 넣는다
- **단계 전환형 설계**: 앞 기간은 고정 배분으로 모든 안의 효과를 추정하고, 뒤 기간은 적응형으로 바꿔 손실을 줄인다. 8.3.4의 "추정과 손실 감소를 동시에 얻지 못한다"는 문제를 시간으로 나누어 푼다

□ 결과를 읽는 순서

○ 이 장의 산출물은 다음 순서로 읽는다

- 1순위 **배정 비율(SRM)**: 설계와 어긋나면 뒤의 숫자는 읽지 않고 기록 과정부터 고친다

- 2순위 **인원과 검정력**: 필요 인원에 도달했는지, 검정력 0.80을 넘겼는지 본다. 넘지 못한 실험의 “유의하지 않음”은 결론이 아니다
- 3순위 **멈춘 절차가 계획대로인가**: 계획은 3회인데 5회 들여다봤다면 그 경계는 무효다
- 4순위 **효과와 구간**: 여기까지 통과한 뒤에 효과 크기를 읽는다. 적응형 실험이면 배분 30명 미만인 안은 건너뛰고, 개선율은 기댓값 기준 수치를 쓴다

□ 실무 적용 점검표

○ 목적을 하나로 정했는가 — 효과 크기를 구간과 함께 보고하는 것인지, 실험 기간의 성과를 올리는 것인지. “둘 다”라고 답하면 설계가 흔들린다

○ 주 지표 하나와 가드레일 지표를 실험 전에 문서에 적었는가?

○ 필요 인원과 검정력을 계산했는가? 검정력 0.80 미만이면 시작하지 않는다

○ 중간 분석 횟수(3~5회)와 시점을 정했는가? 첫 시점은 각 안 50명 이후로 두고, 정한 뒤에는 바꾸지 않는다

○ 목적에 맞게 설계를 골랐는가? 효과 추정이면 고정 배분 + 그룹 순차 설계, 성과 개선이면 적응형, 둘 다면 기간을 나누는 단계 전환형이다

□ 핵심 정리

설계	실험 중에 바꾸는 것	강한 점	포기하는 것
고정 배분 A/B 테스트	없음	모든 안의 효과를 같은 정확도로 추정	실험 기간 내내 나쁜 안에 절반 배정
그룹 순차 설계	끝내는 시점	1종 오류를 5%로 지키며 일찍 멈춤	경계를 미리 계산·문서화하는 부담
톰슨 샘플링(적응형 배분)	배분 비율	기대 손실을 크게 줄임	나쁜 안의 효과 추정
베이지안 적응형 설계	끝내는 시점과 판정 문장	”B안이 나을 확률”로 바로 읽는 결론	사전분포·문턱을 정하는 책임

○ 이 장의 판정 규칙 세 가지

- **실험 전에 정한 숫자만 유효하다.** 표본 크기·분석 시점·경계·문턱을 결과를 본 뒤 바꾸면 무효다
- **적응형 배분에서 배분이 적은 안의 추정치와 배분 순위는 보고하지 않는다.** 손실 감소를 얻는 대신 추정을 내준 설계이기 때문이다
- **성과는 기댓값 기준으로 보고한다.** 실현값에는 이번 실행의 운이 섞여 있다