

Contents

1장. 의사결정 과학과 AI 기반 인과 데이터 사이언스	1
이 장 한 줄 요약	1
이 장을 읽는 방법	1
1부. 이론과 방법	1
1.1 예측과 인과	2
1.2 인과적 데이터 사이언스 프레임워크	4
1.3 어떤 방법을 쓸 것인가	6
2부. 실습	8
실습 준비	8
실습 1 (1-1). 개발환경 점검	10
실습 2 (1-2). 예측과 인과는 다른 질문에 답한다	11
실습 3 (1-3). 무작위 배정이 답을 바꾼다	14
실습 정리: 세 실습이 말하는 것	16
자주 나는 오류 네 가지	16
실습 후 제출 과제	16
1장 핵심 정리	16
더 공부할 자료	17
참고문헌	18

1장. 의사결정 과학과 AI 기반 인과 데이터 사이언스

학습 목표

- 예측이 답하는 질문과 인과가 답하는 질문이 어떻게 다른지 실제 숫자로 구분한다.
- 잘 맞는 예측 모형이 왜 “무엇을 해야 하는가”에 답하지 못하는지 설명한다.
- 무작위 배정이 무엇을 해결하는지, 그리고 왜 항상 쓸 수 없는지 말한다.
- 인과적 데이터 사이언스의 5단계 순환 구조를 단계별로 설명한다.
- 전통적 방법론과 AI 기반 방법론 중 무엇을 쓸지 상황을 보고 판단한다.
- 실습 환경을 구축하고 실습 3개를 실행해 출력을 해석한다.

이 장 한 줄 요약

데이터로 답할 수 있는 질문은 “무슨 일이 일어날까”와 “무엇을 해야 할까” 두 가지다. 앞의 질문은 예측이 답하고, 뒤의 질문은 인과추론이 답한다. **이 교재는 뒤의 질문을 다룬다.**

이 장을 읽는 방법

- **1부(1.1~1.3)**: 이 과목이 무엇을 다루는지 잡는다. 수식은 나오지 않는다.
 - **2부(실습 3개)**: 환경을 구축하고, 예측과 인과가 갈리는 지점을 직접 돌려 본다.
 - 2장부터는 방법 하나에 한 장씩 배정된다. 1장은 전체 지도를 그리는 장이다.
 - 이 장에 나오는 방법은 전부 `practice/chapter01/code/`에 코드가 있다.
-
-

1부. 이론과 방법

1.1 예측과 인과

1.1.1 두 질문은 다르다

쇼핑몰 데이터로 답할 수 있는 질문을 두 가지 적어 보자.

- **질문 A:** 이 고객이 다음 달에 얼마를 살 것인가
- **질문 B:** 이 고객에게 쿠폰을 보내면 구매액이 얼마나 늘어나는가

둘은 다른 질문이다. A는 지금 있는 데이터를 그대로 두고 답한다. B는 **값을 바꿔 넣었을 때**를 묻는다. 쿠폰을 안 받은 고객에게 쿠폰을 줬다면 얼마를 샀을지는 데이터 어디에도 적혀 있지 않다.

그림 1-1. 예측과 인과는 다른 질문에 답한다

예측	인과
이 고객이 얼마를 살 것인가	쿠폰을 보내면 얼마가 늘어나는가
데이터를 있는 그대로 본다	값을 바꿔 넣었을 때를 계산한다
맞히는 정확도로 평가한다	참 효과와의 차이로 평가한다
실습 1-2: R^2 0.552	실습 1-3: 실험값 2,978원

실습 1-2에서 쿠폰 효과를 단순 비교하면 12,710원, 참값은 3,000원이다

Figure 1: 그림 1-1. 예측과 인과는 다른 질문에 답한다

A에 답하는 것이 **예측**이고, B에 답하는 것이 **인과추론**이다.

1.1.2 왜 A를 잘해도 B를 못 하는가

실습 2(1-2)에서 이 차이를 직접 확인한다. 결과를 먼저 보면 이렇다.

항목	값
예측 모형의 결정계수(R^2)	0.552
쿠폰 받은 고객과 안 받은 고객의 구매액 차이	12,710원
쿠폰의 참 효과	3,000원

구매액은 상당히 잘 맞는다. 그런데 쿠폰 효과는 참값의 4.2배로 나왔다. **모형이 부실해서가 아니다.** 두 질문이 다르기 때문이다.

이유는 데이터를 만든 방식에 있다. 쿠폰은 무작위로 뿌려지지 않았다. 앱을 자주 여는 고객이 쿠폰을 더 많이 받아 갖고, 그 고객들은 원래부터 많이 사던 사람들이다.

쿠폰 받은 고객의 구매액이 높은 이유
 = 쿠폰 효과 (3,000원)
 + 원래 많이 사던 사람이라서 (9,710원)

단순 비교는 이 둘을 갈라내지 못한다.

비유: 체온계와 해열제

체온계와 해열제	예측과 인과
체온계로 38.5도를 잰다	예측 모형으로 구매액을 맞힌다
체온계는 열이 몇 도인지 알려준다	예측 모형은 얼마를 살지 알려준다
해열제를 먹으면 몇 도 내려가는가	쿠폰을 보내면 얼마가 늘어나는가
체온계로는 이 질문에 답할 수 없다	예측 모형으로는 이 질문에 답할 수 없다
약을 먹은 사람과 안 먹은 사람을 비교하면?	쿠폰 받은 사람과 안 받은 사람을 비교하면?
약을 먹은 사람이 원래 더 아팠다	쿠폰 받은 고객이 원래 더 많이 샀다

비유가 맞아떨어지는 지점은 마지막 두 줄이다. **아픈 사람이 약을 먹는다.** 그래서 약 먹은 집단의 체온이 더 높게 나온다. 이 숫자를 그대로 “약이 열을 올린다”고 읽으면 안 된다.

1.1.3 변수 중요도는 인과효과가 아니다

실습 2에서 예측 모형의 변수 중요도를 뽑으면 이렇게 나온다.

변수	중요도
앱 접속	0.642
나이	0.220
가입기간	0.113
쿠폰 수령	0.025

쿠폰이 **가장 낮다**. 앞에서는 단순 비교로 12,710원이 나왔는데, 여기서는 거의 쓸모없는 변수로 나온다. 두 숫자가 서로 반대 방향으로 틀렸다.

- 단순 비교(12,710원)는 충성도 차이를 쿠폰 몫으로 잘못 넘겼다.
- 변수 중요도(0.025)는 앱 접속이 충성도 정보를 이미 담고 있어서, 쿠폰이 추가로 설명할 게 없다고 판단했다.

변수 중요도는 “예측에 얼마나 도움이 되는가”를 재는 값이지 “바꾸면 결과가 얼마나 달라지는가”를 재는 값이 아니다. 실무에서 가장 자주 나오는 착각이다.

1.1.4 인과 데이터 사이언스가 서 있는 세 가지 기반

인과 데이터 사이언스(Causal Data Science)는 “무엇을 해야 원하는 결과를 얻는가”에 답하는 분야다(Hernán & Robins, 2020). 실무에서 작동하려면 세 가지가 갖춰져야 한다.

- **데이터**: 행정 데이터, 거래 기록, 센서, 텍스트 등 대규모 자료를 모아 쓴다. 표본 수백 개로는 집단별로 효과가 어떻게 다른지 볼 수 없다.
- **모형**: 머신러닝으로 복잡한 관계를 학습하고, 개입 결과를 사전에 계산한다.
- **평가**: 효과를 실행과 동시에 측정하고, 그 결과를 다음 결정에 반영한다.

세 가지 중 하나만 빠져도 작동하지 않는다. 데이터가 많아도 인과 설계가 없으면 실습 2의 12,710원 같은 값이 나오고, 설계가 좋아도 데이터가 없으면 추정이 흔들린다.

1.1.5 에스토니아: 데이터 기반이 갖춰진 경우

에스토니아는 인구 130만의 작은 나라인데 정부 서비스의 99%를 온라인으로 제공한다(e-Estonia, 2024a).

- **X-Road**: 정부 기관 간 데이터 교환 플랫폼. 연간 22억 건 이상이 오가며, 약 1,345년 분의 근무 시간을 절감한다(e-Estonia, 2024b)
- **Bürokratt**: 시민 문의를 자동 처리하는 AI 시스템
- **디지털 ID**: 보급률 99%. 모든 정부 서비스에 하나의 신원으로 접근한다

여기서 볼 점은 기술 자체가 아니라 **데이터가 한곳에 모여 있다는 사실**이다. 부처마다 자료가 흩어져 있으면 “이 정책을 받은 사람이 그 뒤에 어떻게 됐는가”를 추적할 수 없다. 추적이 안 되면 인과추론도 안 된다.

1.1.6 한국의 현황

한국은 2024년 UN 전자정부 평가에서 193개국 중 4위다(United Nations, 2024). 온라인 서비스와 통신 인프라가 세계 최고 수준이다.

- **정부24**: 중앙부처와 지자체 서비스를 통합한 창구
- **공공데이터포털**: 10만 개 이상의 데이터를 개방했다(행정안전부, 2024)
- **코로나19 대응**: 마스크 재고 실시간 공개가 국제적 모범 사례로 인정받았다

기말 프로젝트에서 실제 데이터를 쓰고 싶다면 공공데이터포털(data.go.kr)과 KOSIS(kosis.kr)에서 시작하면 된다.

1.2 인과적 데이터 사이언스 프레임워크

1.2.1 전통적 분석·평가 모델의 세 가지 한계


전통적 방식은 “문제 정의 → 대안 설계 → 의사결정 → 실행 → 평가”를 순서대로 한 번 지나간다. 반세기 넘게 쓰인 틀이지만 세 가지에서 막힌다.

한계	무엇이 문제인가	구체적으로
시간 지연	평가가 실행 한참 뒤에 나온다	3년 사업의 평가가 4년째 나오면 고칠 기회가 없다
정보 비대칭	현장 상황이 위로 올라가지 않는다	담당 공무원은 아는 문제를 결정권자는 모른다
단절적 피드백	피드백이 평가 단계에서만 생긴다	실행 중 발견한 문제를 그 자리에서 못 고친다

1.2.2 5단계 순환 구조

이 한계를 넘기 위해 각 단계를 순환으로 잇는다.

그림 1-2. 인과적 데이터 사이언스의 5단계 순환



전통적 모델은 1에서 5까지 한 번 지나가고 끝난다.
여기서는 5의 결과가 1로 돌아가 다시 돈다.

Figure 2: 그림 1-2. 인과적 데이터 사이언스의 5단계 순환

1단계: 문제 정의 — 데이터에서 문제를 찾는다. 정기 보고서를 기다리지 않고, 고객센터 문의, 앱 삭제율, 반품률 같은 신호를 실시간으로 본다.

2단계: 대안 설계 — 과거 유사 사례의 성과 데이터를 학습해 후보를 만든다. 시뮬레이션으로 부작용을 미리 본다.

3단계: 의사결정 — 여러 기준으로 대안을 평가한다. 이해관계자마다 중요하게 보는 것이 다르므로 가중치를 나눠 반영한다.

4단계: 적응형 실행 — 반응을 보며 배분을 조정한다. A/B 테스트처럼 끝날 때까지 기다리는 대신, 성과가 좋은 쪽에 노출을 늘려 간다. 8장에서 다룬다.

5단계: 평가와 학습 — 효과를 측정한다. 여기가 이 교재의 중심이다. 2장부터 7장까지가 전부 이 단계의 방법이다.

1.2.3 5단계에서 하는 일

5단계가 전통적 평가와 다른 점은 세 가지다.

- **실시간 평가:** 사업이 끝난 뒤가 아니라 진행 중에 측정한다.
- **인과적 평가:** 다른 요인의 몫을 걷어내고 개입 자체의 효과만 재려 한다. 실습 2에서 본 12,710원과 3,000원의 차이를 갈라내는 일이다.
- **적응적 학습:** 평가 결과가 다음 순환의 문제 정의로 돌아간다.

1.2.4 피드백 루프 세 종류

비유: 자동차 내비게이션

내비게이션	5단계 순환
출발 전 경로를 정한다	1~3단계: 문제 정의부터 의사결정까지
주행 중 정체 정보를 받아 경로를 바꾼다	4단계: 적응형 실행
도착 후 실제 소요 시간이 기록된다	5단계: 평가
그 기록이 다음 경로 추천에 반영된다	평가 결과가 다음 순환으로
목적지에 도착해야만 경로를 바꿀 수 있다면	전통적 선형 모델

내비게이션이 목적지 도착 후에만 경로를 바꿀 수 있다면 쓸모가 없다. 전통적 평가 모델이 그런 구조였다.

피드백은 세 가지 크기로 돌아간다.

- **짧은 주기:** 한 단계 안에서 즉시 조정한다. 실행 중 이상 신호를 발견하면 그 자리에서 고친다.
- **긴 주기:** 5단계를 전부 돈 뒤 전략 자체를 바꾼다.
- **건너뛰기:** 실행 단계 데이터가 평가를 거치지 않고 설계 단계로 바로 간다.

1.3 어떤 방법을 쓸 것인가

1.3.1 무작위 배정이 기준점이다

실습 3(1-3)에서 같은 모집단, 같은 계산인데 답이 갈리는 것을 확인한다.

데이터	쿠폰을 누가 받았나	두 집단 충성도 차이	추정 효과
관찰	고객이 스스로 선택	+0.76	12,373원
실험	동전을 던져 배정	-0.00	2,978원

참 효과는 3,000원이다. 실험 데이터는 맞히고 관찰 데이터는 4.1배로 틀린다.

차이를 만든 것은 계산 방법이 아니라 누가 쿠폰을 받았는가다.

비유: 제비뽑기로 조 나누기

조 나누기	처치 배정
하고 싶은 사람이 손 들어 A조에 간다	고객이 스스로 쿠폰을 받아 간다
A조에 의욕적인 학생이 몰린다	쿠폰 집단에 충성도 높은 고객이 몰린다
A조 성적이 좋아도 조 편성 덕인지 알 수 없다	구매액이 높아도 쿠폰 덕인지 알 수 없다
제비뽑기로 나눈다	무작위로 배정한다
두 조의 평균 실력이 같아진다	두 집단의 충성도 평균이 같아진다(-0.00)
그다음 성적 차이는 조 편성 효과다	그다음 구매액 차이는 쿠폰 효과다(2,978원)

무작위 배정은 처치 말고 다른 모든 것을 두 집단에서 평균적으로 같게 만든다. 그래서 남은 차이를 처치 효과로 읽을 수 있다.

1.3.2 무작위 배정을 못 하는 경우

문제는 무작위 배정이 자주 불가능하다는 것이다.

- **윤리:** 어떤 학생에게만 장학금을 주고 나머지를 대조군으로 둘 수 없다.

- **법·제도:** 소득 기준을 충족한 모든 가구에 지급해야 하는 급여를 무작위로 줄 수 없다.
- **비용·시간:** 도시 절반에 지하철을 놓고 절반에 안 놓는 실험은 불가능하다.
- **이미 벌어진 일:** 작년에 시행된 정책의 효과를 지금 실험으로 확인할 수 없다.

이럴 때 관찰 데이터에서 인과효과를 찾아내는 방법이 2장부터 7장까지의 내용이다.

1.3.3 방법을 고르는 기준

전통적 방법론과 AI 기반 방법론 중 무엇을 쓸지는 상황이 정한다.

상황	적합한 쪽	이유
법적·규제 근거를 제시해야 한다	전통적 방법론	계수와 유의성을 명확히 보고할 수 있다
표본이 수백 개 수준이다	전통적 방법론	머신러닝은 학습할 데이터가 부족하다
이해관계자를 설득해야 한다	전통적 방법론	해석이 직관적이다
수백만 건을 처리해야 한다	AI 기반 방법론	규모를 감당한다
관계가 곡선이고 상호작용이 많다	AI 기반 방법론	항을 사람이 고르지 않아도 된다
실시간 판단이 필요하다	AI 기반 방법론	재학습과 갱신이 빠르다
텍스트·이미지가 자료다	AI 기반 방법론	비정형 자료를 다룰 수 있다

실무에서는 둘 다 돌려 결론의 방향이 같은지 보는 편이 안전하다. 6장에서 이 원칙을 다시 다룬다.

1.3.4 이 교재의 지도




Figure 3: 그림 1-3. 이 교재에서 배울 방법의 지도

첫 갈림길은 **무작위 배정이 가능한가**이다.

갈래	아이디어	장
무작위 배정이 가능하다	직접 실험을 설계한다	8장 A/B 테스트와 적응형 설계
비슷한 사람끼리 짝짓는다	관측된 특성이 같은 사람을 비교한다	2장 DML, 3장 성향점수 매칭
시점·경계를 이용한다	정책 전후, 기준선 좌우를 비교한다	4장 이중차분·합성통제, 5장 회귀불연속
외부 충격을 이용한다	본인 의사와 무관한 변동만 골라 쓴다	6장 도구변수, 7장 분위 회귀
자료 종류가 다르다	시계열·텍스트·네트워크·시뮬레이션	9~12장

각 장은 “이런 상황에서 이렇게 한다”를 하나씩 다룬다. 어떤 방법이 다른 방법보다 낫다는 순위는 없다. **쓸 수 있는 조건이 다를 뿐이다.**

2부. 실습

실습 준비

파일 지도

practice/chapter01/

├─ code/

| └─ 1-1-environment-check.py

← 실습 1: 환경 점검


```

|   | 1-2-prediction-vs-causation.py ← 실습 2: 예측과 인과
|   | 1-3-randomization.py           ← 실습 3: 무작위 배정
└── data/
    | 1-2-coupon-observational.csv    (실습 2가 생성)
    | 1-3-observational.csv           (실습 3이 생성)
    | 1-3-experimental.csv            (실습 3이 생성)

```

세 실습 모두 스크립트가 데이터를 직접 만든다. 참값을 알고 있어야 추정이 맞았는지 확인할 수 있기 때문이다.

프로그램 설치

1단계: VS Code

공식 사이트(<https://code.visualstudio.com/>)에서 내려받아 설치한다. 설치 후 확인한다.

```
code --version
```

2단계: Python 3.10 이상

- 내려받기: <https://www.python.org/>
- 윈도우는 설치 화면에서 **"Add Python to PATH"**를 반드시 체크한다
- macOS는 `brew install python`

```
python --version
```

3단계: Git

- 내려받기: <https://git-scm.com/>
- macOS는 `xcode-select --install`

```
git --version
```

4단계: 패키지 설치

```
pip install numpy pandas scipy matplotlib scikit-learn statsmodels linearmodels
```

패키지	쓰임	처음 쓰는 장
numpy, pandas	데이터 처리	1장
scipy	통계 함수	1장
matplotlib	그래프	1장
scikit-learn	머신러닝	1장
statsmodels	회귀분석	1장
linearmodels	도구변수 추정	6장

econml, torch 같은 패키지는 필요한 장에서 따로 안내한다.

실습실 PC를 쓰는 경우

여러 과목을 같은 PC에서 수강한다면 **윈도우 계정을 과목별로 나누면** 설정이 섞이지 않는다.

1. 설정 → 계정 → 다른 사용자로 이동한다
2. 계정을 추가한다
3. 계정 유형을 **표준 사용자**로 지정한다

표준 사용자로 두면 시스템 파일을 지우거나 허가 없이 프로그램을 설치하는 일이 막힌다. 실습 중 실수로 환경을 망가뜨리는 사고를 줄일 수 있다.

실습 1 (1-1). 개발환경 점검

목적

이 교재의 실습을 돌릴 수 있는 상태인지 네 항목으로 확인한다.

실행

```
cd practice/chapter01/code
python 1-1-environment-check.py
```

실제 출력

[1단계] 파이썬 버전

설치된 버전: 3.12.7

판정: 통과 (3.10 이상 필요)

[2단계] 패키지 확인

numpy	1.26.4	수치 계산
pandas	2.3.3	표 형태 데이터 처리
scipy	1.16.2	통계 함수
matplotlib	3.10.6	그래프
sklearn	1.6.1	머신러닝
statsmodels	0.14.5	회귀분석
linearmodels	7.0	도구변수 추정 (6장)

판정: 통과 (필요한 패키지가 모두 있다)

[3단계] 한글 그래프 확인

사용할 한글 폰트: Malgun Gothic

[4단계] 회귀 한 번 돌려 보기

참 기울기: 2.000

추정 기울기: 2.015 (표준오차 0.029)

95% 신뢰구간: [1.958, 2.072]

신뢰구간이 참값을 포함하는가: 예

[5단계] 그래프 저장

그래프 저장: 1-1-environment-check.png

출력 해석

설치된 버전: 3.12.7

3.10 이상이면 된다. 낮으면 파이썬을 다시 설치한다.

패키지 목록에 없음이 뜨는 경우

스크립트가 설치 명령을 만들어 준다. 그대로 복사해 실행한다.

사용할 한글 폰트: Malgun Gothic

이 줄이 안 나오면 그래프의 한글이 네모로 표시된다. 앞으로 모든 실습 스크립트 맨 위에 두 줄이 들어간다.

```
plt.rcParams['font.family'] = 'Malgun Gothic' # macOS는 'AppleGothic'
plt.rcParams['axes.unicode_minus'] = False
```

두 번째 줄은 마이너스 부호가 깨지는 것을 막는다. 첫 줄만 넣으면 -1.5가 □1.5로 나온다.

추정 기울기: 2.015 (표준오차 0.029), 95% 신뢰구간: [1.958, 2.072]

참 기울기 2.000을 넣고 데이터를 만든 뒤, 그 데이터로 다시 추정했다. 2.015가 나왔고 신뢰구간이 참값을 포함한다.

이 방식이 이 교재 전체의 실습 구조다. **참값을 알고 있는 데이터를 만들어, 방법이 그 값을 되찾는지 확인한다.** 실제 연구에서는 참값을 모르므로 이런 확인이 불가능하다. 그래서 배울 때만 이렇게 한다.

그래프 읽기




Figure 4: 환경 점검

점들이 오른쪽 위로 올라가고 빨간 직선이 그 가운데를 지난다. **축 이름의 한글이 네모로 보이면 3단계 폰트 설정이 안 된 것이다.**

확인 문제

1. 파이썬 버전이 3.9라면 무엇을 해야 하는가.
2. `plt.rcParams['axes.unicode_minus'] = False`를 빼면 그래프에서 무엇이 깨지는가.
3. 추정 기울기 2.015가 참값 2.000과 정확히 같지 않다. 문제인가.

실습 2 (1-2). 예측과 인과는 다른 질문에 답한다

목적

잘 맞는 예측 모형이 “쿠폰을 보내야 하는가”에 답하지 못한다는 것을 숫자로 확인한다.

상황 설정

역할	변수	설명
결과 Y	구매액	월 구매 금액(원)
처치 D	쿠폰 수령 여부	0 또는 1
관측 변수 X	나이, 가입기간, 월 앱 접속 횟수	분석에 쓸 수 있다
숨은 원인 U	충성도	쿠폰 수령과 구매액 둘 다에 영향(관측 불가)

쿠폰의 참 효과는 **3,000원**으로 정해 두었다.

실행

[python](#) 1-2-prediction-vs-causation.py

실제 출력

[1단계] 데이터 만들기

고객 수: 5,000명

쿠폰 수령률: 39.4%

쿠폰의 참 효과: 3,000원 (데이터를 만들 때 넣은 값)

[2단계] 쿠폰 받은 고객과 안 받은 고객을 그냥 비교하면

쿠폰 받은 고객 평균 구매액: 53,717원 (n=1,971)

쿠폰 안 받은 고객 평균 구매액: 41,007원 (n=3,029)

차이: 12,710원

참 효과 3,000원의 4.2배로 부풀려졌다.

[3단계] 예측 모델을 학습시키면

테스트셋 결정계수(R^2): 0.552

구매액을 상당히 잘 맞힌다.

변수 중요도:

앱 접속 0.642

나이 0.220

가입기간 0.113

쿠폰 수령 0.025

[4단계] 왜 어긋났는가

두 집단은 쿠폰 말고도 다른 점이 있다.

충성도 평균 쿠폰 받음 0.46 vs 안 받음 -0.29

월 앱 접속 횟수 쿠폰 받음 10.8 vs 안 받음 6.7

출력 해석

차이: 12,710원

가장 먼저 계산하게 되는 값이고, 가장 자주 틀리는 값이다. 참값 3,000원의 4.2배다.

이 숫자를 그대로 믿으면 “쿠폰 한 장이 12,710원을 만든다”는 결론이 나온다. 실습 3에서 이 결론이 얼마짜리 오판인지 계산한다.

테스트셋 결정계수(R^2): 0.552

결정계수는 결과변수의 변동 중 모형이 설명한 비율이다. 0.552는 55.2%를 설명했다는 뜻이다. 예측 모형으로는 쓸 만하다.

여기가 이 실습의 핵심이다. 예측 성능이 좋다는 사실은 인과 추정이 옳다는 근거가 되지 못한다. 두 지표는 서로 다른 것을 재기 때문이다.

지표	재는 것	답하는 질문
결정계수 0.552	예측이 실제와 얼마나 가까운가	이 고객이 얼마를 살 것인가
참값과의 차이	추정 효과가 참 효과와 얼마나 가까운가	쿠폰을 보내면 얼마가 늘어나는가

쿠폰 수령 0.025

변수 중요도에서 쿠폰이 가장 낮다. 앞의 12,710원과 정반대 방향이다.

앱 접속 횟수가 충성도 정보를 이미 담고 있어서, 쿠폰을 추가로 알려 줘도 예측이 별로 나아지지 않기 때문이다. 중요도는 **예측에 얼마나 보태는가**를 재는 값이지 인과효과가 아니다.

정리하면 같은 데이터에서 두 개의 틀린 답이 반대 방향으로 나왔다.

방법	나온 값	방향
단순 비교	12,710원	참값의 4.2배로 과대
변수 중요도	0.025 (최하위)	효과가 거의 없다고 과소
참값	3,000원	

충성도 평균: 쿠폰 받음 0.46 vs 안 받음 -0.29

원인이 여기 있다. 두 집단은 쿠폰 말고도 다른 점이 있다. 충성도가 0.75만큼 차이 난다. 앱 접속 횟수도 10.8회와 6.7회로 갈린다.

쿠폰을 받은 고객은 원래부터 이 쇼핑몰을 자주 쓰던 사람이다. 12,710원 안에 그 차이가 섞여 들어갔다.

그래프 읽기




Figure 5: 예측과 인과

- (a) 두 막대 높이 차이가 12,710원이다. 이 그림만 보면 쿠폰 효과가 커 보인다.
- (b) 충성도 분포 두 개가 겹치기는 하지만 중심이 어긋나 있다. 파란 쪽(쿠폰 받음)이 오른쪽에 있다. **비교하려는 두 집단이 애초에 다르다는 증거다.**
- (c) 단순 비교(12,710원)와 참값(3,000원)을 나란히 놓았다. 막대 높이 차이가 오차의 크기다.

(b)를 (a)보다 먼저 봐야 한다. 두 집단이 비교 가능한지 확인하지 않고 평균 차이부터 계산한 것이 문제였다.

확인 문제

1. 결정계수 0.552는 무엇을 재는 값인가. 이 값이 0.9였다면 쿠폰 효과 추정이 더 정확해지
는가.
2. 변수 중요도에서 쿠폰이 최하위인데 단순 비교는 12,710원이다. 두 결과가 왜 어긋나는가.
3. 충성도를 관측할 수 있었다면 무엇을 할 수 있었겠는가.

실습 3 (1-3). 무작위 배정이 답을 바꾼다

목적

같은 모집단에 같은 계산을 적용해도 데이터를 어떻게 모았느냐에 따라 답이 달라지는 것을 확인하고, 그 차이가 얼마짜리인지 돈으로 계산한다.

실행

python 1-3-randomization.py

실제 출력

[1단계] 관찰 데이터: 고객이 스스로 쿠폰을 받아 갔다
쿠폰 수령률: 39.5%
두 집단 충성도 차이: +0.76 (0에서 멀수록 집단이 다르다)
평균 구매액 차이: 12,373원

[2단계] 실험 데이터: 동전을 던져 무작위로 배정했다
쿠폰 수령률: 50.0%
두 집단 충성도 차이: -0.00 (무작위 배정이라 0에 가깝다)
평균 구매액 차이: 2,978원
95% 신뢰구간: [2,177원, 3,779원]
신뢰구간이 참값 3,000원을 포함하는가: 예

[3단계] 같은 계산, 다른 답
데이터 쿠폰배정 충성도차이 추정효과 참값대비
관찰 고객이 선택 0.76 12373 4.1배
실험 동전 던지기 -0.00 2978 1.0배

[4단계] 이 차이는 얼마짜리인가
쿠폰 1장 비용: 5,000원
전체 고객: 1,000,000명

관찰 데이터를 믿으면
 쿠폰 1장당 순이익: 12,373 - 5,000 = 7,373원 → 발행한다
 전 고객 발행 시: 73.7억원
실제로는
 쿠폰 1장당 순이익: 3,000 - 5,000 = -2,000원 → 발행하지 않는다
 전 고객 발행 시: -20.0억원

관찰 데이터를 믿고 100만 장을 발행하면 실제로는 20.0억원 손실이다.

출력 해석

두 집단 충성도 차이: +0.76 vs -0.00

이 두 숫자가 모든 것을 설명한다.

관찰 데이터에서는 쿠폰 집단의 충성도가 0.76 더 높다. 실험 데이터에서는 차이가 사실상 0이다. 동전을 던져 배정했으므로 충성도가 높은 고객과 낮은 고객이 양쪽에 골고루 들어갔다.

무작위 배정이 하는 일이 정확히 이것이다. 처치 말고 다른 모든 것을 두 집단에서 평균적으로 같게 만든다. 충성도뿐 아니라 관측하지 못하는 변수까지 같아진다는 점이 중요하다.

평균 구매액 차이: 12,373원 vs 2,978원

두 데이터에 **똑같은 계산을** 했다. 처치 집단 평균에서 통제 집단 평균을 뺀 뿐이다. 그런데 답이 4.1배 차이 난다.

차이를 만든 것은 분석 방법이 아니라 데이터를 모은 방식이다. 이 문장이 이 과목 전체의 출발점이다. 아무리 정교한 모형을 써도, 처치가 어떻게 배정됐는지를 다루지 않으면 답이 어긋난다.

95% 신뢰구간: [2,177원, 3,779원]

실험 추정치 2,978원에 붙는 구간이다. 폭이 1,602원으로 넓다. 표본이 5,000명이고 구매액의 변동이 크기 때문이다.

참값 3,000원이 이 구간 안에 들어 있다. 추정치가 참값과 정확히 같지 않아도(2,978 vs 3,000) **구간이 참값을 포함하면 정상이다.**

관찰 데이터를 믿고 100만 장을 발행하면 20.0억원 손실

계산은 단순하다.

쿠폰 1장당 순이익 = (쿠폰 효과) - (쿠폰 비용 5,000원)

관찰 데이터를 믿을 때: $12,373 - 5,000 = +7,373\text{원} \rightarrow$ 발행한다

실제로는: $3,000 - 5,000 = -2,000\text{원} \rightarrow$ 발행하면 안 된다

부호가 뒤집힌다. 크기가 틀린 정도가 아니라 **결정 자체가 반대로 간다.** 100만 명에게 발행하면 73.7억원을 기대하고 시작해서 20.0억원을 잃는다.

인과추론을 배우는 이유가 여기 있다. 틀린 추정치는 틀린 결정을 낳고, 결정에는 값이 붙는다.

그래프 읽기




Figure 6: 무작위 배정

- **(a)** 두 집단의 충성도 차이다. 관찰 데이터(주황)는 0.76으로 높이 솟아 있고, 실험 데이터(파랑)는 0에 붙어 있다. **막대가 낮을수록 비교 가능한 두 집단이다.**
- **(b)** 관찰·실험·참값을 나란히 놓았다. 실험 막대와 참값 막대의 높이가 거의 같고, 관찰 막대만 4배 높다.
- **(c)** 100만 장 발행의 손익이다. 왼쪽은 관찰 데이터를 믿었을 때 기대한 +73.7억원, 오른쪽은 실제 결과인 -20.0억원이다. **막대가 0선 위아래로 갈린다.**

(a)를 먼저 확인하는 습관이 중요하다. 두 집단이 처치 말고 다른 점이 있는지 보지 않고 (b)의 평균 차이부터 계산하면 실무에서 사고가 난다.

확인 문제

1. 실험 데이터의 충성도 차이가 -0.00이다. 무작위 배정이 관측하지 못하는 변수까지 같게 만드는 이유를 설명하라.
2. 실험 추정치가 2,978원으로 참값 3,000원과 22원 다르다. 이 차이는 편향인가 우연인가. 근거는 무엇인가.
3. 쿠폰 비용이 5,000원이 아니라 2,000원이었다면 관찰 데이터를 믿었을 때와 실제 결과의 결정이 갈리는가.
4. 이 쇼핑몰이 무작위 실험을 할 수 없는 상황을 두 가지 들어라.

실습 정리: 세 실습이 말하는 것

실습	확인한 것	다음 장으로 이어지는 질문
1-1	실습 환경이 작동한다	
1-2	잘 맞는 모형이 개입 효과는 못 맞힌다	그러면 무엇으로 재는가
1-3	무작위 배정이 답을 바로잡는다	무작위 배정을 못 하면 어떻게 하는가

마지막 질문에 답하는 것이 2장부터 7장까지다.

자주 나는 오류 네 가지

오류	왜 문제인가	대신 할 것
평균 차이를 효과로 읽는다	집단이 애초에 다르면 차이에 다른 요인이 섞인다	두 집단이 비교 가능한지 먼저 확인한다
변수 중요도를 인과효과로 읽는다	중요도는 예측 기여도를 잴다	인과 추정 방법을 따로 쓴다
예측 성능이 좋으니 결론도 맞다고 본다	두 지표는 다른 것을 잴다	참값 대비 오차와 신뢰구간으로 판단한다
추정치 크기만 보고 결정한다	부호가 뒤집히면 결정이 반대가 된다	비용을 넣어 순이익 부호까지 계산한다

실습 후 제출 과제

이번 주 과제물은 수업 중 실행한 실습 결과만 제출한다.

- 실습 결과 화면 또는 결과 파일을 제출한다.
- 별도의 해석 보고서와 추가 분석은 제출하지 않는다.
- 제출 여부로 수업 중 실습 실시 여부를 확인한다.

1장 핵심 정리

1. 데이터로 답하는 질문은 두 가지다
→ 예측: 이 고객이 얼마를 살 것인가

- 인과: 쿠폰을 보내면 열마가 늘어나는가
 - 이 교재는 두 번째 질문을 다룬다
 - 2. 예측을 잘해도 인과는 못 맞힌다
 - 실습 1-2: 결정계수 0.552인데 쿠폰 효과는 참값의 4.2배로 나왔다
 - 3. 변수 중요도는 인과효과가 아니다
 - 실습 1-2: 쿠폰의 중요도가 0.025로 최하위인데 단순 비교는 12,710원
 - 같은 데이터에서 두 틀린 답이 반대 방향으로 나왔다
 - 4. 틀리는 원인은 두 집단이 처치 말고도 다르다는 데 있다
 - 실습 1-2: 충성도 평균 0.46 vs -0.29
 - 5. 무작위 배정은 처치 말고 다른 모든 것을 평균적으로 같게 만든다
 - 실습 1-3: 충성도 차이가 관찰 +0.76에서 실험 -0.00으로
 - 6. 같은 계산, 다른 답
 - 실습 1-3: 관찰 12,373원 / 실험 2,978원 / 참값 3,000원
 - 차이를 만든 것은 분석 방법이 아니라 데이터를 모은 방식이다
 - 7. 틀린 추정치에는 값이 붙는다
 - 실습 1-3: 순이익 부호가 +7,373원에서 -2,000원으로 뒤집힌다
 - 100만 장 발행 시 73.7억원을 기대하고 20.0억원을 잃는다
 - 8. 무작위 배정은 윤리·법·비용·시점 때문에 자주 불가능하다
 - 그때 관찰 데이터로 인과효과를 찾는 방법이 2~7장이다
 - 9. 방법에 우열은 없다. 쓸 수 있는 조건이 다를 뿐이다
-

더 공부할 자료

무료 교재 (영문, 온라인 전문 공개)

- Causal Inference: The Mixtape — 1장과 2장이 이 장의 내용과 겹친다. <https://mixtape.scunning.com/>
- The Effect: An Introduction to Research Design and Causality — 1~4장. <https://theeffectbook.net/>

영상 강의

- Marginal Revolution University, Mastering Econometrics. <https://mru.org/courses/mastering-econometrics>

실습 데이터를 구할 곳

- 공공데이터포털 — 정부·지자체 개방 데이터. <https://www.data.go.kr>
- KOSIS 국가통계포털 — 통계청 자료. <https://kosis.kr>

패키지 문서

- statsmodels — 회귀분석과 진단. <https://www.statsmodels.org/stable/index.html>
- scikit-learn — 머신러닝. <https://scikit-learn.org/stable/>

위 URL은 2026년 8월 17일 기준 접속을 확인했다.

참고문헌

- 과학기술정보통신부. (2024). 국가인공지능 전략 정책방향. 정책보고서.
- 행정안전부. (2024). 정부24 및 공공데이터 개방 현황. <https://www.gov.kr>; <https://www.data.go.kr>
- Athey, S., & Imbens, G. W. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685-725.
- e-Estonia. (2024a). Facts and Figures. <https://e-estonia.com/facts-and-figures/>
- e-Estonia. (2024b). X-Road: Interoperability Services. <https://e-estonia.com/solutions/interoperability-services/x-road/>
- Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Boca Raton: Chapman & Hall/CRC.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495.
- Pearl, J., & Mackenzie, D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books.
- United Nations. (2024). UN E-Government Survey 2024. United Nations DESA.