

2장. 인과추론 기초와 인과 머신러닝

요약

관측 데이터에서 처치를 받은 집단과 받지 않은 집단의 평균을 그냥 빼면, 나오는 숫자는 정책 효과가 아니라 **정책 효과에 두 집단의 원래 차이가 더해진 값**이다. 이 장은 그 "원래 차이"를 무엇이라 부르고, 어떤 절차로 걷어내며, 걷어냈다는 사실을 어떤 숫자로 확인하는지를 다룬다.

학습 목표

- 잠재적 결과가 무엇인지 설명하고, 왜 한 사람에게서 두 결과를 동시에 볼 수 없는지 말한다.
- 처치군 평균에서 대조군 평균을 뺀 값이 어떤 두 부분으로 쪼개지는지 숫자를 대입해 보인다.
- 식별에 필요한 세 가지 가정을 각각 어떤 자료로 점검하는지 안다.
- 공변량 균형표를 읽고, 어느 변수가 편향의 원인인지 지목한다.
- 전통적 다섯 방법이 각각 어떤 상황을 전제하는지 구분하고, 주어진 자료에서 어느 방법이 가능한지 판단한다.
- 이중 머신러닝이 무엇을 두 번 빼는지 설명하고, 추정 결과가 믿을 만한지 폴드별 값과 보조 모형 성능으로 판정한다.
- 개인별 처치효과 추정치를 정책 대상 선정으로 옮기고, 대상 축소가 효율을 얼마나 바꾸는지 계산한다.

이 장을 읽는 방법

- 이 장은 **두 파트**로 나뉜다. **1부(2.1~2.4.1)**는 편향의 크기를 재고 전통적 방법과 이중 머신러닝으로 평균 효과를 추정한다. **2부(2.4.2~2.6)**는 개인별 효과를 추정하고, 나온 숫자를 정책 대상 선정과 시나리오 비교로 옮긴다.
- 수식은 여섯 개뿐이며, 유도는 요구하지 않는다. 각 항이 무엇을 가리키는지 말로 풀고 숫자를 대입해 따라간다.
- 실습 코드는 전부 `practice/chapter02/code/`에 있다. 개념을 읽은 자리에서 바로 대응하는 스크립트를 돌린다.
- 그림 다섯 장(2-1 ~ 2-5)은 각 절의 계산 구조를 그대로 옮긴 것이며, 본문의 해당 위치에 읽는 법을 함께 적었다.

이 장에서 처음 나오는 용어를 한 줄씩 미리 정리한다. 본문에서 각 용어가 처음 나올 때 다시 풀어 설명하므로, 여기서는 무엇을 가리키는 말인지만 확인하고 넘어간다.

용어	한 줄 뜻
잠재적 결과	한 사람에 대해 처치를 받았을 때의 결과와 받지 않았을 때의 결과를 각각 따로 적은 값
선택편향	처치를 받은 집단과 받지 않은 집단이 처치 말고도 원래 달라서 생기는 차이
공변량	처치 이전에 이미 정해져 있고 처치 여부와 결과 양쪽에 관련되는 특성
성향점수	어떤 특성을 가진 사람이 처치를 받을 확률
표준화 평균 차이(SMD, Standardized Mean Difference)	두 집단의 평균 차이를 표준편차 단위로 낸 값
보조 모수	효과를 추정하는 데 필요하지만 그 자체가 관심 대상은 아닌 중간 계산값
잔차	실제값에서 예측값을 뺀 나머지
ATE, ATT	전체 대상의 평균 효과, 처치를 실제로 받은 집단의 평균 효과
CATE	특정 특성을 가진 사람들만 놓고 본 평균 효과
이질적 처치효과	같은 처치인데도 효과의 크기가 사람마다 다른 상태

1부. 편향의 크기를 재고 평균 효과를 추정한다

이 파트가 끝나면: 같은 데이터에 대해 참값 처치효과, 단순 비교 추정값, 선택편향의 크기, 공변량 균형표를 한 장으로 정리한 진단 결과와, 성향점수 매칭과 이중 머신러닝으로 각각 보정한 평균 효과 추정값이 남는다. **다루는 절:** 2.1 ~ 2.4.1

2.1 잠재적 결과 프레임워크(Potential Outcomes Framework)

2.1.1 왜 이 계산이 필요한가

직업훈련 프로그램의 효과를 평가한다고 하자. 훈련을 받은 사람들의 평균 연봉이 3,000만 원이고 받지 않은 사람들의 평균이 2,500만 원이라면, 훈련의 효과를 500만 원이라고 보고해도 되는지가 문제다.

이 보고가 틀린 이유는 훈련 참여자가 무작위로 정해지지 않았기 때문이다. 훈련을 스스로 찾아 신청한 사람은 구직 의지가 강하고 기초 학력이 높은 경우가 많으므로, 훈련을 받지 않았더라도 연봉이 더 높았을 가능성이 크다. 두 집단의 평균 차이 500만 원에는 훈련이 만든 몫과 원래부터 있던 차이가 섞여 있으며, 이 둘을 갈라내지 않으면 예산 배정 근거로 쓸 수 없다.

같은 구조가 여러 영역에 반복해서 나타난다.

- 기초연금을 받은 노인과 받지 않은 노인의 삶의 만족도를 비교하면, 수급 자격 자체가 소득·건강과 얽혀 있어 수급자 쪽이 원래 더 낮은 만족도에서 출발한다.
- 할인 쿠폰을 쓴 고객과 쓰지 않은 고객의 구매액을 비교하면, 쿠폰을 챙겨 쓰는 고객이 원래 자주 구매하던 사람이라 쿠폰 효과가 부풀려진다.

2.1.2 무엇을 계산하는가

Rubin(1974)의 **잠재적 결과 프레임워크**(Potential Outcomes Framework)는 이 문제를 정리하는 표기법을 준다. 발상 자체는 단순하다. 한 사람에 대해 결과를 하나가 아니라 두 개 적어 두는 것이다. 훈련을 받았을 때의 연봉과 받지 않았을 때의 연봉을 따로 적고, 그 차이를 그 사람이 받은 효과로 정의한다.

기호	읽는 법	훈련 예에서
Y_{1i}	i 가 처치를 받았을 때의 결과	철수가 훈련을 받았을 때의 연봉
Y_{0i}	i 가 처치를 받지 않았을 때의 결과	철수가 훈련을 받지 않았을 때의 연봉
D_i	i 가 처치를 받았는지 여부(1 또는 0)	철수의 훈련 참여 여부
τ_i	i 가 받은 효과	두 연봉의 차이

아래 첨자 i 는 사람 한 명을 가리키는 번호이며, 개체 수준 처치효과는 두 결과의 차이로 쓴다.

$$\tau_i = Y_{1i} - Y_{0i}$$

앞의 예에서 철수가 훈련을 받아 3,000만 원을 받았고, 받지 않았다면 2,500만 원이었을 것이라면 $Y_1 = 3,000$, $Y_0 = 2,500$, $\tau = 500$ 이다. 문제는 철수가 훈련을 받으면 Y_1 만 관측되고 Y_0 는 영원히 관측되지 않는다는 데 있다. 관측되는 값은 처치 지시자 D_i 에 따라 둘 중 하나로 정해진다.

$$Y_i = D_i \cdot Y_{1i} + (1 - D_i) \cdot Y_{0i}$$

이 식은 D_i 자리에 1과 0을 직접 넣어 경우를 나눠 읽는다.

$D_i = 1$ 인 경우 (처치를 받았다)

$$\begin{aligned} Y_i &= 1 \cdot Y_{1i} + (1 - 1) \cdot Y_{0i} \\ &= Y_{1i} + 0 \cdot Y_{0i} \\ &= Y_{1i} \end{aligned} \quad \leftarrow Y_{0i} \text{는 사라진다}$$

$D_i = 0$ 인 경우 (처치를 받지 않았다)

$$\begin{aligned} Y_i &= 0 \cdot Y_{1i} + (1 - 0) \cdot Y_{0i} \\ &= 0 + 1 \cdot Y_{0i} \\ &= Y_{0i} \end{aligned} \quad \leftarrow Y_{1i} \text{는 사라진다}$$

$(1 - D_i)$ 는 D_i 가 1이면 0이 되고 D_i 가 0이면 1이 되는 스위치로, 두 항 가운데 항상 한쪽만 살리고 다른 쪽에는 0을 곱해 지운다. 그래서 두 잠재적 결과 가운데 한쪽만 데이터에 적히고 다른 쪽은 빈칸으로 남으므로, 개인의 효과 $\tau_i = Y_{1i} - Y_{0i}$ 는 어느 사람에 대해서도 계산되지 않는다.

그림 2-1. 인과추론의 근본 문제: 한 사람의 두 결과를 동시에 볼 수 없다

사람	$D = 1$ 이면	$D = 0$ 이면	효과
철수 $D = 1$	$Y(\text{처치}) = 6.2$ 관측된다	$Y(\text{무처치}) = ?$ 영원히 못 본다	계산 불가
영희 $D = 0$	$Y(\text{처치}) = ?$ 영원히 못 본다	$Y(\text{무처치}) = 2.4$ 관측된다	계산 불가

한 사람에게서 [처치 결과 - 무처치 결과]를 계산할 방법은 없다.
그래서 개인이 아니라 집단의 평균을 목표로 바꾼다.

그림에서 사람마다 초록색 칸 하나만 관측되고 빨간색 칸은 비어 있으며, 빈칸이 있는 한 오른쪽 끝의 효과 열은 철수에 대해서도 영희에 대해서도 채울 수 없다. Holland(1986)는 개체 수준 효과를 원리적으로 볼 수 없는 이 상황을 **인과추론의 근본적 문제**(fundamental problem of causal inference)라고 불렀다.

비유: 갈림길에서 한쪽 길만 걷는다.

갈림길	인과추론
갈림길에서 왼쪽 길을 골라 걷는다	철수가 훈련을 받는다($D = 1$)
도착 시각이 기록으로 남는다	훈련받은 뒤 연봉 Y_1 이 관측된다
오른쪽 길로 갔다면 몇 시에 도착했을지는 기록이 없다	훈련을 받지 않았을 때의 연봉 Y_0 는 관측되지 않는다
같은 갈림길을 지난 다른 사람들의 오른쪽 길 기록을 대신 본다	훈련을 받지 않은 사람들의 연봉 평균을 대신 쓴다
그 사람들의 걸음 속도가 나와 비슷해야 대신 쓸 수 있다	두 집단이 처치 말고 비슷해야 대신 쓸 수 있다

속성 대응의 핵심은 마지막 두 줄에 있다. 관측되지 않는 쪽을 다른 사람들의 기록으로 메우는 것이 인과추론의 기본 전략이며, 메울 자격이 있는지를 따지는 것이 2.1.3에서 다룰 가정이다. 이 비유는 **한 번의 선택이 다른 쪽 기록을 지운다는 구조**까지만 맞고, 갈림길은 되돌아가 다시 걸어 볼 수 있지만 정책 참여는 시점이 지나면 같은 조건으로 되돌릴 수 없다는 점에서 깨진다.

개인의 효과는 볼 수 없지만 집단의 평균은 다룰 수 있으므로, 분석의 목표를 개인에서 평균으로 옮긴다. 전체 모집단의 평균 효과를 **평균처치효과**(Average Treatment Effect, ATE), 처치를 실제로 받은 집단의 평균 효과를 **처치군 평균처치효과**(Average Treatment effect on the Treated, ATT)라 한다.

$$ATE = E[Y_1 - Y_0]$$

$$ATT = E[Y_1 - Y_0 \mid D = 1]$$

$E[\]$ 는 "평균"으로 읽고, 세로선 뒤에 붙은 조건은 "그 조건을 만족하는 사람들만 놓고 볼 때"로 읽는다. 그러면 ATT는 "처치를 실제로 받은 사람들만 놓고 볼 때의 평균 효과"가 된다.

두 값은 **누구를 평균하는가**에서 갈린다. ATE는 훈련을 신청한 사람과 신청하지 않은 사람을 모두 합친 전체를 평균하고, ATT는 신청한 사람만 모아 평균한다. 평균 내는 집단이 다르기 때문에 두 값은 대체로 일치하지 않는다.

두 집단이 같은 훈련에서 얻는 몫이 애초에 다를 수 있다는 점이 핵심이다. 훈련을 스스로 신청한 사람은 과정을 끝까지 이수하고 배운 것을 구직에 쓰지만, 신청하지 않은 사람을 제도로 끌어들여 훈련시키면 같은 과정을 거쳐도 얻는 몫이 작을 수 있다. 구직자 100명 가운데 40명이 훈련을 신청했고 두 집단의 평균 효과가 다음과 같다고 하자.

집단	인원	그 집단의 평균 효과
훈련을 신청한 사람	40명	100만 원
신청하지 않은 사람	60명	40만 원

미신청자의 40만 원은 두 값의 관계를 보이기 위해 둔 예시이며, 실제 자료에서는 관측되지 않는다.

ATT는 신청한 40명만 평균하므로 100만 원이고, ATE는 100명 전체를 평균하므로 $(40 \times 100 + 60 \times 40) \div 100 = 64$ 만 원이다. 같은 사업을 두고도 "이미 참여한 사람들이 얻은 효과"와 "전원에게 시켰을 때의 효과"가 이렇게 갈린다. 여기 쓴 ATT 100만 원은 임의로 고른 값이 아니라, 이 절 끝의 표에서 단순 비교 500만 원을 갈라 얻는 값이다.

묻는 질문이 무엇이나에 따라 답해야 할 값도 갈린다. 이미 시행한 사업의 성과를 평가하는 자리에서는 참여자가 얻은 몫인 ATT를 보고하고, 사업을 미참여자까지 확대할지 검토하는 자리에서는 전원 기준인 ATE를 본다. 위 예처럼 신청자의 효과가 더 큰 경우 ATT를 확대 근거로 가져다 쓰면 64만 원이 나올 사업을 100만 원짜리로 잡게 된다.

이제 단순 비교가 무엇을 재는지 분해할 수 있다. 관측된 처치군 평균에서 대조군 평균을 뺀 값은 다음 두 부분의 합이다.

$$E[Y \mid D=1] - E[Y \mid D=0] = \text{ATT} + (E[Y_0 \mid D=1] - E[Y_0 \mid D=0])$$

효과 선택편향

왼쪽은 데이터에서 바로 계산되는 값이고, 오른쪽 첫 항이 알고 싶은 효과다. 오른쪽 두 번째 괄호가 **선택편향(selection bias)**이며, 두 항을 각각 말로 옮기면 다음과 같다.

- $E[Y_0 \mid D=1]$ — 처치를 받은 사람들이 만약 처치를 받지 않았다면 보였을 결과의 평균이다. 관측되지 않는다.
- $E[Y_0 \mid D=0]$ — 실제로 처치를 받지 않은 사람들의 결과 평균이다. 관측된다.

두 값이 같으면 선택편향이 0이 되어 단순 비교가 그대로 효과가 되지만, 두 값이 다르면 그 차이가 효과 위에 얹혀 나온다. 훈련 예에 숫자를 넣어 따라가면 이렇다.

항목	값	관측되는가
훈련생의 평균 연봉 $E[Y \mid D=1]$	3,000만 원	관측된다
미훈련생의 평균 연봉 $E[Y \mid D=0]$	2,500만 원	관측된다
단순 비교 = $3,000 - 2,500$	500만 원	계산된다
훈련생이 훈련을 안 받았다면의 연봉 $E[Y_0 \mid D=1]$	2,900만 원	관측되지 않는다
선택편향 = $2,900 - 2,500$	400만 원	계산할 수 없다
훈련의 실제 몫 ATT = $500 - 400$	100만 원	계산할 수 없다

단순 비교로 나온 500만 원 가운데 훈련이 만든 몫은 100만 원뿐이고, 나머지 400만 원은 훈련생이 원래 더 잘 벌던 사람들이라는 사실에서 왔다. 실제 자료에서는 넷째 줄을 관측할 수 없으므로 선택편향을 직접 빼지 못하며, 대신 두 집단을 비교 가능하게 만들어 그 차이 0에 가까워지도록 몰아간다.

인과추론 방법론은 전부 이 선택편향 항을 0으로 만들거나, 관측된 변수로 설명해 없애려는 시도다.

2.1.3 식별을 위한 세 가지 가정

선택편향을 공변량 X 로 건어내려면 세 가지 가정이 필요하며, 각 가정은 점검하는 자료가 다르다. 이름은 어렵지만 요구하는 내용은 각각 한 문장으로 옮길 수 있다.

- SUTVA — 남이 처치를 받았다고 해서 내 결과가 달라지지 않아야 하고, 처치의 내용이 사람마다 달라서도 안 된다.
- Unconfoundedness — 같은 X 값을 가진 사람들 안에서는 누가 처치를 받았는지가 동전 던지기와 다를없어야 한다.
- Overlap — 어떤 X 값에서든 처치를 받은 사람과 받지 않은 사람이 둘 다 있어야 비교할 상대가 생긴다.

세 가정을 기호와 점검 방법까지 붙여 정리하면 다음과 같다.

표 2-A 식별 가정과 점검 방법

가정	내용	무엇으로 점검하는가
SUTVA	한 개체의 결과가 다른 개체의 처치 여부에 영향받지 않고, 처치의 종류가 하나다	자료가 아니라 제도·설계를 보고 판단한다
Unconfoundedness	X 를 통제하면 처치 배정이 잠재결과와 무관하다: $(Y_1, Y_0) \perp D \mid X$	원리적으로 검증 불가하므로, 배정 규칙을 문서로 확인하고 누락 변수를 논증한다
Overlap	어떤 X 값에서도 처치 확률이 0도 1도 아니다: $0 < P(D=1 X) < 1$	성향점수 분포를 그려 두 집단이 겹치는 구간을 본다

SUTVA는 남이 받은 처치가 내 결과를 건드리지 않을 것, 그리고 처치의 내용이 모두에게 같을 것을 요구한다. 상대평가 교실을 놓고 보면 앞 조건이 왜 필요한지 드러나는데, 한 학생에게만 과외를 붙이면 그 학생의 등수가 오른 만큼 다른 학생의 등수가 내려가므로 과외 효과를 등수 차이로 재면 실제보다 커진다. 과외받은 학생이 처치군, 등수가 밀린 학생이 대조군, 밀려난 몫이 파급효과에 해당한다. 한 지역에만 직업훈련을 집중해 인근 지역 일자리를 가져가는 경우가 같은 구조이고, 반대로 백신 접종률이 올라 미접종자까지 이득을 보면 같은 뺄셈이 효과를 작게 낸다. 뒤 조건은 같은 사업 이름 아래 40시간 과정과 200시간 과정이 섞이면 효과라는 값이 하나로 정해지지 않는다는 뜻이다. 이 비유는 한쪽의 이득이 다른 쪽 손해로 넘어간다는 구조까지만 맞고 취업자 수는 등수와 달리 총합이 고정되지 않으며, 두 조건 모두 자료로 확인되지 않으므로 분석 단위를 지역으로 올리거나 인접 지역을 대조군에서 빼 설계로 막는다.

Unconfoundedness는 X 값이 같은 사람들끼리 묶었을 때 그 묶음 안에서 누가 처치를 받았는지가 제비뽑기와 다를없을 것을 요구한다. 학생을 직전 성적 구간끼리 묶고 각 묶음 안에서 보충수업 참여자를 제비뽑기로 정하면 이 요구가 충족되며, 성적 구간이 X 에, 묶음 안의 제비뽑기가 조건부 독립에 해당한다. 담임이 의욕 있어 보이는 학생을 골라 넣었다면 성적이 같은 묶음 안에서도 의욕이 갈리는데, 의욕은 기록에 남지 않아 이 어긋남을 자료로 잡아낼 수 없다. 가정의 내용이 관측되지 않는 Y_0 에 대한 진술이라서 원리적으로 증명되지 않고, 2.1.5에서 보는 균형표도 X 의 균형만 보여 줄 뿐 Y_0 까지 균형이라는 증거는 되지

않는다. 그래서 제도 문서의 배정 기준을 데이터 열과 하나씩 대조하고, 문서에 남지 않는 요인 가운데 결과에도 영향을 주는 것을 적어 둔 뒤, 위약 검정(제4장)과 민감도 분석(제3장)으로 보완한다. 이 가정이 깨지면 매칭이든 DML이든 편향이 그대로 남는다.

Overlap은 비슷한 특성을 가진 사람 가운데 처치를 받은 쪽과 받지 않은 쪽이 둘 다 있을 것을 요구한다. 사고 이력이 중고차 값을 얼마나 깎는지 재려면 같은 연식·주행거리의 차가 양쪽에 다 있어야 하고, 무사고 차만 있는 구간에서는 비교 자체가 성립하지 않는다. 연식과 주행거리가 X에, 사고 이력이 처치에, 양쪽에 매물이 있는 구간이 공통되지 영역에 해당한다. 소득 100만 원 미만 구간의 노인이 전원 기초연금 수급자인 경우가 같은 상황인데, 그런데도 회귀 모형에 자료를 넣으면 값은 나온다. 이 값은 소득이 높은 구간에서 얻은 관계를 낮은 구간까지 늘려 만든 **외삽**(extrapolation)이며, 공부 시간 0~5시간 자료로 그린 직선에 20시간을 대입해 점수를 예측하는 계산과 같다. 임계값 제도처럼 Overlap이 구조적으로 깨지면 회귀불연속설계(제5장)로 방법을 바꾸고, 그렇지 않으면 두 집단의 성향점수 분포를 겹쳐 그려 한쪽에만 있는 꼬리 구간의 비율을 보고한 뒤 제외 전후 추정값을 함께 적는다. 세 가정 가운데 Overlap만이 이렇게 데이터로 직접 확인되며, 다음 실습에서 그 확인을 수행한다.

2.1.4 코드로 해 보기

시뮬레이션은 현실에서 볼 수 없는 Y_0 와 Y_1 을 둘 다 만들어 두므로, 참값 효과와 추정값의 차이를 직접 잴 수 있다. 공변량 X_1 이 클수록 처치 확률이 올라가고 X_1 이 클수록 결과도 좋아지도록 설계해, 선택편향이 생기는 상황을 그대로 재현한다.

```
np.random.seed(42)
n = 1000
X = np.random.randn(n, 5)
true_propensity = expit(0.5 * X[:, 0] - 0.3 * X[:, 1]) #  $X_1$ 이 클수록 처치 확률 상승
treatment = np.random.binomial(1, true_propensity)

Y0_true = 2 + X[:, 0] - 0.5 * X[:, 1] + np.random.randn(n) * 0.5 # 관측 불가
Y1_true = Y0_true + 3 + 0.8 * X[:, 2] # 효과는 3, 단  $X_3$ 에 따라 다름
Y_observed = treatment * Y1_true + (1 - treatment) * Y0_true # 실제로 보이는 값

true_ATT = np.mean((Y1_true - Y0_true)[treatment == 1])
naive_estimate = Y_observed[treatment == 1].mean() - Y_observed[treatment == 0].mean()
selection_bias = naive_estimate - true_ATT
```

전체 코드는 `practice/chapter02/code/2-1-potential-outcomes.py` 참고


2.1.5 결과를 읽는 법

스크립트 `2-1-potential-outcomes.py` 를 실행하면 다음 두 표가 출력된다.

표 2-1 잠재적 결과 시뮬레이션 결과 (난수 시드 42)

추정량	값	설명
참값 ATE	3.00	전체 모집단의 평균 처치효과
참값 ATT	3.00	처치군의 평균 처치효과
Naive 추정값	3.71	두 집단 평균의 단순 차이
선택편향	0.71	Naive 추정 - 참값 ATT
편향 비율	23.6%	선택편향 ÷ 참값 ATT × 100

그림 2-2. 단순 평균 차이는 두 조각으로 갈라진다 (실습 1 실측값)



선택편향 0.71은 참값 3.00의 23.6%다. 매칭·DML이 줄이려는 대상이 이 항이다.

그림은 표 2-1의 세 숫자를 등식 하나로 옮긴 것이다. 왼쪽 노란 상자 3.71만 데이터에서 바로 계산되고, 오른쪽 초록 상자 3.00과 빨간 상자 0.71은 참값을 알고 있는 시뮬레이션이기 때문에 갈라 볼 수 있다. 실제 자료에서는 이 갈라짐이 보이지 않으므로, 빨간 상자를 줄이는 절차를 거쳤다는 증거를 따로 제시해야 한다.

표 2-2 공변량 균형 진단

공변량	처치군 평균	대조군 평균	표준화 평균 차이(SMD, Standardized Mean Difference)
X ₁ (교육연수)	0.26	-0.27	0.55
X ₂ (이전 소득)	-0.11	0.09	-0.20
X ₃ (나이)	0.00	0.01	-0.01
X ₄ (가구원 수)	-0.00	0.01	-0.02
X ₅ (거주지 규모)	0.09	-0.03	0.12

괄호 안의 이름은 표를 읽기 편하도록 붙인 것이다. 시뮬레이션은 다섯 변수를 모두 평균 0, 표준편차 1의 표준정규분포에서 뽑으므로 자료 자체에는 의미가 붙어 있지 않으며, 각 변수가 맡은 역할은 데이터 생성 규칙이 정한다. X_1 과 X_2 는 처치 확률과 결과 양쪽에 걸리되 X_1 쪽이 더 강하고, X_3 은 처치효과의 크기를 사람마다 다르게 만들며, X_4 와 X_5 는 어느 쪽에도 걸리지 않는다. X_5 의 SMD 0.12는 배정 규칙이 아니라 표본 추출에서 생긴 값이다.

성향점수 범위는 처치군이 [0.21, 0.93], 대조군이 [0.11, 0.82]이며, 공통지지 영역 밖 개체는 12개(1.2%)다. 읽는 순서는 다음과 같다.

첫째, 편향의 크기를 본다. 단순 비교로 3.71이 나왔고 참값은 3.00이므로, 이 자료에서 단순 비교는 효과를 23.6% 부풀린다. 실제 분석에서는 참값을 모르므로 이 수치를 직접 계산할 수 없지만, 시뮬레이션으로 편향의 방향과 크기를 미리 확인해 두면 실제 자료에서 보정 전후 추정치가 얼마나 움직여야 자연스러운지 감이 잡힌다.

둘째, 편향의 원인을 지목한다. 표 2-2에서 **표준화 평균 차이**(Standardized Mean Difference, SMD)는 두 집단의 평균 차이를 표준편차 단위로 표현한 값이며, 0에 가까울수록 두 집단이 그 변수에서 비슷하다는 뜻이다. X_1 의 SMD가 0.55로 가장 크고, 이 값이 데이터 생성 규칙(X_1 이 클수록 처치 확률 상승)과 정확히 일치한다. 반면 X_3 과 X_4 는 0에 가까워 처치 배정과 무관하다. X_1 을 교육연수로 읽으면, 교육을 오래 받은 사람이 훈련을 더 많이 신청했고 교육연수가 길면 연봉도 높다는 구조가 되며, 이 구조가 곧 선택편향 0.71의 출처다.

판정 기준. 실습 스크립트는 $|SMD| > 0.1$ 인 공변량의 이름과 값을 세어 출력한다. 이 기준에 따라 다음과 같이 행동한다.

- $|SMD| \leq 0.1$ 인 변수만 남으면, 그 변수 집합에서는 두 집단이 균형을 이룬 것으로 보고 다음 단계로 넘어간다.
- $|SMD|$ 가 0.1을 넘는 변수가 하나라도 있으면, 그 변수를 그대로 둔 채 단순 비교 결과를 보고하지 않는다. 매칭·가중·회귀 보정 가운데 하나를 적용한 뒤 SMD를 다시 계산한다.
- 보정 후에도 같은 변수의 $|SMD|$ 가 줄지 않으면 그 변수의 함수 형태를 잘못 설정한 것이므로, 제곱항이나 상호작용을 넣어 성향점수 모형을 다시 적합한다.

셋째, 겹침을 확인한다. 처치군 성향점수의 하한이 0.21이고 대조군의 상한이 0.82이므로, 두 집단이 [0.21, 0.82] 구간에서 겹친다. 이 구간 밖 개체 12개(1.2%)는 비교 상대가 없어 효과를 추정할 근거가 없다. 이 비율이 작으면 해당 개체를 제외하고 추정해도 표본이 거의 줄지 않지만, 비율이 커서 제외 후 표본이 눈에 띄게 줄면 결과를 전체 모집단의 ATE로 보고하지 않고 **공통지지 영역에 한정된 효과**로 명시해 보고한다.

2.2 전통적 인과추론 방법론 개요

2.2.1 왜 방법이 여러 개인가

2.1에서 확인한 선택편향을 없애는 방법은 하나가 아니다. 방법이 여러 개인 이유는 각 방법이 **자료에서 무엇을 얻을 수 있는지**를 다르게 전제하기 때문이다. 처치 배정을 연구자가 직접 통제할 수 있는지, 같은 대상을 정책 전후로 여러 번 관측했는지, 배정을 좌우하는 외부 규칙이 있는지에 따라 쓸 수 있는 방법이 달라진다.

따라서 다섯 방법을 우열로 외우지 않고, 각각이 요구하는 자료 조건으로 구분해 기억한다.

2.2.2 다섯 가지 식별 전략

다섯 방법을 한 줄씩 먼저 요약한다. 다섯 가지 모두 "비교 상대를 어디서 구하는가"에 대한 서로 다른 답이며, 이 한 줄을 잡아 두면 이어지는 설명이 어느 자리에 붙는지 보인다.

방법	비교 상대를 어디서 구하는가
RCT	동전을 던져 처음부터 비슷한 두 집단을 만든다
PSM	처치받을 확률이 비슷한 사람을 찾아 짝지운다
DID	같은 집단의 정책 시행 이전 상태를 비교 상대로 쓴다
IV	본인 의사와 무관하게 처치 여부가 갈린 부분만 골라 쓴다
RDD	기준선 바로 건너편에 있는 사람을 비교 상대로 쓴다

무작위통제시험(Randomized Controlled Trial, RCT)은 처치를 무작위로 배정해 두 집단의 잠재결과 분포를 같게 만든다. 배정이 동전 던지기로 정해지면 처치 여부와 잠재결과가 독립이므로 선택편향 항이 0이 되고, 단순 평균 차이가 그대로 ATE의 비편향 추정값이 된다. 윤리적·비용적 제약으로 항상 실행할 수는 없으며, 설계 원리와 기계학습을 결합한 적응형 시험설계는 제8장에서 다룬다.

성향점수 매칭(Propensity Score Matching, PSM)은 관측된 공변량으로 처치 확률 $e(X) = P(D=1|X)$ 를 추정하고, 이 점수가 비슷한 처치군·대조군 개체를 짝지어 비교한다. Rosenbaum & Rubin(1983)은 여러 개의 공변량을 통제하는 문제를 이 1차원 점수 하나를 맞추는 문제로 줄일 수 있음을 보였다. 관측하지 못한 변수가 배정을 좌우하면 편향이 그대로 남고, 짝을 찾지 못한 개체는 분석에서 빠진다. 상세 내용은 제3장에서 다룬다.

이중차분법(Difference-in-Differences, DID)은 처치군과 대조군의 정책 전후 변화량을 비교한다. 두 집단의 수준 차이가 시간에 관계없이 일정하다면, 변화량끼리 빼는 순간 그 차이가 상쇄된다. 이때 필요한 가정이 **평행추세 가정**으로, 정책이 없었다면 두 집단의 결과가 같은 쪽으로 움직였을 것이라는 전제다. 관측되지 않은 변수라도 시간에 따라 변하지 않으면 통제되므로 정책평가에 널리 쓰이며, 제4장에서 다룬다.

도구변수법(Instrumental Variables, IV)은 처치 D와는 관련이 있지만 결과 Y에는 D를 거쳐서만 영향을 주는 변수 Z를 이용한다. Z가 만드는 D의 변동은 숨은 교란변수와 무관하므로, 그 부분만 골라 쓰면 관측되지 않은 교란이 있어도 효과를 식별할 수 있다. 대신 추정 대상이 전체 평균이 아니라 Z 때문에 처치 상태가 바뀐 집단의 효과, 즉 **국지적 평균처치효과**(Local Average Treatment Effect, LATE)로 좁아진다. 군 복무 추첨 번호로 복무 여부가 갈린 경우가 전형적인 예이며, 제6장에서 다룬다.

회귀불연속설계(Regression Discontinuity Design, RDD)는 연속적인 배정변수가 특정 임계값을 넘을 때 처치가 결정되는 제도를 활용한다. 임계값 바로 위와 바로 아래 개체는 다른 특성이 거의 같으므로, 임계값 근처의 결과 차이를 처치 효과로 읽는다. 소득이 기준선보다 1만 원 적어 지원을 받은 가구와 1만 원 많아 못 받은 가구는 다른 조건이 사실상 같다고 보는 논리다. 임계값 근처에 한정된 효과만 추정되므로 전체 대상으로 일반화하기 어려우며, 제5장에서 다룬다.

표 2-3 전통적 인과추론 방법론 비교

방법론	핵심 식별 전략	주요 가정	추정 대상	상세 내용
RCT	무작위 배정	실험적 독립성	ATE	제8장
PSM	성향점수 매칭	Unconfoundedness	ATT	제3장
DID	사전·사후 비교	평행추세	ATT	제4장
IV	도구변수 활용	관련성, 외생성	LATE	제6장
RDD	임계값 불연속성	국지적 연속성	LATE	제5장

2.2.3 어느 방법을 고르는가

주어진 자료를 앞에 놓고 다음 순서로 판정한다.


1. 처치 배정을 연구자가 통제할 수 있으면 RCT를 설계한다. 배정을 통제할 수 없으면 2로 간다.
2. 처치 여부를 결정하는 명시적 임계값 규칙이 제도에 있고 배정변수가 관측되면 RDD를 쓴다. 없으면 3으로 간다.
3. 같은 대상을 정책 시행 전후로 관측했고 비교 가능한 대조군이 있으면 DID를 쓴다. 없으면 4로 간다.
4. 배정과 관련되면서 결과에는 직접 영향을 주지 않는 외부 변수가 있으면 IV를 쓴다. 없으면 5로 간다.
5. 배정에 쓰인 정보가 공변량으로 대부분 관측되어 있다고 논증할 수 있으면 PSM이나 회귀 보정을 쓴다. 그것도 아니면 인과효과를 추정하지 않고 기술 통계로 보고한다.

마지막 항목이 실무에서 가장 자주 생략되는 선택지다. 어느 가정도 방어할 수 없는 자료에서 숫자를 만들어 내면, 그 숫자는 정책 결정을 잘못된 방향으로 끌고 간다.

2.2.4 코드로 해 보기

2.1에서 만든 자료에 PSM을 적용해 첫 보정 추정치를 얻는다. 로지스틱 회귀로 성향점수를 추정하고, 각 처치군 개체에 성향점수가 가장 가까운 대조군 개체를 붙인 뒤, 짝지어진 결과의 차이를 평균한다.

그림 2-3. 성향점수 매칭의 네 단계



그림의 네 상자가 절차의 순서이고, ③에서 걸러지면 ④로 넘어가지 않고 ①로 돌아간다는 점선 화살표가 이 절차의 핵심이다. 성향점수를 쓰는 이유는 공변량이 다섯 개든 십 개든 "처치받을 확률"이라는 숫자 하나로 줄여 짝을 찾을 수 있기 때문이다. 그림 아래쪽에 적힌 값은 이 실습의 실행 결과로 기록된 것으로, X₁의 SMD가 0.55에서 0.01로 내려가고 매칭 후 ATT가 3.08(참값 3.00)로 나온다.

```
ps_model = LogisticRegression(max_iter=1000)
ps_model.fit(X, treatment)
ps = ps_model.predict_proba(X)[:, 1] # 추정 성향점수

nn = NearestNeighbors(n_neighbors=1).fit(ps[treatment == 0].reshape(-1, 1))
_, idx = nn.kneighbors(ps[treatment == 1].reshape(-1, 1)) # 가장 가까운 대조군 짝

att_psm = (Y_observed[treatment == 1] - Y_observed[treatment == 0][idx.ravel()]).mean()
```

전체 코드는 `practice/chapter02/code/2-2-traditional-psm.py` 참고

2.2.5 결과를 읽는 법

이 스크립트는 매칭 전후의 SMD와 매칭 후 추정된 ATT를 출력하며, 매칭 후 |SMD|가 0.1을 넘는 공변량의 개수를 함께 계산해 보여 준다. 출력 화면에서 다음 세 가지를 순서대로 확인한다.

첫째, 매칭 후 SMD가 줄었는지 본다. 매칭 전 X_1 의 SMD는 0.55였으므로, 매칭이 제 역할을 했다면 이 값이 0.1 아래로 내려가야 한다. $|SMD| > 0.1$ 인 공변량 개수가 0이면 균형이 확보된 것으로 보고 추정값을 읽는다. 개수가 0이 아니면 추정값을 보고하지 않고, 남은 변수를 성향점수 모형에 제공항이나 상호작용 형태로 추가한 뒤 다시 매칭한다.

둘째, 표본이 얼마나 남았는지 본다. 매칭은 짝을 찾지 못한 개체를 버리므로, 처치군 가운데 몇 명이 분석에 남았는지를 확인한다. 표본이 크게 줄었다면 추정 대상이 전체 처치군의 ATT가 아니라 "짝을 찾을 수 있었던 처치군"의 효과로 바뀐 것이므로, 결과를 그 범위로 한정해 보고한다.

셋째, 보정 방향을 확인한다. 2.1에서 단순 비교가 참값보다 컸으므로, 보정된 추정값은 단순 비교값 3.71보다 작아지는 방향으로 움직여야 한다. 보정 후 값이 오히려 커졌다면 성향점수 모형이 잘못 설정되었거나 매칭 코드가 잘못된 것이므로, 결과를 해석하기 전에 코드를 점검한다.

여기까지가 관측 데이터에서 편향을 다루는 표준 절차이며, 이 절차가 흔들리는 지점을 2.3에서 다룬다.

2.3 인과 머신러닝(Causal Machine Learning)의 등장

2.3.1 전통적 절차가 깨지는 세 상황

2.2까지의 절차는 공변량이 다섯 개이고 관계가 단순한 자료에서 잘 작동했다. 현실 자료에서는 다음 세 상황에서 이 절차가 흔들린다.

변수가 많을 때. 행정 데이터에는 인구·소득·가구·이력 변수가 수십에서 수백 개 들어 있다. 로지스틱 회귀로 성향점수를 추정하면 변수 개수가 늘어날수록 계수 추정이 불안정해지고, 어떤 변수를 넣고 뺄지의 선택이 결과를 좌우한다. 변수 200개 가운데 어느 20개를 넣느냐에 따라 추정값이 달라진다면, 그 추정값은 자료가 아니라 분석자의 선택을 반영한 셈이다.

관계가 굽어 있을 때. 소득이 결과에 미치는 영향이 직선이 아니라 로그 형태이거나, 두 변수의 상호작용이 있으면 선형 모형은 그 구조를 놓친다. 예를 들어 훈련의 효과가 30대에서 가장 크고 20대와 50대에서 작다면 나이와 효과의 관계는 직선이 아니라 언덕 모양이며, 나이를 1차항으로만 넣은 모형은 이 모양을 표현하지 못한다. 성향점수 모형이 실제 배정 규칙을 잘못 근사하면 매칭 후에도 편향이 남는다.

효과가 사람마다 다를 때. ATE 하나만 보고하면 "평균적으로 3만큼 올랐다"까지만 말할 수 있다. 예산이 한정된 상황에서 정작 필요한 답은 "누구에게 주면 가장 크게 오르는가"이며, 평균 하나로는 이 질문에 답할 수 없다.

2.3.2 기계학습이 기여하는 네 영역

Athey & Imbens(2017)는 기계학습이 인과추론에 기여하는 지점을 네 가지로 정리했다.

- **보조 모수 추정의 정확도:** 성향점수 $E[D|X]$ 와 결과 회귀 $E[Y|X]$ 는 그 자체가 관심 대상이 아니라 편향을 걷어내기 위한 중간 계산이며, 이런 값을 **보조 모수**(nuisance parameter)라 한다. 예측 성능이 좋은 알고리즘을 여기에 쓰면 굵은 관계도 근사할 수 있다.
- **이질적 효과의 발견:** 어떤 특성을 가진 집단에서 효과가 큰지를 사람이 미리 지정하지 않고 자료에서 찾는다.
- **고차원 공변량 처리:** 변수 개수가 많고 상호작용이 복잡해도 자동으로 다룬다.
- **개입 시나리오의 예측:** 정책을 바꿨을 때의 결과를 사전에 계산해 비교한다.

중요한 것은 기계학습이 인과추론의 가정을 대체하지 않는다는 점이다. Unconfoundedness가 성립하지 않는 자료에서는 어떤 알고리즘을 써도 편향이 남으며, 기계학습이 개선하는 것은 **가정이 성립한다는 전제 아래에서의 추정 정확도**다.

2.4 인과 ML 핵심 방법론

2.4.1 이중 머신러닝(Double Machine Learning, DML)

왜 필요한가

성향점수와 결과 회귀에 기계학습을 그냥 쓰면 새로운 문제가 생긴다. 기계학습 모형은 과적합을 막기 위해 계수를 축소하는 정규화를 걸어 두는데, 이 축소가 예측에는 유리해도 처치효과 추정에는 계통적인 치우침을 남긴다. 게다가 같은 데이터로 보조 모수를 학습하고 그 잔차로 효과를 추정하면, 모형이 이미 본 데이터에 맞춰져 있어 잔차가 실제보다 작아진다.

Chernozhukov et al.(2018)의 **이중 머신러닝**(Double Machine Learning, DML)은 이 두 문제를 각각 **직교화**와 **표본 분할**로 처리한다. **직교화**(orthogonalization)는 결과와 처치 양쪽에서 공변량의 몫을 먼저 빼 두는 조작을 가리키며, 이렇게 해 두면 예측 모형이 조금 어긋나도 그 오차가 처치효과 추정값으로 거의 넘어오지 않는다. **표본 분할**은 예측 모형을 학습하는 데 쓴 자료와 잔차를 계산하는 데 쓰는 자료를 갈라 놓는 것이다.

무엇을 계산하는가

계산은 세 단계다.

1. 결과 Y 를 공변량 X 로 예측하고, 예측값을 뺀 나머지를 남긴다. 이것이 결과 잔차 $Y - \ell(X)$ 이며, X 로 설명되지 않는 결과 변동이다.
2. 처치 D 를 공변량 X 로 예측하고, 예측값을 뺀 나머지를 남긴다. 이것이 처치 잔차 $D - m(X)$ 이며, X 로 설명되지 않는 처치 변동이다.
3. 두 잔차를 회귀해 기울기를 구한다. 이 기울기가 처치효과 추정값이다.

$$\theta = E[(Y - \ell(X))(D - m(X))] / E[(D - m(X))^2]$$

각 항을 말로 옮기면, 분자는 "X로 설명 안 되는 처치 변동"과 "X로 설명 안 되는 결과 변동"이 얼마나 함께 움직이는지이고, 분모는 처치 변동의 크기다. 처치가 X로 거의 완전히 결정되면 분모가 0에 가까워지고 추정값이 불안정해지는데, 이것이 2.1에서 본 Overlap 가정이 DML에서 나타나는 형태다.

잔차가 무엇인지 숫자로 확인한다. 잔차는 실제값에서 예측값을 뺀 나머지다. 어떤 사람의 연봉이 3,200만 원인데 공변량 X로 예측한 값이 3,050만 원이었다면 결과 잔차는 150만 원이고, 같은 사람의 훈련 참여가 D = 1인데 X로 예측한 참여 확률이 0.8이었다면 처치 잔차는 0.2다. 이 사람은 X만 보아도 훈련을 받을 사람이었으므로 그의 연봉이 높다는 사실은 효과의 증거로 거의 쓰이지 않고, 반대로 참여 확률이 0.2인데 훈련을 받은 사람은 처치 잔차가 0.8로 커서 추정에 크게 기여한다.

사람	연봉 Y	예측 $\ell(X)$	결과 잔차	참여 D	예측 $m(X)$	처치 잔차
가	3,200	3,050	+150	1	0.8	+0.2
나	2,600	2,750	-150	0	0.7	-0.7
다	3,400	2,900	+500	1	0.2	+0.8

위 숫자는 계산 구조를 보이기 위해 든 예시이며 실습 출력이 아니다.

세 사람 가운데 '다'는 X로 보면 훈련을 받을 이유가 적은데도 받았고 연봉도 예측보다 500만 원 높으므로, 두 잔차가 함께 크게 움직인 사례다. θ 식의 분자가 세는 것이 바로 이런 동시 움직임이며, X로 설명되는 부분은 이미 빠져 있으므로 남은 움직임만 처치효과의 근거가 된다.

"이중"이라는 이름은 Y와 D **양쪽 모두**에서 X의 영향을 빼기 때문에 붙었다. 여기에 **교차 적합**(cross-fitting)을 얹는다. 데이터를 K개 조각으로 나누고, k번째 조각을 뺀 나머지로 ℓ 과 m 을 학습한 뒤 k번째 조각에서 잔차와 θ 를 계산하는 방식을 K번 반복해 평균한다.


비유: 시험 문제로 공부하고 그 문제로 시험 보기. 속성 대응은 다음과 같다.

시험 상황	DML
시험에 나올 문제로 공부한다	같은 데이터로 보조 모형을 학습한다
그 문제로 시험을 본다	같은 데이터에서 잔차를 계산한다
점수가 실력보다 높게 나온다	잔차가 실제보다 작아져 효과 추정이 치우친다
공부에 안 쓴 문제로 시험 본다	학습에 안 쓴 조각에서 잔차를 계산한다

이 비유는 "학습에 쓴 자료로 평가하면 값이 낙관적으로 나온다"는 구조까지만 맞다. 시험 점수는 한 방향으로 부풀려지지만, 교차 적합 없이 계산한 처치효과는 자료에 따라 커지기도 작아지기도 하므로 치우침의 방향이 정해져 있지 않다.

그림 2-4. 이중 머신러닝이 두 번 빼는 절차

두 번 빼는 이유: X가 Y와 D 양쪽을 동시에 움직이기 때문이다



그림의 위 줄은 결과 Y에서 X의 몫을 빼는 과정이고 아래 줄은 처치 D에서 같은 일을 하는 과정이며, 두 줄의 오른쪽 끝에서 나온 잔차끼리 회귀하는 것이 마지막 단계다. 두 번 빼는 이유는 X가 Y와 D 양쪽을 동시에 움직이기 때문이고, 한쪽만 빼면 다른 쪽에 X의 몫이 그대로 남아 추정값에 섞인다.

코드로 해 보기

```

for train_idx, test_idx in KFold(n_splits=5, shuffle=True, random_state=42).split(X):
    outcome_model = GradientBoostingRegressor(n_estimators=100, max_depth=4)
    outcome_model.fit(X[train_idx], Y[train_idx]) # 학습: 나머지 조각
    Y_residual = Y[test_idx] - outcome_model.predict(X[test_idx]) # 잔차: 남긴 조각

    propensity_model = GradientBoostingClassifier(n_estimators=100, max_depth=4)
    propensity_model.fit(X[train_idx], D[train_idx])

    D_residual = D[test_idx] - propensity_model.predict_proba(X[test_idx])[:, 1]

    theta = np.sum(Y_residual * D_residual) / np.sum(D_residual ** 2)
    theta_estimates.append(theta)

ate_dml = np.mean(theta_estimates)
  
```

전체 코드는 [practice/chapter02/code/2-3-double-ml.py](#) 참고

결과를 읽는 법

이 실습이 쓰는 자료는 2.1의 자료와 다르다. 제곱항·상호작용·주기함수·지수함수를 넣어 관계를 일부러 굽혀 놓았으므로, 참값과 단순 비교값이 2.1과 일치하지 않는다.

표 2-5 이중 머신러닝 추정 결과

추정량	값	표준오차	95% 신뢰구간	편향
DML (Gradient Boosting)	2.88	0.03	[2.83, 2.93]	0.11
참값 ATE	2.99	—	—	—
PSM (로지스틱 회귀)	4.03	0.23	[3.58, 4.48]	1.04
Naive 추정	4.89	0.21	[4.48, 5.30]	1.90
OLS (선형 회귀)	3.90	0.19	[3.53, 4.28]	0.91

표 2-6 교차 적합 폴드별 추정값

Fold	Theta	보조 모형 R ² (결과)	보조 모형 R ² (성향)
1	2.86	0.83	0.12
2	2.97	0.82	0.15
3	2.84	0.85	0.14
4	2.81	0.80	0.17
5	2.93	0.83	0.17
평균	2.88	0.83	0.15
표준편차	0.06	0.02	0.02

표 2-7 방법론 간 성능 비교

지표	DML	PSM	OLS	Naive
절대 편향	0.11	1.04	0.91	1.90
상대 편향	3.7%	34.7%	30.4%	63.3%
95% 신뢰구간이 참값 포함	아니오	아니오	아니오	아니오

첫째, 추정값이 참값에서 얼마나 벗어났는지 본다. DML의 편향은 0.11(3.7%)이고, PSM은 1.04(34.7%), OLS는 0.91(30.4%), 단순 비교는 1.90(63.3%)이다. 같은 자료에서 방법에 따라 결과가 이렇게 갈리는 이유는 PSM과 OLS가 굵은 관계를 직선으로 근사했기 때문이며, DML은 Gradient Boosting이 그 굵음을 학습한 뒤 잔차만 비교했기 때문이다.

둘째, 폴드별 값이 모여 있는지 본다. 표 2-6에서 다섯 폴드의 θ 가 2.81에서 2.97 사이에 있고 표준편차가 0.06이다. 어느 조각을 남기든 비슷한 값이 나오므로 교차 적합이 안정적으로 작동했다고 판정한다. 폴드 간 편차가 보고할 신뢰구간의 폭보다 크게 나오면 추정이 불안정한 것이므로, 폴드 수를 늘리거나 보조 모형을

단순한 것으로 바꾼 뒤 다시 계산한다.

셋째, 보조 모형의 예측 성능을 본다. 결과 회귀 R^2 는 0.83으로 높고, 성향 모형 R^2 는 0.15로 낮다. 여기서 두 값의 해석이 반대라는 점에 주의한다. 결과 회귀 R^2 가 낮으면 결과 변동을 X로 견어내지 못한 것이므로 잔차에 교란이 남는다. 반면 성향 모형 R^2 가 1에 가까우면 처치 여부가 X로 거의 결정된다는 뜻이라 Overlap이 위태로워지므로, 낮은 값 자체는 문제가 아니다.

판정 기준. 표 2-7의 마지막 행에서 네 방법 모두 95% 신뢰구간이 참값을 포함하지 못한다. DML도 예외가 아니며, 구간이 [2.83, 2.93]으로 좁아 참값 2.99를 놓쳤다. 이 결과를 다음과 같이 읽는다.

- 점추정의 편향이 작다고 해서 구간추정까지 믿을 수 있는 것은 아니다. 폴드별 표준편차를 $\sqrt{K}$ 로 나눈 표준오차는 보조 모형 추정의 불확실성을 반영하지 않으므로 실제보다 좁게 나온다.
- 구간이 참값을 놓친 상황에서 보고할 때는 점추정값과 함께 "구간 폭이 과소평가되었을 수 있다"는 사실을 적고, 부트스트랩이나 EconML의 추론 기능처럼 구간을 따로 계산하는 도구를 쓴다.
- 방법을 하나만 돌리고 끝내지 않는다. DML·PSM·OLS를 함께 돌려 값이 크게 갈리면, 갈리는 이유(굽은 관계, 겹침 부족, 변수 누락) 가운데 무엇이 원인인지 확인하기 전에는 어느 값도 결론으로 쓰지 않는다.

1부 정리

- 단순 평균 차이는 처치효과와 선택편향의 합이며, 선택편향은 "처치군이 처치를 받지 않았다면 보였을 결과"와 대조군 결과의 차이다.
- 이 시뮬레이션에서 단순 비교는 3.71, 참값은 3.00, 편향은 0.71(23.6%)이었고, 편향의 원인은 SMD 0.55를 보인 X_1 이었다.
- 세 가지 가정 가운데 데이터로 직접 확인되는 것은 Overlap 하나뿐이며, 나머지 둘은 제도와 배정 규칙 문서로 논증한다.
- 다섯 가지 전통적 방법은 우열이 아니라 자료 조건으로 갈리고, 어느 조건도 만족하지 못하면 효과를 추정하지 않는 선택지가 있다.
- 변수가 많거나 관계가 굽어 있으면 선형 성향점수 모형이 배정 규칙을 잘못 근사한다. 기계학습은 이때 보조 모수 추정의 정확도를 높이지만, Unconfoundedness가 성립하지 않는 자료에서는 어떤 알고리즘을 써도 편향이 남는다.
- DML은 Y와 D 양쪽에서 X의 영향을 뺀 잔차를 비교하고, 보조 모형 학습에 쓴 자료와 잔차 계산에 쓴 자료를 분리한다. 관계를 굽혀 놓은 자료에서 DML의 편향은 3.7%였고 PSM은 34.7%, OLS는 30.4%였다.
- **다음 파트로 넘길 것:** 평균 하나로는 답할 수 없는 질문, 즉 누구에게 처치를 주면 효과가 가장 큰지를 어떤 방법으로 추정하고, 그 추정치를 어떻게 정책 대상 선정으로 옮기는지.

2부 (65분). 개인별 효과를 추정하고 결정으로 옮긴다


이 파트가 끝나면: 메타 학습기와 인과 포레스트로 개인별 처치효과를 추정한 비교표, EconML로 세 추정기를 대조한 결과표, 그리고 개인별 효과 추정치를 정책 대상 선정과 시나리오별 총량 예측으로 옮긴 표가 남는다. **다루는 절:** 2.4.2 ~ 2.6

2.4.2 메타 학습기와 인과 포레스트

왜 필요한가

DML은 평균 하나를 정확히 추정하는 데 강하지만, 2.3.1에서 말한 세 번째 상황에는 답하지 못한다. 예산이 전체 대상의 30%만 감당할 수 있을 때 필요한 것은 **개인별 처치효과**, 즉 특성 x 를 가진 개체의 조건부 평균 처치효과 $\tau(x) = E[Y_1 - Y_0 \mid X = x]$ 다. 이 식은 "특성이 x 인 사람들만 모아 놓고 본 평균 효과"로 읽으며, **조건부 평균 처치효과**(Conditional Average Treatment Effect, CATE)라 부른다. x 자리에 소득 분위를 넣으면 분위별 효과가 되고, 개인의 특성 전체를 넣으면 사람마다 하나씩 나오는 값이 된다.

그림 2-5. 평균 하나와 집단별 효과가 답하는 질문의 차이



왼쪽은 평균 하나만 가지고 있을 때이며, "이 정책을 할지 말지"에는 답하지만 "예산이 절반이면 누구부터"에는 답하지 못한다. 오른쪽은 같은 정책을 소득 분위로 갈라 본 것으로, 최저소득 집단의 28.68점과 최고소득 집단의 19.41점이 평균 24.89점 하나에 묶여 있었다는 사실이 드러난다. 그림의 숫자는 2.5절 기초연금 실습의 참값이며, 개인별 효과를 따로 추정하는 이유가 이 격차에 있다.

무엇을 계산하는가

Wager & Athey(2018)의 **인과 포레스트**(Causal Forest)는 랜덤 포레스트의 분할 규칙을 바꾼다. 일반 회귀 나무는 결과 Y 의 예측 오차가 작아지도록 자료를 가르지만, 인과 나무는 **좌우 자식 노드의 처치효과가 최대한 다르게** 갈라지도록 분할한다. 나아가 분할을 결정하는 데 쓴 표본과 효과를 계산하는 데 쓴 표본을 분리하는 정직한 분할(honest splitting)을 적용해 과적합을 막는다.

Künzel et al.(2019)의 **메타 학습기**(Meta-learners)는 기존 예측 알고리즘을 그대로 쓰되 학습 대상을 바꾸는 네 가지 방식이다. 네 학습기는 새로운 통계 이론을 요구하지 않고, 이미 쓰던 예측 모형을 어디에 몇 개 붙이는지만 다르다.

표 2-B 네 가지 메타 학습기

학습기	계산 방식	강한 상황	약한 상황
S-learner	처치 D를 공변량의 하나로 넣고 모형 하나를 학습한 뒤, D=1일 때와 D=0일 때 예측값의 차이를 쓴다	효과가 결과 변동에 비해 크고 두 집단 크기가 비슷할 때	효과가 작으면 모형이 D를 무시해 효과를 0에 가깝게 낸다
T-learner	처치군 모형과 대조군 모형을 따로 학습하고 두 예측값의 차이를 쓴다	두 집단 표본이 모두 충분할 때	한쪽 집단이 작으면 그쪽 예측 오차가 커진다
X-learner	T-learner로 두 모형을 만든 뒤, 각 개체의 반대편 예측값을 이용해 효과를 채워 넣고 성향점수로 가중평균한다	처치군이 10% 수준으로 작을 때	단계가 많아 구현과 진단이 복잡하다
R-learner	DML처럼 Y와 D의 잔차를 만든 뒤, 잔차 관계에서 $\tau(x)$ 를 학습한다	고차원이고 교란이 복잡할 때	잔차가 작아 신호 대비 잡음이 커지면 성능이 떨어진다

효과가 결과 변동에 비해 작을 때 S-learner가 실패하는 이유를 숫자로 보면 이렇다. 결과 Y의 범위가 0에서 1000이고 처치효과가 5라면, 모형은 Y를 잘 맞히는 데 자원을 쓰느라 D 계수를 0 쪽으로 줄여도 손실이 거의 늘지 않으므로 효과를 놓친다.

코드로 해 보기

```
cf = CausalForestDML(model_y=GradientBoostingRegressor(n_estimators=100),
                     model_t=GradientBoostingRegressor(n_estimators=100),
                     n_estimators=1000, min_samples_leaf=5, random_state=42)
cf.fit(Y_observed, treatment, X=X)
cate_cf = cf.effect(X) # 개체마다 하나씩 나오는 효과 추정치

xl = XLearner(models=[GradientBoostingRegressor(n_estimators=100),
              GradientBoostingRegressor(n_estimators=100)],
              propensity_model=GradientBoostingRegressor(n_estimators=50))
xl.fit(Y_observed, treatment, X=X)
corr_xl = np.corrcoef(xl.effect(X), Y1_true - Y0_true)[0, 1] # 시뮬레이션이라 참값과 비교 가능
```

전체 코드는 [practice/chapter02/code/2-4-causal-ml-comparison.py](#) 참고

결과를 읽는 법

표 2-8 인과 ML 방법론 성능 비교

방법론	평균 CATE	참값과의 상관	RMSE	ATE 편향
Causal Forest	1.59	0.94	1.07	-0.03
X-learner	1.64	0.97	0.69	0.01
R-learner	1.51	0.61	2.29	-0.12
S-learner	1.63	0.95	1.05	0.01
T-learner	1.66	0.98	0.53	0.03
참값 CATE	1.63	1.00	0.00	0.00

표의 각 열이 재는 것은 다르다. 평균 CATE는 개인별 추정치를 전부 평균한 값이라 ATE와 대응되고, 상관은 순위를 얼마나 잘 맞췄는지, RMSE는 개인별 값이 얼마나 어긋났는지를 잴다. 정책 대상 선정에는 순위가 중요하므로 상관이, 개인별 효과 크기를 보고해야 할 때는 RMSE가 판단 근거가 된다.

표 2-9 CATE 분위별 정책 효과

CATE 분위	임계값	평균 CATE	개체 수	주요 특징
상위 10%	≥ 4.50	7.29	200	$X_1 > 1.59$
상위 25%	≥ 3.02	5.08	500	$X_1 > 0.92$
상위 50%	≥ 1.40	3.69	1,000	$X_1 > 0.33$
상위 75%	≥ -0.44	2.61	1,500	평균 수준
상위 90%	≥ -1.46	2.01	1,800	저효과 포함

표 2-10 정책 타겟팅 효율성

타겟팅 전략	수급자 비율	평균 효과	총 효과	효율성 지수
무차별 지급	100%	1.63	3,252	1.00
CATE 상위 50%	50%	3.69	3,692	2.27
CATE 상위 30%	30%	4.72	2,832	2.90
CATE 상위 10%	10%	7.29	1,458	4.48

첫째, 이질성이 실제로 있는지 본다. 개인별 효과 추정치가 -2.45에서 33.82까지 퍼져 있는 반면 평균은 1.63이다. 평균 하나만 보고하면 효과가 음수인 집단과 평균의 스무 배가 넘는 집단이 같은 숫자 뒤에 가려진다.

둘째, 방법 간 결과가 일치하는지 본다. T-learner(0.98), X-learner(0.97), S-learner(0.95), 인과 포레스트(0.94)는 참값과의 상관이 비슷하게 높지만 R-learner는 0.61로 떨어지고 RMSE도 2.29로 크다. 이 자료의 CATE 구조가 지수함수와 주기함수를 섞은 형태여서 잔차 기반 학습이 신호를 잡지 못한 결과다.

판정 기준. 실제 자료에서는 참값 CATE가 없으므로 표 2-8의 상관과 RMSE를 계산할 수 없다. 대신 다음 순서로 판정한다.

- 학습기를 최소 세 개 돌려 개인별 추정치의 순위 상관을 서로 비교한다. 학습기끼리 순위가 크게 어긋나면 이질성 결론을 보고하지 않고, 이질성이 없다는 가정 아래 ATE만 보고한다.
- 학습기끼리 대체로 일치하면, 상위 집단으로 분류된 개체의 관측 특성을 표로 뽑아 실질적으로 해석 가능한지 확인한다. 표 2-9처럼 상위 10%가 특정 변수의 높은 값에 몰려 있으면 해석이 가능하고, 아무 규칙도 보이지 않으면 잡음을 학습했을 가능성이 크다.
- 표 2-10의 효율성 지수는 대상을 좁혔을 때 1인당 평균 효과가 몇 배가 되는지를 나타낸다. 상위 10%로 좁히면 1인당 효과가 1.63에서 7.29로 4.48배가 되지만, 총 효과는 3,252에서 1,458로 줄어든다. 예산이 제약이면 1인당 효과를, 총량 목표가 제약이면 총 효과를 기준으로 고른다.

2.5 EconML 패키지 활용

2.5.1 왜 패키지를 쓰는가

2.4까지는 DML과 메타 학습기를 직접 구현했다. 직접 구현은 원리를 익히는 데 필요하지만 실무에 그대로 쓰기는 어려운데, 표준오차와 신뢰구간을 이론에 맞게 계산하는 부분, 처치가 여러 값을 갖는 경우, 교차 적합의 세부 처리를 모두 손으로 관리해야 하기 때문이다.

Microsoft Research의 **EconML**은 DML, 인과 포레스트, 메타 학습기, 도구변수 확장을 통일된 방식으로 제공하며 scikit-learn 모형을 그대로 끼워 쓸 수 있다. 이 절에서는 세 가지 추정기를 같은 자료에 적용해 결과가 서로 맞는지 확인한다. 그중 **DRLearner**는 성향점수 모형과 결과 회귀 모형 가운데 **하나만 올바르게 설정되어도** 일치추정이 되는 이중 강건(doubly robust) 성질을 갖는다.

2.5.2 무엇을 계산하는가

분석 문제는 기초연금 수급이 65세 이상 노인의 삶의 만족도에 미치는 효과이며, 자료는 가상으로 생성한다. 수급 확률이 소득이 낮을수록 높아지도록 설계했으므로 선택편향이 들어 있고, 참값 효과는 소득이 낮을수록 커지도록 설정했다. 확인할 것은 두 가지다. 세 추정기가 평균 효과에서 서로 비슷한 값을 내는지, 그리고 소득 분위별 효과 차이를 자료에서 찾아내는지도.

2.5.3 코드로 해 보기

```
dml = LinearDML(model_y=GradientBoostingRegressor(n_estimators=100),
                model_t=GradientBoostingRegressor(n_estimators=100),
                discrete_treatment=True, random_state=123)
dml.fit(Y=satisfaction, T=treatment, X=X_df)
ate_dml = dml.effect(X_df).mean()

cf = CausalForestDML(model_y=GradientBoostingRegressor(n_estimators=100),
                     model_t=GradientBoostingRegressor(n_estimators=100),
                     n_estimators=1000, random_state=123)
cf.fit(Y=satisfaction, T=treatment, X=X_df)
cate_cf = cf.effect(X_df)

dr = DRLearner(model_propensity=GradientBoostingRegressor(n_estimators=100),
               model_regression=GradientBoostingRegressor(n_estimators=100),
               random_state=123)
dr.fit(Y=satisfaction, T=treatment, X=X_df)
cate_dr = dr.effect(X_df)
```

전체 코드는 [practice/chapter02/code/2-5-econml-comprehensive.py](#) 참고

2.5.4 결과를 읽는 법

표 2-11 EconML 기초연금 정책 효과 분석 결과

추정 방법	평균 처치효과	참값	편향
LinearDML	24.42	24.89	-0.47
CausalForestDML	24.71	24.89	-0.17
DRLearner	25.25	24.89	+0.37
Naive 차이	26.22	24.89	+1.33
OLS (공변량 조정)	25.20	24.89	+0.32

표 2-12 소득 분위별 처치효과

소득 분위	평균 소득	인과 포레스트 추정 CATE	95% 신뢰구간	참값 CATE
Q1 (최저)	24.9만 원	28.55	[26.41, 30.68]	28.68
Q2	54.3만 원	26.30	[24.34, 28.26]	27.11
Q3	86.5만 원	24.32	[22.28, 26.36]	25.63
Q4	125.1만 원	23.19	[21.34, 25.05]	23.59
Q5 (최고)	214.1만 원	21.21	[18.74, 23.68]	19.41

표 2-13 정책 타겟팅 효율성

타겟팅 전략	수급자 비율	평균 효과	효율성 지수
무차별 지급 (현행)	100%	24.89	1.00
CATE 상위 50%	50%	27.76	1.12
CATE 상위 30%	30%	28.75	1.16
소득 Q1-Q2만	40%	27.90	1.12
소득 Q1만	20%	28.68	1.15

표 2-14 모형 진단

진단 항목	결과	해석
보조 모형 R^2 (결과 회귀)	0.71	결과 변동을 상당 부분 견어냈다
보조 모형 R^2 (성향점수)	0.58	배정이 X로 부분적으로 설명된다
Overlap 위반 비율	2.3%	대부분 개체가 공통지지 영역 안에 있다
소득 변수의 중요도	0.64	이질성의 주된 원천이 소득이다
추정 CATE와 참값의 상관	0.94	순위를 정확히 맞췄다

첫째, 세 추정기가 같은 방향을 가리키는지 본다. LinearDML 24.42, CausalForestDML 24.71, DRLearner 25.25로 세 값의 폭이 0.83이며, 단순 비교 26.22가 세 값보다 모두 크다. 서로 다른 가정에 기대는 추정기가 비슷한 값을 내면 결과가 특정 모형 설정에 좌우되지 않는다는 근거가 된다. 세 값이 크게 갈리면 어느 하나를 고르지 않고, 갈리는 원인을 먼저 찾는다.

둘째, 이질성의 방향이 사전 지식과 맞는지 본다. 표 2-12에서 소득 최하위 Q1의 효과가 28.55이고 최상위 Q5가 21.21로, 소득이 낮을수록 효과가 크다. 소득이 낮은 가구에서 같은 금액의 이전소득이 생활에 미치는 비중이 크다는 사전 지식과 방향이 맞으므로 추정 결과를 받아들일 근거가 된다. 방향이 사전 지식과 반대로 나오면, 결론을 바꾸기 전에 먼저 처치 변수 부호와 표본 정의를 점검한다.

셋째, 신뢰구간이 겹치는지 본다. Q1의 구간 [26.41, 30.68]과 Q5의 구간 [18.74, 23.68]은 겹치지 않으므로, 두 분위 사이 효과 차이를 자료가 뒷받침한다고 판정한다. 인접한 Q3과 Q4의 구간은 겹치므로, 두 분위의 효과가 다르다고 보고하지 않는다.

판정 기준. 표 2-13은 대상을 좁혔을 때의 1인당 효과이며, 여기서 효율성 지수의 이득은 2.4.2의 4.48배와 달리 1.12에서 1.16배에 그친다. 이질성의 폭이 좁으면 타겟팅으로 얻는 이득도 작다는 뜻이므로 다음과 같이 판단한다.

- 효율성 지수 이득이 작으면, 대상 선별에 드는 행정 비용과 자격 심사 오류 비용이 그 이득을 넘을 수 있다. 이때는 선별하지 않고 전면 지급하는 편이 낫다는 결론도 가능하다.
- 표 2-13에서 소득 Q1만 대상으로 하는 안(1.15)과 CATE 상위 30% 안(1.16)의 효율은 거의 같다. 효율이 비슷하면 설명하기 쉽고 집행 가능한 규칙, 즉 소득 기준을 고른다.
- 표 2-14의 Overlap 위반 2.3%는 그 개체에 비교 상대가 없다는 뜻이므로, 해당 개체를 제외한 표본에서 추정값이 크게 달라지는지 확인한 뒤 보고한다.

2.6 인과 ML과 예측 분석의 통합

2.6.1 왜 두 가지를 합치는가

예측 분석은 "다음 해 배출량이 얼마일까"에 답하고, 인과추론은 "탄소세를 매기면 배출량이 얼마나 줄까"에 답한다. 정책을 설계하려면 두 답이 모두 필요하다. 배출량 예측만 있으면 무엇을 해야 할지 알 수 없고, 평균 감축 효과만 있으면 어느 기업에 어떤 강도로 적용할지 정할 수 없기 때문이다.

두 답을 합치는 계산은 단순하다. 개체 x 에 대해 처치하지 않았을 때의 결과 $\hat{Y}_0(x)$ 를 예측 모형으로 구하고, 처치효과 추정치 $\hat{\tau}(x)$ 를 인과 모형으로 구한 뒤 더한다.

$$\hat{Y}_1(x) = \hat{Y}_0(x) + \hat{\tau}(x)$$

적용 대상을 바꿔 가며 이 합을 다시 계산하면 시나리오별 총량이 나오고, 그 총량을 목표치와 비교해 정책안을 고를 수 있다.

2.6.2 코드로 해 보기

```
cf_xgb = CausalForestDML(model_y=xgb.XGBRegressor(n_estimators=200, max_depth=6),
                        model_t=xgb.XGBRegressor(n_estimators=200, max_depth=6),
                        n_estimators=2000, min_samples_leaf=10, random_state=2025)
cf_xgb.fit(emission_train, tax_train, X=X_train)
cate_pred = cf_xgb.effect(X_test) # 기업별 감축 효과

emission_model = xgb.XGBRegressor(n_estimators=300, max_depth=8, random_state=2025)
emission_model.fit(X_train[tax_train == 0], emission_train[tax_train == 0])
emission_no_tax = emission_model.predict(X_test) # 세금 없을 때 배출량 예측

emission_scenario2 = emission_no_tax + cate_pred # 전면 적용
low_eff = X_test[:, 2] < np.median(X_test[:, 2])
emission_scenario3 = emission_no_tax.copy()
emission_scenario3[low_eff] += cate_pred[low_eff] # 효율 하위 50%만 적용
```

전체 코드는 [practice/chapter02/code/2-6-causal-predictive-integration.py](#) 참고

2.6.3 결과를 읽는 법

표 2-15 탄소 배출 감축 정책 인과추론 결과

추정 지표	값	설명
평균 처치효과	-202.15 톤	탄소세로 인한 평균 배출 감축량
참값 ATE	-209.20 톤	실제 평균 감축 효과
추정 오차	+7.05 톤 (3.4%)	감축량을 작게 추정
보조 모형 R ² (배출량)	0.84	결과 회귀 예측 성능
보조 모형 R ² (탄소세)	0.71	성향점수 예측 성능
CATE 범위	-331.6 ~ -98.6 톤	기업 간 3.4배 차이

표 2-16 에너지 효율별 처치효과

효율 분위	평균 효율	추정 CATE	참값 CATE	해석
하위 20%	0.08	-229.84 톤	-237.90 톤	최대 감축
하위 40%	0.17	-216.51 톤	-223.50 톤	큰 감축
중위	0.26	-202.13 톤	-209.75 톤	중간 감축
상위 40%	0.36	-186.86 톤	-196.05 톤	작은 감축
상위 20%	0.53	-175.41 톤	-171.66 톤	최소 감축

표 2-17 정책 시나리오별 배출량 예측

시나리오	평균 배출량	총 배출량	현 상태 대비 감축률	비용 효율성
S1: 현 상태 유지	260.3 톤	234,236 톤	0% (기준)	1.00
S2: 전면 적용	113.3 톤	102,009 톤	-56.5%	1.00
S3: 효율 하위 50%만	205.5 톤	184,993 톤	-21.0%	1.47
S4: 효율 하위 30%만	247.5 톤	222,764 톤	-4.9%	1.72
S5: 대기업 + 하위 50%	173.3 톤	155,946 톤	-33.4%	1.32

표 2-18 이질성 요인의 상대적 기여도

변수	중요도	해석
energy_efficiency	0.62	이질성의 주된 원천
firm_size	0.21	규모별 차이
industry	0.11	업종별 차이
rd_investment	0.05	연구개발 투자 효과
region	0.01	지역 차이 미미

표 2-19 2030년 배출량 예측

연도	S1 (현 상태)	S2 (전면 적용)	S3 (선별 적용)	감축 목표	목표 달성
2025	234,236 톤	102,009 톤	184,993 톤	—	—
2027	242,000 톤	105,500 톤	191,200 톤	330,000 톤	세 안 모두 달성
2030	253,000 톤	110,000 톤	200,000 톤	300,000 톤	세 안 모두 달성

첫째, 추정 오차와 부호를 확인한다. 추정값 -202.15톤과 참값 -209.20톤의 차이는 7.05톤(3.4%)이며 부호가 같다. 감축 정책의 효과는 음수로 나와야 하므로, 부호가 양수로 나오면 처치 변수 정의나 결과 변수 방향이 뒤집힌 것이니 해석 전에 코드를 점검한다.

둘째, 이질성의 방향이 메커니즘과 맞는지 본다. 표 2-16에서 효율 하위 20% 기업의 감축량 229.84톤이 상위 20%의 175.41톤보다 크다. 이미 효율이 높은 기업은 추가로 줄일 여지가 적고, 비효율 기업은 개선 여지가 크기 때문에 나타나는 차이이다. 표 2-18에서 에너지 효율의 기여도가 0.62로 가장 크다는 결과도 같은 방향을 가리킨다.

셋째, 시나리오를 목표와 대조한다. 표 2-17에서 전면 적용은 56.5% 감축하지만 비용 효율성은 기준값 1.00이고, 효율 하위 50%만 적용하면 감축률이 21.0%로 줄어드는 대신 비용 효율성이 1.47배가 된다. 두 지표가 반대로 움직이므로 하나만 보고 고를 수 없다.

판정 기준. 시나리오 선택은 다음 순서로 한다.

- 먼저 감축 목표를 제약으로 놓고 목표를 넘기는 시나리오만 남긴다. 표 2-19에서 2030년 목표 300,000톤을 기준으로 하면 S1, S2, S3가 모두 남는다.
- 남은 안 가운데 비용 효율성이 가장 높은 것을 고른다. S3(1.47)가 S2(1.00)보다 높으므로, 목표만 충족하면 되는 상황에서는 선별 적용이 유리하다.
- 목표가 더 엄격해져 S3가 탈락하면 효율성 지표와 무관하게 S2를 택한다. 효율 지표는 목표를 만족하는 안들 사이에서만 비교 대상이 된다.
- 표 2-19의 2027년과 2030년 수치는 추세를 연장해 얻은 값이므로, 여기에 정책 효과 추정치의 불확실성이 더해진다는 점을 보고서에 적는다.

결과를 어떻게 읽는가

이 장에서 다룬 모든 실습의 출력은 다음 다섯 단계 순서로 읽는다. 순서를 바꾸면 앞 단계에서 걸려야 할 문제를 뒤 단계의 해석으로 덮게 된다.

1. **자료 진단:** 공변량 균형(SMD)과 겹침(성향점수 분포)을 먼저 본다. 여기서 통과하지 못하면 추정값을 읽지 않는다.
2. **추정값 비교:** 최소 세 가지 방법으로 추정하고 값이 모이는지 본다. 값이 갈리면 그 원인을 찾기 전에는 결론을 내지 않는다.
3. **안정성 확인:** 폴드별 값, 보조 모형의 예측 성능, 신뢰구간 폭을 본다. 점추정만으로 보고하지 않는다.
4. **이질성 판단:** 여러 학습기의 개인별 추정치 순위가 서로 맞는지 확인하고, 상위 집단의 특성이 해석 가능한지 본다.
5. **결정 연결:** 대상을 좁혔을 때의 1인당 효과와 총 효과를 함께 계산하고, 제약이 예산인지 총량 목표인지에 따라 기준을 고른다.

실무 적용 점검표

새 과제에 이 장의 방법을 적용할 때 다음을 확인한다.

- 처치와 결과의 정의를 문장으로 적었는가. 처치 시점과 결과 측정 시점이 뒤바뀌지 않았는가.
- 배정 규칙을 제도 문서로 확인하고, 그 규칙에 쓰인 변수가 데이터에 모두 있는지 대조했는가.
- 파급효과가 있을 수 있는 설계인지 검토했는가. 지역 단위 정책이면 인접 지역이 대조군으로 적절한지 따졌는가.
- 공변량 균형표를 만들고 $|SMD| > 0.1$ 인 변수를 남기지 않았는가.
- 공통지지 영역 밖 개체의 비율을 보고했고, 제외 전후로 추정값이 얼마나 달라지는지 확인했는가.
- 최소 세 가지 추정 방법의 결과를 함께 실었는가.
- 신뢰구간을 함께 보고했고, 그 구간이 어떤 방식으로 계산되었는지 적었는가.
- 이질적 효과를 보고할 때, 여러 학습기가 같은 방향을 가리키는지 확인했는가.
- 타겟팅을 제안할 때 선별 비용과 자격 심사 오류를 함께 계산했는가.

핵심 정리

- 관측된 두 집단의 평균 차이는 처치효과와 선택편향의 합이며, 이 장의 시뮬레이션에서 편향은 참값의 23.6%였다.
- 식별에 필요한 세 가정 가운데 데이터로 직접 확인되는 것은 Overlap 하나뿐이고, 나머지는 제도와 배정 규칙을 근거로 논증한다.
- 전통적 다섯 방법은 자료 조건으로 걸리며, 어느 조건도 만족하지 못하면 인과효과를 추정하지 않는 선택지가 있다.
- DML은 Y와 D 양쪽에서 X의 영향을 뺀 잔차를 비교하고, 학습에 쓴 자료와 잔차 계산에 쓴 자료를 분리한다. 이 자료에서 DML의 편향은 3.7%였고 PSM과 OLS는 30%를 넘었다.
- 인과 포레스트와 메타 학습기는 개인별 효과를 추정한다. 상위 10%에 집중하면 1인당 효과는 4.48배가 되지만 총 효과는 절반 이하로 줄어든다.
- 이질성의 폭이 좁으면 타겟팅 이득도 작다. 기초연금 사례에서 효율성 지수 이득은 1.12에서 1.16배에 그쳤다.
- 처치효과 추정치와 예측 모형을 합치면 시나리오별 총량을 계산할 수 있고, 시나리오는 목표 충족 여부를 먼저 걸러낸 뒤 효율로 고른다.

연습 문제

1. 어느 지자체가 청년 창업 지원금 신청자와 미신청자의 3년 생존율을 비교해 지원금 효과를 20% 포인트로 보고했다. 이 숫자를 ATT와 선택편향으로 분해해 설명하고, 선택편향의 부호가 어느 방향일지 근거를 들어 판단하라.
2. 매칭 후 공변량 균형표에서 열 개 변수 중 아홉 개는 $|SMD|$ 가 0.05 아래이고 하나가 0.32로 남았다. 이 상태에서 추정값을 보고해도 되는지 판정하고, 보고하지 않는다면 다음에 무엇을 하겠는지 순서대로 적어라.
3. DML을 돌렸더니 성향 모형의 R^2 가 0.96으로 나왔다. 예측 성능이 높으니 좋은 결과라고 볼 수 있는지 판정하고, 이 값이 2.1의 어느 가정과 관련되는지 연결해 설명하라.
4. 네 가지 메타 학습기를 돌린 결과 개인별 추정치의 순위가 서로 크게 어긋났다. 이때 보고서에 무엇을 쓰고 무엇을 쓰지 않을지 정하고, 그렇게 정한 이유를 적어라.
5. 표 2-10에서 상위 10% 타겟팅은 1인당 효과가 4.48배이지만 총 효과는 3,252에서 1,458로 줄어든다. 감축 총량이 법으로 정해진 정책과, 예산 상한이 정해진 정책에서 각각 어느 전략을 고를지 판단하고 근거를 적어라.

참고문헌

- Abadie, A., & Imbens, G. W. (2006). Large sample properties of matching estimators for average treatment effects. *Econometrica*, 74(1), 235-267.
- Ahrens, A., Hansen, C. B., Schaffer, M. E., & Wiemann, T. (2024). Model averaging and double machine learning. *Journal of Business & Economic Statistics*, 42(2), 628-641.
- Angrist, J. D., & Pischke, J. S. (2009). *Mostly harmless econometrics: An empiricist's companion*. Princeton University Press.
- Athey, S., & Imbens, G. W. (2017). The state of applied econometrics: Causality and policy evaluation. *Journal of Economic Perspectives*, 31(2), 3-32.
- Athey, S., & Imbens, G. W. (2019). Machine learning methods that economists should know about. *Annual Review of Economics*, 11, 685-725.
- Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *The Annals of Statistics*, 47(2), 1148-1178.
- Battocchi, K., Dillon, E., Hei, M., Lewis, G., Oka, P., Oprescu, M., & Syrgkanis, V. (2019). *EconML: A Python package for ML-based heterogeneous treatment effects estimation* [Software documentation]. <https://github.com/microsoft/EconML>

- Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200-230.
- Card, D., & Krueger, A. B. (1994). Minimum wages and employment: A case study of the fast-food industry in New Jersey and Pennsylvania. *American Economic Review*, 84(4), 772-793.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1-C68.
- Chernozhukov, V., Newey, W. K., & Singh, R. (2022). De-biased machine learning of global and local parameters using regularized Riesz representers. *The Econometrics Journal*, 25(3), 571-594.
- de Chaisemartin, C., & D'Haultfœuille, X. (2020). Two-way fixed effects estimators with heterogeneous treatment effects. *American Economic Review*, 110(9), 2964-2996.
- Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254-277.
- Heckman, J. J., Ichimura, H., & Todd, P. E. (1997). Matching as an econometric evaluation estimator: Evidence from evaluating a job training programme. *Review of Economic Studies*, 64(4), 605-654.
- Holland, P. W. (1986). Statistics and causal inference. *Journal of the American Statistical Association*, 81(396), 945-960.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal inference for statistics, social, and biomedical sciences: An introduction*. Cambridge University Press.
- Imbens, G. W., & Wooldridge, J. M. (2009). Recent developments in the econometrics of program evaluation. *Journal of Economic Literature*, 47(1), 5-86.
- Kennedy, E. H. (2023). Semiparametric doubly robust targeted double machine learning: A review [Preprint]. arXiv:2203.06469.
- Künzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the National Academy of Sciences*, 116(10), 4156-4165.
- Lechner, M. (2023). Causal machine learning and its use for public policy. *Swiss Journal of Economics and Statistics*, 159, 8.
- Morgan, S. L., & Winship, C. (2015). *Counterfactuals and causal inference: Methods and principles for social research* (2nd ed.). Cambridge University Press.
- Nie, X., & Wager, S. (2021). Quasi-oracle estimation of heterogeneous treatment effects. *Biometrika*, 108(2), 299-319.

- Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2nd ed.). Cambridge University Press.
- Rambachan, A., & Roth, J. (2023). A more credible approach to parallel trends. *Review of Economic Studies*, 90(5), 2555-2591.
- Robinson, P. M. (1988). Root-N-consistent semiparametric regression. *Econometrica*, 56(4), 931-954.
- Rosenbaum, P. R., & Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1), 41-55.
- Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5), 688-701.
- Sant'Anna, P. H. C., & Zhao, J. (2020). Doubly robust difference-in-differences estimators. *Journal of Econometrics*, 219(1), 101-122.
- Semenova, V., & Chernozhukov, V. (2021). Debiased machine learning of conditional average treatment effects and other causal functions. *The Econometrics Journal*, 24(2), 264-289.
- Sun, L., & Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, 225(2), 175-199.
- Syrkanis, V., Lei, V., Oprescu, M., Hei, M., Battocchi, K., & Lewis, G. (2019). Machine learning estimation of heterogeneous treatment effects with instruments. *Advances in Neural Information Processing Systems (NeurIPS)*, 32.
- Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228-1242.