

3장. 성향점수매칭에서 딥러닝 PSM으로

무작위 배정을 못 하는 상황에서는 처치군과 대조군의 출발선이 다르므로, 처치를 받을 확률(성향점수)이 비슷한 사람끼리 짝지어 비교한다. 이 장에서는 그 확률을 로지스틱 회귀·랜덤 포레스트·그래디언트 부스팅·신경망으로 각각 추정하고, 어느 추정치를 믿어도 되는지 공변량 균형으로 판정하는 절차를 익힌다.

1부. 성향점수를 추정해 매칭하고 균형으로 진단한다

□ 개요

- 이 파트가 끝나면: 로지스틱 회귀로 성향점수를 추정하고 1:1 매칭해 ATT 4.924(95% 신뢰구간 [3.579, 6.268])를 산출한 뒤, 표준화 평균차(SMD)로 보고 가능 여부를 판정
- 다루는 절: 3.1.1 ~ 3.1.6
- 실습 코드: `practice/chapter03/code/3-1-traditional-psm-limitations.py` (그림 생성은 `3-1-figures.py`)

□ 3.1.1 왜 매칭이 필요한가

- 문제 상황: 직업훈련 수료자의 1년 뒤 평균 소득이 비수료자보다 300만 원 높게 관측
 - 300만 원을 훈련 효과로 보고하면 오류. 훈련 지원자는 구직 의지·학력이 높은 쪽으로 쏠려 있어, 훈련이 없었어도 두 집단의 소득 차이는 0이 아님
- 선택편향(selection bias): 처치 여부가 무작위가 아니라 사람의 특성에 따라 정해져, 처치군과 대조군이 처치 이전부터 다른 집단인 상태
 - 관측된 소득 차이 = 훈련 효과 + 원래부터 있던 차이. 데이터만으로는 두 성분을 분리할 수 없음
- 같은 구조의 사례
 - 창업지원금 수혜 → 3년 생존율: 사업 준비도가 높은 팀이 신청서를 더 잘 씀
 - 방과후 프로그램 참여 → 성적: 참여를 결정한 가정의 교육 관심도가 성적에도 영향
 - 멤버십 캠페인 발송 → 구매액: 대상자를 원래 충성도가 높은 고객 위주로 선정


- 신규 매장 근처 거주 → 브랜드 지출액: 매장이 소비력 높은 상권에 입지
- 해결 방향: 처치 이전 특성이 비슷한 사람끼리만 비교
- 차원의 저주(curse of dimensionality): 변수를 높음/낮음 2범주로만 나뉘도 5개면 32칸, 20개면 약 105만 칸. 표본 2,000명이면 거의 모든 칸이 비어 짝이 존재하지 않음
- 실습 데이터: 직업훈련 시뮬레이션 2,000명(처치군 621명, 대조군 1,379명), 공변량 5개(나이·소득·교육년수·경력년수·자산), 참 ATT 6.412를 설정해 생성(3-0-data-gen-misspec.py)
- 참값을 알므로 추정치를 채점할 수 있음. 방법이 실패하는 장면을 확인한 뒤, 참값 없이 실패를 알아차리는 진단(3.1.6)을 학습
- 매칭 전 SMD(콘솔 "1. 매칭 전 공변량 분포 분석"): 나이 0.836, 소득 0.623, 교육년수 -0.368, 경력년수 0.786, 자산 0.687로 다섯 변수 전부 기준 0.1 초과
- 두 집단의 결과를 그냥 빼는 비교는 이 데이터에서 배제

□ 3.1.2 성향점수: 여러 변수를 하나의 숫자로 요약

- 정의(Rosenbaum & Rubin, 1983): $e(X) = P(T=1|X)$. 관측된 특성에서 처치를 받을 확률이며 값은 0~1
- 균형 성질: 성향점수가 같은 층 안에서는 처치 여부와 공변량이 서로 무관 → 성향점수 하나만 맞추면 다섯 변수를 동시에 맞춘 효과
- 정수 예시: 성향점수 0.7인 100명(45세 40명, 35세 60명)이면 처치군 70명의 연령 구성은 28:42 = 40:60, 대조군 30명도 12:18 = 40:60으로 동일
- 이런 성질을 갖는 함수가 균형 점수(balancing score)이며, 성향점수는 그중 가장 압축된 형태
- 신용점수 비유: 여러 입력 변수를 점수 하나로 합산하고 같은 점수를 같은 등급으로 취급하는 구조와 동일
- 비유의 한계: 신용점수 공식은 은행이 정한 정답이 있으나, 성향점수는 정답 공식을 모르는 채 데이터로 추정. 추정이 틀리면 매칭 전체가 무너짐(3.1.6)
- 성립 조건 2가지
- 조건부 독립(unconfoundedness): 결과와 배정 양쪽에 영향을 주는 변수가 모두 X에 포함. 데이터로 검증 불가 — 분석자가 배정 절차(신청 자격·선발 기준·심사 방식)를 문서로 확인해 논증
- 공통지지(common support): 처치군과 대조군의 성향점수 범위가 겹쳐야 함. 겹치지 않는 구간의 사람은 분석에서 제외

□ 3.1.3 1단계 — 성향점수 추정

- 방법: 공변량으로 처치 여부를 예측하는 로지스틱 회귀를 세우고, 예측 확률을 성향점수로 사용
 - 시그모이드 변환: 가중합이 큰 양수면 1 근처, 0이면 0.5, 큰 음수면 0 근처의 확률로 변환
 - 공변량 표준화 필수: 소득(수천만 단위)과 교육년수(한 자리)의 스케일 차이를 보정
- 실행: practice/chapter03/code 폴더에서 python 3-1-traditional-psm-limitations.py
- 분포 3대 점검(콘솔 "3. 공통지지 영역 분석" 블록)
 - 점검 1 분포 겹침: 처치군·대조군 히스토그램이 겹치지 않으면 매칭을 중단하고 분석 대상 재정의
 - 점검 2 극단값(0.05 미만·0.95 초과): 이 데이터에서 7.8%. 5% 초과 시 트리밍(trimming) 검토
 - 점검 3 좁은 구간 뭉침: 처치와 무관한 변수만 쓰는 신호이므로 공변량 재구성



- 그림 3-1 읽는 법: 두 분포가 넓은 구간에서 겹치므로 점검 1 통과. 붉은 음영이 공통지지 밖 구간이며, 점선 0.05 미만 구간의 막대는 전부 대조군으로 극단값 7.8%의 대부분이 여기에 위치

□ 3.1.4 2단계 — 최근접 이웃 매칭과 캘리퍼

- 최근접 이웃 매칭(nearest neighbor matching): 처치군 각자에게 성향점수 차이가 가장 작은 대조군 한 명을 짝으로 지정
- 캘리퍼(caliper) 0.05: 차이가 상한을 넘으면 가장 가까워도 짝 불인정. 억지 짝을 차단하되, 좁힐수록 매칭률 하락

- 복원 매칭: 같은 대조군 한 명이 여러 처치군의 짝으로 재사용 가능 → 짝별 차이값의 비독립(3.1.5 표준오차 단서로 연결)
- 판정 기준(매칭률 = 짝을 찾은 처치군 비율)
 - 95% 이상: 그대로 진행
 - 80~95%: 진행하되 짝을 못 찾은 개체의 특성을 확인해 보고서에 기재
 - 80% 미만: ATT 비보고. 캘리퍼를 넓히거나 분석 대상 재정의
- 이 실습의 결과: 처치군 621명 전원 매칭(표본 손실 0)
- 판정 연습(가상 수치): 매칭률 97% → 진행 / 88% → 조건부 진행(미매칭 특성 보고) / 62% → 중단

□ 3.1.5 3단계 — ATT 계산과 첫 결과

- ATT(처치집단 평균처치효과): 짝마다 (처치군 결과 - 대조군 결과)를 구해 평균
 - 계산 예시: 짝 3쌍의 차이가 5, 7, 3이면 $ATT = (5+7+3)/3 = 5$
 - 95% 신뢰구간 = $ATT \pm 1.96 \times \text{표준오차}$. 1.96은 정규분포에서 값의 95%가 들어오는 구간의 상수
 - 표준오차 단서: 짝 차이를 독립 표본으로 취급한 단순 계산이라 실제 불확실성보다 작게 나올 수 있음(Abadie & Imbens, 2006). 보고용 분석에서는 매칭용 분산 추정법 확인
- 실행 결과: ATT 4.924, 표준오차 0.686, 95% 신뢰구간 [3.579, 6.268], 참 ATT 6.412, 편향 -1.488(-23.2%)
 - 신뢰구간이 0을 제외 → "효과가 0" 가설 기각(콘솔의 $p < 0.05$ 판정과 동일 결론)
 - 신뢰구간이 참값 6.412도 제외 → 점추정과 구간추정 모두 참값 이탈
- Naive 비교(콘솔 "7. 비교: Naive 추정" 블록): 매칭 없이 두 집단 평균을 뺀 값의 편향 비율을 읽어 매칭 편향 -23.2%와 대조(구체 값은 실행해 확인)
- 판정 규칙: ATT 값 하나로는 신뢰 여부를 판정할 수 없음 → 참값 없이 판정하는 도구가 공변량 균형 진단(3.1.6)

□ 3.1.6 매칭 진단 — 공변량 균형

- $SMD = (\text{처치군 평균} - \text{대조군 평균}) \div \text{통합 표준편차}$
 - 통합 표준편차: 처치군 분산과 대조군 분산의 평균에 제곱근을 취한 값
 - 읽기 예시: $(42 - 38) \div 8 = 0.5$ / 연습: 평균 120 대 100, 통합 표준편차 50이면 $(120-100) \div 50 = 0.4$ → 기준 초과로 미달

○ 판정 기준(Austin, 2011): $|SMD| < 0.1$ 균형 달성, 0.1~0.2 경계 구간, 0.2 초과 균형 붕괴


○ 진단 결과 요약(표 3-1)

평가 지표	매칭 전	매칭 후	개선율
평균 SMD	0.660	0.156	-76.4%
최대 SMD	0.836	0.231	-72.4%
SMD < 0.1 달성 공변량 수	0/5	2/5	-
처치군 표본 크기	621	621	0%
공통지지 영역 위반	-	9.9%	-

- 판정은 개선율이 아니라 절대 수준으로: 평균 SMD 0.156은 기준 0.1 초과로 미달

○ 변수별 결과(표 3-2): 나이 0.836→0.231(미달), 소득 0.623→-0.164(미달·부호 반전), 교육년수 -0.368→0.069(달성), 경력년수 0.786→0.224(미달), 자산 0.687→-0.091(달성)

- 소득의 부호 반전(+0.623 → -0.164): 소득 높은 대조군이 과도하게 선택된 과잉 보정 신호



○ 그림 3-2 읽는 법: 주황 빈 점(매칭 전)에서 파란 점(매칭 후)까지의 거리가 개선 폭, 초록 띠($|SMD| < 0.1$) 안의 파란 점만 균형 달성. 교육년수·자산 두 개만 띠 안이며, 소득은 0을 지나 반대쪽으로 이동

○ 미달 시 조치 3가지: ① 매칭 조건 변경(캘리퍼 축소·1:n·정확 매칭) ② 성향점수 모형 교체(이 실습의 선택, 3.2절) ③ 매칭 후 회귀 조정

○ 모형 오설정 진단(표 3-3, 시뮬레이션이라 가능한 진단): 추정 PS와 참 PS의 상관 0.665, $|PS \text{ 차이}| > 0.2$ 비율 40.2%

- 처치 확률이 제공항·상호작용·주기함수를 포함한 곡선인데, 로지스틱 회귀는 가중합의 직선 구조만 표현 → 모델 오설정(model misspecification)
- 공통지지 위반 9.9%(대조군 13.8%): 추정 효과는 겹치는 구간의 사람들에게만 해당. 보고서에 제약 명시
- 결론: 평균 SMD 0.156, 3/5 변수 미달, 참 PS 상관 0.665 — 세 지표가 같은 방향 → ATT 4.924 비보고, 성향점수 추정 방법 교체
- 판정 연습(가상 균형표: 0.08, -0.12, 0.05, 0.19, 0.03)
- 변수별: 3개 달성, 2개 경계 구간(-0.12, 0.19), 0.2 초과 없음
- 요약: 절댓값 평균 0.094(통과), 최대 0.19(기준 0.1 초과)
- 결론: 비보고. 경계 변수 2개를 회귀 조정에 넣거나 매칭 조건을 바꾼 뒤 재진단

□ 1부 정리

- 산출물: 성향점수 배열, 1:1 매칭 결과(캘리퍼 0.05, 손실 0), ATT 4.924(표준오차 0.686), 균형 진단표, 그림 2장(3-1, 3-2)
- 판정 기준
 - 극단 성향점수 비율 5% 초과 시 트리밍 검토
 - 매칭률 80% 미만이면 ATT 비보고
 - 신뢰구간이 0을 제외하면 효과 0 가설 기각
 - SMD는 평균·최대 모두 절댓값 0.1 기준. 개선율이 커도 최종 수준 초과면 미달
 - SMD 0.1~0.2 경계 구간은 다른 변수 상황과 함께 판단
 - 매칭 전후 부호가 뒤집힌 변수는 과잉 보정 신호
- 다음 파트: 균형 미달로 ATT 4.924 비보고 → 로지스틱 회귀가 못 잡은 곡선 구조를 기계학습·딥러닝으로 추정(3.2~3.5)
- 자가 점검(가상 수치): 평균 0.07·최대 0.09·매칭률 96% → 보고 / 평균 0.09·최대 0.24·매칭률 98% → 비보고 후 설계 수정

2부. 기계학습과 딥러닝으로 성향점수를 다시 추정한다

□ 개요

- 이 파트가 끝나면: 랜덤 포레스트·그래디언트 부스팅·LBC-Net으로 성향점수를 다시 추정하고, 균형 패널티의 세기를 정한 뒤, 네 방법의 균형·ATT·계산 비용을 같은 표에 놓고 하나를 선택
- 다루는 절: 3.2 ~ 3.5
- 출발점: 1부에서 로지스틱 회귀의 매칭 후 평균 SMD 0.156(기준 0.1 초과), 추정 PS와 참 PS의 상관 0.665로 ATT 4.924를 비보고 판정 → 성향점수를 만드는 방법 자체를 교체
- 실습 코드: `practice/chapter03/code/3-2-ml-psm.py`, `3-3-deep-psm-pytorch.py`, `3-4-covariate-balance.py`, `3-5-comprehensive-comparison.py` (그림 생성은 `3-5-figures.py`)

□ 3.2 기계학습으로 성향점수 추정하기

- 필요한 이유: 로지스틱 회귀(직선 구조)가 곡선 형태의 처치 배정을 재현하지 못함. 어떤 상호작용·제공향을 넣을지 모르므로, 곡선의 모양을 데이터가 스스로 찾게 하는 방법 필요
- 랜덤 포레스트(Breiman, 2001): 복원 추출 표본으로 만든 수백 개 나무의 예측을 평균
 - 계단 근사 예시: 나무 하나가 "나이 42세 이상인가"로만 쪼개면 두 구간에 0.8/0.3처럼 다른 확률을 주는 두 단짜리 계단. 조건이 늘고 수백 그루를 평균하면 곡선에 근접
- 그래디언트 부스팅(Friedman, 2001): 나무를 순서대로 만들어 앞 나무의 오차를 뒤 나무가 보정
 - 예시: 실제 처치 1에 첫 나무가 0.6을 예측하면 오차 0.4를 두 번째 나무가 학습. 학습률 0.1이면 맞춘 몫의 1/10만 반영해 천천히 축적
- 공통 함정: 처치 배정을 완벽히 예측하면 성향점수 분포가 갈라져 매칭 불가 → 나무 깊이·잎 크기를 보수적으로 제한
- 선택 기준의 전환(McCaffrey et al., 2004): 예측 정확도가 아니라 매칭 후 평균 절대 SMD(ASAM)가 최소가 되는 반복 횟수를 선택
- 데이터: `synthetic_policy_data.csv` (참 ATT 5.0, 1부와 다른 데이터). 로지스틱 행은 `3-1-traditional-psm.py`, RF·GB 행은 `3-2-ml-psm.py` 출력
- 결과 (표 3-4)

방법론	평균 SMD	최대 SMD	균형 달성	ATT	표준오차	매칭률
로지스틱 회귀	0.071	0.163	4/5	5.065	0.212	97.2%
랜덤 포레스트	0.086	0.162	3/5	5.068	0.201	100%
그래디언트 부스팅	0.039	0.081	5/5	4.862	0.204	99.5%

- 판정: 그래디언트 부스팅만 평균·최대 모두 기준 0.1 통과. 로지스틱·RF는 평균은 통과했으나 최대 (0.163, 0.162)가 초과 — 평균만 보고 판단하지 않음
- ATT는 세 방법 모두 참값 5.0 근처(편향 -2.8%~+1.4%) → 이 데이터에서는 방법 선택이 결론을 바꾸지 않음
- 변수 중요도(RF, 표 3-5): 나이 0.354, 경력년수 0.332로 합계 약 69% — 중요도 상위 변수의 균형이 특히 중요하고, 처치 배정 규칙의 사후 역추적에도 사용
- GB 최적화(표 3-6): 반복 100회·학습률 0.01에서 평균 SMD 0.039 최소. 학습률을 키우면 예측은 정확해지나 분포가 양극단으로 벌어져 균형 악화
- 직접 해 보기: 3-2-ml-psm.py 실행(수십 초) 후 콘솔 "최적 하이퍼파라미터"."최소 평균 SMD" 줄을 표 3-6과 대조. 콘솔 마지막 "주요 발견" 세 줄은 계산과 무관한 고정 문장이므로 판정 근거로 쓰지 않음
- 판정 연습(가상 수치): 평균 0.04·최대 0.22 vs 평균 0.06·최대 0.09 → 최대가 0.2를 넘는 앞 방법 탈락, 두 값 모두 기준 안인 뒤 방법 채택

□ 3.3 딥러닝으로 균형을 직접 학습하기 (LBC-Net)

- 필요한 이유: 기존 방법은 예측을 목표로 학습한 뒤 균형을 사후 확인 — 최적화 대상과 판정 대상이 다름. Peng et al.(2024)의 LBC-Net은 균형 자체를 학습 목표에 포함
- 손실 함수 = $BCE + \lambda_{balance} \times \text{국소 균형} + \lambda_{calib} \times \text{국소 보정}$
- BCE: 처치 예측의 기본 손실
- 국소 균형: 성향점수를 10구간으로 나눠 구간마다 처치-대조 공변량 차이를 합산. 전체 평균에서 상쇄되는 구간별 어긋남(+0.3/-0.3)을 잡아냄
- 국소 보정: 구간별 예측 확률 평균과 실제 처치 비율의 차이. 성향점수를 확률로 해석할 수 있게 담보
- 설정: $\lambda_{balance}=1.0$, $\lambda_{calib}=2.0$ (초기 5.0은 성향점수를 좁은 구간에 눌러 보정이 무너져 하향), 은닉층 128-128-64, Adam(학습률 0.0003), 최대 300 에폭·조기 종료(이번 실행 122 에폭)
- 결과 (표 3-8, 데이터는 3.2절과 동일, 참 ATT 5.0)

평가 지표	로지스틱	RF	GB	LBC-Net
평균 SMD	0.071	0.086	0.039	0.078
최대 SMD	0.163	0.162	0.081	0.134
균형 달성	80%	60%	100%	60%
ATT	5.065	5.068	4.862	4.895
95% CI	[4.650, 5.480]	[4.673, 5.462]	[4.461, 5.262]	[4.475, 5.316]
매칭률	97.2%	100.0%	99.5%	100.0%

○ 읽는 순서: 균형 → 정확도 → 신뢰구간

- 균형: LBC-Net 평균 0.078은 통과이나 나이(-0.114)·경력년수(-0.134)가 경계 구간 → 달성 3/5. 이 데이터의 균형 1위는 GB(5/5)
- 정확도: 네 방법 ATT 4.862~5.068(편향 -2.8%~+1.4%)로 근접 — 온건한 비선형에서는 방법 선택의 영향 작음
- 신뢰구간: LBC-Net [4.475, 5.316]과 GB [4.461, 5.262] 모두 참값 5.0 포함. 균형 달성률이 낮아도 구간이 참값을 담을 수 있음 — 균형 지표와 정확도가 항상 같은 방향은 아님
- 민감도 분석: 방법별 값을 나란히 보고. 범위가 좁으면 결론이 방법 선택에 강건하다는 근거, 넓으면 그 사실을 보고서에 기재
- 계산 비용(3.5절 측정, 환경 의존): 로지스틱 0.01초, GB 1.3초, LBC-Net 27.3초 + 조정할 하이퍼파라미터 다수
- 직접 해 보기: 3-3-deep-psm-pytorch.py 실행(1분 안팎) 후 콘솔 "구간별 보정" 블록 확인 — 이번 실행 최대 차이는 [0.4, 0.5) 구간의 -0.143이며, 세 번째 손실 항이 줄이려는 값
- 유의: 원 논문은 arXiv preprint(2404.04794)로 동료 심사 전 — 단독 근거로 쓰지 않고 검증된 방법과 병행

□ 3.4 균형 패널티의 세기를 정하기

- 문제: 손실 = 예측 손실 + $\lambda \times$ 균형 손실에서 λ 를 얼마로 둘 것인가. 0이면 예측만 최적화, 과대하면 예측 정보를 버림
- 균형 손실: 역확률 가중(IPW) 후 SMD — 대조군에 $ps/(1-ps)$ 를 곱해 처치군을 닮은 대조군에 큰 비중
- 예시: 성향점수 0.75인 대조군의 가중치는 $0.75/0.25 = 3$ (세 명처럼 셈), 0.2이면 0.25명으로 낮춰 셈


○ 선행 연구: Imai & Ratkovic(2014)의 CBPS — 예측 조건과 균형 조건을 동시에 만족. 여기서는 신경망에서 λ 로 비중을 명시적으로 조절

○ 결과 (표 3-10, λ 격자 6개, 참 ATT 5.0)

λ	BCE 손실	가중 SMD	매칭 후 SMD	ATT	편향
0.0	0.502	0.022	0.101	3.822	-1.178
0.1	0.538	0.017	0.059	4.676	-0.324
0.3	0.549	0.025	0.060	4.528	-0.472
0.5	0.569	0.022	0.061	4.658	-0.342
0.7	0.578	0.014	0.078	4.599	-0.401
1.0	0.558	0.021	0.045	4.684	-0.316

– $\lambda=0$: 매칭 후 SMD 0.101(기준 경계), 편향 -1.178로 최대 / $\lambda \geq 0.1$: SMD 0.045~0.078, 편향 -0.32~-0.47 — 예측(BCE 0.502→0.578)을 조금 포기하고 균형·정확도를 얻는 교환

– 가중 SMD 최소는 $\lambda=0.7$, 편향 최소는 $\lambda=1.0$ 으로 두 기준이 불일치. $\lambda=0.3$ (0.025)이 $\lambda=0.1$ (0.017)보다 나쁜 것처럼 단조롭지도 않음



○ 그림 3-3 읽는 법: 왼쪽 패널에서 BCE가 λ 와 함께 상승, 오른쪽 패널에서 매칭 후 SMD(파란 사각)가 $\lambda=0$ 의 0.101에서 $\lambda>0$ 의 0.045~0.078로 내려와 기준선 0.1 아래 진입

○ 판정 규칙

– $\lambda=0$ 에서 이미 매칭 후 SMD가 0.1을 크게 밑돌면 패널티 불필요

– λ 를 키워도 SMD가 줄지 않으면 데이터 문제(공통지지 부족·공변량 누락)를 먼저 점검


- 격자를 좁게 훑고, ATT가 λ 에 흔들리지 않는 구간(여기서는 $\lambda=0.1\sim1.0$ 에서 4.53~4.68)을 확인한 뒤 최종 선택

□ 3.5 네 방법 종합 비교 — 강한 비선형 교란 상황

- 설계: nonlinear_confounded_data.csv — 3,000명, 공변량 7개(잠재 교란 Z1·Z2 포함), 처치군 1,022명(34.1%), 참 ATT 6.000. 로그오즈에 제곱항·가우시안 범프·상호작용·주기함수를 넣어 직선 모형이 실패하도록 설계. 로지스틱 PS와 참 PS의 상관 0.4338(1부 데이터 0.665보다 낮음). 캘리퍼 0.01로 1:1 매칭
- 결과 (표 3-11, 학습 시간은 이 컴퓨터 기준)

평가 지표	진정한 값	로지스틱	RF	GB	LBC-Net
평균 SMD	0.000	0.066	0.075	0.182	0.164
최대 SMD	0.000	0.094	0.132	0.364	0.278
ATT	6.00	11.063	5.705	4.737	8.623
편향율	0%	+84.4%	-4.9%	-21.1%	+43.7%
95% CI	-	[10.61, 11.52]	[5.48, 5.93]	[4.48, 4.99]	[8.26, 8.99]
학습 시간	-	0.01초	0.8초	1.3초	27.3초

- 핵심 발견 1 — 균형과 편향의 정반대 신호: 로지스틱은 평균 0.066·최대 0.094로 균형 판정 1위이지만 ATT 11.063(+84.4%)으로 편향 최대. 잘못된 성향점수로 지은 짝이 관측 공변량 평균만 우연히 맞춘 사례 — 균형은 필요조건이지 충분조건이 아님
- 핵심 발견 2 — 어느 방법의 신뢰구간도 참값 6.0을 포함하지 못함. 최소 편향은 RF(-4.9%)이나 CI 상한 5.93이 참값에 0.07 미달. 단순 표준오차(1부 3.1.5 단서)가 구간을 실제보다 좁게 만든 요인도 겹침
- 핵심 발견 3 — 우열의 반전: 3.2절 데이터에서 균형 1위였던 GB가 여기서는 최대 SMD 0.364로 최악, CI가 참값을 담았던 LBC-Net이 +43.7% 편향. 한 데이터에서 좋았던 방법·설정을 다른 과제에 그대로 옮기지 않음



○ 그림 3-4 읽는 법: 왼쪽 패널에서 어느 방법의 신뢰구간도 참값 6.0 수평선에 닿지 않음(로지스틱·LBC-Net은 위로, RF·GB는 아래로 이탈). 오른쪽 패널에서 균형 통과(SMD < 0.1)는 로지스틱·RF뿐 — 균형 통과 여부와 편향 크기는 서로 다른 정보

○ 성향점수 모형 타당성 확인법(참값을 모르는 현실 데이터에서)

- 서로 다른 모형의 성향점수끼리 상관 확인 — 0.6 미만이면 최소 하나는 구조를 잘못 잡은 신호
- 모형별 ATT를 나란히 배치 — 11.063과 4.737이 함께 나오면 어느 하나를 골라 보고할 수 없음
- 공변량-처치 관계 산점도에서 곡선 패턴 확인 — 곡선이 보이면 직선 모형 제외

○ 직접 해 보기: 3-5-comprehensive-comparison.py 실행(약 30초, PyTorch 포함) 후 콘솔 "최소 편향 방법"."매칭 후 평균 SMD가 0.1 미만인 방법" 두 줄을 표 3-11과 대조 — 균형 통과 목록에 든 로지스틱의 편향이 가장 크다는 어긋남을 직접 확인

○ 실무 권장 (표 3-12)

상황	권장 방법	이유
비선형 교란 의심 시	랜덤 포레스트	이 실험에서 편향 -4.9%로 최소
빠른 탐색적 분석	랜덤 포레스트	학습 0.8초, 기본 설정으로 안정적
선형 관계 확신 시	로지스틱 회귀	0.01초, 계수 해석 가능
하이퍼파라미터 튜닝 불가 시	랜덤 포레스트	기본 설정 성능이 가장 안정적
딥러닝(LBC-Net) 사용 시	튜닝·보정 진단 동반 필수	설정을 그대로 옮기면 +43.7% 편향 가능
민감도 분석	로지스틱 + RF + GB 병행	값의 범위로 강건성 확인

□ 결과를 어떻게 읽는가 (읽기 순서 5단계)

- 1순위 — 공통지지·매칭률: 위반 10% 초과 또는 매칭률 80% 미만이면 뒤의 숫자를 읽지 않고 설계 수정
- 2순위 — 공변량 균형: 평균·최대 SMD를 0.1과 대조, 변수별 표에서 걸린 변수 확인. 중요도 상위 변수가 걸리면 특히 문제
- 3순위 — 성향점수 모형 타당성: 모형 간 상관·ATT 불일치 확인. 3.5절 로지스틱은 이 단계에서 걸려야 하는 사례
- 4순위 — ATT·신뢰구간: 앞 세 단계 통과 후에야 효과 크기를 읽음. 0 포함 여부로 유의성, 구간 폭으로 정밀도 판단
- 5순위 — 민감도: 방법을 바꿔도 값이 비슷한지 확인. 두세 방법의 값을 나란히 보고

□ 실무 적용 점검표

- 처치 배정이 관측 변수로 설명되는가 — 담당자 재량 기준이 데이터에 없으면 PSM으로 해결 불가
- 처치 이후 측정 변수를 공변량에 넣지 않았는가 — 처치의 결과를 통제하면 효과 일부를 지움
- 성향점수 분포가 겹치는가 — 좁으면 분석 대상을 좁혀 정의하고 적용 범위 명시
- 표본이 충분한가 — 매칭 쌍이 수십 개면 신뢰구간이 지나치게 넓어짐
- 균형 판정(평균·최대 SMD 0.1)을 통과했는가 — 미달이면 매칭 조건 또는 모형 교체
- 모형을 바꿔 가며 값을 확인했는가 — 최소 두 방법의 ATT 대조
- 결론의 적용 범위(ATT는 처치받은 집단, 공통지지 안)를 적었는가
- 관측되지 않은 교란의 가능성을 한계로 명시했는가

□ 핵심 정리

- 방법 요약

방법	방식	강점	유의점
로지스틱 회귀	가중합을 확률로 변환	0.01초, 계수 해석	곡선 구조 표현 불가
랜덤 포레스트	수백 개 나무의 평균	곡선 자동 학습, 3.5절 편향 최소화	균형 최적화는 간접적
그래디언트 부스팅	오차를 순차 보정	ASAM 기준 반복 조절	하이퍼파라미터에 민감
LBC-Net	구간별 균형·보정을 손실에 포함	균형을 학습 목표로 최적화	27초, 설정 민감(+43.7% 편향 사례)

○ 판정 규칙 3가지

- SMD 0.1 기준은 평균과 최대 모두 적용 — 평균 통과·최대 0.2 초과면 미달
- 균형은 필요조건이지 충분조건이 아님 — 3.5절 로지스틱은 균형 통과 후 +84.4% 과대추정
- 한 데이터의 우열을 다른 데이터로 옮기지 않음 — GB는 3.2절 균형 1위·3.5절 최악, LBC-Net은 3.2절 CI 참값 포함·3.5절 +43.7% 편향