

4장. 이중차분법(DID)과 합성통제법(SCM)

□ 이 장의 질문

- 서울에만 광고를 내보내고 전후 매출을 비교했더니 매출이 늘었다. 그러면 "늘어난 만큼이 광고 효과"라고 보고해도 될까?
- 이 장의 답은 "안 된다"이다. 전후 차이에는 광고와 무관한 시간의 흐름이 섞여 있기 때문이다. 그 흐름을 빼는 방법(이중차분), 비교할 지역이 하나뿐일 때 대조군을 만들어 쓰는 방법(합성통제), 그리고 그렇게 얻은 숫자를 언제 믿어도 되는지 판정하는 검사들을 차례로 배운다

□ 이 장을 읽는 방법

- 이 장은 두 파트로 나뉜다
 - 1부(4.1~4.2): 전후 비교의 문제에서 출발해, 두 번의 뺄셈으로 효과를 재는 이중차분법을 실행하고, 그 결과를 믿어도 되는지 사전 추세 검사로 판정한다. 공변량이 많을 때 쓰는 확장(DML)까지 다룬다
 - 2부(4.3~4.7): 처치받은 지역이 하나뿐이어서 대조군을 고를 수 없을 때, 여러 후보 지역을 섞어 대조군을 만들어 쓰는 합성통제법과 그 검증 절차를 다룬다
- 이 장의 실습은 서로 다른 데이터를 쓴다. 4.1은 45개 도시·24개 시점의 패널(참 효과 2.35), 4.2는 공변량 5개짜리 별도 데이터(참 효과 4.01), 4.3 이후는 처치 도시 1곳과 후보 20곳의 데이터(참 효과 -3.47 또는 -3.50)다. 절이 바뀌면 추정값의 크기와 부호가 달라지는데, 이는 오류가 아니라 데이터가 다르기 때문이다
- 실습 코드는 `practice/chapter04/code/` 에 있다. 스크립트를 실행하면 콘솔 출력 전체가 `practice/chapter04/results/<스크립트명>.log` 로 저장되고, 그림도 `results` 폴더에 저장된다. 본문의 실행 결과 발췌는 모두 이 코드가 실제로 계산한 값이다
- 용어 미리보기 — 본문에서 처음 나올 때마다 다시 풀어 설명하므로, 여기서는 눈에 익히기만 하면 된다

용어	쉬운 뜻
이중차분법(DID)	처치군의 전후 변화에서 대조군의 전후 변화를 한 번 더 빼는 방법
평행추세	정책이 없었더라면 두 집단의 결과가 같은 폭으로 움직였을 것이라는 가정
고정효과	개체마다(또는 시점마다) 하나씩 붙여, 그 개체(시점)의 고유한 수준을 흡수하는 상수
클러스터 표준오차	같은 개체의 관측들이 서로 얽혀 있음을 감안해, 개체 단위로 묶어 계산한 오차
사전 추세 검정	정책 전 구간에서 두 집단의 간격이 일정했는지 확인하는 검사
합성통제법(SCM)	여러 후보 지역의 가중평균으로 처치 지역과 닮은 가상 대조군을 만드는 방법
donor pool	가상 대조군을 만들 때 섞는 후보 지역의 목록
가중치	각 후보 지역을 섞는 비율. 합이 1이고 음수는 없다
RMSPE(사전 적합도)	정책 전 구간에서 합성 대조군이 실제 지역과 어긋난 평균 크기
HHI(가중치 집중도)	가중치가 소수 지역에 쏠렸는지 재는 값. 한 지역이 독차지하면 1
플라시보 검정	아무 일 없던 지역을 처치받은 척 세워 같은 계산을 해 보는 검사
SDID	이중차분의 뼈대에 합성통제의 가중치를 얹어, 두 가정 중 하나만 맞아도 버티는 방법

1부. 두 번의 뺄셈으로 시간의 흐름을 걷어낸다

□ 1부 개요

- 이 파트가 끝나면: 이원 고정효과 회귀로 처치효과 추정값 2.45를 얻고, 이 값을 보고해도 되는지 사전 추세 검정의 네 기준으로 판정하며, 공변량이 많을 때의 확장(DML)까지 실행할 수 있다
- 다루는 절: 4.1.1 ~ 4.2

□ 4.1.1 전후 비교만으로는 왜 안 되는가


- 서울에만 광고를 내보내고 광고 전후 매출을 비교했더니 매출이 늘었다고 하자. 이 증가분을 광고 효과라고 부를 수는 없다
 - 같은 기간에 명절이 끼어 있었거나 경기가 회복 국면이었다면, 광고가 없었어도 매출은 늘었을 것이다. 전후 차이 안에는 **광고 효과**와 **광고와 무관한 시간 흐름**이 함께 들어 있다
- 해결 장치가 대조군이다. 광고를 하지 않은 부산도 같은 명절과 같은 경기 국면을 겪었으므로, 부산의 전후 변화를 "광고가 없었을 때 일어났을 변화"의 대역으로 쓴다
- 예시 숫자로 네 칸을 채워 보면 계산 구조가 보인다 (표 4-1의 숫자는 설명용 예시다)

<표 4-1: 이중차분의 네 칸 구조 (예시 숫자)>

집단	정책 전	정책 후	전후 차이(1차 뺄셈)
서울(처치군)	100	112	+12
부산(대조군)	80	88	+8
집단 간 차이(2차 뺄셈)	—	—	+4

- 서울만 보면 +12지만, 광고가 없었어도 +8은 일어났을 변화이므로 광고 몫은 $12 - 8 = +4$ 다
- 이렇게 두 번 빼서 효과를 재는 방법이 **이중차분법(Difference-in-Differences, DID)** 이다.
처치군의 전후 변화에서 대조군의 전후 변화를 한 번 더 빼다

그림 4-2. 두 번 빼서 처치효과를 얻는 구조



- ① 각 집단 안에서 시간에 따른 변화를 먼저 뺀다 (변하지 않는 집단 특성이 사라진다)
- ② 두 변화의 차이를 다시 뺀다 (두 집단에 공통으로 온 변화가 사라진다)

남는 값 2.452가 처치효과 추정치다 (실습 1 데이터의 실측 평균)

○ 그림 4-2 읽는 법

- 위 줄이 처치군, 아래 줄이 대조군이다. 각 줄에서 먼저 전후 차이를 구하고(① +3.915, ② +1.462), 두 차이를 다시 빼면 $3.915 - 1.462 = 2.452$ 가 남는다. 이 숫자는 4.1.3 실습 데이터에서 실제로 계산한 집단 평균이며, 네 칸만으로 뺀 값 2.452가 뒤에서 회귀로 얻는 2.45와 사실상 같다는 점을 미리 확인해 둔다

한 줄 정리: 전후 차이에는 시간의 흐름이 섞여 있다. 대조군의 전후 차이를 한 번 더 빼서 그 흐름을 걷어낸다.

□ 4.1.2 두 번의 뺄셈이 무엇을 지우고, 무엇이 남는가

- 첫 번째 뺄셈(같은 집단의 전후 차이)은 시간이 지나도 변하지 않는 집단 특성을 지운다

- 서울의 매출 수준이 원래 부산보다 높다는 사실은 정책 전에도 후에도 똑같이 작용하므로, 전후 차이를 구하는 순간 사라진다
- 두 번째 뺄셈(두 집단의 변화량 차이)은 모든 집단에 공통으로 작용한 시간 요인을 지운다
 - 명절 특수나 전국적 경기 변동은 서울과 부산을 같은 방향으로 밀었으므로, 변화량의 차이에는 남지 않는다
- 문제는 무엇이 남느냐다. 두 번을 빼도 지워지지 않는 것은 **처치군에만 작용한 시간 요인**이다
 - 서울에서만 같은 시기에 지하철 노선이 개통되었다면, 그 효과는 광고 효과와 함께 +4 안에 들어가며 데이터만 보고는 둘을 나눌 수 없다
 - 그래서 이 방법은 "정책이 없었더라면 두 집단의 결과가 같은 쪽으로 움직였을 것"이라는 가정에 기댄다. 이것이 **평행추세(parallel trends) 가정**이다
- 구조는 에스컬레이터에 나란히 탄 두 사람과 같다
 - 에스컬레이터가 올려 주는 높이가 공통 시간 추세에, 한 사람만 그 위에서 걸어 올라간 거리가 처치효과에, 두 사람의 출발 높이 차이가 1차 뺄셈이 지우는 집단 특성에 대응한다. 이 대응은 두 사람이 같은 속도의 에스컬레이터에 탔을 때까지만 성립하며, 한 사람이 더 빠른 에스컬레이터에 타고 있었다면 걷지 않아도 높이 차이가 벌어진다 — 이것이 평행추세 위배다

한 줄 정리: 두 번의 뺄셈은 "원래 수준 차이"와 "공통 시간 흐름"을 지운다. 처치군에만 온 변화는 못 지우며, 그것이 없다는 가정이 평행추세다.

□ 4.1.3 도시가 45개면 회귀로 뺀다 — 이원 고정효과 모형

- 집단이 둘, 시점이 둘이면 네 칸을 손으로 빼면 되지만, 45개 도시를 24개 시점에서 관찰한 자료에서는 그렇게 할 수 없다. 이때 쓰는 표준 도구가 **이원 고정효과 모형(TWFE)** 이다
 - 구조는 뺄셈의 회귀판이다. 도시마다 상수 하나(그 도시의 고유 수준), 시점마다 상수 하나(그 시점의 공통 충격)를 붙이고, "처치군이면서 정책 이후인 칸"에만 1이 되는 표시 변수를 넣는다
 - 도시별 상수가 1차 뺄셈의 일을, 시점별 상수가 2차 뺄셈의 일을 회귀 안에서 대신한다. 표시 변수에 붙는 계수가 처치효과이며, 집단 둘·시점 둘인 특수한 경우에는 네 칸 계산과 정확히 같은 값이 나온다
- 같은 도시를 여러 시점에서 관찰하면 오차가 시점 간에 서로 얹힌다. 그래서 표준오차는 도시 단위로 묶어 계산하는 **클러스터 강건 표준오차**를 쓴다(Bertrand, Duflo & Mullainathan, 2004)
- 실습 데이터: 45개 도시 × 24개 시점 = 1,080개 관측치, 처치는 t=20부터, 참 효과는 2.35로 심어 두었다
- 실습 코드(핵심 부분, 전체는 `4-1-traditional-did.py`)

```
# 이원 고정효과 DID: 도시 더미 + 시점 더미 + 처치 표시 변수
model = smf.ols('outcome ~ C(entity) + C(time) + treat_post', data=df).fit()
did_effect = model.params['treat_post']

# 도시 단위 클러스터 강건 표준오차
cov_entity = cov_cluster(model, df['entity'])
```

○ 실행 결과(results/4-1-traditional-did.log 발췌)

```
처치효과 (δ):      2.45
표준오차:          0.25
95% 신뢰구간:      [1.97, 2.93]

R² (전체):         0.84
R² (within):       0.09
관측치 수:         1080
```

- 해석: 신뢰구간 [1.97, 2.93]이 0을 벗어나므로 "효과가 없다"고 보기 어렵고, 참값 2.35를 구간이 담고 있다. 추정값 2.45는 참값에서 0.10 떨어져 있다
- 전체 R^2 0.84와 within R^2 0.09가 크게 다른 것은 오류가 아니다. 0.84의 대부분은 "도시마다 수준이 다르다"는 사실을 도시 상수가 흡수한 몫이고, 상수들을 걷어낸 뒤 처치가 설명하는 몫은 9%. DID에서는 전체 R^2 가 높다는 것이 정보가 되지 못하므로 within R^2 를 본다


○ 직접 해 보기: practice/chapter04/code 폴더에서 `python 4-1-traditional-did.py` 실행 → 콘솔의 "이원 고정효과 DID 추정 결과"에서 위 값을 확인한다

한 줄 정리: 도시별 상수와 시점별 상수가 두 번의 뺄셈을 대신하고, 처치 표시 변수의 계수가 효과다.

□ 4.1.4 평행추세를 검사한다 — 사전 추세 검정

- 평행추세는 "정책이 없었더라면"이라는 관측되지 않은 상황에 관한 진술이므로 직접 검증할 수 없다. 대신 **정책 이전** 구간을 본다
- 정책 전에는 아직 처치가 없었으므로 두 집단의 간격이 시점마다 일정해야 한다. 일정하지 않았다면, 정책 후에도 두 집단이 다른 속도로 움직였으리라 의심할 근거가 된다

그림 4-1. 평행추세 가정과 반사실



○ 그림 4-1 읽는 법

- 정책 전에는 빨간 선(처치군)과 파란 선(대조군)의 간격이 3.0으로 일정하다. 회색 점선은 "정책이 없었을 때의 처치군" — 관측 불가능한 가상의 선 — 이며 간격 3.0이 유지된다고 가정하고 그린 것이고, 정책 후 빨간 선과 이 점선의 세로 거리가 DID가 재는 처치효과다. 점선의 기울기가 실제와 달랐다면 이 거리는 효과가 아니라 가정의 오차를 낸다

○ 검사 절차: 정책 직전 시점($t-1$)을 기준 0으로 놓고, 그 앞의 각 시점마다 "그 시점에 두 집단의 간격이 기준보다 얼마나 벌어져 있었나"를 재는 계수를 회귀로 얻는다. 이것이 **사전 추세 검정(pre-trend test)** 이다

○ 계수를 눈대중으로 판정하지 않는다. 네 기준을 순서대로 대입한다

<표 4-2: 사전 추세 판정 기준과 위반 시 조치>

번호	기준	통과 조건	위반 시 조치
1	개별 유의성	사전 계수 각각의 p값이 0.05보다 크다	유의한 시점이 정책 직전에 몰려 있으면 예고 효과를 의심하고 그 구간을 사전 기간에서 뺀다
2	결합 유의성	계수 전체를 묶은 Joint F검정의 p값이 0.10보다 크다	DID 추정치를 단독 결과로 보고하지 않는다
3	크기	사전 계수의 절댓값이 처치효과 추정값의 절반 미만이다	이벤트 스터디 그래프(시점별 계수 그림)를 함께 싣는다
4	패턴	계수의 부호가 한 방향으로 계속 커지거나 작아지지 않는다	DID를 보고하지 않고 추세 조정 DID나 합성통제로 옮긴다

- 기준 3의 근거: 사전 계수는 원래 0이어야 하는 값이므로 그 크기가 곧 잡음의 규모다. 잡음이 효과의 절반에 이르면, 사후에 본 차이의 어디까지가 효과인지 갈라내기 어렵다
- 기준 4를 따로 두는 이유: 계수가 하나하나는 비유의해도 부호가 한 방향으로 계속 커지면 두 집단이 애초에 벌어지는 중이었다는 신호인데, 결합 검정은 이런 완만한 추세를 놓치는 경우가 있다

○ 실행 결과(results/4-1-traditional-did.log 발췌)

동태적 DID 계수 (t-5 to t-1):

```
t-5:  -0.25  (p=0.597)
t-4:  -1.17  (p=0.015)
t-3:  -0.21  (p=0.660)
t-2:  -0.07  (p=0.888)
t-1:   0.08  (p=0.874)
```

Joint F-test 통계량: 1.26

p-value: 0.28

- 해석: 네 기준에 실제로 대입해 본다. 기준 1 — t-4의 p값 0.015가 0.05보다 작아 한 시점이 걸린다. 다만 유의한 시점이 정책 직전(t-1 근처)이 아니라 t-4 하나이므로 예고 효과의 전형은 아니다. 기준 2 — Joint F의 p값 0.28은 0.10보다 커서 통과다. 기준 3 — 가장 큰 절댓값 1.17은 추정값 2.45의 약 48%로, 경계선 50% 바로 아래다. 기준 4 — 부호가 음·양으로 섞여 있고 시점이 정책에 가까울수록 0에 다가가므로 단조 추세가 아니다
 - 종합 판정: 기준 1에서 한 시점, 기준 3에서 경계선. **추정치 2.45를 보고하되, 다섯 시점의 계수를 이벤트 스터디 그래프로 함께 싣고 t-4의 예외를 본문에 적는다가** 이 결과의 조치다
 - 유의할 점: Joint F 통과는 "평행추세가 성립한다는 증거"가 아니라 "위배를 잡아내지 못했다"는 사실이다. 표본이 작아 검정력이 낮으면 실제 위배가 있어도 p값이 크게 나온다
- 판정 연습(가상의 수치다): 사전 계수가 시점 순서대로 -0.10, -0.25, -0.44, -0.61, -0.80이고 개별 p값과 Joint F가 모두 비유의하다면?
- 기준 1:2는 통과지만 부호가 한 방향으로 계속 커지므로 기준 4 위반이다. DID를 보고하지 않고 추세 조정이나 합성통제로 옮긴다. 검정 통과가 판정의 전부가 아니라는 예다

한 줄 정리: 정책 전 간격이 일정했는지 네 기준으로 판정한다. p값 하나가 아니라 개별·결합·크기·패턴을 모두 본다.

□ 4.1.5 표준오차는 묶는 방식에 따라 흔들린다

- 추정값이 같아도 표준오차는 클러스터를 무엇으로 묶느냐에 따라 달라진다. 세 방식을 모두 계산해 비교한다
- 실행 결과(results/4-1-traditional-did.log 발췌)

개체 수준 클러스터링: SE = 0.21 (기준)
시간 수준 클러스터링: SE = 0.15 (31% 감소)
이원 클러스터링: SE = 0.26 (22% 증가)

- 해석: 추정값 2.45는 그대로인데 표준오차는 0.15에서 0.26까지 1.7배 차이가 난다. 판정 규칙 — 가장 큰 표준오차 0.26을 대입해도 결론이 유지되면 원래 추정을 보고하고, 가장 큰 값에서 유의성이 사라지면 그 보수적인 값을 본문에 싣는다. 여기서는 $2.45 \div 0.26 = 9.4$ 로 결론이 유지된다

한 줄 정리: 표준오차는 세 방식 중 가장 큰 값으로도 결론이 버티는지 확인한 뒤 보고한다.

□ 4.2 처치 시점이 엇갈리거나 공변량이 많을 때

- 첫 번째 확장 상황: 정책이 전국 한 날짜에 시행되는 경우는 드물고, 지자체마다 도입 시점이 다른 **시차 도입(staggered adoption)** 이 흔하다
 - 이때도 처치 표시 변수 하나로 TWFE를 돌릴 수는 있는데, Goodman-Bacon(2021)이 그 계수가 자료 안 모든 2×2 비교의 가중평균임을 보였다. 그 비교에는 **이미 처치받은 집단을 나중 집단의 대조군으로 쓰는 조합**이 들어가며, 효과가 시간에 따라 변하면 일부 비교에 음수 가중치가 붙어 모든 도시의 효과가 양수여도 전체 계수가 0이나 음수로 나올 수 있다
 - 판정 규칙: **처치 시점이 두 종류 이상이면 단일 계수 TWFE를 최종 결과로 보고하지 않고**, 처치 시점이 같은 집단별로 따로 추정해 합치는 방법(Callaway & Sant'Anna, 2021)을 함께 제시한다
- 두 번째 확장 상황: 통제할 공변량이 많고 관계가 곡선일 때. 공변량이 50개면 두 변수 조합만 1,225개라 연구자가 필요한 항을 손으로 골라 넣을 수 없다
 - **이중 기계학습(Double Machine Learning, DML)** 은 이 조정을 기계에 맡긴다(Chernozhukov et al., 2018). 계산은 세 단계다. ① 공변량으로 결과를 예측하고 실제에서 예측을 뺀다(결과 잔차 — 예측으로 설명하고 남은 부분). ② 같은 공변량으로 처치 여부를 예측하고 실제에서 뺀다(처치 잔차). ③ 처치 잔차로 결과 잔차를 회귀한 기울기가 처치효과다
 - 양쪽을 모두 잔차로 만들면, 예측 모형이 다소 틀려도 그 오차가 효과 추정에 곧바로 실리지 않는다. 한쪽만 잔차화하면 그 모형의 오차가 효과에 그대로 얹힌다
 - 절차가 하나 더 붙는다. 같은 데이터로 잔차도 만들고 효과도 재면 과적합만큼 왜곡되므로, 자료를 5조각으로 나눠 k번째 조각의 잔차는 나머지 4조각으로 학습한 모형으로 만든다. 이것이 **교차 적합(cross-fitting)** 이다
- 실습 코드(핵심 부분, 전체는 4-2-ml-did.py)

```

kf = KFold(n_splits=K, shuffle=True, random_state=seed) # K=5 교차 적합
for train_idx, test_idx in kf.split(X):
    outcome_model.fit(X_train[control_idx], Y_train[control_idx]) # 결과 모형은 대조군으로 학습
    treat_model.fit(X_train, D_train)
    Y_res = Y_test - outcome_model.predict(X_test) # 결과 잔차
    D_res = D_test - treat_model.predict(X_test) # 처치 잔차
theta_dml = np.sum(Y_res_all * D_res_all) / np.sum(D_res_all ** 2) # 잔차 회귀의 기울기

```

○ 실행 결과(results/4-2-ml-did.log 발췌. 데이터는 공변량 5개·1,000명, 참값 4.01의 별도 데이터다)

방법론	처치효과	표준오차	95% 신뢰구간	RMSE	K
DML-RF	3.76	0.18	[3.41, 4.11]	1.72	5
DML-XGBoost	3.56	0.17	[3.22, 3.90]	1.76	5
DML-Lasso	3.98	0.18	[3.62, 4.34]	1.72	5
Traditional DID	3.98	0.12	[3.75, 4.22]	-	-

- 해석 1(학습기 민감도): 세 학습기의 추정값 범위는 3.56~3.98로 폭이 0.42다. 판정 기준은 "폭이 표준오차의 2배 안인가"인데, 폭 0.42는 표준오차 0.18의 2배(0.36)를 넘는다. 이 기준으로는 학습기 선택이 결과에 영향을 준 것이므로, 어느 모형이 데이터를 더 잘 맞추는지 예측 오차(RMSE)로 가려야 한다. 그런데 RMSE가 1.72~1.76으로 사실상 같아 우열이 갈리지 않으므로, 한 값을 고르지 않고 **세 값을 모두 보고하고 범위 3.56~3.98을 결론으로 적는다**
- 해석 2(참값 대조): 네 방법 모두 참값 4.01에서 0.45 이내에 있고, 이 데이터에서는 선형 회귀 기반의 전통적 DID(3.98)도 참값에 근접했다. 비선형이 있어도 항상 DML이 이긴다고 일반화하면 안 된다는 예다
- 해석 3(예측 품질): 결과 예측의 RMSE 1.72가 결과 변수의 흠어짐에 근접하면 예측이 사실상 평균만 맞는 수준이므로, 그 경우 DML 결과를 보고하지 않고 공변량 구성부터 다시 본다
- 덧붙여, 결과 예측과 처치 확률 예측을 결합해 **둘 중 하나만 옳게 지정해도 버티게** 만든 추정량이 DR-DID다(Sant'Anna & Zhao, 2020)
 - 두 예측이 모두 틀렸을 때만 편향이 생긴다. 두 모형을 동시에 맞추기는 어렵지만 하나를 맞힐 확률은 그보다 높으므로 실패 조건이 한 칸으로 줄어드는데, 다만 그 한 칸은 남는다

한 줄 정리: 시점이 엇갈리면 단일 계수 TWFE를 버리고, 공변량이 많으면 잔차 두 벌을 만들어 회귀한다. 학습기를 바꿔도 값이 버티는지가 판정 기준이다.

□ 1부 정리

- 지금까지 만든 것: 처치효과 2.45와 신뢰구간 [1.97, 2.93], 사전 추세 계수 다섯 개와 Joint F(p=0.28)의 네 기준 판정, 클러스터 방식별 표준오차 0.15~0.26, DML 세 학습기의 범위 3.56~3.98

○ 확인한 판정 기준

- 사전 추세는 개별 p-결합 p-크기(효과의 50%)·패턴(단조 여부) 네 가지를 모두 보고, 표준오차는 가장 큰 클러스터 값으로도 결론이 버티는지 확인한다
- 처치 시점이 두 종류 이상이면 단일 계수 TWFE를 최종 결과로 쓰지 않는다

○ 남은 조건이 하나 있다. 지금까지는 처치군에 도시가 여럿 있었다. 정책이 한 도시에만 적용되면 평균 널 처치군도, 고를 대조군도 없다. 그 상황이 2부의 출발점이다

2부. 대조군이 없으면 만들어 쓰고, 만든 것은 검증한다


□ 2부 개요

- 이 파트가 끝나면: 후보 도시 20곳을 섞어 합성 대조군을 만들고, 그 품질을 세 지표로 판정하며, 플라스보·leave-one-out·시간 플라스보 검증을 돌려 무엇을 보고할지 결정할 수 있다
- 다루는 절: 4.3 ~ 4.7

□ 4.3 합성통제법 — 대조군을 섞어서 만든다

- 정책이 서울 한 곳에만 적용되었다면, 대조군으로 부산을 쓸지 대구를 쓸지 연구자가 고르는 순간 그 선택이 결과를 좌우한다. 여러 도시의 단순 평균을 쓰면 서울과 전혀 닮지 않은 도시까지 같은 비중으로 들어간다
- **합성통제법(Synthetic Control Method, SCM)** 은 후보 도시들의 가중평균으로 서울과 닮은 가상 대조군을 만든다(Abadie & Gardeazabal, 2003)
 - 후보 도시 목록이 **donor pool**, 만들어진 가상 대조군이 **합성 대조군**이다. 정책 효과는 정책 이후 실제 서울의 값에서 합성 대조군의 값을 뺀 것이다
 - 가중치는 사람이 정하지 않는다. "정책 이전 구간에서 서울의 궤적과 가중평균의 차이가 가장 작아지도록" 컴퓨터가 푼다. 조건은 두 개 — 가중치는 0 이상(음수를 허용하면 후보 범위 밖으로 튀는 외삽이 생긴다), 합은 1(이 제약이 없으면 전체 수준을 마음대로 늘릴 수 있다)
- 구조는 물감 섞기와 같다. 목표 색이 서울의 정책 이전 궤적에, 팔레트의 물감들이 donor pool에, 물감을 짜 넣는 비율이 가중치에, 섞은 색과 목표 색의 차이가 사전 적합도에 대응한다. 다만 물감은 목표 색을 보면서 맞출 수 있지만, 합성통제가 맞추는 대상은 정책 이전 구간뿐이고 정작 알고 싶은 정책 이후 구간에서 잘 맞는지는 확인할 방법이 없다

그림 4-3. 대조군을 조합해서 만드는 방식 (실습 2 실측 가중치)



가중치는 정책 시행 전 서울을 가장 잘 재현하도록 데이터가 정한다.
음수 가중치를 허용하지 않고 합을 1로 묶는다.

- 그림 4-3 읽는 법: 왼쪽 상자들이 donor 도시와 이번 실습에서 실제로 계산된 가중치(광주 0.35, 울산 0.16, 창원 0.12, 전주 0.12, 성남 0.09, 나머지 15곳 합계 0.16)다. 가중 합이 "가짜 서울"이 되고, 정책 후 실제 서울과 가짜 서울의 차이가 처치효과다
- 실습 코드(핵심 부분, 전체는 4-3-scm.py)

```
def objective(w):
    # 사전 기간 예측오차 최소화
    residuals = Y_treated_pre - Y_donors_pre @ w
    return np.mean(residuals**2) + reg_param * np.sum(w**2) # reg_param=0.01

constraints = {'type': 'eq', 'fun': lambda w: np.sum(w) - 1} # 합 = 1
result = minimize(objective, w_init, method='SLSQP',
                  bounds=[(0, 1)] * n_donors, constraints=constraints)
```

- 실행 결과(results/4-3-scm.log 발췌. 데이터는 donor 20곳·사전 20개월·사후 10개월, 참 효과 -3.47을 심었다)

사전 MSPE:	0.06
사전 RMSPE:	0.24
결과 변수 표준편차 대비:	24.5%
가중치 HHI:	0.20 (< 0.3 분산)
평균 처치효과 (사후):	-3.25
최대 단일 donor 가중치:	0.35 (< 0.5 양호)
0에 가까운 가중치 수:	14개 (총 20개 중)

- 해석: 출력은 효과 하나가 아니라 "품질 지표 + 효과"의 묶음이며, 품질을 먼저 보고 통과한 뒤에야 효과를 읽는다
- 품질 1(사전 적합): **RMSPE**는 정책 전 구간에서 합성 대조군이 실제 서울과 어긋난 평균 크기다. 절대값 0.24만으로는 판단할 수 없어 결과 변수의 표준편차로 나눈 비율(24.5%)을 쓰고, 30% 미만이면 통과로 본다(Abadie et al., 2010의 관행). 30%를 넘으면 정책 후의 차이가 효과인지 원래 못 맞추던 부분인지 갈라낼 수 없으므로, 효과를 읽지 않고 donor pool 구성으로 되돌아간다
- 품질 2(가중치 집중): **HHI**는 가중치를 각각 제공해 더한 값으로, 한 도시가 독차지하면 1, 고르게 퍼지면 0에 가깝다. 눈금 — 0.3 미만 분산, 0.3~0.7이면 leave-one-out 결과를 반드시 병기, 0.7 초과면 사실상 한 도시가 대조군이므로 보고를 보류한다. 이번 값 0.20은 통과다
- 효과: 품질을 통과했으므로 -3.25를 읽는다. 정책 후 10개월 동안 서울이 합성 대조군보다 평균 3.25 낮았다는 뜻이고, 심어 둔 참값 -3.47과 0.22 차이다. 다만 이 단계에서는 아직 유의성을 말할 수 없으며, 판정은 4.5의 플라시보 검정에서 한다

한 줄 정리: 가중치는 데이터가 정하고, 효과는 품질 지표(사전 적합 30%, HHI 눈금)를 통과한 뒤에만 읽는다.

□ 4.4 합성 이중차분법(SDID) — 두 가정 중 하나만 맞아도 버틴다

- DID는 평행추세에 기대고, SCM은 사전 적합에 기대다. 실제 자료에서는 둘 다 부분적으로만 성립하는 경우가 흔하다
 - Arkhangelsky et al.(2021)의 **합성 이중차분법(SDID)**은 계산의 뼈대는 DID로 두고, 비교 대상 구성만 SCM에서 가져온다. 가중치를 두 벌 얻는데, **단위 가중치**는 donor를 섞어 서울과 닮은 조합을 만들고, **시간 가중치**는 정책 이전 시점들에 서로 다른 비중을 준다
 - 평행추세가 정확히 성립하면 결과가 DID에 수렴하고, 사전 적합이 완벽하면 SCM에 수렴하며, 둘 다 부분적이면 양쪽 정보를 함께 쓴다
- 실습 코드(핵심 부분, 전체는 4-4-sdid.py)

```
def unit_objective(omega):
    # 단위 가중치: SCM과 같은 구조
    residuals = Y_treated[:n_pre] - Y_donors[:n_pre, :] @ omega
    return np.mean(residuals**2) + reg_param * np.sum(omega**2) # reg_param=0.01

def time_objective(lambda_t):
    # 시간 가중치: 가중 사전 격차를 0에 맞춤
    weighted_gap = lambda_t @ pre_gaps
    return weighted_gap**2 + reg_param * np.sum((lambda_t - uniform)**2)

sdid_effect = post_gap - weighted_pre_gap # 사후 격차 - 가중 사전 격차
```

- 실행 결과(results/4-4-sdid.log 발췌. 평행추세가 부분적으로만 성립하도록 만든 데이터, 참 효과 -3.50)

초기 기간 (t=1~10): 추세 차이 SD = 0.733

후기 기간 (t=11~20): 추세 차이 SD = 0.517

방법론	처치효과	표준오차	95% 신뢰구간
DID	-3.67	0.98	[-5.59, -1.75]
SCM	-3.41	0.23	[-3.86, -2.97]
SDID	-3.41	0.23	[-3.86, -2.97]

최근 5시점 가중치 합계: 0.25 (25%)

- 해석 1(정밀도): DID의 표준오차 0.98과 SDID의 0.23을 비교하면, 표준오차 비의 제곱 $(0.98 \div 0.23)^2 \approx 18$ 이 같은 정밀도에 필요한 표본 배수다. 다만 이 자료는 **평행추세를 일부러 흔들어 놓았기** 때문에(초기 추세 차이 0.733) DID가 특히 불리했던 것이며, **평행추세가 잘 맞는 자료에서도 항상** 이만큼 벌어진다고 읽으면 안 된다
- 해석 2(참값 대조): 참값 -3.50에 SDID(-3.41)가 DID(-3.67)보다 가깝다. 두 값의 차이 0.26은 DID의 표준오차 0.98 안이므로 통계적으로 구분되는 차이는 아니고, 읽어야 할 것은 **평행추세가 흔들리면 DID의 신뢰구간이 크게 벌어진다**는 점이다
- 해석 3(가중치 두 벌): 최근 5시점의 시간 가중치 합 25%는 균등 배분일 때의 값(20시점 중 5시점 = 25%)과 같다. 가중치가 특정 구간에 몰리면 "그 구간에서만 비교가 성립한다"는 판단이므로 그 구간이 왜 다른지 확인해야 하는데, 여기서는 균등이므로 그대로 진행한다. 단위 가중치(순천 0.30, 대구 0.30, 광주 0.10, 세종 0.10, 울산 0.09)는 SCM의 해와 차이가 0.00이다

한 줄 정리: SDID는 DID의 뼈대에 가중치 두 벌을 얹어, 평행추세와 사전 적합 중 하나만 성립해도 버티게 만든다.

□ 4.5 만든 대조군을 검증한다 — 플라시보, leave-one-out, 시간 플라시보

- 합성통제법은 처치 단위가 하나뿐이라 회귀처럼 p값을 직접 내놓지 못한다. 대신 "이 정도 크기의 차이가 아무 일 없는 도시에서도 흔히 나오는가"를 직접 만들어 비교한다
 - 이 절의 데이터는 검증 연습용으로 새로 만든 것이다(donor 20곳, 참 효과 -3.50). 그래서 실제 효과가 4.3의 -3.25가 아니라 -3.18로 나온다
- 검증 1 — **플라시보 검증**: donor 각각을 "가상의 처치 도시"인 척 세우고 나머지로 합성 대조군을 만들어, 아무 정책도 없었는데 나타난 가상 효과를 계산한다. 실제 효과가 이 가상 효과들 속에서 몇 번째로 극단적인지가 p값이 된다
- 실습 코드(핵심 부분, 전체는 4-5-validation.py)

```

for i in range(n_donors):                                # donor 하나씩을 가짜 처치 도시로
    Y_other_pre = np.delete(Y_donors_pre, i, axis=1)
    w_placebo = compute_scm_weights(Y_placebo_pre, Y_other_pre, reg_param)
    placebo_effects.append(np.mean(Y_placebo_post - Y_other_post @ w_placebo))

# 실제 처치 도시도 분포의 한 원소다: 분자에 1을 더하고 분모는 J+1
n_extreme = int(np.sum(np.abs(placebo_effects) >= np.abs(real_effect)))
p_value = (1 + n_extreme) / (len(placebo_effects) + 1)

```

○ 실행 결과(results/4-5-validation.log 발췌)

```

실제 처치효과:      -3.18
플라시보 평균:      -0.07
플라시보 표준편차:   0.79
p-value (양측):      0.048
p-value (필터링):    0.143
필터링 통과 지역:   6/20

```

- 해석 1: 실제 효과 -3.18은 가상 효과들의 분포(평균 -0.07, 표준편차 0.79)에서 약 3.9 표준편차 떨어진 가장 극단적인 값이고, p값은 $1 \div 21 = 0.048$ 이다
- 해석 2(최소 p값의 함정): 이 방식의 p값은 아무리 극단적이어도 $1 \div (\text{donor 수} + 1)$ 보다 작아질 수 없다. donor가 20이면 최소값이 0.048이므로 0.05를 간신히 지나가지만, **19곳 미만이면 애초에 0.05에 도달할 수 없다.** 검정을 돌리기 전에 donor 수부터 센다
- 해석 3(필터링): 사전 구간조차 못 맞춘 donor는 정책 후에도 크게 어긋나는 것이 당연하므로, 사전 적합이 나쁜 도시를 빼고 다시 계산한다. 이번 실행에서는 필터를 통과한 도시가 6곳뿐이라 분모가 7이 되어 최소 p값이 $1 \div 7 \approx 0.143$ 으로 올라갔고, 실제로 $p=0.143$ 이 나왔다. 해석 2의 함정이 실제로 발생한 것이다 — 이 경우 필터링 p값으로는 유의성을 말할 수 없으므로, 두 p값을 모두 신평고 필터 기준을 분석 전에 정했음을 밝힌다

○ 검증 2 — **leave-one-out**: 가중치를 받은 donor를 하나씩 빼고 효과를 다시 쟀다. 한 도시를 뺐을 때 결과가 크게 달라지면 그 도시 하나가 결론을 만들고 있었다는 뜻이다

○ 실행 결과(로그 발췌)

```

기준 효과 (전체):      -3.18
대전   제외:  -3.07 ( -3.3%)
최대 변화율:           3.3%
±10% 초과 빈도:        0/5

```

- 해석: 판정 눈금은 두 단계다. 어느 donor를 빼도 변화율이 $\pm 10\%$ 안이면 안정으로 보고 그대로 보고하고, 어느 하나에서 30%를 넘으면 그 donor를 뺀 추정치를 본문에 병기한다. 최대 3.3% 이므로 통과다

- 검증 3 — **시간 플라시보**: 실제 정책보다 앞선 시점을 가짜 시행 시점으로 놓고 같은 분석을 돌린다. 그때는 아무 일도 없었으므로 효과가 나오면 안 된다
- 실행 결과(로그 발췌)

t-10: 효과 = -0.97, p-value = 0.15 (비유의)
 t- 5: 효과 = -0.41, p-value = 0.40 (비유의)
 t- 1: 효과 = -0.34, p-value = 0.70 (비유의)
 평균 가상 효과: -0.47 (실제 효과 대비 14.7%)

- 해석: 판정선은 셋이다. 모든 시점에서 $p > 0.10$ 이면 통과, $0.05 \sim 0.10$ 구간이 있으면 그 시점 근처의 다른 사건을 확인한 뒤 진행, $p < 0.05$ 가 하나라도 나오면 사전 기간에 이미 차이가 벌어지고 있었다는 뜻이므로 **주 분석을 인과효과로 보고하지 않는다**. 다섯 시점 모두 0.15 이상이므로 통과다

- 검증 4 — 분석자가 고른 값의 민감도: 가중치 계산에 들어가는 정규화 값은 사전 기간을 훈련·검증 구간으로 나눠 고른다. 이번 실행에서는 후보 0.001~0.1 전부에서 검증 오차가 0.393~0.394, 효과가 -3.32~-3.33으로 사실상 같았다. 이 값의 선택이 결과를 만들지 않았다는 판정이다
- 판정 연습(가상의 수치다): donor 12곳인 분석에서 실제 효과가 가상 효과 13개 중 1위로 극단적이라면?
 - 최소 p값이 $1 \div 13 \approx 0.077$ 이므로 아무리 극단적이어도 5% 유의수준에는 도달할 수 없다. donor를 늘리거나 유의수준 기준 자체를 바꿔 보고한다

한 줄 정리: 유의성은 가짜 처치(다른 도시·다른 시점)를 세워 직접 만들어 재고, 그 전에 donor 수로 최소 p값부터 센다.

□ 4.6 세 방법을 한 표에 놓고 판정한다

- 실무에서는 한 방법만 쓰지 않고 DID·SCM·SDID를 모두 돌린 뒤 같은 방향을 가리키는지 확인한다. 이를 **삼각검증(triangulation)** 이라 부른다
- 실행 결과(results/4-6-comprehensive.log 발췌. 45개 지역(처치 1 + donor 44)·30개월 데이터에 세 방법을 한꺼번에 적용했다. 참 효과 -3.50. 전체 코드는 4-6-comprehensive.py)

Method	Effect	SE	p-value	CI_Lower	CI_Upper
DID	-3.63	0.13	0.000	-3.89	-3.38
SCM	-3.17	0.51	0.022	-4.17	-2.16
SDID	-3.34	0.24	0.000	-3.82	-2.86

공통 구간: [-3.82, -3.38]


- 해석 1(폭과 부호): 판정 기준은 "세 추정값의 폭이 가장 큰 표준오차의 2배 안인가"다. 폭은 -3.17에서 -3.63까지 0.46이고 가장 큰 표준오차는 SCM의 0.51이므로 2배 1.02보다 작으며, 세 신뢰구간 모두 음수 구간에 있어 부호도 일치한다. 방법 선택으로 결론이 뒤집히지 않는다. 부호가 같으면 폭 기준을 통과해도 결론을 내리지 않는다
- 해석 2(위치): SDID(-3.34)가 DID(-3.63)와 SCM(-3.17)의 사이, 표준오차 0.24도 0.13과 0.51의 사이에 있다. 두 방법의 정보를 섞은 결과가 값과 정밀도 양쪽에서 중간에 놓인 것으로, SDID의 설계에서 예상되는 위치다
- 해석 3(참값 대조): 참값 -3.50을 기준으로 세 방법의 빗나감은 DID -0.13, SCM +0.33, SDID +0.16이다. 세 구간 중 DID와 SDID의 신뢰구간이 참값을 담았다

한 줄 정리: 세 방법을 나란히 놓고 폭과 부호를 판정한다. 폭이 기준을 넘으면 어느 방법의 가정이 깨졌는지 진단으로 되돌아간다.

□ 4.7 무엇을 쓸지는 자료의 구조가 정한다

- 방법 선택을 좌우하는 것은 방법의 새로움이 아니라 자료의 구조다. 네 가지를 순서대로 확인한다
 - ① 처치 단위가 몇 개인가 — 여럿이면 DID 계열, 하나면 SCM 계열
 - ② 처치 시점이 하나인가 여럿인가 — 여럿이면 단일 계수 TWFE를 버리고 코호트별 추정으로
 - ③ 사전 추세 검정을 통과했는가 — 못 했으면 DID 단독 보고를 접고 SDID나 민감도 분석으로
 - ④ 공변량이 많고 관계가 곡선인가 — 그렇다면 DML을 엮는다

그림 4-4. 분석 순서와 판정 지점



○ 그림 4-4 읽는 법

- 맨 위 질문(처치 단위 수)에서 갈라져, 왼쪽 가지는 사전 추세 F검정을 거쳐 TWFE 또는 DML로, 오른쪽 가지는 사전 적합도(RMSPE)를 거쳐 SCM 또는 SDID로 간다
- 어느 경로로 내려가든 맨 아래 붉은 상자 — 플라시보·leave-one-out·시간 플라시보 검증 — 를 통과해야 보고할 수 있다

<표 4-3: 상황별 방법 선택>

상황	방법	함께 확인할 것
처치 단위 다수, 평행추세 통과	DID	사전 추세 네 기준
단일 처치, donor pool이 크다	SCM	RMSPE 비율, HHI
단일 처치, 평행추세 불확실	SDID	시간 가중치 분포
공변량 고차원·비선형	DML	예측 오차(RMSE), 학습기 민감도
처치 시점이 엇갈림	Callaway-Sant'Anna 계열	코호트별 표본 크기

한 줄 정리: 처치 단위 수 → 처치 시점 수 → 사전 추세 → 공변량 구조의 순서로 확인하면 방법이 갈린다. 어느 길이든 마지막은 검증이다.

□ 결과를 읽는 순서

- 이 장의 산출물은 다음 순서로 읽는다. 순서를 지키지 않으면 품질이 불합격한 대조군의 효과를 읽게 된다
 - 1순위 **처치 시점의 종류 수**: 두 종류 이상이면 단일 계수 TWFE를 읽지 않고 코호트별 추정으로 바꾼다
 - 2순위 **사전 추세(DID) 또는 사전 적합(SCM)**: Joint F의 p가 0.10 이하이거나 RMSPE 비율이 30% 이상이면, 효과 숫자를 읽지 않고 설계로 되돌아간다
 - 3순위 **가중치 집중도(HHI)와 leave-one-out**: 결과가 소수 donor에 매달려 있지 않은지 본다
 - 4순위 **플라시보 p값**: donor 수로 최소 p값을 먼저 세고, 실제 효과가 가상 효과들보다 극단적인지 본다. 시간 플라시보에서 $p < 0.05$ 가 하나라도 나오면 인과효과로 보고하지 않는다
 - 5순위 **효과와 신뢰구간**: 앞의 관문을 통과한 뒤에야 크기를 읽고, 방법 2~3개의 값을 나란히 놓아 폭과 부호를 판정한다

□ 실무 적용 점검표

- 처치군과 대조군이 어떤 기준으로 갈렸는지 적었는가? 그 기준이 결과 변수와 직접 연결되어 있지 않은가?
- 정책 시행 시점을 개체별로 나열해 몇 종류인지 세고, 사전 기간이 검정 가능할 만큼 확보되었는지 확인했는가?
- 사전 추세 계수와 Joint F를 네 기준에 대입한 결과, 그리고 클러스터 단위와 그 근거를 기록했는가?
- SCM이라면 donor pool의 포함·제외 기준을 명시하고, 처치의 영향을 받았을 수 있는 인접 지역은 뺐는가?
- 플라시보에 쓸 donor 수를 세어 도달 가능한 최소 p값을 계산하고, 필터링 기준과 정규화 값의 범위를 분석 전에 정해 문서로 남겼는가?
- 최종 보고에 추정값·표준오차·신뢰구간과 함께, 사용한 가정과 그 가정의 진단 결과를 실었는가?

□ 핵심 정리

방법	핵심 구조	기대는 가정	무너지는 지점
DID(TWFE)	전후 뺄셈과 집단 간 뺄셈	평행추세	처치군에만 온 시간 요인, 시차 도입
DML-DID	결과·처치를 각각 잔차화한 뒤 회귀	공변량 조건부 독립, 교차 적합	예측이 나쁘거나 처치 확률이 극단값
DR-DID	결과 예측과 처치 확률 예측을 결합	둘 중 하나가 옳게 지정	두 모형이 모두 틀린 경우
SCM	donor 가중평균으로 대조군 구성	사전 구간 적합	사전 적합 실패, 가중치 집중
SDID	DID 뼈대에 가중치 두 벌	평행추세 또는 사전 적합	두 가정이 모두 크게 어긋난 경우

○ 이 장의 판정 규칙 세 가지

- **검정 통과는 성립의 증거가 아니다.** 사전 추세 F 통과는 "위배를 잡아내지 못했다"는 사실이며, 크기·패턴 기준까지 함께 본다
- **품질 지표를 통과하기 전에는 효과를 읽지 않는다.** RMSPE 비율 30%, HHI 눈금, leave-one-out 10%가 관문이다
- **p값을 만들 수 있는지부터 센다.** 플라시보의 최소 p값은 $1 \div (\text{donor 수} + 1)$ 이다. 이번 실습에서도 필터링 후 donor가 6곳으로 줄자 최소 p값이 0.143으로 올라가 유의성을 말할 수 없게 되었다