

4장. 이중차분법(DID)과 합성통제법(SCM)

□ 이 장의 질문

- 서울에만 광고를 내보내고 전후 매출을 비교했더니 매출이 늘었다. 그러면 "늘어난 만큼이 광고 효과"라고 보고해도 될까?
- 이 장의 답은 "안 된다"이다. 전후 차이에는 광고와 무관한 시간의 흐름이 섞여 있기 때문이다. 그 흐름을 빼는 방법(이중차분), 비교할 지역이 하나뿐일 때 대조군을 만들어 쓰는 방법(합성통제), 그리고 그렇게 얻은 숫자를 언제 믿어도 되는지 판정하는 검사들을 차례로 배운다

□ 이 장을 읽는 방법

- 이 장은 두 파트로 나뉜다
 - 1부(4.1.1~4.1.5): 전후 비교의 문제에서 출발해, 두 번의 뺄셈으로 효과를 재는 이중차분법을 실행하고, 그 결과를 믿어도 되는지 사전 추세 검사로 판정한다
 - 2부(4.3~4.7): 처치받은 지역이 하나뿐이어서 대조군을 고를 수 없을 때, 여러 후보 지역을 섞어 대조군을 만들어 쓰는 합성통제법과 그 검증 절차를 다룬다. 각 절은 **원리**와 **실습** 두 토막이다. 원리를 수식 없이 읽고 결과가 어느 방향으로 나와야 하는지 먼저 정한 뒤, 실습 출력과 맞춰 본다
- 이 장의 실습은 서로 다른 데이터를 쓴다. 4.1은 45개 도시·24개 시점의 패널(참 효과 2.35)이고, 4.3 이후는 처치 도시 1곳과 후보 20곳의 데이터(참 효과 -3.47 또는 -3.50)다. 절이 바뀌면 추정값의 크기와 부호가 달라지는데, 이는 오류가 아니라 데이터가 다르기 때문이다
- 실습 코드는 `practice/chapter04/code/` 에 있다. 스크립트를 실행하면 콘솔 출력 전체가 `practice/chapter04/results/<스크립트명>.log` 로 저장되고, 그림도 `results` 폴더에 저장된다. 본문의 실행 결과 발췌는 모두 이 코드가 실제로 계산한 값이다
- 용어 미리보기 — 본문에서 처음 나올 때마다 다시 풀어 설명하므로, 여기서는 눈에 익히기만 하면 된다

용어	쉬운 뜻
이중차분법(DID)	처치군의 전후 변화에서 대조군의 전후 변화를 한 번 더 빼는 방법
평행추세	정책이 없었더라면 두 집단의 결과가 같은 폭으로 움직였을 것이라는 가정
고정효과	개체마다(또는 시점마다) 하나씩 붙여, 그 개체(시점)의 고유한 수준을 흡수하는 상수
클러스터 표준오차	같은 개체의 관측들이 서로 얽혀 있음을 감안해, 개체 단위로 묶어 계산한 오차
사전 추세 검정	정책 전 구간에서 두 집단의 간격이 일정했는지 확인하는 검사
합성통제법(SCM)	여러 후보 지역의 가중평균으로 처치 지역과 닮은 가상 대조군을 만드는 방법
donor pool	가상 대조군을 만들 때 섞는 후보 지역의 목록
가중치	각 후보 지역을 섞는 비율. 합이 1이고 음수는 없다
RMSPE(사전 적합도)	정책 전 구간에서 합성 대조군이 실제 지역과 어긋난 평균 크기
HHI(가중치 집중도)	가중치가 소수 지역에 쏠렸는지 재는 값. 한 지역이 독차지하면 1
플라시보 검정	아무 일 없던 지역을 처치받은 척 세워 같은 계산을 해 보는 검사
SDID	이중차분의 뼈대에 합성통제의 가중치를 얹어, 두 가정 중 하나만 맞아도 버티는 방법

1부. 두 번의 뺄셈으로 시간의 흐름을 걷어낸다

□ 1부 개요

- 이 파트가 끝나면: 이원 고정효과 회귀로 처치효과 추정값 2.45를 얻고, 이 값을 보고해도 되는지 사전 추세 검정의 네 기준으로 판정하며, 클러스터를 바꿔도 결론이 버티는지 확인할 수 있다
- 다루는 절: 4.1.1 ~ 4.1.5

□ 4.1.1 전후 비교만으로는 왜 안 되는가


- 서울에만 광고를 내보내고 광고 전후 매출을 비교했더니 매출이 늘었다고 하자. 이 증가분을 광고 효과라고 부를 수는 없다
 - 같은 기간에 명절이 끼어 있었거나 경기가 회복 국면이었다면, 광고가 없었어도 매출은 늘었을 것이다. 전후 차이 안에는 **광고 효과**와 **광고와 무관한 시간 흐름**이 함께 들어 있다
- 해결 장치가 대조군이다. 광고를 하지 않은 부산도 같은 명절과 같은 경기 국면을 겪었으므로, 부산의 전후 변화를 "광고가 없었을 때 일어났을 변화"의 대역으로 쓴다
- 예시 숫자로 네 칸을 채워 보면 계산 구조가 보인다 (표 4-1의 숫자는 설명용 예시다)

<표 4-1: 이중차분의 네 칸 구조 (예시 숫자)>

집단	정책 전	정책 후	전후 차이(1차 뺄셈)
서울(처치군)	100	112	+12
부산(대조군)	80	88	+8
집단 간 차이(2차 뺄셈)	—	—	+4

- 서울만 보면 +12지만, 광고가 없었어도 +8은 일어났을 변화이므로 광고 몫은 $12 - 8 = +4$ 다
- 이렇게 두 번 빼서 효과를 재는 방법이 **이중차분법(Difference-in-Differences, DID)** 이다.
처치군의 전후 변화에서 대조군의 전후 변화를 한 번 더 빼다

그림 4-2. 두 번 빼서 처치효과를 얻는 구조



- ① 각 집단 안에서 시간에 따른 변화를 먼저 뺀다 (변하지 않는 집단 특성이 사라진다)
- ② 두 변화의 차이를 다시 뺀다 (두 집단에 공통으로 온 변화가 사라진다)

남는 값 2.452가 처치효과 추정치다 (실습 1 데이터의 실측 평균)

○ 그림 4-2 읽는 법

- 위 줄이 처치군, 아래 줄이 대조군이다. 각 줄에서 먼저 전후 차이를 구하고(① +3.915, ② +1.462), 두 차이를 다시 빼면 $3.915 - 1.462 = 2.452$ 가 남는다. 이 숫자는 4.1.3 실습 데이터에서 실제로 계산한 집단 평균이며, 네 칸만으로 뺀 값 2.452가 뒤에서 회귀로 얻는 2.45와 사실상 같다는 점을 미리 확인해 둔다

한 줄 정리: 전후 차이에는 시간의 흐름이 섞여 있다. 대조군의 전후 차이를 한 번 더 빼서 그 흐름을 걷어낸다.

□ 4.1.2 두 번의 뺄셈이 무엇을 지우고, 무엇이 남는가

- 첫 번째 뺄셈(같은 집단의 전후 차이)은 시간이 지나도 변하지 않는 집단 특성을 지운다

- 서울의 매출 수준이 원래 부산보다 높다는 사실은 정책 전에도 후에도 똑같이 작용하므로, 전후 차이를 구하는 순간 사라진다
- 두 번째 뺄셈(두 집단의 변화량 차이)은 모든 집단에 공통으로 작용한 시간 요인을 지운다
 - 명절 특수나 전국적 경기 변동은 서울과 부산을 같은 방향으로 밀었으므로, 변화량의 차이에는 남지 않는다
- 문제는 무엇이 남느냐다. 두 번을 빼도 지워지지 않는 것은 **처치군에만 작용한 시간 요인**이다
 - 서울에서만 같은 시기에 지하철 노선이 개통되었다면, 그 효과는 광고 효과와 함께 +4 안에 들어가며 데이터만 보고는 둘을 나눌 수 없다
 - 그래서 이 방법은 "정책이 없었더라면 두 집단의 결과가 같은 쪽으로 움직였을 것"이라는 가정에 기댄다. 이것이 **평행추세(parallel trends) 가정**이다
- 구조는 에스컬레이터에 나란히 탄 두 사람과 같다
 - 에스컬레이터가 올려 주는 높이가 공통 시간 추세에, 한 사람만 그 위에서 걸어 올라간 거리가 처치효과에, 두 사람의 출발 높이 차이가 1차 뺄셈이 지우는 집단 특성에 대응한다. 이 대응은 두 사람이 같은 속도의 에스컬레이터에 탔을 때까지만 성립하며, 한 사람이 더 빠른 에스컬레이터에 타고 있었다면 걷지 않아도 높이 차이가 벌어진다 — 이것이 평행추세 위배다

한 줄 정리: 두 번의 뺄셈은 "원래 수준 차이"와 "공통 시간 흐름"을 지운다. 처치군에만 온 변화는 못 지우며, 그것이 없다는 가정이 평행추세다.

□ 4.1.3 도시가 45개면 회귀로 뺀다 — 이원 고정효과 모형

- 집단이 둘, 시점이 둘이면 네 칸을 손으로 빼면 되지만, 45개 도시를 24개 시점에서 관찰한 자료에서는 그렇게 할 수 없다. 이때 쓰는 표준 도구가 **이원 고정효과 모형(TWFE)** 이다
 - 구조는 뺄셈의 회귀판이다. 도시마다 상수 하나(그 도시의 고유 수준), 시점마다 상수 하나(그 시점의 공통 충격)를 붙이고, "처치군이면서 정책 이후인 칸"에만 1이 되는 표시 변수를 넣는다
 - 도시별 상수가 1차 뺄셈의 일을, 시점별 상수가 2차 뺄셈의 일을 회귀 안에서 대신한다. 표시 변수에 붙는 계수가 처치효과이며, 집단 둘·시점 둘인 특수한 경우에는 네 칸 계산과 정확히 같은 값이 나온다
- 같은 도시를 여러 시점에서 관찰하면 오차가 시점 간에 서로 얹힌다. 그래서 표준오차는 도시 단위로 묶어 계산하는 **클러스터 강건 표준오차**를 쓴다(Bertrand, Duflo & Mullainathan, 2004)
- 실습 데이터: 45개 도시 × 24개 시점 = 1,080개 관측치, 처치는 t=20부터, 참 효과는 2.35로 심어 두었다
- 실습 코드(핵심 부분, 전체는 `4-1-traditional-did.py`)

```
# 이원 고정효과 DID: 도시 더미 + 시점 더미 + 처치 표시 변수
model = smf.ols('outcome ~ C(entity) + C(time) + treat_post', data=df).fit()
did_effect = model.params['treat_post']

# 도시 단위 클러스터 강건 표준오차
cov_entity = cov_cluster(model, df['entity'])
```

○ 실행 결과(results/4-1-traditional-did.log 발췌)

```
처치효과 (δ):      2.45
표준오차:          0.25
95% 신뢰구간:      [1.97, 2.93]

R² (전체):          0.84
R² (within):        0.09
관측치 수:          1080
```

- 해석: 신뢰구간 [1.97, 2.93]이 0을 벗어나므로 "효과가 없다"고 보기 어렵고, 참값 2.35를 구간이 담고 있다. 추정값 2.45는 참값에서 0.10 떨어져 있다
- 전체 R^2 0.84와 within R^2 0.09가 크게 다른 것은 오류가 아니다. 0.84의 대부분은 "도시마다 수준이 다르다"는 사실을 도시 상수가 흡수한 몫이고, 상수들을 걷어낸 뒤 처치가 설명하는 몫은 9%. DID에서는 전체 R^2 가 높다는 것이 정보가 되지 못하므로 within R^2 를 본다


○ 직접 해 보기: practice/chapter04/code 폴더에서 `python 4-1-traditional-did.py` 실행 → 콘솔의 "이원 고정효과 DID 추정 결과"에서 위 값을 확인한다

한 줄 정리: 도시별 상수와 시점별 상수가 두 번의 뺄셈을 대신하고, 처치 표시 변수의 계수가 효과다.

□ 4.1.4 평행추세를 검사한다 — 사전 추세 검정

- 평행추세는 "정책이 없었더라면"이라는 관측되지 않은 상황에 관한 진술이므로 직접 검증할 수 없다. 대신 **정책 이전** 구간을 본다
- 정책 전에는 아직 처치가 없었으므로 두 집단의 간격이 시점마다 일정해야 한다. 일정하지 않았다면, 정책 후에도 두 집단이 다른 속도로 움직였으리라 의심할 근거가 된다

그림 4-1. 평행추세 가정과 반사실



○ 그림 4-1 읽는 법

- 정책 전에는 빨간 선(처치군)과 파란 선(대조군)의 간격이 3.0으로 일정하다. 회색 점선은 "정책이 없었을 때의 처치군" — 관측 불가능한 가상의 선 — 이며 간격 3.0이 유지된다고 가정하고 그린 것이고, 정책 후 빨간 선과 이 점선의 세로 거리가 DID가 재는 처치효과다. 점선의 기울기가 실제와 달랐다면 이 거리는 효과가 아니라 가정의 오차를 낸다

○ 검사 절차: 정책 직전 시점($t-1$)을 기준 0으로 놓고, 그 앞의 각 시점마다 "그 시점에 두 집단의 간격이 기준보다 얼마나 벌어져 있었나"를 재는 계수를 회귀로 얻는다. 이것이 **사전 추세 검정(pre-trend test)** 이다

○ 계수를 눈대중으로 판정하지 않는다. 네 기준을 순서대로 대입한다

<표 4-2: 사전 추세 판정 기준과 위반 시 조치>

번호	기준	통과 조건	위반 시 조치
1	개별 유의성	사전 계수 각각의 p값이 0.05보다 크다	유의한 시점이 정책 직전에 몰려 있으면 예고 효과를 의심하고 그 구간을 사전 기간에서 뺀다
2	결합 유의성	계수 전체를 묶은 Joint F검정의 p값이 0.10보다 크다	DID 추정치를 단독 결과로 보고하지 않는다
3	크기	사전 계수의 절댓값이 처치효과 추정값의 절반 미만이다	이벤트 스터디 그래프(시점별 계수 그림)를 함께 싣는다
4	패턴	계수의 부호가 한 방향으로 계속 커지거나 작아지지 않는다	DID를 보고하지 않고 추세 조정 DID나 합성통제로 옮긴다

- 기준 3의 근거: 사전 계수는 원래 0이어야 하는 값이므로 그 크기가 곧 잡음의 규모다. 잡음이 효과의 절반에 이르면, 사후에 본 차이의 어디까지가 효과인지 갈라내기 어렵다
- 기준 4를 따로 두는 이유: 계수가 하나하나의 비유의해도 부호가 한 방향으로 계속 커지면 두 집단이 애초에 벌어지는 중이었다는 신호인데, 결합 검정은 이런 완만한 추세를 놓치는 경우가 있다

○ 실행 결과(results/4-1-traditional-did.log 발췌)

동태적 DID 계수 (t-5 to t-1):

```
t-5:  -0.25  (p=0.597)
t-4:  -1.17  (p=0.015)
t-3:  -0.21  (p=0.660)
t-2:  -0.07  (p=0.888)
t-1:   0.08  (p=0.874)
```

Joint F-test 통계량: 1.26

p-value: 0.28

- 해석: 네 기준에 실제로 대입해 본다. 기준 1 — t-4의 p값 0.015가 0.05보다 작아 한 시점이 걸린다. 다만 유의한 시점이 정책 직전(t-1 근처)이 아니라 t-4 하나이므로 예고 효과의 전형은 아니다. 기준 2 — Joint F의 p값 0.28은 0.10보다 커서 통과다. 기준 3 — 가장 큰 절댓값 1.17은 추정값 2.45의 약 48%로, 경계선 50% 바로 아래다. 기준 4 — 부호가 음·양으로 섞여 있고 시점이 정책에 가까울수록 0에 다가가므로 단조 추세가 아니다
 - 종합 판정: 기준 1에서 한 시점, 기준 3에서 경계선. **추정치 2.45를 보고하되, 다섯 시점의 계수를 이벤트 스터디 그래프로 함께 싣고 t-4의 예외를 본문에 적는다가** 이 결과의 조치다
 - 유의할 점: Joint F 통과는 "평행추세가 성립한다는 증거"가 아니라 "위배를 잡아내지 못했다"는 사실이다. 표본이 작아 검정력이 낮으면 실제 위배가 있어도 p값이 크게 나온다
- 판정 연습(가상의 수치다): 사전 계수가 시점 순서대로 -0.10, -0.25, -0.44, -0.61, -0.80이고 개별 p값과 Joint F가 모두 비유의하다면?
- 기준 1:2는 통과지만 부호가 한 방향으로 계속 커지므로 기준 4 위반이다. DID를 보고하지 않고 추세 조정이나 합성통제로 옮긴다. 검정 통과가 판정의 전부가 아니라는 예다

한 줄 정리: 정책 전 간격이 일정했는지 네 기준으로 판정한다. p값 하나가 아니라 개별·결합·크기·패턴을 모두 본다.

□ 4.1.5 표준오차는 묶는 방식에 따라 흔들린다

- 추정값이 같아도 표준오차는 클러스터를 무엇으로 묶느냐에 따라 달라진다. 세 방식을 모두 계산해 비교한다
- 실행 결과(results/4-1-traditional-did.log 발췌)

개체 수준 클러스터링: SE = 0.21 (기준)
시간 수준 클러스터링: SE = 0.15 (31% 감소)
이원 클러스터링: SE = 0.26 (22% 증가)

- 해석: 추정값 2.45는 그대로인데 표준오차는 0.15에서 0.26까지 1.7배 차이가 난다. 판정 규칙 — 가장 큰 표준오차 0.26을 대입해도 결론이 유지되면 원래 추정을 보고하고, 가장 큰 값에서 유의성이 사라지면 그 보수적인 값을 본문에 싣는다. 여기서는 $2.45 \div 0.26 = 9.4$ 로 결론이 유지된다

한 줄 정리: 표준오차는 세 방식 중 가장 큰 값으로도 결론이 버티는지 확인한 뒤 보고한다.

□ 1부 정리

- 지금까지 만든 것: 처치효과 2.45와 신뢰구간 [1.97, 2.93], 사전 추세 계수 다섯 개와 Joint F($p=0.28$)의 네 기준 판정, 클러스터 방식별 표준오차 0.15~0.26
- 확인한 판정 기준
 - 사전 추세는 개별 p-결합 p-크기(효과의 50%)·패턴(단조 여부) 네 가지를 모두 보고, 표준오차는 가장 큰 클러스터 값으로도 결론이 버티는지 확인한다
 - 두 번의 뺄셈으로 시간의 흐름을 지우려면 평행추세가 성립해야 하고, 그 성립 여부는 정책 이전 구간에서만 검사할 수 있다
- 남은 조건이 하나 있다. 지금까지는 처치군에 도시가 여럿 있었다. 정책이 한 도시에만 적용되면 평균 널 처치군도, 고를 대조군도 없다. 그 상황이 2부의 출발점이다

2부. 대조군이 없으면 만들어 쓰고, 만든 것은 검증한다


□ 4.3 합성통제법 — 대조군을 섞어서 만든다

원리 — 대조군을 고르지 않고 섞어서 만든다

- 상황: 정책이 서울 한 곳에만 적용되어 고를 대조군이 없다. 부산이나 대구냐를 연구자가 고르면 그 선택이 결과를 좌우하고, 단순 평균을 쓰면 닮지 않은 도시도 같은 비중으로 들어간다
- 방법: 후보 도시들의 가중평균으로 서울과 닮은 가상 대조군을 만든다(Abadie & Gardeazabal, 2003). 후보 목록이 **donor pool**, 만들어진 것이 **합성 대조군**이다
- 입력: 처치 도시 시계열, donor 시계열, 시행 시점 / 출력: donor별 가중치, RMSPE, HHI, 처치효과
- 단계

- 1단계: 정책 이전 구간에서 "서울 - donor 가중평균"의 제곱 평균이 가장 작아지는 가중치를 찾는다
 - 2단계: 그 가중치로 정책 이후 구간의 합성 대조군을 만든다
 - 3단계: 정책 이후 실제 서울 - 합성 대조군 = 처치효과
- **가중치 제약:** 0 이상(음수면 후보 범위 밖으로 튜다), 합은 1(없으면 전체 수준을 늘릴 수 있다)

그림 4-3. 대조군을 조합해서 만드는 방식 (실습 2 실측 가중치)



- **그림 4-3:** 왼쪽 상자가 donor 도시와 계산된 가중치(광주 0.35, 울산 0.16, 창원 0.12, 전주 0.12, 성남 0.09, 나머지 15곳 합계 0.16)다. 가중 합이 "가짜 서울"이고, 정책 후 실제 서울과의 차이가 처치효과다

실습 — 가중치를 풀고 품질 지표부터 읽는다

- **준비물:** donor 20곳·사전 20개월·사후 10개월 패널(참값 -3.47), 4-3-scm.py
- **1단계 — 실행**

```
def objective(w):
    # 사전 기간 예측오차 최소화
    residuals = Y_treated_pre - Y_donors_pre @ w
    return np.mean(residuals**2) + reg_param * np.sum(w**2) # reg_param=0.01

constraints = {'type': 'eq', 'fun': lambda w: np.sum(w) - 1} # 합 = 1
result = minimize(objective, w_init, method='SLSQP',
                  bounds=[(0, 1)] * n_donors, constraints=constraints)
```

- **2단계 — 출력**(results/4-3-scm.log 발췌)

사전 MSPE: 0.06
 사전 RMSPE: 0.24
 결과 변수 표준편차 대비: 24.5%
 가중치 HHI: 0.20 (< 0.3 분산)
 평균 처치효과 (사후): -3.25
 최대 단일 donor 가중치: 0.35 (< 0.5 양호)
 0에 가까운 가중치 수: 14개 (총 20개 중)

○ **3단계 — 판정.** 위에서 아래로, 앞 줄이 통과해야 다음 줄을 읽는다

점검 항목	이번 값	통과 기준	판정	불합격이면
사전 적합(RMSPE 비율)	24.5%	30% 미만	통과	효과를 읽지 않고 donor pool 구성으로 되돌아간다
가중치 집중(HHI)	0.20	0.3 미만	통과	0.3~0.7이면 leave-one-out 병기, 0.7 초과면 보고 보류
최대 단일 가중치	0.35	0.5 미만	통과	그 donor를 뺀 추정치를 병기
처치효과	-3.25	위 셋 통과 후	읽어도 됨	—

- **사전 적합** — 만든 가짜 서울이 진짜 서울을 닮았는지 잔다. 정책 이전 20개월에서 어긋난 크기의 평균이 **RMSPE**이고, 절대값 0.24로는 크고 작음을 판단할 수 없어 결과 변수의 표준편차로 나눈 비율 24.5%를 쓴다(Abadie et al., 2010)
 - 이 값이 나쁘면 정책 후의 -3.25가 정책 때문인지 애초에 안 맞았기 때문인지 갈라낼 수 없으므로, 효과보다 먼저 본다
- **가중치 집중** — 결론이 몇 곳에 걸려 있는지 잔다. 가중치를 각각 제공해 더한 값이 **HHI**이며, 한 도시가 1.0을 독차지하면 1이고 20곳이 0.05씩 나누면 0.05다
 - 한 도시에 쏠려 있으면 그 도시 한 곳에 생긴 일이 서울의 효과로 읽히므로, 사전 적합이 좋아도 따로 본다
- 효과 -3.25는 정책 후 10개월 동안 서울이 합성 대조군보다 평균 3.25 낮았다는 뜻이고, 참값 -3.47과 0.22 차이다. 유의성 판정은 4.5에서 한다

한 줄 정리: 가중치는 데이터가 정하고, 효과는 품질 지표(사전 적합 30%, HHI 눈금)를 통과한 뒤에만 읽는다.

□ 4.4 합성 이중차분법(SDID) — 두 가정 중 하나만 맞아도 버틴다

원리 — DID의 뼈대에 SCM의 가중치를 얹는다

- **상황**: 평행추세도 사전 적합도 부분적으로만 성립한다. DID는 평행추세에, SCM은 사전 적합에 기댄다
- **방법**: 계산의 뼈대는 DID로 두고, 비교 대상 구성만 SCM에서 가져온다(Arkhangelsky et al., 2021)
- **입력**: SCM과 같다 / **출력**: 단위 가중치, 시간 가중치, 처치효과
- **단계**
 - 1단계: **단위 가중치** — donor를 섞어 서울과 닮은 조합을 만든다. SCM과 같은 계산이다
 - 2단계: **시간 가중치** — 정책 이전 시점 중 격차가 정책 직전과 비슷하게 유지된 시점에 큰 비중을 준다
 - 3단계: 사후 격차 - 가중 사전 격차 = 처치효과
- **수렴**: 평행추세가 정확하면 DID와, 사전 적합이 완벽하면 SCM과 같아진다. 둘 다 부분적이면 양쪽 정보를 함께 쓴다

실습 — 세 방법을 같은 자료에 나란히 돌린다

- **준비물**: 평행추세가 부분적으로만 성립하는 데이터(참값 -3.50), 4-4-sdid.py
- **1단계 — 실행**

```
def unit_objective(omega):  
    # 단위 가중치: SCM과 같은 구조  
    residuals = Y_treated[:n_pre] - Y_donors[:n_pre, :] @ omega  
    return np.mean(residuals**2) + reg_param * np.sum(omega**2) # reg_param=0.01  
  
def time_objective(lambda_t):  
    # 시간 가중치: 가중 사전 격차를 0에 맞춤  
    weighted_gap = lambda_t @ pre_gaps  
    return weighted_gap**2 + reg_param * np.sum((lambda_t - uniform)**2)  
  
sdid_effect = post_gap - weighted_pre_gap # 사후 격차 - 가중 사전 격차
```

- **2단계 — 출력**(results/4-4-sdid.log 발췌)

초기 기간 ($t=1\sim10$): 추세 차이 SD = 0.733

후기 기간 ($t=11\sim20$): 추세 차이 SD = 0.517

방법론	처치효과	표준오차	95% 신뢰구간
DID	-3.67	0.98	[-5.59, -1.75]
SCM	-3.41	0.23	[-3.86, -2.97]
SDID	-3.41	0.23	[-3.86, -2.97]

최근 5시점 가중치 합계: 0.25 (25%)

○ 3단계 — 판정

점검 항목	이번 값	통과 기준	판정	불합격이면
시간 가중치 분포	최근 5시점 25%	균등 배분값(5/20) 과 비슷	통과	특정 구간에 몰리면 그 구간이 왜 다른지 확인 후 진행
단위 가중치 대 SCM	차이 0.00	—	SCM 쪽 수렴	차이가 크면 어느 가정이 깨졌는지 진단
세 방법 부호	모두 음수	일치	통과	갈리면 결론을 내리지 않는다

– **시간 가중치 분포**: 20시점 중 5시점이니 균등하면 $5 \div 20 = 25\%$ 다. 나온 값이 25%여서 어느 구간에도 몰리지 않았다는 뜻이며, 몰렸다면 그 구간만 유독 정책 직전과 닮은 이유를 확인해야 한다

– **단위 가중치 대 SCM**: 합격·불합격이 아니라 진단이라 통과 기준 칸이 비어 있다. 차이 0.00은 SDID가 SCM과 같은 답(-3.41, 표준오차 0.23)을 냈다는 뜻이고, 원리의 수렴 항목이 그대로 나타난 것이다

– **세 방법 부호**: 위 출력의 DID(-3.67)·SCM(-3.41)·SDID(-3.41) 세 값의 부호다. DID는 평행추세에, SCM은 사전 적합에, SDID는 둘 중 하나에 기대므로, 한 가정이 깨지면 그 방법의 값만 밀린다. 셋 다 음수면 어느 가정이 깨졌든 방향은 같다는 뜻이고, 부호가 갈리면 크기를 견줄 단계가 아니다

○ 참값 -3.50에 SDID(-3.41)가 DID(-3.67)보다 가깝지만, 차이 0.26은 DID의 표준오차 0.98 안이라 통계적으로 구분되지 않는다. 읽을 것은 **평행추세가 흔들리면 DID의 신뢰구간이 크게 벌어진다**는 점이다

한 줄 정리: SDID는 DID의 뼈대에 가중치 두 벌을 얹어, 평행추세와 사전 적합 중 하나만 성립해도 버티게 만든다.

□ 4.5 만든 대조군을 검증한다 — 플라시보, leave-one-out, 시간 플라시보

원리 — 유의성을 계산하지 못하면 직접 만들어 낸다

- **문제:** 처치 단위가 하나뿐이라 회귀처럼 p값을 내놓지 못한다. 평균 낼 처치군이 없으니 표준오차를 구할 표본도 없다
- **해결:** 아무 일 없던 도시를 처치받은 척 세워 같은 계산을 돌리고, "**이 정도 차이가 아무 일 없는 도시에서도 흔히 나오는가**" 를 세어 본다. p값이 작으면 아무 일 없는 도시에서는 드문 차이라는 뜻이고, 크면 흔한 차이라는 뜻이다
- **검증 네 가지**
 - 1 **플라시보:** donor를 하나씩 가짜 처치 도시로 세운다 → p값
 - 2 **leave-one-out:** 가중치를 받은 donor를 하나씩 뺀다 → 결론이 한 도시에 매달렸는지
 - 3 **시간 플라시보:** 정책 전 시점을 가짜 시행 시점으로 세운다 → 사전 기간에 이미 벌어졌는지
 - 4 **정규화 값 민감도:** 분석자가 고른 값을 바꿔 본다 → 그 선택이 결과를 만들었는지
- **최소 p값:** p값은 $1 \div (\text{donor 수} + 1)$ 보다 작아지지 않는다. donor 20곳이면 0.048이고, donor가 적으면 이 값이 0.05를 넘어 서울이 1위를 해도 유의하다고 말할 수 없다. 그래서 검정을 돌리기 전에 donor 수부터 센다

실습 — 가짜 처치를 세워 넷을 돌린다

- **준비물:** 검증용으로 새로 만든 데이터(donor 20곳, 참값 -3.50), 4-5-validation.py . 데이터가 달라 실제 효과가 4.3의 -3.25가 아니라 -3.18이다
- **0단계 — 최소 p값:** donor 20곳이므로 $1 \div 21 = 0.048$. 이보다 작은 값은 나올 수 없다
- **1단계 — 실행(검증 1)**

```
for i in range(n_donors):                                # donor 하나씩을 가짜 처치 도시로
    Y_other_pre = np.delete(Y_donors_pre, i, axis=1)
    w_placebo = compute_scm_weights(Y_placebo_pre, Y_other_pre, reg_param)
    placebo_effects.append(np.mean(Y_placebo_post - Y_other_post @ w_placebo))

# 서울까지 함께 세트로 분자·분모에 1을 더한다
n_extreme = int(np.sum(np.abs(placebo_effects) >= np.abs(real_effect)))
p_value = (1 + n_extreme) / (len(placebo_effects) + 1)
```

- **2단계 — 출력**(results/4-5-validation.log 발췌)

실제 처치효과: -3.18
 플라시보 평균: -0.07
 플라시보 표준편차: 0.79
 p-value (양측): 0.048
 p-value (필터링): 0.143
 필터링 통과 지역: 6/20

기준 효과 (전체): -3.18
 대전 제외: -3.07 (-3.3%)
 최대 변화율: 3.3%
 ±10% 초과 빈도: 0/5

t-10: 효과 = -0.97, p-value = 0.15 (비유의)

t- 5: 효과 = -0.41, p-value = 0.40 (비유의)

t- 1: 효과 = -0.34, p-value = 0.70 (비유의)

평균 가상 효과: -0.47 (실제 효과 대비 14.7%)

○ 3단계 — 판정

검증	이번 값	통과 기준	판정	불합격이면
1. 플라시보 p(전체 20곳)	0.048	0.05 이하	통과	donor를 늘리거나 유의수준 기준을 바꿔 보고
1. 플라시보 p(필터링 6곳)	0.143	0.05 이하	불통과	두 p값을 모두 신고 이 값으로 유의성을 주장하지 않는다
2. leave-one-out 최대 변화율	3.3%	±10% 이내	통과	30% 초과 donor가 있으면 그 donor를 뺀 추정치 병기
3. 시간 플라시보 최소 p	0.15	모든 시점 0.10 초과	통과	0.05~0.10이면 그 시점의 다른 사건 확인 후 진행, 0.05 미만이 하나라도 있으면 인과효과로 보고하지 않는다
4. 정규화 값 민감도	효과 -3.32~-3.33	후보 범위에서 값이 같음	통과	흔들리면 선택 근거를 문서로 남긴다

- 실제 효과 -3.18은 가상 효과 분포(평균 -0.07, 표준편차 0.79)에서 약 3.9 표준편차 떨어진 가장 극단적인 값이다. 가상 효과의 평균이 0에 가깝다는 것은 계산 절차가 없는 효과를 만들어 내지 않았다는 확인이다
- **필터링이 불통과인 이유:** 사전 구간조차 못 맞춘 donor를 빼고 다시 계산했더니 통과 도시가 6곳뿐이라 분모가 7이 되고, 최소 p값이 $1 \div 7 \approx 0.143$ 으로 올라갔다. 0단계에서 예고한 최소 p값이 실제로 걸린 것이다. 필터 기준은 분석 전에 정해 두고 그 사실을 함께 밝힌다

- **판정 연습**(가상의 수치다): donor 12곳에서 실제 효과가 가상 효과 13개 중 1위라면? 최소 p값이 $1 \div 13 \approx 0.077$ 이므로 5% 유의수준에 도달할 수 없다

한 줄 정리: 유의성은 가짜 처치(다른 도시·다른 시점)를 세워 직접 만들어 재고, 그 전에 donor 수로 최소 p값부터 센다.

□ 4.6 세 방법을 한 표에 놓고 판정한다

원리 — 기대는 가정이 다른 방법들이 같은 곳을 가리키는지 본다

- **상황**: 최종 보고 직전. 한 방법만 돌리면 그 방법이 기댄 가정이 깨졌을 때 알 길이 없다
- **방법**: DID는 평행추세에, SCM은 사전 적합에, SDID는 둘 중 하나에 기댄다. 한 가정이 깨지면 그 가정에 기댄 방법의 값만 밀리므로, 셋을 모두 돌려 같은 방향인지 확인한다. 이를 **삼각검증 (triangulation)** 이라 부른다
- **판정 기준**: 세 추정값의 폭이 가장 큰 표준오차의 2배 안인가, 세 신뢰구간의 부호가 일치하는가. 부호가 갈리면 폭 기준을 통과해도 결론을 내리지 않는다

실습 — 45개 지역 자료에 세 방법을 한꺼번에 적용한다

- **준비물**: 45개 지역(처치 1 + donor 44)·30개월(참값 -3.50), `4-6-comprehensive.py`
- **1단계 — 출력**(`results/4-6-comprehensive.log` 발췌)

Method	Effect	SE	p-value	CI_Lower	CI_Upper
DID	-3.63	0.13	0.000	-3.89	-3.38
SCM	-3.17	0.51	0.022	-4.17	-2.16
SDID	-3.34	0.24	0.000	-3.82	-2.86

공통 구간: [-3.82, -3.38]

- **2단계 — 판정**

점검 항목	계산	통과 기준	판정	불합격이면
추정값 폭	-3.63 ~ -3.17 = 0.46	최대 표준오차 0.51의 2배인 1.02 미만	통과	어느 방법의 가정이 깨졌는지 진단으로 되돌아간다
부호 일치	세 신뢰구간 모두 음수	전부 일치	통과	결론을 내리지 않는다
SDID 위치	-3.34, SE 0.24	DID와 SCM의 사이	통과	바깥으로 벗어나면 가중치 계산을 확인한다


- 참값 -3.50 기준 빗나감은 DID -0.13, SCM +0.33, SDID +0.16이고, DID와 SDID의 신뢰구간이 참값을 담았다

한 줄 정리: 세 방법을 나란히 놓고 폭과 부호를 판정한다. 폭이 기준을 넘으면 어느 방법의 가정이 깨졌는지 진단으로 되돌아간다.

□ 4.7 무엇을 쓸지는 자료의 구조가 정한다

- 방법 선택을 좌우하는 것은 방법의 새로움이 아니라 자료의 구조다. 두 가지를 순서대로 확인한다
 - ① 처치 단위가 몇 개인가 — 여럿이면 DID 계열, 하나면 SCM 계열
 - ② 사전 추세 검정을 통과했는가 — 못 했으면 DID 단독 보고를 접고 SDID나 민감도 분석으로

그림 4-4. 분석 순서와 판정 지점



플라시보 검정 · leave-one-out · 시간 플라시보

- **그림 4-4:** 맨 위 질문(처치 단위 수)에서 갈라져, 왼쪽 가지는 사전 추세 F검정을 거쳐 TWFE로, 오른쪽 가지는 사전 적합도(RMSPE)를 거쳐 SCM 또는 SDID로 간다. 어느 경로든 맨 아래 붉은 상자 — 플래시보·leave-one-out·시간 플래시보 검증 — 를 통과해야 보고할 수 있다

<표 4-3: 상황별 방법 선택>

상황	방법	함께 확인할 것
처치 단위 다수, 평행추세 통과	DID	사전 추세 네 기준
단일 처치, donor pool이 크다	SCM	RMSPE 비율, HHI
단일 처치, 평행추세 불확실	SDID	시간 가중치 분포

한 줄 정리: 처치 단위 수를 세고 사전 추세를 검사하면 방법이 갈린다. 어느 길이든 마지막은 검증이다.

□ 결과를 읽는 순서

- 순서를 지키지 않으면 품질이 불합격인 대조군의 효과를 읽게 된다
 - 1순위 **사전 추세(DID) 또는 사전 적합(SCM):** Joint F의 p가 0.10 이하이거나 RMSPE 비율이 30% 이상이면, 효과를 읽지 않고 설계로 되돌아간다
 - 2순위 **가중치 집중도(HHI)와 leave-one-out:** 결과가 소수 donor에 매달려 있지 않은지 본다
 - 3순위 **플래시보 p값:** donor 수로 최소 p값을 먼저 세고, 나온 p값이 아무 일 없는 도시에서는 드문 차이라고 할 만큼 작은지 본다. 시간 플래시보에서 $p < 0.05$ 가 하나라도 나오면 인과효과로 보고하지 않는다
 - 4순위 **효과와 신뢰구간:** 앞의 관문을 통과한 뒤에 크기를 읽고, 방법 2~3개의 값을 나란히 놓아 폭과 부호를 판정한다